

Matematică 3

Notițe de seminar

ADRIAN MANEA

Curs: Luminița Costache

15 mai 2021

Cuprins

1 Numere și funcții complexe – recapitulare	2
1.1 Numere complexe – Noțiuni de bază	2
1.2 Funcții complexe elementare	3
1.3 Funcții olomorfe	5
1.4 Exerciții	6
2 Integrale complexe	9
2.1 Teorema lui Cauchy	9
2.2 Exerciții	11
2.3 Teorema reziduurilor	12
2.4 Exerciții	14
2.5 Aplicații ale teoremei reziduurilor	17
3 Serii Laurent și reziduuri	19
3.1 Serii de puteri. Serii Laurent	19
3.2 Singularități și reziduuri	21
3.3 Exerciții	24
4 Recapitulare analiză complexă	27
5 Transformata Laplace	30
5.1 Definiții și proprietăți	30
5.2 Tabel de transformate Laplace	32
5.3 Exerciții	33
5.4 Aplicații ale transformatei Laplace	35
5.5 Exerciții	37
5.6 Formula de inversare Mellin-Fourier	37
5.7 Exerciții	39
6 Transformata Z	40
6.1 Exerciții	42
6.2 Exerciții suplimentare (L. Costache)	47

7 Transformarea Fourier	49
7.1 Elemente teoretice	49
7.2 Aplicații la ecuații integrale	52
7.3 Exerciții	53
8 Recapitulare test (L. Costache)	54
9 Spații de probabilitate	56
9.1 Noțiuni teoretice	56
9.2 Exerciții	59
9.2.1 Calcul „clasic“	59
9.2.2 Probabilități geometrice	61
10 Scheme clasice de probabilitate	64
10.1 Schema lui Poisson	64
10.2 Schema lui Bernoulli (binomială)	65
10.3 Schema multinomială	65
10.4 Schema geometrică	66
10.5 Exerciții	66
11 Variabile aleatoare	68
11.1 Cazul discret	68
11.2 Exemple de repartiții discrete	74
11.2.1 Repartiția binomială (Bernoulli)	74
11.2.2 Repartiția geometrică	74
11.2.3 Repartiția binomial negativă	75
11.2.4 Repartiția hipergeometrică	75
11.2.5 Repartiția Poisson	75
11.3 Cazul continuu	76
11.4 Repartiții absolut continue	77
11.4.1 Repartiția normală (gaussiană)	77
11.4.2 Repartiția uniformă	78
11.4.3 Repartiția exponențială	78
11.4.4 Repartiția Gamma	79
11.4.5 Repartiția Cauchy	79
11.5 Exerciții rezolvate	79
11.6 Exerciții propuse	82
12 Vectori aleatori bidimensionali	84
12.1 Repartiții condiționate	85
12.2 Variabile aleatoare independente	85

12.3 Caracteristici numerice	87
12.4 Exerciții	89

Index	92
--------------	-----------

SEMINAR 1

NUMERE ȘI FUNCȚII COMPLEXE – RECAPITULARE

1.1 Numere complexe – Noțiuni de bază

Începem cu cîteva noțiuni esențiale și recapitulative privitoare la mulțimea numerelor complexe. Amintim definiția:

$$\mathbb{C} = \{a + bi \mid a, b \in \mathbb{R}, i^2 = -1\},$$

precum și faptul că avem, în general, sirul de incluziuni:

$$\mathbb{N} \subseteq \mathbb{Z} \subseteq \mathbb{Q} \subseteq \mathbb{R} \subseteq \mathbb{C}.$$

Dat un număr complex $z = a + bi$, se numește *partea reală*, notată $\text{Re}(z)$, numărul real a , iar *partea imaginară*, notată $\text{Im}(z)$, numărul real b .

De asemenea, *conjugatul* numărului complex z de mai sus este $\bar{z} = z^* = a - bi$, iar *modulul* numărului complex z este $|z| = \sqrt{a^2 + b^2}$.

Există mai multe forme de reprezentare a numerelor complexe:

- *forma algebrică*, dată mai sus, $z = a + bi$, $a, b \in \mathbb{R}$;
- *forma trigonometrică*, $z = r(\cos \theta + i \sin \theta)$, unde $r = |z|$, iar $\theta = \text{Arg}(z)$ se numește *argumentul principal*;
- *forma polară*, $z = re^{i\theta} = r \exp(i\theta)$, unde r și θ au înțelesul din forma trigonometrică;
- *forma geometrică*, în care $z = a + bi$ reprezintă *afixul* punctului din plan $A(a, b)$. Pentru acest caz, mentionăm că $|z| = \sqrt{a^2 + b^2}$ reprezintă lungimea vectorului de poziție al punctului A , iar θ reprezintă unghiul pe care îl face acest vector de poziție cu axa OX , măsurat în sens trigonometric.

Operațiile cu numere complexe se fac în modul uzual, tinând seama de proprietatea $i^2 = -1$. Mai amintim *formula lui Moivre*, utilă în special atunci când numărul complex a fost scris sub formă trigonometrică. Fie, aşadar, numerele complexe:

$$z_1 = r_1(\cos \theta_1 + i \sin \theta_1), \quad z_2 = r_2(\cos \theta_2 + i \sin \theta_2).$$

Atunci înmulțirea acestora se face cu formula:

$$z_1 \cdot z_2 = r_1 r_2 (\cos(\theta_1 + \theta_2) + i \sin(\theta_1 + \theta_2)),$$

formulă care se generalizează ușor în forma:

$$z^n = r^n(\cos(n\theta) + i \sin(n\theta)), \forall n.$$

Tot folosind numere complexe, putem reprezenta și curbe:

- *Cercul* centrat în punctul de afix z_0 și de rază R are ecuația:

$$|z - z_0| = r;$$

- *Elipsa* cu focarele în punctele de afixe z_0 și w_0 , iar axa mare are lungimea d are ecuația:

$$|z - z_0| + |z - w_0| = d.$$

Amintim și *formelete canonice* ale ecuațiilor acestor conice:

- *Cercul* centrat în (x_0, y_0) și de rază R are ecuația:

$$(x - x_0)^2 + (y - y_0)^2 = R^2;$$

- *Elipsa* de semiaxe a, b are ecuația:

$$\frac{x^2}{a^2} + \frac{y^2}{b^2} = 1.$$

Tot din punct de vedere geometric, mai amintim și că *distanța* între două puncte $A(z)$ și $B(w)$ este $AB = |z - w|$.

1.2 Funcții complexe elementare

Cea mai simplă funcție complexă este *funcția exponentială*, definită prin:

$$\exp : \mathbb{C} \rightarrow \mathbb{C}, \quad \exp z = e^z = \sum_{n \geq 0} \frac{z^n}{n!}.$$

Se observă imediat că au loc proprietățile așteptate:

- $\exp(0) = 1$;
- $\exp(z_1 + z_2) = \exp(z_1) \cdot \exp(z_2), \forall z_{1,2} \in \mathbb{C}$;
- $\exp(iy) = \cos y + i \sin y, \forall y \in \mathbb{R}$ (formula lui Euler).

Mai departe, putem calcula simplu *logaritmul complex*, dacă numărul complex a fost adus în forma polară. Fie, aşadar, $z = re^{i\theta}$. Rezultă:

$$\ln z = \ln r + i\theta.$$

În general, cum argumentul unui număr complex nu este unic (θ de mai sus reprezintă *argumentul principal*, dar $\theta + 2k\pi$ este argumentul general), spunem că funcția logaritm este *multi-formă*, deoarece valoarea ei generală este:

$$\text{Ln}z = \{\ln|z| + i(\text{Arg}z + 2k\pi) \mid k \in \mathbb{Z}\},$$

iar $\ln z$ se numește *valoarea principală* a logaritmului.

Funcția putere se definește acum simplu pornind de la formula:

$$a^b = \exp(b \ln a).$$

Rezultă:

$$z^m = \exp(m \ln z) = \exp(m(\ln|z| + i\text{Arg}z)),$$

folosind valoarea principală.

Similar se definește și puterea ratională, adică *funcția radical*:

$$\sqrt[n]{z} = z^{\frac{1}{n}} = \exp\left(\frac{1}{n} \ln z\right).$$

Folosind funcțiile exponentiale și identitatea lui Euler, putem defini și *funcții trigonometrice complexe*:

$$\begin{aligned} \cos z &= \frac{\exp(iz) + \exp(-iz)}{2} \\ \sin z &= \frac{\exp(iz) - \exp(-iz)}{2i} \\ \tan z &= -i \frac{\exp(iz) - \exp(-iz)}{\exp(iz) + \exp(-iz)} \end{aligned}$$

Mai avem nevoie și de *funcțiile trigonometrice hiperbolice*:

$$\begin{aligned}\sinh z &= \frac{\exp(z) - \exp(-z)}{2} \\ \cosh z &= \frac{\exp(z) + \exp(-z)}{2} \\ \tanh z &= \frac{\sinh z}{\cosh z}\end{aligned}$$

și au loc legăturile:

$$\sinh z = -i \sin(iz), \quad \cosh z = \cos(iz).$$

Funcțiile trigonometrice inverse se pot obține din rezolvarea unor ecuații trigonometrice¹:

$$w = \arcsin z \Rightarrow z = \sin w \Rightarrow z = \frac{\exp(iw) - \exp(-iw)}{2i} \Leftrightarrow \exp(2iw) - 2iz \exp(iw) - 1 = 0,$$

care se rezolvă (pentru w) ca o ecuație de gradul al doilea și se obține:

$$w = \arcsin z = -i \ln(iz \pm \sqrt{1 - z^2})$$

și se procedează similar pentru \arccos și \arctan .

1.3 Funcții olomorfe

Fie o funcție complexă oarecare $f : A \rightarrow \mathbb{C}$, cu $A \subseteq \mathbb{C}$. Pentru orice $z \in A \subseteq \mathbb{C}$, deoarece z are o parte reală și o parte imaginară, și imaginea sa prin f se poate separa. Deci, în general, orice funcție complexă f ca mai sus poate fi scrisă sub forma

$$f = P + iQ, \quad P, Q : \mathbb{R}^2 \rightarrow \mathbb{R}.$$

Rezultă că noțiunile de *limită, continuitate, derivabilitate* pot fi puse pe componente.

Definiție 1.1: O funcție complexă $f : \mathbb{C} \rightarrow \mathbb{C}$ se numește *olomorfă* dacă este derivabilă în orice punct din domeniul de definiție.

Nu intrăm în detalii, deoarece nu vom rezolva exerciții cu derive complexe.

Vor fi foarte importante, însă, rezultatele:

Teoremă 1.1: *Funcția $f : \mathbb{C} \rightarrow \mathbb{C}, f = P + iQ$ este olomorfă dacă $P, Q : \mathbb{R}^2 \rightarrow \mathbb{R}$ sunt diferențiabile, iar derivele lor parțiale verifică condițiile Cauchy-Riemann, adică:*

$$\frac{\partial P}{\partial x} = \frac{\partial Q}{\partial y}, \quad \frac{\partial Q}{\partial x} = -\frac{\partial P}{\partial y}.$$

¹Pentru corectitudine, ar trebui să notăm funcțiile trigonometrice cu initială mare, Arcsin, Arccos etc. Dar vom folosi de fiecare dată doar valoarea principală, astfel că, prin abuz de notație, folosim scrierea din cazul real. Însă trebuie reținut că majoritatea funcțiilor complexe sunt *multiforme*, i.e. pot avea mai multe valori!

Observație 1.1: Pentru simplitate, vom mai nota derivatele parțiale cu indici, adică, de exemplu:

$$\frac{\partial f}{\partial x} \stackrel{\text{not.}}{=} f_x$$

și similar $f_y, f_{xx}, f_{xy}, f_{yx}$ etc.

Corola 1.1: Dacă funcția complexă $f = P + iQ$ este olomorfă, atunci P și Q sunt armonice, adică:

$$\Delta P = P_{xx} + P_{yy} = \Delta Q = Q_{xx} + Q_{yy} = 0.$$

Atenție, însă, la formularea rezultatului: condiția de olomorfie este *necesară*, în niciun caz suficientă! Negarea corolarului de mai sus este:

Corola 1.2: Dacă una dintre funcțiile P sau Q nu este armonică, atunci funcția $f = P + iQ$ nu poate fi olomorfă.

1.4 Exerciții

1. Verificați dacă funcția de mai jos este olomorfă:

$$f : \mathbb{C} \rightarrow \mathbb{C}, \quad f(z) = z^2 + \exp(iz).$$

Indicație: Se separă partea reală și partea imaginară a funcției și se verifică condițiile Cauchy-Riemann și faptul că cele două componente sunt armonice.

2. Fie $P(x, y) = e^{3x} \cos 2y + y^2 - x^2$. Determinați funcția olomorfă $f = P + iQ$ astfel încât $f(0) = 1$.

Indicație: Verificăm dacă $\Delta P = 0$ (condiție necesară!). Apoi, prin integrarea condițiilor Cauchy-Riemann, se obține componenta Q . În final, $f(z) = e^{2z} - z^2 + ki$, $k \in \mathbb{C}$ și folosind condiția din enunț, obținem $k = 0$.

3. Rezolvați ecuațiile:

- (a) $\exp w = -2i$;
- (b) $z^3 + 2 - 2i = 0$;
- (c) $\sin z = 2$.

4. Calculați:

- (a) $\sin(1 + i)$;
- (b) $\sinh(1 - i)$;

- (c) $\ln i$;
- (d) $\ln(1 - i)$;
- (e) $(1 + i)^{20}$;
- (f) $\sqrt[5]{1 - i}$;
- (g) $\arcsin(i\sqrt{3})$;
- (h) $\arccos(i\sqrt{3})$;
- (i) $\tan(1 - i)$.

5. Verificați dacă funcțiile date sunt armonice și, în caz afirmativ, determinați funcția complexă $f = P + iQ$, pentru:

- (a) $P(x, y) = x^2 - y^2 - 2y$, știind că $f(0) = 1$;
- (b) $P(x, y) = x^4 - 6x^2y^2 + y^4$, știind că $f(1) = 1$;
- (c) $P(x, y) = (x \cos y - y \sin y)e^x$;
- (d) $P(x, y) = xy + x + 2y$, știind că $f(2i) = -1 + 5i$;
- (e) $P(x, y) = 4xy^3 - 4x^3y + x$, știind că $f(1 + i) = 5 + 4i$;
- (f) $P(x, y) = 3x^2y + 2x^2 - y^3 - 2y^2$;
- (g) $P(x, y) = x^4 - 6x^2y^2 + y^2$;
- (h) $Q(x, y) = \frac{x}{x^2 + y^2}$.

6. Determinați $k \in \mathbb{C}$ astfel încât funcția:

$$P(x, y) = x^3 - kxy^2 + 12xy - 12x$$

să fie armonică și determinați f olomorfă pentru care $P = \operatorname{Re}(f)$.

7. Scrieți sub formă trigonometrică și polară numerele complexe:

- (a) $z = 3 - i$;
- (b) $z = 3 + i$;
- (c) $z = i$;

- (d) $z = 1;$
- (e) $z = 1 + 2i;$
- (f) $z = 2 + i.$

8. Găsiți forma canonica și ecuația complexă pentru:

- (a) Cercul centrat în $(0, 1)$ și cu raza 2;
- (b) Cercul centrat în $(1, 0)$ și cu raza 1;
- (c) Cercul centrat în $(1, 2)$ și cu raza 1;
- (d) Elipsa cu focarele în $(-1, 0)$ și $(3, 0)$ și cu axa mare de lungime 6;
- (e) Elipsa cu focarele în $(0, 1)$ și $(0, -2)$ și cu axa mare de lungime 5.

Reprezentăți grafic fiecare dintre cazurile de mai sus.

9. Fie punctele $A(1 + 2i)$ și $B(-1)$, iar M , mijlocul segmentului $[AB]$. Calculați distanța de la punctul M la punctul N , de afix $-2 + 3i$. Reprezentare grafică.

SEMINAR 2

INTEGRALE COMPLEXE

2.1 Teorema lui Cauchy

În multe situații, putem calcula integralele complexe direct, într-o manieră asemănătoare cu integralele curbilinii. Un exemplu simplu:

$$I_1 = \int_{|z|=1} z |dz|.$$

Folosind forma polară, $z = e^{it}$, deoarece integrala se face pe $|z| = 1$, iar $t \in [0, 2\pi]$. Rezultă $dz = ie^{it} dt$, deci $|dz| = dt$. Atunci:

$$I_1 = \int_0^{2\pi} e^{it} dt = \frac{1}{i} e^{it} \Big|_0^{2\pi} = 0.$$

Un alt exemplu:

$$I_2 = \int_S z |dz|,$$

unde S este segmentul care unește pe 0 și i . Putem parametriza acest segment: $S : z = ti, t \in [0, 1]$, deci $dz = idt$ și din nou $|dz| = dt$. Rezultă:

$$I_2 = \int_0^1 t i dt = \frac{i}{2}.$$

Dar în unele situații, putem calcula chiar mai ușor:

Teoremă 2.1 (Cauchy): *Fie $D \subseteq \mathbb{C}$ un domeniu simplu conex și $f : D \rightarrow \mathbb{C}$ o funcție olomorfă pe D , cu $P = \operatorname{Re} f$ și $Q = \operatorname{Im} f$, funcții de clasă $\mathcal{C}^1(D)$.*

Fie $\gamma : [a, b] \rightarrow D$ o curbă închisă și jordaniană (fără autointersecții) de clasă C^1 pe porțiuni, astfel încât $\text{Int}\gamma$ să verifice condițiile formulei Green-Riemann.

Atunci $\int_{\gamma} f(z) dz = 0$.

Acesta este un caz simplu în care calculul se termină imediat cu rezultat nul.

În exercițiii, vom folosi adesea următoarea:

Teoremă 2.2 (Formula integrală Cauchy): Fie $D \subseteq \mathbb{C}$ un domeniu și $f : D \rightarrow \mathbb{C}$ o funcție olomorfă pe D . Fie $\bar{\Delta} \subseteq D$, unde Δ este un domeniu simplu conex, mărginit, cu frontieră γ , care este o curbă închisă, jordaniană, de clasă C^1 pe porțiuni, orientată pozitiv.

Atunci pentru orice $a \in \Delta$ fixat are loc:

$$f(a) = \frac{1}{2\pi i} \int_{\gamma} \frac{f(z)}{z - a} dz.$$

Principala aplicație a acestei teoreme este să ne ajute să calculăm integrale pe domenii în interiorul cărora funcția pe care o integrăm are probleme. Un exemplu:

$$\int_{|z-2i|=1} \frac{1}{z^2 + 4} dz.$$

Observăm că $z = 2i$ este un punct cu probleme pentru funcția considerată și aplicăm formula integrală Cauchy.

Putem rescrie integrala astfel, izolînd punctul cu probleme:

$$\int_{|z-2i|=1} \frac{1}{z^2 + 4} dz = \int_{|z-2i|=1} \frac{\frac{1}{z+2i}}{z-2i} dz = \frac{f(z)}{z-2i} dz,$$

unde am introdus exact funcția cu probleme, adică $f(z) = \frac{1}{z+2i}$.

Aplicăm formula integrală Cauchy și obținem:

$$f(2i) = \frac{1}{2\pi i} \int_{|z-2i|=1} \frac{f(z)}{z-2i} dz \Rightarrow \int_{|z-2i|=1} \frac{f(z)}{z-2i} dz = 2\pi i f(2i) = \frac{\pi}{2}.$$

Vor exista situații cînd punctul izolat nu poate fi eliminat atît de ușor (sau chiar deloc), cazuri în care vom aplica un rezultat fundamental, *teorema reziduurilor*.

Esențialmente, formula integrală Cauchy se aplică atunci cînd avem *un singur pol simplu*, aflat în interiorul domeniului de integrare. În afara teoremei reziduurilor, pe care o vom studia imediat, mai există un rezultat care ne permite să calculăm pentru cazul cînd avem un pol multiplu:

Teoremă 2.3 (Formula integrală Cauchy pentru derivate): În condițiile și ipoteza formulei integrale Cauchy, are loc și rezultatul:

$$f^{(n)}(z_0) = \frac{n!}{2\pi i} \int_{\gamma} \frac{f(z)}{(z - z_0)^{n+1}} dz.$$

Această formulă permite calculul atunci cînd avem *un pol multiplu*. În cazul în care sînt mai mulți poli, se poate aplica descompunerea în fractii elementare sau teorema reziduurilor.

2.2 Exerciții

1. Calculați integrala $\int_{\Gamma} z^2 dz$, unde:

- (a) $\Gamma = [-1, i] \cup [i, 1]$;
- (b) $\Gamma = \{z(t) = 2 + it^2 \mid 0 \leq t \leq 1\}$;
- (c) $\Gamma = \{z(t) = t + i \cos \frac{\pi t}{2} \mid -1 \leq t \leq 1\}$;
- (d) $\Gamma = OA$, cu $O(0, 0)$ și $A(2, 1)$.

Indicații: Se parametrizează drumurile și se calculează ca în exemplele de mai sus.

2. Folosind teorema Cauchy sau formula integrală Cauchy, calculați:

- (a) $\int_{|z-1|=3} z^4 dz$;
- (b) $\int_{|z|=4} \frac{\cos z}{z^2 - 6z + 5} dz$;
- (c) $\int_{|z|=1} \frac{\sin z}{z(z-2)} dz$;
- (d) $\int_{\Gamma} \frac{\exp(z^2)}{z^2 - 6z} dz$, unde $\Gamma : |z-2| = r$, $r \in \{1, 3, 5\}$;
- (e) $\int_{|z|=1} \frac{\exp(3z)}{z^4} dz$;
- (f) $\int_{|z-i|=1} \frac{1}{(z^2 + 1)^2} dz$;
- (g) $\int_{|z|=1} \frac{\sin z}{z^2(z-2)} dz$.

Indicații: Ideea de bază este să identificăm punctele cu probleme ale funcțiilor de integrat în interiorul domeniilor pe care integrăm, apoi să descompunem integrandul cu o funcție căreia îl se poate aplica teorema Cauchy.

(a) funcția z^4 este olomorfă, deci integrala este nulă;

(b) avem $\frac{\cos z}{(z-1)(z-5)}$, dar singurul punct cu probleme din interiorul domeniului este $z_1 = 1$.

Definim $f(z) = \frac{\cos z}{z-5}$, iar integrala devine $\int_{|z|=4} \frac{f(z)}{z-1} dz$, care se calculează cu formula Cauchy.

- (c) pentru $r = 1$, funcția este olomorfă, deci integrala este nulă. Pentru $r = 3$, $z = 0$ este punct cu probleme, deci definim $f(z) = \frac{\exp(z^2)}{z - 6}$.

3. Folosind formula integrală Cauchy pentru derivate, calculați:

$$(a) I_1 = \oint_{|z|=2} \frac{z+2}{z^3(z-1)} dz;$$

$$(b) I_2 = \oint_{|z|=\frac{1}{2}} \frac{z+2}{z^3(z-1)} dz.$$

Indicație: Pentru punctul (a), observăm că ambii poli ($z = 0$ și $z = 1$) se află în interiorul domeniului, astfel că, înainte de calcul, trebuie aplicată descompunerea în fractii simple.

Pentru punctul (b), singurul pol în interiorul domeniului este $z = 0$, care este pol triplu, deci se poate aplica direct formula.

2.3 Teorema reziduurilor

Similar cu orice funcție reală, și funcțiile complexe pot fi dezvoltate în serii de puteri. În cazul complex, seriile se numesc *serii Laurent* și pot conține și puteri negative.

Informal, punctele cu probleme care ne interesează se numesc *poli* sau *puncte singulare*. Ordinul unui pol $z = a$ este multiplicitatea algebrică a rădăcinii $z = a$ în dezvoltarea în serie Laurent a funcției f . În particular, avem *poli simpli, dubli* etc.

Definiție 2.1: Fie $f : \mathbb{C} \rightarrow \mathbb{C}$ o funcție complexă și dezvoltarea sa în serie Laurent în jurul unui punct $z_0 \in \mathbb{C}$:

$$f(z) = \sum_{n \in \mathbb{Z}} a_n (z - z_0)^n, \quad a_n \in \mathbb{R}.$$

Se numește *reziduul* funcției f în punctul singular z_0 coeficientul a_{-1} din dezvoltarea de mai sus, notat $\text{Rez}(f, z_0)$.

Următoarea teoremă ne dă metode de calcul al reziduurilor, în funcție de multiplicitatea lor:

Teoremă 2.4 (Calculul reziduurilor): (1) $\text{Rez}(f, a) = c_{-1}$, unde c_{-1} este coeficientul lui $\frac{1}{z-a}$ în dezvoltarea în serie Laurent a funcției f în vecinătatea singularității $z = a$.

(2) Dacă $z = a$ este pol de ordinul $p \geq 2$ pentru f , atunci:

$$\text{Rez}(f, a) = \frac{1}{(p-1)!} \lim_{z \rightarrow a} \left[(z-a)^p f(z) \right]^{(p-1)};$$

(3) Dacă $z = a$ este pol simplu pentru f , atunci, particularizând formula de mai sus, avem:

$$\text{Rez}(f, a) = \lim_{z \rightarrow a} (z-a) f(z);$$

(4) Dacă f se poate scrie ca un cît de funcții, $f = \frac{A}{B}$, olomorfe în jurul lui a și dacă $z = a$ este pol simplu pentru f , adică $B(a) = 0$, atunci:

$$\text{Rez}(f, a) = \lim_{z \rightarrow a} \frac{A(z)}{B'(z)}.$$

Rezultatul esențial al acestei secțiuni ne arată că, dacă integrăm o funcție cu probleme, valoarea integralei este dată în mod esențial de reziduurile sale:

Teoremă 2.5 (Teorema reziduurilor): *Fie $D \subseteq \mathbb{C}$ un domeniu și $f : D - \{\alpha_1, \dots, \alpha_k\} \rightarrow \mathbb{C}$ o funcție olomorfă pentru care α_i sunt poli.*

Fie $K \subseteq D$ un compact cu frontieră $\Gamma = \partial K$, o curbă de clasă C^1 , jordaniană, orientată pozitiv și care conține toate α_i în interior. Atunci:

$$\int_{\Gamma} f(z) dz = 2\pi i \sum_{j=1}^k \text{Rez}(f, \alpha_j).$$

De exemplu, să calculăm integrala:

$$I = \int_{|z|=r} \frac{e^z}{(z-i)(z-2)} dz, r > 0, r \neq 1, 2.$$

Solutie: Dacă $0 < r < 1$, putem aplica teorema lui Cauchy (2.1) și găsim $I = 0$.

Dacă $1 < r < 2$, aplicăm formula integrală a lui Cauchy (2.2) și găsim:

$$\int_{|z|=r} \frac{e^z}{(z-i)(z-2)} dz = \int_{|z|=r} \frac{\frac{e^z}{z-2}}{z-i} dz = \int_{|z|=r} \frac{f(z)}{z-i} dz,$$

unde $f(z) = \frac{e^z}{z-2}$. Rezultă:

$$\int_{|z|=r} \frac{f(z)}{z-i} dz = 2\pi i f(i) = 2\pi i \frac{e^i}{i-2}.$$

Dacă $r > 2$, aplicăm teorema reziduurilor, cu i și 2 poli simpli. Avem:

$$\begin{aligned} \text{Rez}(f, i) &= \lim_{z \rightarrow i} (z-i) \frac{e^z}{(z-i)(z-2)} = \frac{e^i}{i-2} \\ \text{Rez}(f, 2) &= \lim_{z \rightarrow 2} \frac{e^z}{(z-i)(z-2)} = \frac{e^2}{2-i}. \end{aligned}$$

Rezultă, din teorema reziduurilor:

$$\int_{|z|=r} \frac{e^z}{(z-i)(z-2)} dz = 2\pi i \left(\frac{e^i}{i-2} + \frac{e^2}{2-i} \right).$$

2.4 Exerciții

1. Calculați reziduurile funcțiilor în punctele a indicate:

$$(a) f(z) = \frac{\exp(z^2)}{z - 1}, a = 1;$$

$$(b) f(z) = \frac{\exp(z^2)}{(z - 1)^2}, a = 1;$$

$$(c) f(z) = \frac{z + 2}{z^2 - 2z}, a = 0;$$

$$(d) f(z) = \frac{1 + e^z}{z^4}, a = 0;$$

$$(e) f(z) = \frac{\sin z}{4z^2}, a = 0;$$

$$(f) f(z) = \frac{z}{1 - \cos z}, a = 0.$$

Indicație: Verificăm multiplicitatea polului $z = a$ și aplicăm formula corespunzătoare din teorema 2.4.

2. Să se calculeze următoarele integrale:

$$(a) I = \int_{|z|=2} \frac{dz}{z^2 - 1};$$

$$(b) I = \int_{\gamma} \frac{dz}{z^4 + 1}, \gamma : x^2 + y^2 - 2x = 0;$$

$$(c) I = \int_{|z|=3} \frac{z^2 + 1}{(z - 1)^2(z + 2)} dz.$$

Soluție: (a) Punctele $z = \pm 1$ sunt poli de ordinul 1 pentru funcția $f(z) = \frac{1}{z^2 - 1}$. Ele sunt situate în interiorul discului pe care integrăm, cu $|z| = 2$, deci putem aplica teorema reziduurilor:

$$I = 2\pi i \cdot \left(\operatorname{Rez}(f, z_1) + \operatorname{Rez}(f, z_2) \right).$$

Calculăm separat reziduurile:

$$\operatorname{Rez}(f, z_1) = \lim_{z \rightarrow 1} (z - 1) \cdot \frac{1}{z^2 - 1} = \frac{1}{2}$$

$$\operatorname{Rez}(f, z_2) = \lim_{z \rightarrow -1} (z + 1) \cdot \frac{1}{z^2 - 1} = -\frac{1}{2}.$$

Rezultă:

$$I = \int_{|z|=2} \frac{dz}{z^2 - 1} = 2\pi i \cdot \left(\frac{1}{2} - \frac{1}{2} \right) = 0.$$

(b) Curba γ este un cerc centrat în $(1, 0)$ și cu raza 1. Căutăm polii funcției $f(z) = \frac{1}{z^4 + 1}$ care se află în interiorul lui γ .

Avem succesiv:

$$\begin{aligned} z^4 + 1 = 0 &\Rightarrow z^4 = -1 = \cos \pi + i \sin \pi \Rightarrow \\ z &= \sqrt[4]{\cos \pi + i \sin \pi} \Rightarrow \\ z_k &= \cos \frac{\pi + 2k\pi}{4} + i \sin \frac{\pi + 2k\pi}{4}, k = 0, 1, 2, 3. \end{aligned}$$

Doar punctele z_0, z_3 se află în interiorul discului delimitat de γ și calculăm reziduurile în aceste puncte.

Putem aplica formula din Teorema 2.4 (4) și avem:

$$\begin{aligned} \text{Rez}(f, z_0) &= \frac{A(z)}{B'(z)} \Big|_{z_0} = \frac{1}{4z^3} \Big|_{z_0} = -\frac{1}{4} e^{\frac{\pi i}{4}} \\ \text{Rez}(f, z_3) &= \frac{A(z)}{B'(z)} \Big|_{z_3} = \frac{1}{4z^3} \Big|_{z_3} = -\frac{1}{4} e^{\frac{7\pi i}{4}}. \end{aligned}$$

Rezultă:

$$I = \int_{\gamma} \frac{dz}{z^4 + 1} = 2\pi i \left(-\frac{1}{4} e^{\frac{\pi i}{4}} - \frac{1}{4} e^{\frac{7\pi i}{4}} \right) = -\frac{\pi \sqrt{2}i}{2}.$$

(c) Avem doi poli, $z = 1, z = -2$ în interiorul conturului. Se vede că $z_1 = 1$ este pol de ordinul 2, iar $z_2 = -2$ este pol de ordinul 1. Calculăm reziduurile:

$$\begin{aligned} \text{Rez}(f, z_1) &= \frac{1}{2!} \lim_{z \rightarrow 1} \left[(z-1)^2 \frac{z^2 + 1}{(z-1)^2(z+2)} \right] \\ &= \frac{1}{2!} \lim_{z \rightarrow 1} \frac{z^2 + 4z - 1}{(z+2)^2} \\ &= \frac{2}{9} \\ \text{Rez}(f, z_2) &= \lim_{z \rightarrow -2} (z+2) \frac{z^2 + 1}{(z-1)^2(z+2)} = \frac{5}{9}. \end{aligned}$$

Rezultă:

$$I = \int_{|z|=3} \frac{z^2 + 1}{(z - 1)^2(z + 2)} dz = \frac{14}{9}\pi i.$$

3. Să se calculeze integralele:

$$(a) \int_{|z|=1} \frac{dz}{\sin z};$$

$$(b) \int_{|z|=1} \frac{e^z}{z^2} dz;$$

$$(c) \int_{|z|=5} ze^{\frac{3}{z}} dz;$$

$$(d) \int_{|z-1|=1} \frac{dz}{(z+1)(z-1)^3};$$

$$(e) \int_{|z|=1} \frac{\sin z}{z^4} dz.$$

Indicații: (a) $z = 0$ este singurul pol din interiorul domeniului;

(b), (c): Dezvoltăm în serie Laurent și identificăm reziduurile folosind definiția.

(d) Avem $z = 1$ pol de ordin 3 și $z = -1$ pol simplu. Doar $z = 1$ se află în interiorul domeniului și dezvoltăm în serie Laurent după puterile lui $z - 1$:

$$\begin{aligned} \frac{1}{z+1} &= \frac{1}{2 - (-(z-1))} \\ &= \frac{1}{2} \frac{1}{1 - \left(-\frac{z-1}{2}\right)} \\ &= \frac{1}{2} \sum_{n \geq 0} (-1)^n \frac{(z-1)^n}{2^n} \\ &= \sum_{n \geq 0} (-1)^n \frac{(z-1)^n}{2^{n+1}}, \end{aligned}$$

pentru $|z-1| < 2$.

Rezultă:

$$\frac{1}{(z+1)(z-1)^3} = \sum_{n \geq 0} (-1)^n \frac{(z-1)^{n-3}}{2^{n+1}} = \frac{1}{2(z-1)^3} - \frac{1}{4(z-1)^2} + \frac{1}{8(z-1)} - \frac{1}{16} + \dots,$$

$$\text{deci } \text{Rez}(f, 1) = \frac{1}{8}.$$

2.5 Aplicații ale teoremei reziduurilor

Putem folosi teorema reziduurilor pentru a calcula integrale trigonometrice de forma:

$$I = \int_0^{2\pi} R(\cos \theta, \sin \theta) d\theta,$$

unde R este o funcție ratională.

Facem schimbarea de variabilă $z = e^{i\theta}$ și atunci, pentru $\theta \in [0, 2\pi]$, z descrie cercul $|z| = 1$, o dată, în sens direct.

Folosim formulele lui Euler:

$$\begin{aligned}\cos \theta &= \frac{e^{i\theta} + e^{-i\theta}}{2} = \frac{1}{2} \left(z + \frac{1}{z} \right) \\ \sin \theta &= \frac{e^{i\theta} - e^{-i\theta}}{2i} = \frac{1}{2i} \left(z - \frac{1}{z} \right).\end{aligned}$$

Atunci, dacă $z = e^{i\theta}$, rezultă $dz = ie^{i\theta} d\theta = iz d\theta$, iar integrala devine:¹

$$I = \int_0^{2\pi} R(\cos \theta, \sin \theta) d\theta = \oint_{|z|=1} R_1(z) dz,$$

unde:

$$R_1(z) = \frac{1}{iz} R\left(\frac{z^2 + 1}{2z}, \frac{z^2 - 1}{2iz}\right).$$

Această funcție poate avea poli și deci putem folosi teorema reziduurilor. Dacă a_1, \dots, a_n sunt polii din interiorul cercului unitate, avem:

$$I_1 = 2\pi i \sum_{k \geq 1} \text{Rez}(R_1, a_k).$$

Să vedem câteva exemple:

$$(a) \int_0^{2\pi} \frac{d\theta}{2 + \cos \theta};$$

$$(b) \int_0^{2\pi} \frac{d\theta}{1 + 3 \cos^2 \theta};$$

$$(c) \int_0^{2\pi} \frac{\sin \theta}{1 + i \sin \theta} d\theta;$$

¹ \oint marchează o integrală pe un contur *închis*

$$(d) \int_0^{2\pi} \frac{d\theta}{1 + a \sin \theta}, |a| < 1, a \in \mathbb{R};$$

$$(e) \int_{-\pi}^{\pi} \frac{\cos 3t}{5 - 4 \cos t} dt.$$

Soluție:

(a) Notăm $z = e^{i\theta}$, cu $\theta \in [0, 2\pi]$. Atunci avem succesiv:

$$\begin{aligned} dz &= ie^{i\theta} d\theta = iz dz \implies d\theta = \frac{dz}{iz} \\ \cos \theta &= \frac{e^{i\theta} + e^{-i\theta}}{2} = \frac{1}{2} \left(z + \frac{1}{z} \right) \\ \frac{1}{2 + \cos \theta} &= \frac{2z}{z^2 + 4z + 1} \\ \int_0^{2\pi} \frac{d\theta}{2 + \cos \theta} &= \oint_{|z|=1} \frac{2z}{z^2 + 4z + 1} \frac{dz}{iz} \\ &= -2i \oint_{|z|=1} \frac{dz}{z^2 + 4z + 1}. \end{aligned}$$

Acum folosim teorema reziduurilor. Singularitățile funcției $f(z) = \frac{1}{z^2 + 4z + 1}$ sunt $z = -2 \pm \sqrt{3}$, care sunt poli simpli. Numai $z = -2 + \sqrt{3}$ se află în interiorul cercului $|z| = 1$ și calculăm reziduul folosind Teorema 2.4(2).

SEMINAR 3

SERII LAURENT ȘI REZIDUURI

3.1 Serii de puteri. Serii Laurent

Notiunile privitoare la scrierea funcțiilor cu ajutorul seriilor de puteri, întâlnite în cazul real prin seri Taylor, se pot generaliza și în cazul complex. Situația este ceva mai problematică în acest caz, deoarece argumentele sunt obiecte bidimensionale. În orice caz, multe dintre notiunile din cazul real pot fi preluate aproape fără modificare și în cazul complex.

Definiție 3.1: O serie de forma $\sum_{n \geq 0} a_n(z - z_0)^n$, cu $z \in \mathbb{C}$ oarecare, $z_0 \in \mathbb{C}$ fixat și $a_n \in \mathbb{C}$ coeficienți, pentru orice $n \in \mathbb{N}$, se numește *serie de puteri centrată* în z_0 .

Ca în cazul real, se poate calcula *raza de convergență* a seriilor de puteri cu una dintre formulele:

$$R = \frac{1}{\lim_{n \rightarrow \infty} \sqrt[n]{|a_n|}} = \lim_{n \rightarrow \infty} \left| \frac{a_n}{a_{n+1}} \right|.$$

Atunci, deoarece lucrăm în planul complex, se definește *discul de convergență* al seriei prin:

$$B(z_0, R) = \{z \in \mathbb{C} \mid |z - z_0| < R\}.$$

Stim, de asemenea, că:

- seria este absolut convergentă pe $|z - z_0| < R$;
- seria este divergentă pe $|z - z_0| > R$;
- seria este uniform convergentă pe $|z - z_0| \leq \rho$, pentru orice $\rho < R$,

iar pe frontieră discului trebuie testat separat.

În interiorul discului de convergență, suma seriei este o funcție olomorfă $S(z)$ și are sens rezultate de forma derivării sau integrării termen cu termen.

Definiție 3.2: O funcție $f : A \rightarrow \mathbb{C}$ se numește *analitică* dacă poate fi dezvoltată într-o serie de puteri complexă cu discul de convergență inclus în A .

Dacă acesta este cazul, avem formula cunoscută:

$$f(z) = \sum_{n \geq 0} \frac{f^{(n)}(z_0)}{n!} (z - z_0)^n.$$

Are loc rezultatul important:

Teoremă 3.1 (Weierstrass-Riemann-Cauchy): *O funcție complexă definită pe o mulțime deschisă este analitică dacă și numai dacă este olomorfă.*

Deducem de aici că, dacă domeniul de definiție A al funcției complexe studiate, $f : A \rightarrow \mathbb{C}$, este o mulțime deschisă, atunci olomorfia (pe care o verificăm cu condițiile Cauchy-Riemann, de exemplu) este echivalentă cu analiticitatea, verificată cu ajutorul seriilor de puteri. Rezultă implicit că orice funcție olomorfă definită pe un deschis poate fi dezvoltată în serie de puteri.

Dar pentru cazul complex, avem și serii ceva mai complicate:

Definiție 3.3: O serie de puteri de forma $\sum_{n \in \mathbb{Z}} a_n (z - z_0)^n$, cu $a_n, z, z_0 \in \mathbb{C}$ se numește *serie Laurent* centrată în punctul $z_0 \in \mathbb{C}$.

O serie Laurent este convergentă dacă și numai dacă atât partea pozitivă $a_n > 0$, cât și partea negativă, $a_n \leq 0$ sănătate convergente.

Partea pozitivă se numește *partea Taylor*, iar partea negativă se numește *partea principală*. Pentru cazul Taylor, seriile uzuale pentru funcțiile elementare, împreună cu domeniile de

convergentă, sănătate date mai jos. În toate cazurile, $x \in \mathbb{R}$ se poate înlocui cu $z \in \mathbb{C}$.

$$\begin{aligned} e^x &= \sum_{n \geq 0} \frac{1}{n!} x^n, x \in \mathbb{R} \\ \frac{1}{1-x} &= \sum_{n \geq 0} x^n, |x| < 1 \\ \frac{1}{1+x} &= \sum_{n \geq 0} (-1)^n x^n, |x| < 1 \\ \cos x &= \sum_{n \geq 0} \frac{(-1)^n}{(2n)!} x^{2n}, x \in \mathbb{R} \\ \sin x &= \sum_{n \geq 0} \frac{(-1)^n}{(2n+1)!} x^{2n+1}, x \in \mathbb{R} \\ (1+x)^\alpha &= \sum_{n \geq 0} \frac{\alpha(\alpha-1)(\alpha-2)\cdots(\alpha-n+1)}{n!} x^n, |x| < 1, \alpha \in \mathbb{R} \\ \arctan x &= \sum_{n \geq 0} \frac{(-1)^n}{2n+1} x^{2n+1}, |x| \leq 1. \end{aligned}$$

Seriile pentru alte funcții se pot obține fie prin calcul direct, fie prin substituții, fie prin derivare sau integrare termen cu termen a seriilor de mai sus.

3.2 Singularități și reziduuri

În cazul funcțiilor reale, domeniul de definitie trebuie ales atent astfel încât să evităm „punctele cu probleme“. Exemplul tipic sănătate cele în care se anulează numitorul unei fracții, cînd apar logaritmi sau radicali etc. Pentru funcții reale, cel mult putem calcula asymptote verticale în acele „puncte cu probleme“. Dar în cazul complex, distincția se face mult mai fin.

Definiție 3.4: Fie $A \subseteq \mathbb{C}$ o mulțime deschisă nevidă și $f : A \rightarrow \mathbb{C}$ o funcție complexă, olomorfă pe A . Fie un punct $z_0 \in \mathbb{C}$.

Punctul z_0 se numește *punct singular izolat* (*singularitate izolată*) pentru f dacă există un disc centrat în z_0 , de forma $B(z_0, r)$, cu $r \neq 0$, astfel încât, dacă eliminăm centrul discului, funcția este olomorfă pe $B(z_0, r) \setminus \{z_0\}$.

Amintim că, dacă funcția este olomorfă pe *discul punctat* (i.e. discul $B(z_0, r)$, din care am scos centrul), atunci ea are o dezvoltare în serie Laurent, conform teoremei Weierstrass-Riemann-Cauchy.

Definiție 3.5: În condițiile și cu notatiile din definiția anterioară, punctul $z_0 \in \mathbb{C}$ se numește *punct singular izolat* (*singularitate izolată*) dacă seria Laurent asociată funcției f are partea principală nulă, adică este o serie Taylor.

Definiție 3.6: În condițiile și cu notațiile din definiția anterioară, punctul $z_0 \in \mathbb{C}$ se numește *pol* dacă în seria Laurent asociată funcției f există un număr finit de termeni nenuli în partea principală. Indicele ultimului termen nenul m (în sensul că $|m|$ este cel mai mare, iar $m < 0$) se numește *ordinul polului*.

Definiție 3.7: În condițiile și cu notațiile din definiția anterioară, punctul $z_0 \in \mathbb{C}$ se numește *punct singular esențial (singularitate esențială)* dacă în partea principală a seriei Laurent asociată funcției f există o infinitate de termeni nenuli.

Idee intuitivă: Singularitățile, în general, sănt „puncte cu probleme“. Chiar și în cazul real există această noțiune, întâlnită în analiză. De exemplu, un punct unghiular sau de întoarcere al unei funcții reale se numește singularitate. Alt exemplu la îndemână: găurile negre sănt interpretate în cosmologie (ramura fizicii teoretice care utilizează geometria pentru studiul „formeи“ Universului) ca *singularități ale spațiu-timpului*. Dar, din fericire, în majoritatea cazurilor, singularitățile fie pot fi „ignorate“ sau „eliminate“ i.e. se poate extrage informația de bază și din domeniul din care ele au fost scoase. Amintiți-vă, de exemplu, că în analiza de liceu există o teoremă care afirmă că *dacă se scoate un număr numărabil de puncte din graficul unei funcții, integrala sa definită nu se schimbă*.

Similar este și cazul singularităților din analiza complexă: toate, cu excepția celor esențiale, pot fi „eliminate“, adică se poate extrage informație foarte importantă despre comportamentul funcțiilor și în lipsa lor (sau, uneori, chiar *numai* din ele, ca în cazul reziduurilor, precum vom vedea).

Polii vor fi elementul central de studiu mai departe. Pentru ei, mai avem o caracterizare utilă:

Propoziție 3.1: În condițiile și cu notațiile de mai sus, punctul $z_0 \in \mathbb{C}$ este pol pentru funcția f dacă și numai dacă $\lim_{z \rightarrow z_0} f(z) = \infty$.

Exemplu: Putem vedea foarte simplu acest lucru pentru funcția $f(z) = \frac{z}{z-1}$. Atunci $z = 1$ este pol simplu, deoarece $\lim_{z \rightarrow 1} f(z) = \infty$ și mai mult, putem scrie dezvoltarea în serie Laurent a funcției f în jurul lui $z = 1$, sub forma:

$$f(z) = \frac{1+z-1}{z-1} = \frac{1}{z-1} + 1,$$

care are partea principală $\frac{1}{z-1}$, cu un singur termen (care dă ordinul polului).

Propoziție 3.2: În condițiile și cu notațiile de mai sus, punctul $z_0 \in \mathbb{C}$ este singularitate esențială dacă și numai dacă nu există $\lim_{z \rightarrow z_0} f(z)$.

Ajungem la o altă noțiune esențială:

Definiție 3.8: În condițiile și cu notăriile de mai sus, fie z_0 o singularitate izolată a funcției f . Coeficientul a_{-1} din seria Laurent a funcției f în coroana $B(z_0; 0, r)$ se numește *reziduul* funcției în z_0 și se notează $\text{Rez}(f, z_0)$.

Observație 3.1: În multe situații, reziduurile se pot calcula simplu cu teorema 2.4, dar uneori sănătem obligați să folosim definiția, pentru că limitele complexe se calculează mult mai dificil decât în cazul real.

Un exemplu este următorul: considerăm funcția $f(z) = \frac{1}{z \sin z^2}$. Vrem să calculăm $\text{Rez}(f, 0)$. Evident, acest punct este pol, deoarece $\lim_{z \rightarrow 0} f(z) = \infty$, dar orice formulă am folosi din teorema 2.4, nedeterminarea nu este eliminată. Astfel că sănătem obligați să folosim definiția, cu ajutorul seriei Laurent.

Ca în cazul seriei Taylor pentru funcția sinus, avem:

$$\begin{aligned}\sin z &= \frac{z}{1!} - \frac{z^3}{3!} + \frac{z^5}{5!} - \dots \\ \Rightarrow z \sin z^2 &= z \cdot \left(\frac{z^2}{1!} - \frac{z^6}{3!} + \frac{z^{10}}{5!} - \dots \right) \\ &= z^3 \left(1 - \frac{z^4}{3!} + \frac{z^8}{5!} - \dots \right).\end{aligned}$$

Atunci, inversând, obținem funcția scrisă sub forma:

$$f(z) = z^{-3} \cdot \left(1 - \frac{z^4}{3!} + \frac{z^8}{5!} - \dots \right)^{-1}.$$

Vrem să inversăm seria din paranteză (admitem fără demonstrație că acest lucru este posibil), pentru ca în final, să putem scrie toată funcția ca o serie de puteri (în forma actuală nu este așa ceva!). Așadar, căutăm o serie de formă $\sum a_n z^n$, cu $n \in \mathbb{N}$, astfel încât:

$$\left(1 - \frac{z^4}{3!} + \frac{z^8}{5!} - \dots \right) \cdot (a_0 + a_1 z + a_2 z^2 + \dots) = 1.$$

Prin identificarea coeficienților, rezultă $a_0 = 1$, $a_2 = 0$. Făcind acum înmulțirea, avem:

$$f(z) = \frac{1}{z^3} \sum_{n \geq 0} a_n z^n = \frac{a_0}{z^3} + \frac{a_1}{z^2} + \frac{a_2}{z} + a_3 + \dots$$

Partea principală a seriei are 3 termeni nenuli, deci $z = 0$ este pol triplu (intuitiv, simplu pentru z și dublu pentru $\sin z^2$), deci rezultă $\text{Rez}(f, 0) = a_2 = 0$.

3.3 Exerciții

1. Determinați dezvoltarea în serie Taylor sau Laurent pentru funcțiile următoare, în jurul punctelor indicate z_0 , precizînd și domeniile pe care sînt valabile:

(a) $f(z) = \cos^2 z, z_0 = 0;$

(b) $f(z) = \frac{z+3}{z^2 - 8z + 15}, z_0 = 4;$

(c) $f(z) = \sin \frac{1}{1-z}, z_0 = 1;$

(d) $f(z) = \frac{2z^2 + 9z + 5}{z^3 + z^2 - 8z - 12}, z_0 = 1;$

(e) $f(z) = \frac{z-1}{z-2}, z_0 = 1;$

(f) $f(z) = \frac{1}{z^2 - 3z + 2}$, pe domeniile $|z| < 1$, $1 < |z| < 2$ și $|z| > 2$.

Indicație: Se pot folosi seriile uzuale, cu anumite substituții, dar atenție la domeniile de convergență, precum și la eventualii poli ai funcțiilor. A se vedea exemplul rezolvat de mai jos.

2. Determinați punctele singulare și precizați natura lor pentru funcțiile:

(a) $f(z) = \frac{z^5}{(z^2 + 1)^2};$

(b) $f(z) = z^3 \exp\left(-\frac{3}{z}\right);$

(c) $f(z) = \sin \frac{1}{z};$

(d) $f(z) = \frac{\sin 2z}{z^6};$

(e) $f(z) = \frac{6z + 1}{z - 3};$

(f) $f(z) = \frac{1}{z^2 \sin z};$

Indicație: După identificarea „punctelor cu probleme“, se cercetează existența limitei către punctele respective și/sau se utilizează dezvoltarea în serie Taylor/Laurent.

3. Calculați:

- (a) $\int_{|z|=1} \frac{z^2 + \exp(z)}{z^3} dz;$
- (b) $\int_{\gamma} (z+1) \exp\left(\frac{1}{z+1}\right) dz$, unde $\gamma : x^2 + y^2 + 2x = 0$;
- (c) $\int_{|z|=r} \frac{\exp(z^{-1})}{1-z} dz$, pentru $r \in \left\{\frac{1}{2}, 1, 2\right\}$.

Indicație: Se folosește teorema reziduurilor.

Exemplu rezolvat pentru seria Laurent: Să se dezvolte funcția

$$f(z) = \frac{2z^2 + 3z - 1}{z^3 + z^2 - z - 1}$$

în jurul originii și în jurul punctelor $z = \pm 1$.

Soluție: Numitorul se descompune sub forma $(z-1)(z+1)^2$, deci avem un pol simplu $z = 1$ și un pol dublu $z = -1$.

Putem descompune funcția în fracții simple, sub forma:

$$f(z) = \frac{1}{z-1} + \frac{1}{z+1} + \frac{1}{(z+1)^2}.$$

Primii doi termeni sunt sume de serii geometrice, iar al treilea poate fi obținut prin derivarea seriei geometrice:

$$\frac{1}{z+1} = \sum (-1)^n z^n \Rightarrow -\frac{1}{(z+1)^2} = \sum (-1)^{n+1} (n+1) z^n,$$

după ce am făcut trecerea $n \mapsto n+1$, întrucât seria derivatelor ar fi pornit de la $n=1$, dat fiind termenul z^{n-1} .

Pe cazuri acum:

Pentru $|z| < 1$: funcția este olomorfă, deoarece nu avem niciun pol în acest disc deschis. Atunci putem scrie direct seria ca sumă a celor trei serii corespunzătoare:

$$f(z) = -\sum_{n \geq 0} z^n + \sum_{n \geq 0} (-1)^n z^n + \sum_{n \geq 0} (-1)^n (n+1) z^n = \sum_{n \geq 0} z^n (-1 + (-1)^n + (-1)^n (n+1)).$$

În jurul punctului $z = -1$, unde avem pol, trebuie să rescriem funcția sub forma:

$$f(z) = \frac{1}{(z+1)^2} + \frac{1}{z+1} - \frac{1}{2} \cdot \frac{1}{1 - \frac{z+1}{2}},$$

astfel punând în evidență puteri (negative!) ale lui $z+1$. Primii doi termeni nu necesită prelucrare, iar pentru al treilea, întrucât ne aflăm în domeniul de convergență a seriei geometrice, adică $|z+1| < 2$ putem scrie:

$$\frac{1}{1 - \frac{z+1}{2}} = \sum_{n \geq 0} \left(\frac{z+1}{2}\right)^n.$$

În jurul punctului $z = 1$, unde avem din nou pol, rescriem funcția sub forma:

$$f(z) = \frac{1}{z - 1} + \frac{1}{2} \cdot \frac{1}{1 + \frac{z-1}{2}} + \frac{1}{4} \cdot \frac{1}{\left(1 + \frac{z-1}{2}\right)^2}.$$

Primul termen nu necesită prelucrare, iar pentru al doilea, remarcăm că ne aflăm în interiorul domeniului său de convergență, căci $|z - 1| < 2$ și atunci avem direct suma seriei geometrice:

$$\frac{1}{1 + \frac{z-1}{2}} = \sum_{n \geq 0} (-1)^n \left(\frac{z-1}{2}\right)^n.$$

Al treilea termen se obține prin derivarea termen cu termen a seriei de mai sus (ca în cazul de la început) și avem:

$$\frac{1}{\left(1 + \frac{z-1}{2}\right)^2} = \sum_{n \geq 0} (-1)^n \frac{(n+1)(z-1)^n}{2^n}$$

și în fine, funcția se obține ca sumă a acestor trei serii, adică, după calcule:

$$f(z) = \frac{1}{z - 1} + \sum_{n \geq 0} \frac{n+3}{2^{n+2}} (z-1)^n.$$

SEMINAR 4

RECAPITULARE ANALIZĂ COMPLEXĂ

1. Determinați funcția olomorfă $f = P + iQ$ în cazurile:

- (a) $Q(x, y) = \ln(x^2 + y^2) + x - 2y;$
- (b) $P(x, y) = x^2 - y^2$ și știind $f(0) = 0;$
- (c) $P(x, y) = x^2 - y^2 - 2y;$
- (d) $Q(x, y) = x^3 - 3xy^2;$

2. Calculați:

- (a) $\exp\left(-\frac{5\pi i}{2}\right);$
- (b) $\text{Ln}(-2);$
- (c) $i^{3i};$
- (d) $i^{1+i};$
- (e) $(1 + i\sqrt{3})^{42}.$

3. Să se dezvolte în serie de puteri ale lui z funcția $f(z) = \frac{1}{z^2 - 3z + 2}$ în domeniile $|z| < 1$, $1 < |z| < 2$ și $|z| > 2$.

4. Determinați singularitățile, precizați natura lor și calculați reziduurile pentru funcțiile:

(a) $f(z) = \frac{z^5}{(z^2 + 1)^2};$

(b) $f(z) = \frac{\sin z}{z^2};$

(c) $f(z) = z^2 \cdot \cos \frac{1}{z};$

(d) $f(z) = \frac{\exp(z^{-1})}{z^4}.$

5. Calculați integralele complexe:

(a) $\int_0^{1+i} z^2 dz;$

(b) $\int_C (z^2 + \bar{z}^2) dz,$ unde C este segmentul care unește punctele 0 și $2 + 2i.$

(c) $\int_{|z|=3} \bar{z}^2 dz;$

(d) $\int_0^{2\pi} \frac{\cos 2\theta}{2 + \cos^2 \theta} d\theta;$

(e) $\int_0^{2\pi} \frac{1 + \sin \theta}{(3 - 2 \cos \theta)^2} d\theta;$

(f) $\int_{-\infty}^{\infty} \frac{dx}{(1 + x^4)^2};$

(g) $\int_{-\infty}^{\infty} \frac{dx}{(1 + x^2)^4}.$

Indicații: (f,g): Se definește un contur închis de forma $C = [-r, r] \cup \Gamma_r$, unde Γ_r este cercul centrat în origine și de rază r . Considerăm funcția complexă asociată $f(z) = \frac{1}{(1 + z^4)^2}$ sau, respectiv, $f(z) = \frac{1}{(1 + z^2)^4}$ și se calculează reziduurile pentru integrarea lui $f(z)$ pe C . Integrala reală revine la a calcula limita $r \rightarrow \infty$ a integralei complexe, deoarece conform lemei Jordan, integrala pe semicercul Γ_r este nulă. Rămîne calculul cu reziduuri.

Pe scurt:

Luăm $\Gamma : (-r, r) \cup \gamma$, unde $\gamma : |z| = r, \text{Im}(z) > 0$ și fie $f(z) = \frac{P(z)}{Q(z)}$.

Calculăm:

$$\begin{aligned} I_r &= \int_{\Gamma} f(z) dz = \int_{-r}^r f(x) dx + \int_{\gamma} f(z) dz \\ &= 2\pi i \sum_{k=1}^n \text{Rez}(f, z_k), \end{aligned}$$

Apoi:

$$\lim_{r \rightarrow \infty} I_r = \int_{-\infty}^{\infty} \frac{P(x)}{Q(x)} dx + \lim_{r \rightarrow \infty} \int_{\gamma} f(z) dz.$$

Și, deoarece $\lim_{z \rightarrow \infty} |zf(z)| = 0$, rezultă, cu lema Jordan, că integrala pe semicerc e nulă, adică $\lim_{r \rightarrow \infty} \int_{\gamma} f(z) dz = 0$, deci integrala reală căutată este egală cu rezultatul obținut cu teorema reziduurilor.

SEMINAR 5

TRANSFORMATĂ LAPLACE

5.1 Definiții și proprietăți

Transformata Laplace este o transformare integrală, care se poate aplica unor funcții speciale, numite *funcții original*.

Definiție 5.1: O funcție $f : \mathbb{R} \rightarrow \mathbb{C}$ se numește *original* dacă:

- (a) $f(t) = 0$ pentru orice $t < 0$;
- (b) f este continuă (eventual pe portiuni) pe intervalul $[0, \infty)$;
- (c) Este mărginită de o exponentială, adică există $M > 0$ și $s_0 \geq 0$ astfel încât:

$$|f(t)| \leq M e^{s_0 t}, \quad \forall t \geq 0.$$

Numărul s_0 se mai numește *indicele de creștere* al funcției f .

Vom nota cu \mathcal{O} multimea funcțiilor original.

Pornind cu o funcție original, definiția transformatei Laplace este:

Definiție 5.2: Păstrînd contextul și notatiile de mai sus, fie $f \in \mathcal{O}$ și multimea:

$$S(s_0) = \{s \in \mathbb{C} \mid \operatorname{Re}(s) > s_0\}.$$

Funcția:

$$F : S(s_0) \rightarrow \mathbb{C}, \quad F(s) = \int_0^\infty f(t) e^{-st} dt$$

se numește *transformata Laplace* a lui f sau *imaginea Laplace* a originalului f .

Vom mai folosi notația $F = \mathcal{L}f$ sau, explicit, $\mathcal{L}f(t) = F(s)$.

Proprietățile esențiale ale transformatei Laplace săt date mai jos. Fiecare dintre ele va fi folosită pentru a calcula o transformată Laplace pentru o funcție care nu se regăsește direct într-un tabel de valori.

- **Liniaritate:** $\mathcal{L}(\alpha f + \beta g) = \alpha \mathcal{L}f + \beta \mathcal{L}g$, pentru orice $\alpha, \beta \in \mathbb{C}$, iar f, g funcții original;

- **Teorema asemănării:**

$$\mathcal{L}f(\alpha t) = \frac{1}{\alpha} F\left(\frac{s}{\alpha}\right);$$

- **Teorema deplasării:**

$$\mathcal{L}(f(t)e^{s_0 t}) = F(s - s_0);$$

- **Teorema întîrzierii:** Definim *întîrziata cu τ* a funcției $f \in \mathcal{O}$ prin:

$$f_\tau(t) = \begin{cases} 0, & t < \tau \\ f(t - \tau), & t \geq \tau \end{cases}.$$

Atunci, dacă $\mathcal{L}f(t) = F(s)$, $\mathcal{L}f_\tau(t) = e^{-s\tau}F(s)$;

- **Teorema derivării imaginii:**

$$\mathcal{L}(t^n f(t)) = (-1)^n F^{(n)}(s);$$

- **Teorema integrării originalului:** Fie $f \in \mathcal{O}$, $\mathcal{L}f(t) = F(s)$ și $g(t) = \int_0^t f(\tau)d\tau$. Atunci:

$$\mathcal{L}g(t) = \frac{1}{s}F(s);$$

- **Teorema integrării imaginii:** Fie $\mathcal{L}f(t) = F(s)$ și G o primitivă a lui F în $S(s_0)$, cu $G(\infty) = 0$. Atunci:

$$\mathcal{L}\frac{f(t)}{t} = -G(s).$$

- **Teorema de convoluție:** Definim *produsul de convoluție* al două funcții, $h = f * g$, prin formula:

$$h(t) = \int_0^t f(\tau) \cdot g(t - \tau)d\tau$$

și fie F, G transformatele Laplace ale funcțiilor f și respectiv g , presupuse original. Dacă H este imaginea Laplace a funcției h , atunci $H(s) = F(s) \cdot G(s)$. Cu alte cuvinte, transformata Laplace acționează ca înmulțire pe produsul de convoluție.

5.2 Tabel de transformate Laplace

În tabelul de mai jos, vom considera funcțiile $f(t)$ ca fiind funcții original, adică nule pentru argument negativ. Echivalent, putem gîndi $f(t)$ ca fiind, de fapt, înmulțite cu *funcția lui Heaviside*:

$$u(t) = \begin{cases} 1, & t \geq 0 \\ 0, & t < 0 \end{cases}$$

$f(t) = \mathcal{L}^{-1}(F(s))$	$F(s) = \mathcal{L}(f(t))$
$u(t)$	$\frac{1}{s}$
$u(t - \tau)$	$\frac{1}{s} e^{-\tau s}$
t	$\frac{1}{s^2}$
t^n	$\frac{n!}{s^{n+1}}$
$t^n e^{-\alpha t}$	$\frac{1}{(s + \alpha)^{n+1}}$
$e^{-\alpha t}$	$\frac{1}{s + \alpha}$
$\sin(\omega t)$	$\frac{\omega}{s^2 + \omega^2}$
$\cos(\omega t)$	$\frac{s}{s^2 + \omega^2}$
$\sinh(\alpha t)$	$\frac{\alpha}{s^2 - \alpha^2}$
$\cosh(\alpha t)$	$\frac{s}{s^2 - \alpha^2}$
$e^{-\alpha t} \sin(\omega t)$	$\frac{\omega}{(s + \alpha)^2 + \omega^2}$
$e^{-\alpha t} \cos(\omega t)$	$\frac{s}{(s + \alpha^2) + \omega^2}$
$\ln t$	$-\frac{1}{s} (\ln s + \gamma^1)$

¹Constanta Euler-Mascheroni, $\gamma \approx 0,577\cdots \in \mathbb{R} - \mathbb{Q}$

5.3 Exerciții

1. Calculați transformatele Laplace pentru funcțiile (presupuse original):

- (a) $f(t) = 1, t \geq 0;$
- (b) $f(t) = t, t \geq 0;$
- (c) $f(t) = t^n, n \in \mathbb{N};$
- (d) $f(t) = e^{at}, t \geq 0, a \in \mathbb{R};$
- (e) $f(t) = \sin(at), t \geq 0, a \in \mathbb{R}.$

Soluție: (a) Avem direct din definiție:

$$F(s) = \int_0^\infty e^{-st} dt = \lim_{n \rightarrow \infty} \int_0^n e^{-st} dt = \frac{1}{s}, s > 0.$$

- (b) Integrăm prin părți și obținem $F(s) = \frac{1}{s^2}.$
- (c) Facem substituția $st = \tau$ și găsim:

$$F(s) = \int_0^\infty e^{-st} t^n dt = \frac{1}{s^{n+1}} \int_0^\infty e^{-\tau} \tau^n d\tau = \frac{n!}{s^{n+1}},$$

pentru $s > 0$, folosind funcția Gamma a lui Euler:

$$\Gamma(a) = \int_0^\infty x^{a-1} e^{-x} dx, a > 0, \quad \Gamma(n+1) = n!, n \in \mathbb{N}.$$

- (d) $F(s) = \int_0^\infty e^{at} e^{-st} dt = \int_0^\infty e^{-(s-a)t} dt = \frac{1}{s-a}, s > a.$
- (e) Integrăm prin părți și ajungem la:

$$F(s) = \frac{1}{a} - \frac{s^2}{a^2} F(s) \Rightarrow F(s) = \frac{a}{s^2 + a^2}, s > 0.$$

2. Folosind tabelul de valori și proprietățile, să se determine transformatele Laplace pentru funcțiile (presupuse original):

- (a) $f(t) = 5;$
- (b) $f(t) = 3t + 6t^2;$
- (c) $f(t) = e^{-3t};$

- (d) $f(t) = 5e^{-3t}$;
- (e) $f(t) = \cos(5t)$;
- (f) $f(t) = \sin(3t)$;
- (g) $f(t) = 3(t - 1) + e^{-t-1}$;
- (h) $f(t) = 3t^3(t - 1) + e^{-5t}$;
- (i) $f(t) = 5e^{-3t} \cos(5t)$;
- (j) $f(t) = e^{2t} \sin(3t)$;
- (k) $f(t) = te^{-t} \cos(4t)$;
- (l) $f(t) = t^2 \sin(3t)$;
- (m) $f(t) = t^3 \cos t$.

Indicații: În majoritatea cazurilor, se folosește tabelul și proprietatea de liniaritate. În plus:

- (i, j) Folosim $\mathcal{L}(e^{at}f(t)) = F(s - a)$;
- (k) Folosim $\mathcal{L}(tf(t)) = -\frac{d}{ds}\mathcal{L}(f(t))$;
- (l) Folosim $\mathcal{L}(t^n f(t)) = (-1)^n \frac{d^n F(s)}{ds^n}$;

3. Folosind teorema derivării imaginii, să se determine transformatele Laplace pentru funcțiile (presupuse original):

- (a) $f(t) = t$;
- (b) $f(t) = t^2$;
- (c) $f(t) = t \sin t$;
- (d) $f(t) = te^t$.

Indicație: Conform proprietății de derivare a imaginii, avem:

$$\mathcal{L}(tf(t)) = -\frac{d}{ds}\mathcal{L}(f(t)).$$

4. Folosind teorema integrării originalului, să se determine transformatele Laplace pentru funcțiile (presupuse original):

- (a) $f(t) = \int_0^t \cos(2\tau)d\tau$;

$$(b) f(t) = \int_0^t e^{3\tau} \cos(2\tau) d\tau;$$

$$(c) f(t) = \int_0^t \tau e^{-3\tau} d\tau.$$

Indicație: Conform proprietății de integrare a originalului, avem:

$$\mathcal{L} \int_0^t f(\tau) d\tau = \frac{F(s)}{s}.$$

5.4 Aplicații ale transformatei Laplace

Principala aplicație a transformatei Laplace este pentru rezolvarea ecuațiilor și sistemelor diferențiale de ordinul întâi sau superior.

Aceste aplicații se bazează pe calculele care se pot obține imediat din definiția transformatei Laplace și a proprietăților sale:

$$\begin{aligned}\mathcal{L}f' &= s\mathcal{L}f - f(0) \\ \mathcal{L}f'' &= s^2\mathcal{L}f - sf(0) - f'(0).\end{aligned}$$

De fapt, în general, avem:

$$\mathcal{L}f^{(n)} = s^n \mathcal{L}f - s^{n-1}f(0) - s^{n-2}f'(0) - \dots - f^{(n-1)}(0).$$

De asemenea, pentru integrale, știm deja teorema integrării originalului:

$$\mathcal{L} \int_0^t f(\tau) d\tau = \frac{1}{s} F(s), \quad F(s) = \mathcal{L}f(t).$$

Rezultă, folosind transformarea inversă:

$$\int_0^t f(\tau) d\tau = \mathcal{L}^{-1} \left(\frac{1}{s} F(s) \right).$$

De exemplu, pentru a rezolva ecuația diferențială:

$$y'' + ay' + by = r(t), \quad y(0) = K_0, y'(0) = K_1,$$

aplicăm transformata Laplace și folosim proprietățile de mai sus. Fie $Y = \mathcal{L}y(t)$

Se obține ecuația algebrică:

$$(s^2 Y - sy(0) - y'(0)) + a(sY - y(0)) + bY = R(s),$$

unde $R(s) = \mathcal{L}r$. Forma echivalentă este:

$$(s^2 + as + b)Y = (s + a)y(0) + y'(0) + R(s).$$

Împărțim prin $s^2 + as + b$ și folosim formula:

$$Q(s) = \frac{1}{s^2 + as + b} = \frac{1}{(s + \frac{1}{2}a)^2 + b - \frac{1}{4}a^2},$$

de unde rezultă:

$$Y(s) = ((s + a)y(0) + y'(0))Q(s) + R(s)Q(s).$$

În forma aceasta, descompunem $Y(s)$ în fractii simple, dacă este nevoie și folosim tabelul de transformate Laplace, pentru a afla $y = \mathcal{L}^{-1}(Y)$.

De exemplu:

$$y'' - y = t, \quad y(0) = 1, y'(0) = 1.$$

Soluție: Aplicăm transformata Laplace și ajungem la ecuația:

$$\begin{aligned} s^2 Y - sy(0) - y'(0) - Y &= \frac{1}{s^2} \\ (s^2 - 1)Y &= s + 1 + \frac{1}{s^2}. \end{aligned}$$

Rezultă $Q = \frac{1}{s^2 - 1}$ și ecuația devine:

$$\begin{aligned} Y &= (s + 1)Q + \frac{1}{s^2}Q \\ &= \frac{s + 1}{s^2 - 1} + \frac{1}{s^2(s^2 - 1)} \\ &= \frac{1}{s - 1} + \left(\frac{1}{s^2 - 1} - \frac{1}{s^2} \right) \end{aligned}$$

Folosind tabelul și proprietățile transformatei Laplace, obținem soluția:

$$\begin{aligned} y(t) &= \mathcal{L}^{-1}Y \\ &= \mathcal{L}^{-1}\left(\frac{1}{s-1}\right) + \mathcal{L}^{-1}\left(\frac{1}{s^2-1}\right) - \mathcal{L}^{-1}\left(\frac{1}{s^2}\right) \\ &= e^t + \sinh t - t. \end{aligned}$$

5.5 Exerciții

1. Să se rezolve următoarele probleme Cauchy, folosind transformata Laplace:

- (a) $y'(t) + 2y(t) = 4t, y(0) = 1;$
- (b) $y'(t) + y(t) = \sin 4t, y(0) = 0;$
- (c) $y''(t) + 2y'(t) + 5y(t) = 0, y(0) = 0, y'(0) = 0;$
- (d) $2y''(t) - 6y'(t) + 4y(t) = 3e^{3t}, y(0) = 1, y'(0) = -1;$
- (e) $y''(t) - 2y'(t) + y(t) = e^t, y(0) = -2, y'(0) = -3;$
- (f) $y''(t) + 4y(t) = 3\cos^2(t), y(0) = 1, y'(0) = 2.$

2. Să se rezolve următoarele sisteme diferențiale:

$$(a) \begin{cases} x' + x + 4y &= 10 \\ x - y' - y &= 0 \\ x(0) = 4, & y(0) = 3 \end{cases}$$

$$(b) \begin{cases} x' + x - y &= e^t \\ y' + y - x &= e^t \\ x(0) = 1, & y(0) = 1 \end{cases}$$

$$(c) \begin{cases} x' + 2y' + x - y &= 5 \sin t \\ 2x' + 3y' + x - y &= e^t \\ x(0) = 2, & y(0) = 1 \end{cases}$$

Indicație: Aplicăm transformata Laplace fiecărei ecuații și notăm $\mathcal{L}x(t) = X(s)$ și $\mathcal{L}y(t) = Y(s)$. Apoi rezolvăm sistemul *algebric* obținut cu necunoscutele X și Y , cărora la final le aplicăm transformata Laplace inversă.

5.6 Formula de inversare Mellin-Fourier

În cazul simplu, dacă se dă o imagine Laplace și vrem să recuperăm funcția originală, putem pur și simplu să citim tabelul de transformate de la stînga la dreapta, eventual după prelucrarea imaginii Laplace, precum am văzut în exemplele de mai sus. Dar avem nevoie și de o metodă care să funcționeze pe cazul general. Mai precis, avem nevoie de o metodă de a *inversa* transformatele Laplace. Această metodă este dată de formula de inversare Mellin-Fourier, pe care o prezentăm mai jos într-o variantă simplificată, mai potrivită pentru aplicații.

Teoremă 5.1 (Mellin-Fourier): Fie f o funcție original, $F = \mathcal{L}f$.

Atunci are loc egalitatea:

$$f(t) = \sum_{k=1}^n \operatorname{Rez} (F(s)e^{st}, s_k).$$

Deoarece avem mai multe moduri particulare de a calcula reziduurile, distingem și aici două calcule speciale:

- Dacă s_1, s_2, \dots, s_r sunt poli de ordin n_1, n_2, \dots, n_r , atunci formula de inversare se mai scrie:

$$f(t) = \sum_{k=1}^r \frac{1}{(n_k - 1)!} \cdot \lim_{s \rightarrow s_k} \frac{d^{n_k-1}}{ds^{n_k-1}} [F(s)(s - s_k)^{n_k} e^{st}];$$

- Dacă imaginea Laplace se poate scrie $F(s) = \frac{A(s)}{B(s)}$, unde A și B sunt polinoame cu coeficienți reali, astfel încât $\operatorname{grad}(A) < \operatorname{grad}B$, atunci formula de inversare devine:

$$f(t) = \sum_k \operatorname{Rez} \left(\frac{A(s)}{B(s)} e^{st}, s_k \right) + \sum_k 2\operatorname{Re} \left(\operatorname{Rez} \left(\frac{A(s)}{B(s)} e^{st}, s_k \right) \right),$$

unde prima sumă se calculează pentru polii reali, iar cea de-a doua, pentru polii complecși cu partea imaginară pozitivă.

Exemplu: Determinați funcția original corespunzătoare imaginii Laplace:

$$F(s) = \frac{3s - 4}{s^2 - s - 6}.$$

Soluție: Observăm că avem $s_1 = 3$, $s_2 = -2$ poli simpli. Atunci rezultă:

$$f(t) = \operatorname{Rez} \left(\frac{3s - 4}{s^2 - s - 6} e^{st}, 3 \right) + \operatorname{Rez} \left(\frac{3s - 4}{s^2 - s - 6} e^{st}, -2 \right).$$

Cum ambii sunt poli simpli, reziduurile se calculează folosind formula din teorema 2.4(3) și se obține în final $f(t) = e^{3t} + 2e^{-2t}$.

Observație 5.1: Această problemă, ca și altele, pot fi rezolvate și fără formula de inversare. Trebuie doar atenție și suficient exercițiu astfel încât, în afară de citirea „invers“ a tabelului de transformate Laplace, să putem folosi și teoreme de tip întîrziere, derivarea originalului etc. De exemplu, exercițiul de mai sus putea începe cu descompunerea în fracții simple:

$$\frac{3s - 4}{s^2 - s - 6} = \frac{A}{s - 3} + \frac{B}{s + 2}.$$

Se determină A și B , apoi se folosește tabelul de transformate.

5.7 Exerciții

Folosind, eventual, formula de inversare Mellin-Fourier, aflați funcțiile originale care au transformatele Laplace date:

$$(1) \quad F(s) = \frac{s+3}{s^3 + 4s^2};$$

$$(2) \quad F(s) = \frac{s^2 + 3s + 1}{(s+1)(s+2)(s+3)};$$

$$(3) \quad F(s) = \frac{2s+1}{s(s+1)};$$

$$(4) \quad F(s) = \frac{4s+10}{s^2 - 12s + 32};$$

$$(5) \quad F(s) = \frac{5s+1}{s^2 + 1};$$

$$(6) \quad F(s) = \frac{s+2}{s^2(s+3)};$$

$$(7) \quad F(s) = \frac{1}{s^2(s-2)^2};$$

$$(8) \quad F(s) = \frac{2s-7}{s^2 + 2s + 6}.$$

SEMINAR 6

TRANSFORMATĂ Z

Această transformată se definește pe un caz discret, pornind de la:

Definiție 6.1: Se numește *semnal discret* o funcție $x : \mathbb{Z} \rightarrow \mathbb{C}$ dată de $n \mapsto x_n$ sau, echivalent, $x(n)$ ori $x[n]$.

Mulțimea semnalelor discrete se va nota cu S_d , iar cele cu suport pozitiv (nule pentru $n < 0$) se va nota S_d^+ .

Un semnal particular este *impulsul unitar discret* la momentul k , definit prin:

$$\delta_k(n) = \begin{cases} 1, & n = k \\ 0, & n \neq k \end{cases},$$

definit pentru $k \in \mathbb{Z}$ fixat.

Pentru $k = 0$, vom nota $\delta_0 = \delta$.

Definiție 6.2: Fie $x \in S_d$ și $k \in \mathbb{Z}$ fixat. Semnalul $y = (x_{n-k})$ se numește *întârziatul lui x cu k momente*.

O operatie foarte importantă, pe care se vor baza unele proprietăți esențiale ale transformatei Z este *convoluția*:

Definiție 6.3: Fie $x, y \in S_d$. Dacă seria $\sum_{k \in \mathbb{Z}} x_{n-k}y_k$ este convergentă pentru orice $n \in \mathbb{Z}$ și are suma z_n , atunci semnalul $z = (z_n)$ se numește *convoluția* semnalelor x și y și se notează $z = x * y$.

Trei proprietăți imediate sînt:

- $x * y = y * x$;

- $x * \delta = x$;
- $(x * \delta_k)(n) = x_{n-k}$.

Ajungem acum la definiția principală:

Definiție 6.4: Fie $s \in S_d$, cu $s = (a_n)_n$. Se numește *transformata Z* sau *transformata Laplace discretă* a acestui semnal funcția definită prin:

$$L_s(z) = \sum_{n \in \mathbb{Z}} a_n z^{-n},$$

care se definește în domeniul de convergență al seriei Laurent din definiție.

Principalele proprietăți pe care le vom folosi în calcule sănt:

- (1) **Liniaritatea:** Transformata Z este liniară în raport cu înmulțirea cu scalari și adunarea semnalelor discrete;
- (2) **Inversarea transformării Z:** Fie $s \in S_d^+$, cu $s = (a_n)$. Presupunem că $L_s(z)$ este olomorfă în domeniul $|z| \in (r, R)$. Atunci putem recupera semnalul a_n prin formula:

$$a_n = \frac{1}{2\pi i} \int_{\gamma} z^{n-1} L_s(z) dz, \quad n \in \mathbb{Z},$$

unde γ este discul de rază $\rho \in (r, R)$.

- (3) **Teorema de convoluție:** Fie $s, t \in S_d^+$. Atunci $s * t = S_d^+$ și are loc $L_{s*t} = L_s \cdot L_t$. În particular:

$$L_{s*\delta_k}(z) = z^{-k} L_s(z), \quad k \in \mathbb{Z};$$

s	$L_s(z)$
$\begin{cases} h_n = 0, & n < 0 \\ h_n = 1, & n \geq 0 \end{cases}$	$\frac{z}{z-1}$
$\delta_k, k \in \mathbb{Z}$	$\frac{1}{z^k}$
$s = (n)_{n \in \mathbb{N}}$	$\frac{z}{(z-1)^2}$
Cîteva transformate uzuale sînt:	$s = (n^2)_{n \in \mathbb{N}}$
$s = (a^n)_{n \in \mathbb{N}}, a \in \mathbb{C}$	$\frac{z}{z-a}$
$s = (e^{an})_{n \in \mathbb{N}}, a \in \mathbb{R}$	$\frac{z}{z-e^a}$
$s = (\sin(\omega n))_{n \in \mathbb{N}}, \omega \in \mathbb{R}$	$\frac{z \sin \omega}{z^2 - 2z \cos \omega + 1}$
$s = (\cos(\omega n))_{n \in \mathbb{N}}, \omega \in \mathbb{R}$	$\frac{z(z - \cos \omega)}{z^2 - 2z \cos \omega + 1}$

6.1 Exerciții

1. Să se determine semnalul $x \in S_d^+$, a cărui transformată Z este dată de:

(a) $L_x(z) = \frac{z}{(z-3)^2}$;

(b) $L_x(z) = \frac{z}{(z-1)(z^2+1)}$;

(c) $L_x(z) = \frac{z}{(z-1)^2(z^2+z-6)}$;

(d) $L_x(z) = \frac{z}{z^2+2az+2a^2}, a > 0$ parametru.

Soluție:

(a) Avem:

$$\begin{aligned}
x_n &= \frac{1}{2\pi i} \int_{|z|=\rho} z^{n-1} L_s(z) dz \\
&= \operatorname{Rez}(z^{n-1} L_s(z), 3) \\
&= \operatorname{Rez}\left(\frac{z^n}{(z-3)^2}, 3\right) \\
&= \lim_{z \rightarrow 3} \left((z-3)^2 \cdot \frac{z^n}{(z-3)^2} \right)' \\
&= \lim_{z \rightarrow 3} nz^{n-1} \\
&= n3^{n-1}.
\end{aligned}$$

(b)

$$\begin{aligned}
x_n &= \frac{1}{2\pi i} \int_{|z|=\rho} z^{n-1} L_s(z) dz \\
&= \operatorname{Rez}(z^{n-1} L_s(z), 1) + \operatorname{Rez}(z^{n-1} L_s(z), i) + \operatorname{Rez}(z^{n-1} L_s(z), -i) \\
\operatorname{Rez}(z^{n-1} L_s(z), 1) &= \lim_{z \rightarrow 1} z^{n-1} \frac{z}{(z-1)(z^2+1)} \cdot (z-1) = \frac{1}{2} \\
\operatorname{Rez}(z^{n-1} L_s(z), i) &= \frac{i^n}{2i \cdot (i-1)} \\
\operatorname{Rez}(z^{n-1} L_s(z), -i) &= \frac{(-1)^n i^n}{2i(i+1)}.
\end{aligned}$$

Remarcăm că pentru $n = 4k$ și $n = 4k + 1$, avem $x_n = 0$, iar în celelalte două cazuri, $x_n = 1$.

(c)

$$\begin{aligned}
\operatorname{Rez}(z^{n-1} L_s(z), 1) &= \lim_{z \rightarrow 1} \left[z^{n-1} \cdot (z-1)^2 \cdot \frac{z^2}{(z-1)^2 \cdot (z^2+z-6)} \right]' \\
&= -\frac{4n+3}{16}. \\
\operatorname{Rez}(z^{n-1} L_s(z), 2) &= \frac{2^n}{5} \\
\operatorname{Rez}(z^{n-1} L_s(z), -3) &= -\frac{(-3)^n}{80}.
\end{aligned}$$

$$\text{Obținem } x_n = -\frac{4n+3}{16} + \frac{2^n}{5} - \frac{(-3)^n}{80}.$$

(d) $z_{1,2} = a(-1 \pm i)$ sunt poli simpli. Avem:

$$\begin{aligned} x_n &= \operatorname{Rez}\left(\frac{z^n}{(z^2 + 2a + 2a^2)}, z_1\right) + \operatorname{Rez}\left(\frac{z^n}{(z^2 + 2a + 2a^2)}, z_2\right) \\ &= \frac{a^n(-1+i)^n}{2z_1 + 2a} + \frac{a^n(-1-i)^n}{2z_2 + 2a} \\ &= -\frac{i}{2a}(z_1^n - z_2^n). \end{aligned}$$

Putem scrie trigonometric numerele z_1 și z_2 :

$$\begin{aligned} z_1 &= a(-1+i) = a\sqrt{2}\left(\cos\frac{3\pi}{4} + i\sin\frac{3\pi}{4}\right) \\ z_2 &= a(-1-i) = a\sqrt{2}\left(\cos\frac{3\pi}{4} - i\sin\frac{3\pi}{4}\right). \end{aligned}$$

Deci: $x_n = 2^{\frac{n}{2}}a^{n-1}\sin\frac{3n\pi}{4}$.

2. Fie $x = (x_n) \in S_d^+$ și $y = (y_n)$, unde $y_n = x_0 + \dots + x_n$. Să se arate că $Y(z) = \frac{z}{z-1}X(z)$, unde $Y(z) = L_x(z)$ și $X(z) = L_x(z)$ sunt transformatele Z pentru semnalele x și y :

Soluție:

Avem $Y(z) = \sum_{n=0}^{\infty} y_n z^{-n}$. Dar:

$$X(z) = \sum_{n=0}^{\infty} x_n z^{-n} \text{ și } \sum_{n=0}^{\infty} x_{n-1} z^n = \frac{1}{z} X(z),$$

deoarece $x_{-1} = 0$. Putem continua și obținem $\sum_{n=0}^{\infty} x_{n-k} z^{-n} = \frac{1}{z^k} X(z)$. Așadar:

$$Y(z) = X(z) \cdot \left(1 + \frac{1}{z} + \frac{1}{z^2} + \dots\right) = X(z) \cdot \frac{z}{z-1}.$$

3. Cu ajutorul transformării Z , să se determine sirurile (x_n) definite prin următoarele relații:

- (a) $x_0 = 0, x_1 = 1, x_{n+2} = x_{n+1} + x_n, n \in \mathbb{N}$ (sirul lui Fibonacci);
- (b) $x_0 = 0, x_1 = 1, x_{n+2} = x_{n+1} - x_n, n \in \mathbb{N}$;
- (c) $x_0 = x_1 = 0, x_2 = -1, x_3 = 0, x_{n+4} + 2x_{n+3} + 3x_{n+2} + 2x_{n+1} + x_n = 0, n \in \mathbb{N}$;
- (d) $x_0 = 2, x_{n+1} + 3x_n = 1, n \in \mathbb{Z}$;
- (e) $x_0 = 0, x_1 = 1, x_{n+2} - 4x_{n+1} + 3x_n = (n+1)4^n, n \in \mathbb{N}$.

Soluție:

Abordarea generală este să considerăm sirul (x_n) ca fiind restricția unui semnal $x \in S_d^+$ la \mathbb{N} și rescriem relațiile de recurență sub forma unor ecuații de convoluție $a * x = y$, pe care le rezolvăm în S_d^+ .

(a) Fie $x \in S_d^+$, astfel încât restricția lui la \mathbb{N} să fie sirul căutat. Deoarece avem:

$$x_{n+2} - x_{n+1} - x_n = y_n, n \in \mathbb{Z},$$

cu $y_n = 0$ pentru $n \neq -1$ și $y_{-1} = 1$, avem ecuația de convoluție:

$$a * x = y, \text{ unde } a = \delta_{-2} - \delta_{-1} - \delta, y = \delta_{-1}.$$

Aplicăm transformata Z și rezultă:

$$L_x(z) \cdot (z^2 - z - 1) = z \implies x_n = \frac{1}{\sqrt{5}} \left[\left(\frac{1 + \sqrt{5}}{2} \right)^n - \left(\frac{1 - \sqrt{5}}{2} \right)^n \right].$$

(b) Ca în cazul anterior, avem $a * x = y$, cu $a = \delta_{-2} - \delta_{-1} + \delta$, unde $y = \delta_{-1}$. Aplicând transformata Z , obținem:

$$L_x(z) \cdot (z^2 - z + 1) = z \implies L_x(z) = \frac{z}{z^2 - z + 1}.$$

Obținem:

$$x_n = \operatorname{Rez} \left(z^{n-1} \frac{z}{z^2 - z + 1}, \frac{1 + i\sqrt{3}}{2} \right) + \operatorname{Rez} \left(z^{n-1} \frac{z}{z^2 - z + 1}, \frac{1 - i\sqrt{3}}{2} \right).$$

Calculăm reziduurile, cu notația $\varepsilon = \frac{1 + i\sqrt{3}}{2}$ și $\bar{\varepsilon} = \frac{1 - i\sqrt{3}}{2}$:

$$\begin{aligned} \operatorname{Rez} \left(\frac{z^n}{z^2 - z + 1}, \varepsilon \right) &= \lim_{z \rightarrow \varepsilon} \frac{z^n}{z^2 - z + 1} (z - \varepsilon) \\ &= \frac{\varepsilon^n}{i\sqrt{3}} \\ &= \frac{\cos \frac{2n\pi}{3} + i \sin \frac{2n\pi}{3}}{i\sqrt{3}}. \end{aligned}$$

Similar:

$$\operatorname{Rez} \left(\frac{z^n}{z^2 - z + 1}, \bar{\varepsilon} \right) = \frac{\cos \frac{2n\pi}{3} - i \sin \frac{2n\pi}{3}}{-i\sqrt{3}}.$$

Rezultă:

$$x_n = \frac{2}{\sqrt{3}} \sin \frac{2n\pi}{3}, n \in \mathbb{N}.$$

(c) Ecuatia $a * x = y$ este valabilă pentru:

$$a = \delta_{-4} + 2\delta_{-3} + 3\delta_{-2} + 2\delta_{-1} + \delta, \quad y = -\delta_{-2} - 2\delta_{-1}.$$

Aplicăm transformata Z și obținem: $L_x(z) = -\frac{z(z+2)}{(z^2+z+1)^2}$. Descompunem în fractii simple, calculăm reziduurile și ținem cont de faptul că rădăcinile numitorului, $\varepsilon_1, \varepsilon_2$ sunt poli de ordinul 2, obținem:

$$x_n = \frac{(2n-4)(\varepsilon_1^n - \varepsilon_2^n) - (n+1)(\varepsilon_1^{n-1} + \varepsilon_1^{n-2} - \varepsilon_2^{n-1} - \varepsilon_2^{n-2})}{(\varepsilon_2 - \varepsilon_1)^3} = \frac{2(n-1)}{\sqrt{3}} \sin \frac{2n\pi}{3}, n \in \mathbb{N}.$$

(d) Ecuatia corespunzătoare este $a * x = y$, cu $a = \delta_{-1} + 3\delta$ și $y_n = 1, \forall n \geq 1$, iar $y_{-1} = x_0 + 3x_{-1} = 2$, cu $y_n = 0, \forall n \leq -2$, adică $y = 1 + 2\delta_{-1}$.

Așadar:

$$\delta_{-1} * x + 3\delta * x = 1 + 2\delta_{-1}.$$

Aplicăm transformata Z și obținem:

$$\begin{aligned} zL_x(z) + 3L_x(z) &= \frac{z}{z-1} + 2z \\ &= \frac{2z^2 + 3z}{z-1} \\ \implies L_x(z) &= \frac{2z^2 + 3z}{(z-1)(z+3)} \\ \implies x_n &= \text{Rez}\left(z^{n-1} \cdot \frac{2z^2 + 3z}{(z-1)(z+3)}, 1\right) + \text{Rez}\left(z^{n-1} \cdot \frac{2z^2 + 3z}{(z-1)(z+3)}, -3\right) \\ \text{Rez}\left(z^{n-1} \cdot \frac{2z^2 + 3z}{(z-1)(z+3)}, 1\right) &= \lim_{z \rightarrow 1} (z-1) \cdot z^{n-1} \cdot \frac{2z^2 + 3z}{(z-1)(z+3)} = \frac{5}{4} \\ \text{Rez}\left(z^{n-1} \cdot \frac{2z^2 + 3z}{(z-1)(z+3)}, -3\right) &= \lim_{z \rightarrow -3} (z+3)z^{n-1} \cdot \frac{2z^2 + 3z}{(z-1)(z+3)} \\ &= (-3)^{n-1} \cdot \frac{12}{-4} = -3 \cdot (-3)^{n-1}. \end{aligned}$$

$$\text{Rezultă: } x_n = \frac{5}{4} - 3 \cdot (-3)^{n-1}.$$

(e) Avem ecuația: $a * x = y$, unde $a = \delta_{-2} - 4\delta_{-1} + 3\delta$, cu $y_n = 0, \forall n \leq -2$, $y_{-1} = 1$ și $y_n = (n+1)4^n, \forall n \in \mathbb{N}$.

Fie $s_1 = (n4^n)_n$, $s_2 = (4^n)_n$. Atunci:

$$\begin{aligned} L_{s_1}(z) &= -zL'_{s_2}(z) = -z\left(\frac{z}{z-4}\right)' = \frac{4z}{(z-4)^2} \\ \implies L_x(z)(z^2 - 4z + 3) &= \frac{4z}{(z-4)^2} + \frac{z}{z-4} + z \\ &= \frac{z^2}{(z-4)^2} + z \\ \implies L_x(z) &= \frac{z(z^2 - 7z + 16)}{(z-4)^2(z-1)(z-3)}. \end{aligned}$$

Descompunem în fractii simple și obținem, în fine:

$$x_n = \frac{1}{9} [18 \cdot 3^n + (3n - 13)4^n - 5], n \in \mathbb{N}.$$

OBSERVATIE: Toate exercițiile cu recurențe se mai pot rezolva în alte două moduri:

(1) Se poate aplica teorema de convoluție relatiei de recurență. De exemplu, din recurența:

$$x_{n+2} - 2x_{n+1} + x_n = 2$$

putem obține:

$$L_{x_{n+2}}(z) - 2L_{x_{n+1}}(z) + L_{x_n}(z) = 2L_1(z),$$

iar $L_{x_{n+2}}(z) = L_{x_n * \delta_{-2}}(z) = L_{x_n}(z) \cdot L_{\delta_{-2}}(z)$ etc.

(2) Se poate aplica teorema de deplasare. În aceeași recurență de mai sus, de exemplu, avem:

$$L_{x_{n+2}}(z) = z^n (L_{x_n}(z) - x_0 - x_1 z^{-1})$$

și la fel pentru celelalte.

6.2 Exerciții suplimentare (L. Costache)

1. Să se determine semnalul $x \in S_d^+$ a cărui transformată Z este:

(a) $L_x(z) = \frac{2z + 3}{z^2 - 5z + 6};$

(b) $L_x(z) = \frac{z^2 + 1}{z^2 - z + 1};$

(c) $L_x(z) = \frac{z}{(z - 5)^2};$

(d) $L_x(z) = \frac{z + 2}{z^2 + z + 1}.$

2. Cu ajutorul transformatei Z , să se determine sirurile $(x_n)_{n \in \mathbb{N}}$ definite prin următoarele relații de recurență:

- (a) $x_0 = 4, x_1 = 6$ și $x_{n+2} - 3x_{n+1} + 2x_n = 0, \forall n \in \mathbb{N}$;
- (b) $x_0 = 0, x_1 = 11, x_2 = -8, x_3 = 6$ și $x_{n+4} - \frac{5}{2}x_{n+3} + \frac{5}{2}x_{n+1} - x_n = 1, \forall n \in \mathbb{N}$;
- (c) $x_0 = 0, x_1 = 3$ și $x_{n+2} - 4x_{n+1} + 3x_n = 2, \forall n \in \mathbb{N}$;
- (d) $x_0 = 0, x_1 = -1$ și $x_{n+2} + x_{n+1} - 6x_n = n, \forall n \in \mathbb{N}$;
- (e) $x_0 = 0, x_1 = 1$ și $x_{n+2} - 5x_{n+1} + 6x_n = 4 \cdot 5^n, \forall n \in \mathbb{N}$.

SEMINAR 7

TRANSFORMAREA FOURIER

Transformarea Fourier, cu diversele sale variante (discretă, rapidă etc.) este foarte utilă pentru studiul undelor sinusoidale. Dacă o serie Fourier dezvoltă o funcție într-o serie în care termenii sănt sinusuri și cosinusuri, transformata Fourier este o transformare integrală, în care aspectele periodice corespunzătoare funcțiilor trigonometrice se păstrează.

De aceea, veți întâlni foarte des transformatele Fourier în cazul analizelor semnalelor sonore, fie pentru digitalizare sau pentru diverse descompuneri. Un exemplu concret este în inteligența artificială și învățarea automată, unde se lucrează la programe care să facă recunoaștere vocală, transcrieri și traduceri. În toate aceste aplicații, o analiză a semnalului audio cu ajutorul transformatei Fourier este indispensabil.

7.1 Elemente teoretice

Foarte pe scurt, vom da definițiile și principalele proprietăți care vor fi de folos în exerciții.

Audem nevoie de următoarea notiune:

Definiție 7.1: Fie $f : \mathbb{R} \rightarrow \mathbb{R}$ o funcție reală. Spunem că ea este L^1 (formal, *apartine multimii $L^1(\mathbb{R})$*), dacă are proprietatea:

$$\int_{-\infty}^{\infty} |f(t)| dt < \infty.$$

Intuitiv, mutînd tot graficul funcției deasupra axei Ox (prin oglindire pe intervalele negative), aria de sun grafic este finită. Deci funcția nu are nicio zonă în care „explodează“ spre $\pm\infty$ asimptotic.

Acestea sănt funcțiile cărora le vom defini transformările Fourier. Deci, dacă nu se precizează altfel, toate funcțiile care se transformă vor fi presupuse L^1 .

Definiția principală urmează.

Definiție 7.2: Fie f o funcție L^1 . Se definește *transformata Fourier* a lui f , notată \mathcal{F} (alternativ, $\mathcal{F}[f]$ sau, și mai explicit, $\mathcal{F}[f(t)](\omega)$)¹ funcția complexă definită prin:

$$\mathcal{F}[f] : \mathbb{R} \rightarrow \mathbb{C}, \quad \mathcal{F}[f](\omega) = \int_{-\infty}^{\infty} f(t) e^{-i\omega t} dt.$$

Se vede aici importanța faptului că f este L^1 .

Folosind formula lui Euler pentru exponentiala complexă care apare în integrală, precum și paritatea funcțiilor trigonometrice, facem următoarele observații imediate:

- Dacă f este funcție pară, atunci transformata Fourier are partea imaginară nulă (integrala sinsului pe un interval simetric față de origine – în acest caz special, $(-\infty, \infty)$ – este nulă, iar integrala funcției pare cosinus este dublul integralei calculate pe jumătate din interval) și rămînem cu:

$$\mathcal{F}[f](\omega) = 2 \int_0^{\infty} f(t) \cos(\omega t) dt;$$

- Dacă f este funcție impară, folosind argumentul din cazul anterior, transformarea Fourier are partea reală nulă și rămînem cu:

$$\mathcal{F}[f](\omega) = -2i \int_0^{\infty} f(t) \sin(\omega t) dt.$$

Cele două cazuri speciale se numesc, respectiv, *transformarea (Fourier) prin sinus* și *transformarea (Fourier) prin cosinus* ale funcției f .

Transformarea Fourier se poate inversa relativ simplu:

Teoremă 7.1 (Transformarea Fourier inversă): *Fie f o funcție L^1 și $\mathcal{F}[f]$ transformata sa Fourier. Presupunem că și $\mathcal{F}[f]$ este funcție L^1 și atunci se poate recupera funcția f prin formula:*

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \mathcal{F}[f](\omega) e^{i\omega t} d\omega.$$

Dacă funcția f care se transformă are „puncte cu probleme“ (care sigur aparțin domeniului de integrare, deoarece acesta este întreg \mathbb{R}), atunci transformarea Fourier se calculează cu ajutorul reziduurilor. Fie, aşadar, p_1, \dots, p_n poli ai funcției f și presupunem că $\lim_{|z| \rightarrow \infty} f(z) = 0$. Atunci:

- Dacă $\text{Im} p_k > 0$, atunci:

$$\mathcal{F}[f](\omega) = 2\pi i \sum_{k=1}^n \text{Rez}(f(z) e^{-i\omega z}, p_k), \quad \text{pentru } \omega < 0;$$

¹Pentru a nu încărca inutil notația, vom folosi această variantă explicită doar aici. Regula care se va păstra în continuare este următoarea: argumentul funcției f care se transformă este t , iar argumentul transformatei $\mathcal{F}[f]$ este ω . De asemenea, argumentul t al funcției f se mai numește *temp*, iar argumentul ω al transformatei se mai numește *frecvență*.

- Dacă $\operatorname{Im} p_k < 0$, atunci:

$$\mathcal{F}[f](\omega) = -2\pi i \sum_{k=1}^n \operatorname{Rez} (f(z)e^{-i\omega z}, p_k), \quad \text{pentru } \omega > 0;$$

În exerciții, ne vor mai fi de folos și următoarele proprietăți ale transformatei Fourier:

- (1) **Liniaritatea:** $\mathcal{F}[\alpha f + \beta g] = \alpha \mathcal{F}[f] + \beta \mathcal{F}[g]$, pentru orice f, g funcții L^1 și $\alpha, \beta \in \mathbb{C}$ scalari;
- (2) **Simetria:** $\mathcal{F}[\mathcal{F}[f](\omega)] = 2\pi f(-\omega)$;
- (3) **Rescalarea:** Fie $\alpha \in \mathbb{C}$. Atunci:

$$\mathcal{F}[f(\alpha t)](\omega) = \frac{1}{|\alpha|} \mathcal{F}[f]\left(\frac{\omega}{\alpha}\right).$$

- (4) **Translația după t :**

$$\mathcal{F}[f(t - t_0)] = \mathcal{F}[f(t)] \cdot e^{-i\omega t_0}, \quad \forall t_0 \in \mathbb{R};$$

- (5) **Translația după ω :**

$$\mathcal{F}[e^{i\omega_0 t} f(t)] = \mathcal{F}[f(t)](\omega - \omega_0), \quad \forall \omega_0 \in \mathbb{R};$$

- (6) **Derivarea după t :**

$$\mathcal{F}[f^{(n)}(t)] = (i\omega)^n \mathcal{F}[f](\omega),$$

în ipoteza că f este de n ori derivabilă, pentru un anume n ;

- (7) **Derivarea după ω :**

$$\mathcal{F}[(-it)^n f(t)] = \mathcal{F}^{(n)}[f](\omega),$$

în ipoteza că derivatele de pînă la n ori au sens;

- (8) **Transformata conjugatei complexe:** Notăm $f^*(t)$ funcția conjugată complexă asociată lui $f(t)$. Atunci:

$$\mathcal{F}[f^*(t)] = (\mathcal{F}[f(t)])^*(-\omega).$$

Altfel spus, se transformă funcția inițială, apoi se ia conjugatul rezultatului și se schimbă semnul argumentului;

- (9) **Convoluția în timp:** Definim:

$$h(t) = (f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$$

produsul de convoluție al funcțiilor f și g . Atunci:

$$\mathcal{F}[f * g] = \mathcal{F}[f] \cdot \mathcal{F}[g];$$

- (10) **Convoluția în frecvență:**

$$\mathcal{F}[f(t) \cdot g(t)] = \frac{1}{2\pi} \int_{-\infty}^{\infty} \mathcal{F}[f](y) \cdot \mathcal{F}[g](\omega - y)dy.$$

7.2 Aplicații la ecuații integrale

Folosind formula de transformare Fourier, precum și inversarea acesteia, putem rezolva ecuații integrale. Vom prezenta acest lucru pe un exemplu.

Exemplu: Rezolvăm ecuația integrală:

$$\int_0^\infty y(t) \cos tx dt = \frac{1}{x^2 + 1}.$$

Soluție: Pentru a face legătura cu transformările Fourier, avem nevoie să prelungim funcția y (astfel încât integrala să fie pe $(-\infty, \infty)$). Deoarece integrandul este par, acest lucru conduce la dublarea rezultatului. Deci avem:

$$\int_{-\infty}^\infty y(t) \cos tx dt = \frac{2}{x^2 + 1}, \quad \int_{-\infty}^\infty y(t) \sin tx dt = 0.$$

Acest lucru conduce la:

$$\frac{1}{2\pi} \int_{-\infty}^\infty y(t) e^{-itx} dt = \frac{1}{\pi(x^2 + 1)}.$$

Recunoaștem în membrul stîng formula de trasnformare Fourier, deci rezultă:

$$\mathcal{F}[y(t)](x) = \frac{1}{\pi(x^2 + 1)}.$$

Folosim acum formula de inversare și rezultă:

$$y(t) = \frac{1}{\pi} \int_{-\infty}^\infty \frac{1}{x^2 + 1} e^{itx} dx.$$

Acest calcul se poate face cu teorema reziduurilor, deoarece integrandul are doi poli, $p_{1,2} = \pm i$, ambii simpli. Obținem:

- Pentru $t < 0$ și polul $p_1 = i$:

$$\begin{aligned} y(t) &= \frac{1}{\pi} \cdot 2\pi i \operatorname{Rez} \left(\frac{1}{x^2 + 1} e^{itx}, i \right) \\ &= 2i \cdot \lim_{z \rightarrow i} (z - i) \frac{1}{z^2 + 1} e^{itz} \\ &= 2i \cdot e^{-t}; \end{aligned}$$

- Pentru $t > 0$ și polul $p_2 = -i$:

$$\begin{aligned} y(t) &= \frac{1}{\pi i} \cdot -2\pi i \operatorname{Rez} \left(\frac{1}{x^2 + 1} e^{itx}, -i \right) \\ &= -2i \cdot \lim_{z \rightarrow -i} (z + i) \frac{1}{z^2 + 1} e^{itz} \\ &= 2ie^t. \end{aligned}$$

Concluzia este că soluția arată astfel:

$$y(t) = \begin{cases} 2i \cdot \exp(-t), & t < 0 \\ 2i \cdot \exp(t), & t > 0 \end{cases} = 2i \cdot \exp(|t|).$$

7.3 Exerciții

1. Rezolvați ecuațiile integrale:

$$(a) \int_0^\infty f(t) \sin tx dt = e^{-x}, \quad x > 0;$$

$$(b) \int_0^\infty f(t) \cos tx dt = \frac{1}{(1+x^2)^2};$$

2. Calculați transformatele Fourier pentru funcțiile:

$$(a) f(t) = \begin{cases} 1 - |t|, & t \in [-1, 1] \\ 0, & \text{în rest} \end{cases};$$

$$(b) f(t) = \frac{t}{t^2 + a^2}, a > 0;$$

$$(c) f(t) = \frac{1}{(t^2 + 1)^2};$$

$$(d) f(t) = \begin{cases} \exp(2t), & t \leq 0 \\ 0, & t > 0 \end{cases};$$

$$(e) f(t) = \begin{cases} t^2 - t, & 0 < t < 1 \\ 0, & \text{în rest} \end{cases};$$

$$(f) f(t) = \begin{cases} t, & |t| < 1 \\ 0, & |t| > 1 \end{cases}.$$

3. Calculați transformatele Fourier pentru funcțiile de mai jos, folosind teorema reziduurilor:

$$(a) f(t) = \frac{2}{t^2 + 9};$$

$$(b) f(t) = \frac{t}{(t^2 + 9)(t^2 + 1)};$$

$$(c) f(t) = \frac{1}{(t^2 + 4)^2}.$$

SEMINAR 8

RECAPITULARE TEST (L. COSTACHE)

Integrale complexe

Calculați:

(a) $\int_{|z|=4} \frac{z dz}{\sin z(1 - \cos z)};$

(b) $\int_{|z|=4} \frac{dz}{3 \sin z - \sin 3z};$

(c) $\int_{|z|=2} \frac{z^n \cdot e^{\frac{1}{z}}}{z^2 - 1} dz;$

(d) $\int_0^{2\pi} \frac{\cos 4\theta}{1 - 2a \cos \theta + a^2} d\theta, a > 1;$

(e) $\int_{-\infty}^{\infty} \frac{x \cos x}{x^2 - 6x + 13} dx;$

(f) $\int_0^{\infty} \frac{x \sin ax}{(x^2 + b^2)(x^2 + c^2)} dx, b, c > 0.$

Transformata Laplace

1. Să se determine transformata Laplace a funcției:

$$f(t) = \begin{cases} 2, & 0 < t < 1 \\ \frac{t^2}{2}, & 1 < t < \frac{\pi}{2} \\ \cos t, & t > \frac{\pi}{2} \end{cases}$$

2. Folosind transformata Laplace, rezolvați ecuațiile diferențiale:

(a) $y'' + 3y' + 2y = u(t - 1) - u(t - 2)$, știind $y(0) = 0, y'(0) = 0$;

(b) $y'' + 4y = \begin{cases} 8t^2, & 0 < t < 5 \\ 200, & t > 5 \end{cases}$, știind $y(1) = 1 + \cos 2$ și $y'(1) = 4 - 2 \sin 2$;

(c) $x''(t) - 2x'(t - 1) = t$, știind $x(0) = x'(0) = 0$;

(d) $y'' + 2y' - 2y = \begin{cases} 3 \sin t - \cos t, & 0 < t < 2\pi \\ 3 \sin 2t - \cos 2t, & t > 2\pi \end{cases}$, știind $y(0) = 1, y'(0) = 0$.

3. Folosind transformata Laplace, rezolvați ecuația integrală:

$$x(t) = t + 2 \int_0^t [t - \tau - \sin(t - \tau)] \cdot x(\tau) d\tau$$

Transformata Fourier

1. Determinați transformata Fourier a semnalului:

$$f(t) = (t + 2)e^{-(t+2)(3i+5)}, \quad t > 0.$$

2. Rezolvați ecuația integrală, folosind transformata Fourier:

$$\int_0^\infty f(t) \sin(\omega t) dt = \begin{cases} \frac{\pi}{2} \sin \omega, & \omega \in (0, \pi) \\ 0, & \omega \geq \pi \end{cases}$$

SEMINAR 9

SPATII DE PROBABILITATE

9.1 Notiuni teoretice

Trecem acum la studiul probabilităților într-un context mai abstract decât în liceu, unde se defineau și studiau evenimentele aleatoare concret.

Definiție 9.1: Se numește *spatiu (cîmp) discret de probabilitate* o mulțime finită sau numărabilă $\Omega = (\omega_n)_n$, împreună cu un sir $(p_n)_n$, cu $0 \leq p_n \leq 1$, care satisfac condiția $\sum_n p_n = 1$.

Orice submulțime $A \subseteq \Omega$ este un *eveniment*, căruia i se atașează o probabilitate

$$P(A) = \sum_{\omega_n \in A} p_n.$$

Intuitiv, putem privi elementele mulțimii Ω drept *experiente*, pe care le putem colecta în *evenimente*, iar p_n este probabilitatea ca o experiență să se realizeze.

Alte definiții elementare sunt următoarele:

Definiție 9.2: *Evenimentul sigur* este un eveniment care se realizează cu certitudine la fiecare repetare a experienței.

Evenimentul imposibil nu se produce la nicio efectuare a experienței.

Dat un eveniment $A \subseteq \Omega$, lui i se asociază *evenimentul contrar*, notat \overline{A} , C_A sau A^c , care constă în nerealizarea lui A .

Două evenimente $A, B \subseteq \Omega$ se numesc *compatibile* dacă se pot produce simultan și *incompatibile* în caz contrar.

Pentru evenimente incompatibile, avem o definiție alternativă, calculatorie:

Definiție 9.3: Dacă A și B sunt evenimente incompatibile, atunci:

$$P(A \cup B) = P(A) + P(B).$$

Mai general, pentru orice sir (A_n) de evenimente două cîte două incompatibile, avem:

$$P\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{n \in \mathbb{N}} P(A_n).$$

Definiția abstractă a contextului în care vom studia teoria probabilităților urmează.

Definiție 9.4: Se numește *spatiu de probabilitate* un triplet (Ω, \mathcal{K}, P) , unde Ω este o mulțime de evenimente elementare (individuale), \mathcal{K} este o submulțime a $\mathcal{P}(\Omega)$, iar $P : \mathcal{K} \rightarrow [0, 1]$ este o funcție de probabilitate, care satisface:

- $P(\Omega) = 1$;
- $P\left(\bigcup_{n \geq 0} A_n\right) = \sum_{n \geq 0} P(A_n)$, pentru orice sir (A_n) de evenimente două cîte două incompatibile.

Pornind de la această definiție generală, putem obține cazuri particulare cunoscute:

Definiția clasică a probabilității: Dacă Ω este o mulțime cu N elemente, putem defini un spațiu discret de probabilitate, definind $p_n = \frac{1}{N}$, pentru orice $n \in \{1, \dots, N\}$. În acest caz, probabilitățile sunt egale pentru toate evenimentele, deci spunem că *evenimentele sunt echiprobabile*. Pentru orice eveniment $A \subseteq \Omega$, avem:

$$P(A) = \frac{\text{card}(A)}{\text{card}(\Omega)},$$

care coincide cu definiția clasică a raportului dintre numărul cazurilor favorabile unui eveniment și numărul cazurilor posibile.

Probabilități geometrice: Dacă luăm $\Omega \subseteq \mathbb{R}^n$ o submulțime oarecare, pe care considerăm *măsura Lebesgue* (cea cu ajutorul căreia calculăm integralele), atunci obținem un spațiu de probabilitate definind pentru orice eveniment A probabilitatea prin:

$$P(A) = \frac{\mu(A)}{\mu(\Omega)},$$

unde μ este măsura Lebesgue din \mathbb{R}^n (în particular, e vorba de lungimea dl pe \mathbb{R} , aria $dA = dx dy$ din \mathbb{R}^2 etc.).

Următoarele sunt proprietăți elementare ale probabilităților:

Fie (Ω, \mathcal{K}, P) un spațiu de probabilitate.

- (1) Dacă $A, B \in \mathcal{K}$ și $A \subseteq B$, atunci $P(B - A) = P(B) - P(A)$;

(2) **Poincaré**: Fie n evenimente arbitrarie $A_1, \dots, A_n \in \mathcal{K}$. Atunci are loc:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{i \neq j} P(A_i \cap A_j) + \dots + (-1)^{n-1} P(A_1, \dots, A_n).$$

(3) Pentru orice sir crescător de evenimente $A_0 \subseteq A_1 \subseteq \dots \subseteq A_n \subseteq \dots$, avem:

$$P\left(\bigcup_{n \geq 0} A_n\right) = \lim_{n \rightarrow \infty} P(A_n).$$

Definiție 9.5: Evenimentele A și B se numesc *independente* dacă $P(A \cap B) = P(A) \cdot P(B)$.

În general, evenimentele A_1, \dots, A_n se numesc *independente în ansamblu* dacă pentru orice $m \geq n$ și $1 \leq j_1 \leq \dots \leq j_m \leq n$, avem:

$$P(A_{j_1} \cap \dots \cap A_{j_m}) = P(A_{j_1}) \cdots P(A_{j_m}).$$

Observație 9.1: Dacă avem n evenimente independente două câte două (cf. primei părți a definitiei de mai sus), nu rezultă neapărat că sunt evenimente în ansamblul lor (cf. părții a doua a definiției).

Un contraexemplu, datorat lui S. N. Bernstein este următorul. Considerăm un tetraedru omogen cu fețele colorate alb, negru, roșu, iar a patra, cu toate cele trei culori. Aruncăm acest corp și notăm cu A_i probabilitatea ca tetraedrul să se așeze (cu baza) pe față cu numărul $i \in \{1, 2, 3, 4\}$. Aceste evenimente sunt elementare și $P(A_i) = \frac{1}{4}, \forall i$. Acum fie $A = A_1 \cup A_2$, $B = A_1 \cup A_3$ și $C = A_1 \cup A_4$.

Atunci $P(A) = P(B) = P(C) = \frac{1}{2}$, deoarece pentru fiecare culoare sunt 4 cazuri posibile și 2 favorabile (față cu culoarea respectivă și față cu toate culorile).

În plus, avem:

$$P(A \cap B) = P(B \cap C) = P(C \cap A) = \frac{1}{4},$$

deci evenimentele sunt independente două câte două.

În plus, avem:

$$\begin{aligned} P(A \cap B \cap C) &= P(A_1) = \frac{1}{4} \\ P(A)P(B)P(C) &= \frac{1}{8}, \end{aligned}$$

deci evenimentele nu sunt independente în ansamblul lor.

Mai avem nevoie de următorul concept:

Definiție 9.6: Fie A și B două evenimente, cu $P(B) \neq 0$.

Probabilitatea lui A conditionată de B , notată $P(A|B)$ sau $P_B(A)$ se definește prin:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

De asemenea, în calcule, vom mai folosi:

Formula de înmulțire a probabilităților: Fie A_1, \dots, A_n evenimente. Atunci are loc:

$$P(A_1 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2/A_1) \cdot P(A_3/A_1 \cap A_2) \cdots P(A_n/A_1 \cap \dots \cap A_{n-1}).$$

Formula probabilității totale: Dacă avem descompunerea evenimentului sigur Ω în reuniunea de n evenimente incompatibile H_1, \dots, H_n , atunci pentru orice eveniment $A \in \mathcal{K}$, are loc:

$$P(A) = \sum_{i=1}^n P(A/H_i) \cdot P(H_i).$$

Formula lui Bayes: În contextul și cu notatiile de mai sus:

$$P(H_j/A) = \frac{P(A/H_j) \cdot P(H_j)}{\sum_{i=1}^n P(A/H_i) \cdot P(H_i)}.$$

În particular, pentru două evenimente A, B , avem:

$$\begin{aligned} P(A) &= P(A/B) \cdot P(B) + P(A/B^c) \cdot P(B^c) \\ P(B/A) &= \frac{P(A/B) \cdot P(B)}{P(A/B) \cdot P(B) + P(A/B^c) \cdot P(B^c)}. \end{aligned}$$

9.2 Exerciții

9.2.1 Calcul „clasic“

1. Într-un spațiu de probabilitate se consideră evenimentele A, B , cu:

$$P(A) = \frac{1}{3}, P(B) = \frac{1}{4}, P(A \cap B) = \frac{1}{6}.$$

Determinați $P(A^c)$, $P(A^c \cup B)$, $P(A \cup B^c)$, $P(A^c \cup B^c)$, $P(A^c \cap B^c)$.

2. Care dintre următoarele evenimente rezultate în urma aruncării cu zarul este mai probabil:

- (a) obținerea numărului 6 în cel puțin una din 4 aruncări;
- (b) obținerea cel puțin a unei duble de 6 în 24 aruncări cu 2 zaruri?

3. O urnă conține 12 bile numerotate de la 1 la 12. Să se determine probabilitatea ca bilele numerotate cu 5, 7, 11 să iasă la extragerile cu numărul de ordine 5, 7, 11.

Soluție: Cazurile posibile sunt $12!$ la număr.

Cazurile favorabile sunt $9!$, deoarece dacă fixăm de fiecare dată bilele cu numerele 5, 7, 11, rămân $9!$ libere.

$$\text{Rezultă } P = \frac{9!}{12!} = \frac{1}{1320}.$$

4. O urnă conține 50 bile, dintre care 10 sunt negre, iar restul albe. Se scot la întâmplare 5 bile. Care e probabilitatea ca între cele 5 bile să fie bile negre?

Indicație: Se calculează mai ușor probabilitatea evenimentului complementar.

5. Coeficienții întregi ai ecuației $ax^2 + bx + c = 0$ sunt obținuți prin aruncarea unui zar de 3 ori. Să se determine probabilitatea ca rădăcinile ecuației să fie reale.

$$\text{Indicație: Calculăm clasice probabilitatea ca } \frac{b^2}{4} \geq ac, \text{ unde } a, b, c \in \{1, 2, \dots, 6\}.$$

6. Într-o cameră întunecoasă se găsesc 5 perechi de pantofi. Se aleg la întâmplare 5 pantofi.

- (a) Care este probabilitatea ca între cei 5 pantofi aleși să fie cel puțin o pereche, în ipoteza că cele 5 perechi sunt identice (deci este suficient să avem un pantof stîng și unul drept)?
- (b) Care e probabilitatea ca între cei 5 pantofi aleși să fie cel puțin o pereche, dacă toate cele 5 perechi sunt distințe (culoare, număr)?

7. **Problema aniversării:** Într-o cameră sunt k persoane. Care este probabilitatea ca cel puțin două din aceste persoane să aibă aceeași zi de naștere, adică aceeași zi și lună a anului?

8. Se aruncă 3 zaruri. Calculați probabilitatea ca suma punctelor obținute să fie:

- (a) mai mică decât 8;
- (b) mai mare decât 7;
- (c) egală cu 12.

9. Un scafandru are 2 sisteme de oxigen independente. Presupunem că probabilitatea ca primul sistem să funcționeze este 0,9, iar probabilitatea ca al doilea sistem să funcționeze este 0,8.

- (a) Găsiți probabilitatea ca niciun sistem să nu se defecteze;
- (b) Găsiți probabilitatea ca cel puțin unul din sisteme să funcționeze.

Soluție: Fie $S_{1,2}$ evenimentul ca sistemul 1, 2 să funcționeze. (a) Cum evenimentele sunt independente, avem:

$$P(S_1 \cap S_2) = P(S_1) \cdot P(S_2) = 0,72.$$

(b)

$$P(S_1 \cup S_2) = P(S_1) + P(S_2) - P(S_1 \cap S_2) = 0,98.$$

9.2.2 Probabilități geometrice

10. Care este probabilitatea ca suma a 3 numere din intervalul $[0, a]$ alese la întâmplare să fie mai mare decât a ?

Soluție: Spațiul de probabilitate este $\Omega = [0, a]^3$. Evenimentul cerut este dat de punctele multimii:

$$E = \{(x, y, z) \in \Omega \mid x + y + z \geq a\}.$$

Alegem un sistem ortogonal de axe și Ω devine un cub de latură a situat în primul octant. În acest caz, E este una din regiunile lui Ω separate de planul $x + y + z = a$. Rezultă:

$$P(E) = \frac{a^3 - \frac{a^3}{2}}{a^3} = \frac{1}{2}.$$

11. Pe un plan orizontal considerăm un sistem de axe XOY și mulțimea E a punctelor cu coordonate întregi. O monedă cu diametrul $\frac{1}{2}$ este aruncată la întâmplare pe acest plan. Care e probabilitatea ca moneda să acopere un punct din E ?

Soluție: Fie $C(x_0, y_0)$ cel mai apropiat punct din E de centrul M al monedei, deci coordonatele lui M sunt de forma:

$$(x_0 + x, y_0 + y), \quad -\frac{1}{2} < x, y < \frac{1}{2}.$$

Spațiul de probabilitate este:

$$\Omega = \left\{ (x, y) \in \mathbb{R}^2 \mid -\frac{1}{2} < x, y < \frac{1}{2} \right\}.$$

Mulțimea evenimentelor favorabile este dată de:

$$A = \left\{ (x, y) \in \Omega \mid (x - x_0)^2 + (y - y_0)^2 < \frac{1}{16} \right\},$$

deoarece raza monedei este $\frac{1}{4}$.

Rezultă:

$$p = \frac{\text{aria}(A)}{\text{aria}(\Omega)} = \frac{\pi}{16}.$$

12. Se alege aleatoriu un număr real x în intervalul $[0, 3]$. Care este probabilitatea ca x să fie mai apropiat de 0 decât de 1?

Soluție: Interpretând problema geometric, ne putem gîndi la x ca fiind un punct pe axa reală. Atunci cazurile favorabile se află în segmentul $[0; 0,5]$, iar cazurile posibile sunt pe tot segmentul.

Probabilitatea, calculată cu formula geometrică, este dată de raportul lungimilor celor două segmente:

$$P = \frac{0,5}{3} = \frac{1}{6} \approx 17\%.$$

13. Se trage cu o săgeată la o ţintă circulară de rază r . Care este probabilitatea ca săgeata să ajungă mai aproape de centru decât de margine?

Soluție: Aria cercului, care ne dă și „cazurile posibile“, este πr^2 .

Cazurile favorabile se află în cercul concentric de rază $< \frac{r}{2}$, care are aria $\frac{\pi r^2}{4}$. Atunci:

$$P = \frac{1}{4}.$$

14. **Problema autobuzului (cu așteptare):** Să presupunem că ajungeți în stația de autobuz la o oră aleatorie din intervalul 12 și 1. Așteptați 20 minute în stație, iar dacă autobuzul nu vine, plecati. Același „program“ îl are și autobuzul, dar cu condiția că așteaptă 5 minute în stație, apoi pleacă.

Care este probabilitatea să prindeți autobuzul?¹

Soluție: Avem două variabile independente: momentul în care ajungeți în stație și momentul în care autobuzul ajunge. Deci putem modela problema bidimensional. Mai precis, să luăm un pătrat cu latura de 60 de unități (1/minut) și-i notăm laturile cu c și a („călător“ și „autobuz“).

Remarcăm că avem cazurile (cf. Figura 9.1):

- Pentru a prinde autobuzul la fix, ar trebui să ne situăm pe segmentul $a = c$;
- Cum autobuzul așteaptă 5 minute, de fapt putem să ne situăm în zona $c \leq a + 5$, *neînînd seama de faptul că și călătorul așteaptă (deocamdată)!*;
- Cum călătorul așteaptă 20 minute, ne situăm în zona $c \geq a - 20$ (*neînînd seama că și autobuzul așteaptă!*);
- Luînd toate restricțiile în considerare, ne interesează, de fapt, zona dintre cele două puncte anterioare, deci sub segmentul $c = a + 5$ și deasupra lui $c = a - 20$.

Acum trebuie doar să calculăm aria zonei corespunzătoare și să o împărțim la aria pătratului:

$$P = \frac{60^2 - \frac{55^2}{2} - \frac{40^2}{2}}{60^2} \approx 36\%.$$

15. Trei persoane aleg la întîmplare un număr real între 0 și 1. Care este probabilitatea ca suma pătratelor numerelor alese de ei să nu depășească 1?

Soluție: Pentru a modela problema geometric, e clar că o putem gîndi ca pe alegerea unui punct din cubul unitate, $(x, y, z) \in [0, 1]^3$. Cazurile posibile sunt, atunci, date de volumul cubului, care este 1.

¹Mai multe exemple și explicații puteți găsi, de exemplu, [aici](#).

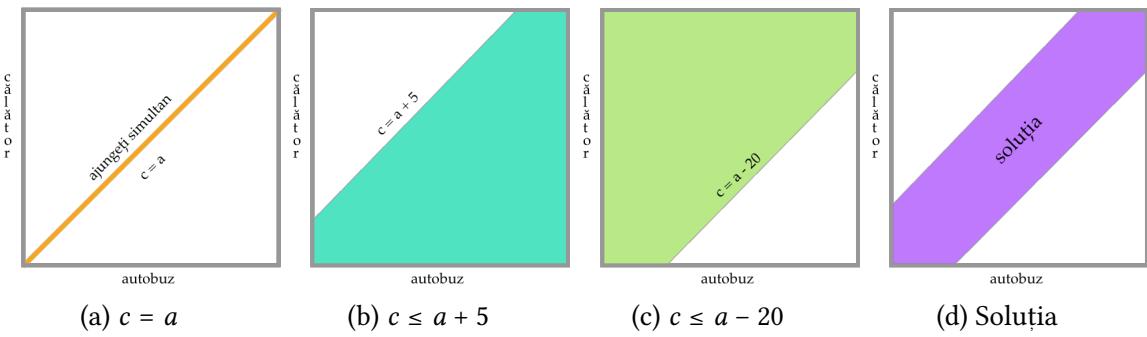


Figura 9.1: Problema autobuzului (cu așteptare)

Pentru cazurile favorabile, avem nevoie de $x^2 + y^2 + z^2 \leq 1$, care este sfera unitate. Dar, cum ne interesează doar alegerile de numere pozitive, i.e. partea din sferă care se găsește în interiorul cubului, adică $\frac{1}{8}$ din ea.

Avem, deci:

$$P = \frac{\frac{1}{8} \cdot \frac{4\pi \cdot 1^3}{3}}{1} \approx 52\%.$$

Mult mai multe exemple sofisticate de probabilități geometrice se pot găsi la [Wolfram MathWorld](#).

SEMINAR 10

SCHEME CLASICE DE PROBABILITATE

Schemele clasice de probabilitate sunt modele matematice care ne permit calculul probabilității de realizare a unui eveniment în cazul unor distribuții anume.

10.1 Schema lui Poisson

Schema lui Poisson se formulează astfel. Presupunem că avem n urne U_i , $1 \leq i \leq n$, care contin bile albe și bile negre în proporții cunoscute. Fie p_i probabilitatea de extragere a unei bile albe din urna U_i , respectiv q_i , probabilitatea de extragere a unei bile negre din urna U_i .

Extragem câte o bilă din fiecare urnă. Probabilitatea de a obține k bile albe este coeficientul lui X^k din polinomul:

$$\prod_{i=1}^n (p_i X + q_i) = (p_1 X + q_1)(p_2 X + q_2) \cdots (p_n X + q_n).$$

Observație: În cazul schemei lui Poisson, extragerea se face *fără revenire*. O bilă, după ce a fost extrasă, nu este repusă în urnă, astfel că, după fiecare extragere, numărul de bile din urnă scade.

Exemplu: Avem 3 sisteme de siguranță, primul funcționează cu probabilitatea de 80%, al doilea, de 70%, iar al treilea, în 90% din cazuri. Să se determine probabilitatea ca oricare două dintre sisteme să funcționeze simultan.

Soluție: Ne aflăm în cazul schemei lui Poisson, „bilele“ fiind sistemele de siguranță, iar „extragerea“ înseamnă funcționarea lor. Așadar, căutăm coeficientul lui X^2 din polinomul:

$$\pi = (0,8 \cdot X + 0,2)(0,7 \cdot X + 0,3)(0,9 \cdot X + 0,1),$$

coeficient care este $p = 0,398$.

10.2 Schema lui Bernoulli (binomială)

Situatia este similară cu cea din cazul Poisson, doar că acum extragerile se fac *cu repunere*. Adică, după ce fiecare bilă este extrasă și se înregistrează culoarea sa, este repusă în urnă, pentru a putea fi extrasă din nou, eventual.

Așadar, schema lui Bernoulli se formulează astfel. Avem o urnă cu a bile albe și b bile negre. Extragem cu repunere n bile. Probabilitatea să extragem k bile albe, cu $0 \leq k \leq n$ este dată de:

$$p(n, k) = C_n^k p^k q^{n-k}, \quad \text{unde } p = \frac{a}{a+b}, q = \frac{b}{a+b}.$$

De remarcat că în acest caz, p corespunde evenimentului favorabil, iar $q = 1 - p$.

Exemplu: Se aruncă două zaruri de 10 ori. Care este probabilitatea să se obțină de exact 4 ori suma 7?

Soluție: Ne aflăm în cazul schemei lui Bernoulli, unde „bilele“ sunt sumele de pe zaruri, iar „extragerea“ este aruncarea zarului. Evident, modelul potrivit este acela al extragerii cu revenire, deoarece orice sumă poate fi obținută la fiecare aruncare.

În acest caz, avem $p = \frac{1}{6}$, deoarece suma 7 poate fi obținută în 6 moduri din punctele de pe două zaruri, iar cazurile posibile sunt 36. Rezultă $q = \frac{5}{6}$.

În plus, avem $n = 10$, $k = 4$, deci:

$$p(10, 4) = C_{10}^4 \frac{1}{6^4} \cdot \frac{5^6}{6^6}.$$

10.3 Schema multinomială

Schema lui Bernoulli se mai numește *schema binomială*, deoarece $p(n, k)$ este, de fapt, coeficientul lui X^k din dezvoltarea binomului $(pX + q)^n$.

O generalizare a acestei situații este *schema multinomială*, în care presupunem că avem o urnă cu bile de $s \in \mathbb{N}$ culori și se extrag cu repunere n bile. Probabilitatea de a extrage k_i bile de culoare i , cu $1 \leq i \leq s$ este dată de formula:

$$p(n; k_1, \dots, k_s) = \frac{n!}{k_1! k_2! \cdots k_s!} \cdot p_1^{k_1} \cdot p_2^{k_2} \cdots p_s^{k_s},$$

unde $n = k_1 + \cdots + k_s$ și $p_1 + \cdots + p_s = 1$, iar p_i este probabilitatea de a extrage o bilă de culoare i .

Exemplu: Se aruncă cu un zar de 10 ori. Care este probabilitatea ca exact de 2 ori să apară față cu 1 punct și de 3 ori să apară față cu 2 puncte?

Soluție: Evident, suntem în cazul schemei multinomiale. „Culorile“ sunt punctele de pe zaruri și vrem să „extragem 2 bile de culoarea 1 și 3 bile de culoarea 2“.

Atunci $n = 10$, deoarece facem 10 „extrageri“, $k_1 = 2$ și $k_2 = 3$. În plus, avem $p_1 = p_2 = \frac{1}{6}$, deoarece orice număr de pe zar are aceeași probabilitate de a apărea. Rezultă, de asemenea, că avem nevoie și de $k_3 = n - k_1 - k_2 = 5$ și $p_3 = 1 - p_1 - p_2 = \frac{2}{3}$.

Probabilitatea cerută este:

$$p(10; 2, 3, 5) = \frac{10!}{2! \cdot 3! \cdot 5!} \cdot \frac{1}{6^2} \cdot \frac{1}{6^3} \cdot \frac{2^5}{3^5}.$$

10.4 Schema geometrică

Dintr-o urnă cu a bile albe și b bile negre, extragem fără repunere n bile, cu $n \leq a + b$. Probabilitatea de a obține $k \leq a$ bile albe, *fără repunere*, este dată de:

$$p_{a,b}^{k,n-k} = \frac{C_a^k \cdot C_b^{n-k}}{C_{a+b}^n}.$$

Mai general, dacă avem a_i bile de culoarea i , $1 \leq i \leq s$ și extragem n bile fără repunere, atunci probabilitatea de a extrage k_i , cu $k_1 + \dots + k_s = n$ bile de culoarea i este dată de formula:

$$p_{a_1, \dots, a_s}^{k_1, \dots, k_s} = \frac{C_{a_1}^{k_1} \cdots C_{a_s}^{k_s}}{C_{k_1 + \dots + k_s}^n}.$$

Exemplu: Avem un lot de 100 articole, dintre care 80 sunt corespunzătoare, 15 sunt cu defecțiuni remediable și 5 rebuturi. Alegem 6 articole. Care este probabilitatea ca dintre acestea, 3 să fie bune, 2 cu defecțiuni remediable și un rebut?

Soluție: Presupunem că extragerile se fac cu repunere. Atunci suntem în cazul schemei multinomiale, deci:

$$p(6; 3, 2, 1) = \frac{6!}{3! \cdot 2! \cdot 1!} \left(\frac{80}{100}\right)^3 \cdot \left(\frac{15}{100}\right)^2 \cdot \left(\frac{5}{100}\right)^1.$$

Dacă extragerile se fac fără repunere, ne aflăm în cazul schemei geometrice și avem:

$$p_{80,15,5}^{3,2,1} = \frac{C_{80}^3 \cdot C_{15}^2 \cdot C_5^1}{C_{100}^6}.$$

10.5 Exerciții

1. Un lot de 50 de procesoare conține 3 defecte. Alegem la întâmplare 10, simultan, și le verificăm. Care este probabilitatea ca 2 să fie defecte?

Indicație: Schema geometrică (fără repunere).

2. (a) Un semnal este transmis pe 3 canale diferite, iar probabilitățile de recepționare corectă sunt 0,9; 0,8 și 0,7. Care este probabilitatea să se recepționeze corect un semnal?

(b) Dar dacă semnalul este transmis pe un canal ales la întâmplare și presupunem că orice canal poate fi ales cu aceeași probabilitate?

Indicație: (a) Schema lui Poisson.

(b) Formula probabilității totale: $\frac{1}{3} \cdot (0,9 + 0,8 + 0,7)$.

3. O urnă conține 2 bile albe și 3 bile negre. Alegem la întâmplare 2 bile, fără repunere. Care este probabilitatea ca acestea să fie ambele negre?

Dar dacă extragerea se face cu repunere?

4. Se testează 5 dispozitive care funcționează în condiții identice, independent și cu randament de 0,9 fiecare. Care este probabilitatea ca exact două să funcționeze?

Indicație: Schema Bernoulli.

5. Se consideră 3 urne: U_1 , care conține 5 bile albe și 5 negre, U_2 , care conține 4 bile albe și 6 negre și U_3 , care conține 4 bile albe și 5 negre. Din fiecare urnă se extrag cu repunere cîte 5 bile.

Care este probabilitatea ca din 2 urne să obținem cîte 2 bile albe și 3 negre, iar din a treia urnă să obținem o altă combinație?

Indicație: Schema Poisson sau Bernoulli, după cazuri (cu/fără repunere).

6. Se consideră urnele din problema precedentă. Din fiecare urnă se extrage cîte o bilă. Dacă se repetă experiența de 5 ori, care este probabilitatea ca de 3 ori să se obțină o bilă albă și 2 negre?

Indicație: Schema Poisson.

7. Fie 8 canale de transmisie a informației care funcționează independent. Presupunem că un canal este activ cu probabilitatea $1/3$.

Să se calculeze probabilitatea ca la un moment dat să fie mai mult de 6 canale active.

Indicație: Schema Bernoulli.

8. Șase vînători au zărit o vulpe și au tras simultan. Presupunem că de la distanță de la care au tras, fiecare vînător nimerește în mod obișnuit vulpea cu o probabilitate de $\frac{1}{3}$. Aflați probabilitatea ca vulpea să fie nimerită.

9. Se aruncă o monedă de 8 ori. Aflați probabilitatea ca stema să apară de 6 ori. Aflați probabilitatea ca stema să apară de *cel puțin* 6 ori.

10. Un muncitor produce piese astfel încît 99% sănt bune, 7% au defecte remediable și 3% sănt rebuturi.

Se alege aleatoriu 3 piese produse de muncitor. Care este probabilitatea ca dintre aceste 3 piese, cel puțin una să fie bună și cel puțin una să fie rebut?

SEMINAR 11

VARIABILE ALEATOARE

11.1 Cazul discret

Variabilele aleatoare sunt moduri de reprezentare a informației în calculul probabilităților, precum matricele ne pot ajuta să „codificăm” informații geometrice sau algebrice. De obicei, ele se reprezintă asemenea permutărilor, anume ca tablouri bidimensionale.

Începem cu definițiile fundamentale.

Definiție 11.1: O variabilă a cărei valoare se determină de un eveniment rezultat în urma unei experiențe se numește *variabilă aleatoare*.

Definiție 11.2: Fie X o variabilă aleatoare care poate lua valorile x_1, \dots, x_n , cu probabilitățile $f(x_1), \dots, f(x_n)$. Multimea de perechi ordonate $\{(x_i, f(x_i))\}_i$ definește *repartiția* variabilei aleatoare.

Mai general, dacă X este o variabilă aleatoare reală (adică $\text{Im}f \subseteq \mathbb{R}$), atunci funcția $F : \mathbb{R} \rightarrow \mathbb{R}$ definită prin:

$$F_X(x) = P(X < x), \forall x \in \mathbb{R}$$

se numește *funcția de repartiție* a variabilei aleatoare X .

Putem interpreta funcția de repartiție în sensul următor: calculată în x , ea ne dă probabilitatea ca valorile variabilei aleatoare să fie pînă în x .

Se poate vedea din definiție că au loc următoarele *proprietăți*:

- (1) $\lim_{x \rightarrow -\infty} F_X(x) = 0$, iar $\lim_{x \rightarrow \infty} F_X(x) = 1$;
- (2) F_X este crescătoare (deoarece acumulează) și este continuă la dreapta în orice punct $x \in \mathbb{R}$;
- (3) $P(X = x) = F(x) - F(x - 0)$, unde $F(x - 0)$ notează limita la stînga

$$\lim_{x_0 \nearrow x} F(x_0).$$

$$(4) \quad P(a < X \leq b) = F(b) - F(a).$$

Ne vor interesa două cazuri, anume acelea ale variabilelor aleatoare continue și discrete, pe care le definim mai jos.

Definiție 11.3: Variabila aleatoare X se numește *discretă* dacă multimea valorilor ei este o multime cel mult numărabilă de numere reale sau complexe (în bijecție cu o submulțime [nestrictă] a lui \mathbb{N}), $\{a_n\}_n$.

În acest caz, dacă $P(X = a_n) = p_n$, atunci condiția de normare este $\sum p_n = 1$, iar funcția de repartitie F_X este o funcție în scară, cu:

$$F_X(x) = \sum_{a_n < x} p_n.$$

În acest caz, putem reprezenta variabila aleatoare într-o formă matriceală:

$$X \sim \begin{pmatrix} a_0 & a_1 & \dots & a_n & \dots \\ p_0 & p_1 & \dots & p_n & \dots \end{pmatrix},$$

matrice care se numește *matricea de repartitie* a lui X sau *distribuția* sa.

Cazul continuu este definit mai jos.

Definiție 11.4: Dacă $P(X = x) = 0$, pentru orice $x \in \mathbb{R}$, atunci variabila aleatoare X se numește *continuă*. Echivalent, funcția ei de repartitie este o funcție reală continuă (v. proprietatea (3)).

În multe situații, vom lucra cu variabile aleatoare discrete, reprezentate matriceal. Va fi util să definim cîteva operații elementare între aceste obiecte.

Fie, aşadar, două variabile aleatoare discrete:

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}, \quad Y : \begin{pmatrix} y_j \\ q_j \end{pmatrix}$$

Definim $p_{ij} = P(X = x_i, Y = y_j)$, $\forall i, j$. Atunci au loc formulele de calcul:

$$\begin{aligned} p_i &= \sum_j p_{ij} \\ q_j &= \sum_i p_{ij} \\ 1 &= \sum_{i,j} p_{ij}. \end{aligned}$$

Variabilele X și Y se numesc **independente** dacă $p_{ij} = p_i \cdot q_j$.

Suma variabilelor are repartitia:

$$X + Y : \begin{pmatrix} x_i + y_j \\ p_{ij} \end{pmatrix}.$$

Dacă $\alpha \in \mathbb{R}$ este o constantă reală, atunci variabila $X + \alpha$ are repartiția:

$$X + \alpha : \begin{pmatrix} x_i + \alpha \\ p_i \end{pmatrix}.$$

Produsul variabilelor X și Y are repartiția:

$$XY : \begin{pmatrix} x_i y_j \\ p_{ij} \end{pmatrix}$$

Produsul αX , pentru $\alpha \in \mathbb{R}$ are repartiția:

$$\alpha X : \begin{pmatrix} \alpha x_i \\ p_i \end{pmatrix}.$$

Să vedem un exemplu de calcul:

Exemplu: Se dau variabilele independente:

$$X : \begin{pmatrix} 0 & 1 & 2 \\ 0,2 & 0,4 & 0,4 \end{pmatrix}, \quad Y : \begin{pmatrix} 1 & 2 \\ 0,6 & 0,4 \end{pmatrix}.$$

Determinați repartițiile variabilelor $X + Y, XY, 2 + X, X^2, 3Y$.

Soluție: Vom prezenta repartițiile punând valorile pentru evenimente în ordine crescătoare.
De exemplu, $X + Y$ poate lua valorile 1, 2, 3, 4, iar X^2 poate lua valorile 0, 1, 4.

Folosim independenta și formulele de calcul pentru probabilități și obținem, de exemplu:

$$\begin{aligned} P(X + Y = 1) &= P(X = 0 \wedge Y = 1) \\ &= P(X = 0) \cdot P(Y = 1) \\ &= 0,12 \end{aligned}$$

$$\begin{aligned} P(X + Y = 2) &= P((X = 0 \wedge Y = 2) \vee (X = 1 \wedge Y = 1)) \\ &= P(X = 0 \wedge Y = 2) + P(X = 1 \wedge Y = 1) \\ &= 0,32 \end{aligned}$$

Similar se calculează și celelalte valori și, folosind definițiile operațiilor, obținem:

$$\begin{aligned} X + Y &: \begin{pmatrix} 1 & 2 & 3 & 4 \\ 0,12 & 0,32 & 0,4 & 0,16 \end{pmatrix} \\ XY &: \begin{pmatrix} 0 & 1 & 2 & 4 \\ 0,2 & 0,24 & 0,4 & 0,6 \end{pmatrix} \\ 2 + X &: \begin{pmatrix} 2 & 3 & 4 \\ 0,2 & 0,4 & 0,4 \end{pmatrix} \\ X^2 &: \begin{pmatrix} 0 & 1 & 4 \\ 0,2 & 0,4 & 0,4 \end{pmatrix} \\ 3Y &: \begin{pmatrix} 3 & 6 \\ 0,6 & 0,4 \end{pmatrix} \end{aligned}$$

Pentru studiul variabilelor aleatoare se folosesc mai multe mărimi, pe care le introducem, pe rînd.

Definiție 11.5: Fie X o variabilă aleatoare discretă.

(1) Dacă seria $\sum_{n \geq 0} x_n p_n$ este absolut convergentă, atunci spunem că X admite medie, iar numărul:

$$E(X) = \sum_{n \geq 0} x_n p_n$$

se numește *media* lui X ;

- (2) Pentru $n \neq 0$, media $E(X^n)$ a variabilei X^n se numește *momentul de ordinul n* al lui X ;
(3) Media variabilei $(X - E(X))^2$ se numește *varianță* sau *dispersia* lui X , notată $\text{Var}(X)$ sau $D^2(X)$.

Funcția de medie are următoarele proprietăți esențiale:

- (a) **Liniaritatea:** $E(\alpha X + \beta Y) = \alpha E(X) + \beta E(Y)$, pentru orice $\alpha, \beta \in \mathbb{C}$;
(b) **Monotonie:** Dacă $X \leq Y$, atunci $E(X) \leq E(Y)$;
(c) Dacă X este o constantă c , atunci $E(X) = c$;
(d) Dacă X și Y sunt variabile aleatoare independente, adică descriu evenimente independente, atunci $E(XY) = E(X) \cdot E(Y)$.

Funcția de dispersie are proprietățile:

- (a) $D^2(X) = E(X^2) - (E(X))^2$;

- (b) $D^2(X) \geq 0$;
- (c) $D^2(X) = 0 \iff P(X = E(X)) = 1$, adică X este o constantă cu probabilitatea 1 (X descrie doar evenimentul sigur);
- (d) **Cebîșev:** Pentru orice $\varepsilon > 0$, are loc:

$$P(|X - E(X)| \geq \varepsilon) < \frac{D^2(X)}{\varepsilon^2}.$$

Echivalent, se mai poate scrie:

$$P(|X - E(X)| < \varepsilon) \geq 1 - \frac{D^2(X)}{\varepsilon^2}.$$

- (e) $D^2(\alpha X) = \alpha^2 D^2(X)$, pentru orice $\alpha \in \mathbb{C}$;
- (f) Dacă X și Y sunt independente, atunci:

$$D^2(X + Y) = D^2(X) + D^2(Y).$$

Mai definim două mărimi care se asociază variabilelor aleatorii.

Definiție 11.6: Fie X și Y două variabile aleatoare. Numim covarianță a variabilelor X și Y , notată $\text{cov}(X, Y)$ numărul:

$$\text{cov}(X, Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y).$$

Proprietățile esențiale ale covarianței sunt date de:

- (a) Dacă X și Y sunt variabile aleatoare independente, atunci $\text{cov}(X, Y) = 0$;
- (b) Dacă X_1, \dots, X_n sunt variabile aleatoare cu dispersiile D_i^2 și covariantele $\text{cov}(X_i, X_j)$, $i \neq j$, atunci are loc:

$$D^2\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D_i^2 + 2 \sum_{i < j} \text{cov}(X_i, X_j).$$

Definiție 11.7: Dacă X și Y sunt variabile aleatoare, se numește coeficient de corelație al lor, notat $\rho(X, Y)$, numărul calculat prin:

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{D^2(X) \cdot D^2(Y)}}$$

Se poate vedea din definiție că, atât covarianța, cât și corelația arată „gradul de independentă“ a variabilelor aleatoare X și Y . Într-adevăr, dacă X și Y sunt independente, atunci avem $\rho(X, Y) = 0$. Afirmația reciprocă este, însă, falsă!

Să luăm un exemplu: Fie $A = \{a_1, a_2, a_3, a_4\}$, cu $P(a_i) = \frac{1}{4}$.

Presupunem că variabila aleatoare X realizează corespondența:

$$X(a_1) = 1, X(a_2) = -1, X(a_3) = 2, X(a_4) = -2.$$

Atunci, ea are matricea de repartitie:

$$X \sim \begin{pmatrix} -2 & -1 & 1 & 2 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}.$$

Presupunem că o altă variabilă aleatoare Y realizează corespondența:

$$Y(a_1) = 1, Y(a_2) = 1, Y(a_3) = -1, Y(a_4) = -1.$$

Atunci matricea ei se poate reduce la:

$$Y \sim \begin{pmatrix} -1 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}.$$

Produsul celor două variabile aleatoare are matricea de repartitie:

$$XY : \begin{pmatrix} -2 & -1 & 1 & 2 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}.$$

Rezultă că $E(X) = E(Y) = E(XY)$, deci $\text{cov}(X, Y) = 0$. Însă putem observa că X și Y nu sunt independente. Într-adevăr, avem:

$$P(X = 1 \wedge Y = 1) = P(a_1) = \frac{1}{4} \neq P(X = 1) \cdot P(Y = 1) = \frac{1}{4} \cdot \frac{1}{2}.$$

În fine, o altă noțiune de care avem nevoie este *funcția generatoare*.

Definiție 11.8: Fie X o variabilă aleatoare discretă care ia valori naturale.

Funcția $G_X(t)$, definită prin:

$$G_X(t) = E(t^X) = \sum_{n \geq 0} p_n t^n,$$

cu $t \leq 1$ și $p_n = P(X = n)$ se numește *funcția generatoare* a variabilei aleatoare X .

Funcția generatoare codifică, de fapt, în coeficienții unei serii formale, repartitia unei variabile aleatoare. Ea are următoarele proprietăți:

(a) Dacă avem variabilele aleatoare independente X_1, \dots, X_n , iar $X = X_1 + \dots + X_n$, atunci:

$$G_X(t) = G_{X_1}(t) \cdots G_{X_n}(t);$$

(b) $E(X) = G'_X(1)$;

(c) $D^2(X) = G''_X(1) + G'_X(1) - [G'_X(1)]^2$;

(d) Două variabile aleatoare cu aceeași funcție generatoare au aceeași repartitie.

11.2 Exemple de repartiții discrete

Vom regăsi acum, în contextul teoriei variabilelor aleatoare, scheme clasice de probabilitate.

11.2.1 Repartiția binomială (Bernoulli)

Presupunem că se fac n experiențe independente, în fiecare din experiențe, probabilitatea de realizare a unui eveniment A fiind constantă și egală cu p (rezultă că probabilitatea ca A să nu se realizeze este $q = 1 - p$).

Numărul de realizări ale evenimentului A în cele n experiențe se constituie ca o variabilă aleatoare X , ale cărei valori posibile sunt $k = 0, 1, \dots, n$, în funcție de câte din experiențe realizează A . Așadar, avem $P(X = k) = p_k$.

Când considerăm fiecare k , cu probabilitatea sa de realizare, mulțimea perechilor (k, p_k) , $k \in \{0, 1, \dots, n\}$ se numește *repartiție binomială* sau *repartiție Bernoulli*.

Pentru acestea, valorile principalelor parametri sunt:

- $P(X = k) = C_n^k p^k q^{n-k}$, $k \in \{0, 1, \dots, n\}$;
- $E(X) = np$;
- $D^2(X) = npq$;
- $G_X(t) = (pt + q)^n$.

Observație: Pentru $n \rightarrow \infty$, $p \rightarrow 0$, astfel încât $np = \lambda$, probabilitățile $P(X = k)$ pot fi approximate prin valorile repartiției Poisson (vezi mai jos).

11.2.2 Repartiția geometrică

Fie X numărul de experimente de tip Bernoulli, cu probabilitatea p de succes, care trebuie repetate pînă la apariția primului succes. Atunci:

- $P(X = k) = p(1 - p)^{k-1}$, $k \in \mathbb{N}^*$;

- $E(X) = \frac{1}{p};$
- $D^2(X) = \frac{1-p}{p^2};$
- $G_X(t) = \frac{pt}{1-qt}.$

11.2.3 Repartiția binomial negativă

Fie X numărul de experimente de tip Bernoulli cu probabilitatea de succes p care trebuie efectuate pentru a obține m succese. Atunci:

- $P(X = n) = C_{n-1}^{m-1} p^m q^{n-m}$ (pentru $m = 1$, găsim repartiția geometrică);
- $E(X) = \frac{m}{p};$
- $D^2(X) = \frac{mq}{p^2};$
- $G_X(t) = \frac{p^m t^m}{(1-qt)^m}.$

11.2.4 Repartiția hipergeometrică

Fie X o variabilă aleatoare care reprezintă numărul de bile albe obținute după n extrageri fără repunere dintr-o urnă ce conține a bile albe și b bile negre. Atunci avem:

- $P(X = x) = \frac{C_a^x C_b^{n-x}}{C_{a+b}^n}, 0 \leq x \leq n;$
- $E(X) = np;$
- $D^2(X) = xpq \cdot \frac{a+b-x}{a+b-1}$, unde $p = \frac{a}{a+b}$, iar $q = 1-p = \frac{b}{a+b}.$

11.2.5 Repartiția Poisson

Repartiția Poisson se caracterizează printr-un parametru $\lambda > 0$ (v. repartiția binomială [Bernoulli] mai sus). Avem:

- $P(X = n) = \frac{\lambda^n}{n!} \cdot e^{-\lambda}, n \in \mathbb{N};$
- $E(X) = \lambda;$

- $D^2(X) = \lambda$;
- $G_X(t) = e^{\lambda(t-1)}$.

11.3 Cazul continuu

Definiție 11.9: Variabila aleatoare X se numește *absolut continuă* dacă există o funcție integrabilă $f : \mathbb{R} \rightarrow \mathbb{R}_+$ astfel încât funcția de repartiție $F(x)$ a lui X să fie dată de:

$$F(x) = \int_{-\infty}^x f(t)dt.$$

În acest caz, f se numește *densitatea de probabilitate* a lui X .

Ca în cazul discret, avem următoarele proprietăți esențiale:

- (a) Funcția f este pozitivă și are loc condiția de normare

$$\int_{-\infty}^{\infty} f(x)dx = 1.$$

- (b) În orice punct de continuitate a lui f , avem $F'(x) = f(x)$;

(c) $P(a \leq X \leq b) = \int_a^b f(x)dx$;

(d) $E(X) = \int_{-\infty}^{\infty} xf(x)dx$;

- (e) Dacă X are densitatea X , iar $Y = aX + b$ este o altă variabilă aleatoare, cu $a, b \in \mathbb{R}, a \neq 0$, atunci Y are densitatea:

$$f_Y(x) = \frac{1}{|a|}f\left(\frac{x-b}{a}\right).$$

Definiție 11.10: Pentru orice variabilă aleatoare X , funcția:

$$\varphi_X(t) = E(e^{itX})$$

se numește *funcția caracteristică* a lui X .

Funcția caracteristică joacă un rol similar funcției generatoare din cazul discret. Astfel, ea are următoarele proprietăți:

- (a) Dacă X_1, \dots, X_n sunt variabile aleatoare independente, iar $X = X_1 + \dots + X_n$, atunci:

$$\varphi_X(t) = \prod_{k=1}^n \varphi_{X_k}(t);$$

(b) Dacă X admite moment de ordinul n , atunci:

$$E(X^k) = \frac{\varphi_X^{(k)}(0)}{i^k}, \quad 1 \leq k \leq n;$$

(c) Două variabile aleatoare cu aceeași funcție caracteristică au aceeași repartiție;

(d) Dacă X este discretă, atunci obținem:

$$\varphi_X(t) = \sum_n e^{ita_n} p_n;$$

(e) Dacă X are densitatea de repartiție $f(x)$, atunci:

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx,$$

iar în punctele de continuitate ale lui f , are loc relația:

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi_X(t) dt.$$

În continuare, prezentăm cele mai cunoscute repartiții absolut continue.

11.4 Repartiții absolut continue

11.4.1 Repartiția normală (gaussiană)

Dată media m și abaterea pătratică σ , repartiția variabilei aleatoare X are densitatea:

$$f(x) = \frac{1}{\sigma \sqrt{2\pi}} \cdot e^{-\frac{(x-m)^2}{2\sigma^2}}.$$

În acest caz, se mai notează $X \sim N(m, \sigma)$.

Pentru cazul particular $m = 0$ și $\sigma = 1$, X se numește *variabilă aleatoare standard*.

Funcția caracteristică este dată de $\varphi_X(t) = e^{imt - \frac{\sigma^2 t^2}{2}}$.

Pentru cazul variabilelor normale standard, funcția de repartiție are o formă particulară și se numește *funcția lui Laplace* (eng. CDF, *Cumulative Distribution Function*):

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$$

Observație: Valorile funcției Laplace sunt tabelate și, de obicei, se dau în probleme.

În general, dacă avem o variabilă aleatoare normală de tip $N(m, \sigma)$, atunci funcția ei de repartiție F se poate obține din funcția lui Laplace în forma:

$$F(x) = \Phi\left(\frac{x - m}{\sigma}\right).$$

Așadar, avem:

$$P(a \leq X \leq b) = \Phi\left(\frac{b - m}{\sigma}\right) - \Phi\left(\frac{a - m}{\sigma}\right), \quad (11.1)$$

de unde putem obține mai departe:

$$P(|X - m| < \varepsilon\sigma) = \Phi(\varepsilon) - \Phi(-\varepsilon) = 2\Phi(\varepsilon) - 1.$$

11.4.2 Repartiția uniformă

Pentru un interval $[a, b]$, densitatea de repartiție este:

$$f(x) = \begin{cases} \frac{1}{b - a}, & a \leq x \leq b \\ 0, & \text{în rest} \end{cases}.$$

În acest caz, avem media $E(X) = \frac{a + b}{2}$ și $D^2(X) = \frac{(b - a)^2}{12}$.

11.4.3 Repartiția exponentială

Dat un parametru $\lambda > 0$, repartiția exponentială are densitatea:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}.$$

Pentru aceasta, avem:

- $E(X) = \frac{1}{\lambda};$
- $D^2(X) = \frac{1}{\lambda^2};$
- $\varphi_X(t) = \left(1 - \frac{it}{\lambda}\right)^{-1}.$

11.4.4 Repartiția Gamma

Dati parametrii $\lambda, p > 0$, densitatea variabilei aleatoare de repartitie Gamma este:

$$f(x) = \begin{cases} \frac{\lambda^p}{\Gamma(p)} x^{p-1} e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases},$$

unde Γ este funcția lui Euler. În acest caz, avem:

- $E(X) = \frac{p}{\lambda};$
- $D^2(X) = \frac{p}{\lambda^2};$
- $\varphi_X(t) = \left(1 - \frac{it}{\lambda}\right)^{-p}.$

Din repartitia Gamma, putem obtine alte cîteva cazuri particulare:

- pentru $p = 1$, se obtine repartitia exponentișală;
- pentru $\lambda = \frac{1}{2}, p = \frac{n}{2}$, se obtine repartitia numită *hi pătrat*, cu n grade de libertate, notată $\chi^2(n)$.

11.4.5 Repartiția Cauchy

Aceasta are densitatea $f(x) = \frac{1}{\pi(1+x^2)}$.

În acest caz, X nu admite valoare medie.

11.5 Exerciții rezolvate

1. Doi parteneri egal cotați boxează 12 runde. Probabilitatea ca oricare dintre ei să cîștige o rundă este 50%. Să se calculeze valoarea medie, dispersia și abaterea medie pătratică a variabilei aleatoare care reprezintă numărul de runde cîștigate de unul din parteneri.

Soluție: Variabila aleatoare are o distribuție binomială. Astfel, avem:

- $P(X = k) = C_{12}^k \frac{1}{2^k} \cdot \frac{1}{2^{12-k}};$
- $E(X) = np = 12 \cdot \frac{1}{2};$

- $D^2(X) = npq = 12 \cdot \frac{1}{2} \cdot \frac{1}{2} = 3;$

- $D(X) = \sqrt{D^2(X)} = \sqrt{3}.$

2. La o agenție de turism s-a constatat că 5% dintre persoanele care au făcut rezervări renunță. Se presupune că s-au făcut 100 de rezervări pentru un hotel cu 95 locuri. Care este probabilitatea ca toate persoanele ce se prezintă la hotel să aibă loc?

Soluție: Fie X variabila aleatoare corespunzătoare numărului de persoane care se prezintă la hotel. X urmează o repartiție binomială, cu $n = 100$ și $p = 0,95$. Atunci avem:

$$P(X \leq 95) = 1 - P(X > 95) = 1 - \sum_{k=96}^{100} C_{100}^k (0,95)^{100-k} \cdot (0,05)^k.$$

3. La examenul de matematică, probabilitatea ca o teză să fie notată cu notă de trecere este 75%. Se aleg la întâmplare 10 lucrări. Fie X variabila aleatoare ce reprezintă numărul tezelor ce vor fi notate cu notă de trecere. Calculați:

- (a) repartitia lui X ;
- (b) $E(X), D^2(X)$;
- (c) $P(X \geq 5), P(7 \leq X \leq 10/X \geq 8), P(X = 10)$;
- (d) funcția caracteristică a lui X .

Soluție: (a) Avem o variabilă aleatoare cu repartiție binomială și $n = 10, p = 0,75$. Atunci X ia valorile $x \in \{0, 1, \dots, 10\}$ cu probabilitățile corespunzătoare distribuției binomiale, deci:

$$p(x) = C_{10}^x (0,75)^x \cdot (0,25)^{10-x}.$$

(b) Conform formulelor de calcul, avem:

$$\begin{aligned} E(X) &= np = 10 \cdot 0,75 = 7,5 \\ D^2(X) &= npq = 10 \cdot 0,75 \cdot 0,25 = 1,875. \end{aligned}$$

(c)

$$P(X \geq 5) = \sum_{x=5}^{10} C_{10}^x (0,75)^x \cdot (0,25)^{10-x}$$

Pentru $P(7 \leq X \leq 10/X \geq 8)$ avem un *eveniment condiționat*. Dacă A și B sunt două evenimente, amintim că probabilitatea $P(A/B)$, adică probabilitatea evenimentului A condiționat de evenimentul prealabil B este:

$$P(A/B) = \frac{P(A \cap B)}{P(B)}.$$

Atunci, obținem:

$$\begin{aligned}
 P(7 \leq X \leq 10/X \geq 8) &= \frac{P(8 \leq X \leq 10)}{P(X \geq 8)} \\
 &= \frac{\sum_{x=8}^{10} C_{10}^x (0,75)^x (0,25)^{10-x}}{\sum_{x=8}^{10} C_{10}^x (0,75)^x (0,25)^{10-x}} \\
 &= 1
 \end{aligned}$$

În fine:

$$P(X = 10) = C_{10}^{10} (0,75)^x (0,25)^0.$$

(d) Calculăm succesiv:

$$\begin{aligned}
 \varphi_X(t) &= E(e^{itX}) \\
 &= \sum_{x=0}^{10} e^{itx} C_{10}^x (0,75)^x (0,25)^{10-x} \\
 &= (0,75 \cdot e^{it} + 0,25)^{10}.
 \end{aligned}$$

4. Presupunem că la 100 de con vorbiri telefonice au loc 1000 de bruiaje. Care este probabilitatea de a avea o con vorbire fără bruiaje? Dar una cu cel puțin 2 bruiaje?

Variabila aleatoare ce reprezintă numărul de bruiaje se consideră a fi repartizată Poisson, cu $\lambda = E(X)$.

Solutie: Avem $E(X) = \frac{1000}{100} = 10 = \lambda$, care este și parametrul distribuției Poisson. Atunci:

$$\begin{aligned}
 P(X = 0) &= e^{-10} \cdot \frac{10^0}{0!} = e^{-10} \\
 P(X \geq 2) &= 1 - P(X = 0) - P(X = 1) \\
 &= 1 - e^{-10} - 10 \cdot e^{-10}.
 \end{aligned}$$

5. Într-o mină au loc în medie 2 accidente pe săptămînă, distribuite după legea Poisson. Să se calculeze probabilitatea de a avea cel mult 2 accidente:

- (a) într-o săptămînă;
- (b) în 2 săptămîni;
- (c) în fiecare săptămînă dintr-un interval de 2 săptămîni.

Soluție: (a) Fie X variabila aleatoare ce desemnează numărul de accidente dintr-o săptămână. Distribuția este de tip Poisson, cu $\lambda = E(X) = 2$. Atunci:

$$P(X \leq 2) = e^{-2} \left(1 + \frac{2}{1!} + \frac{4}{2!} \right) = 5e^{-2}.$$

(b) Fie Y variabila aleatoare ce desemnează numărul de accidente în 2 săptămâni. Distribuția este de asemenea de tip Poisson, cu $\lambda = 2 + 2 = 4$. Atunci:

$$P(Y \leq 2) = e^{-5} \left(1 + \frac{4}{1!} + \frac{16}{2!} \right) = 13e^{-4}.$$

(c) Probabilitatea cerută este:

$$P(X \leq 2) \cdot P(Y \leq 2) = 25e^{-4}.$$

6. La un anumit cîntar erorile de măsurare sunt normal distribuite cu $m = 0$ și $\sigma = 0,1$ g. Dacă se cîntărește un obiect la acest aparat, care este probabilitatea ca eroarea de măsurare să fie mai mică decît 0,15g?

Soluție: Fie X variabila aleatoare care reprezintă eroarea de măsurare dată cînd un obiect este cîntărit. Această variabilă este continuă și distribuită normal cu parametrii dați. Notăm acest lucru cu $X \sim N(0; 0, 1)$. Vrem să calculăm probabilitatea $P(-0,15 \leq X \leq 0,15)$.

Avem succesiv (cf. (11.1)):

$$\begin{aligned} P(-0,15 \leq X \leq 0,15) &= P\left(\frac{-0,15 - 0}{0,1} \leq \frac{X - 0}{0,1} \leq \frac{-0,15 + 0}{0,1}\right) \\ &= P(-1,5 \leq Z \leq 1,5) \\ &= \Phi(1,5) - \Phi(-1,5) \\ &= \Phi(1,5) - 1 + \Phi(1,5) \\ &= 0,8664. \end{aligned}$$

11.6 Exerciții propuse

1. Dacă efectuăm o măsurătoare, iar rezultatul este cuprins între valorile k și $k + 1$, îl aproximăm cu $k + \frac{1}{2}$. Astfel, eroarea comisă poate fi presupusă uniform distribuită pe intervalul $\left(-\frac{1}{2}, \frac{1}{2}\right)$.

Care este probabilitatea ca eroarea să fie mai mare ca $\frac{1}{4}$?

2. Fie variabila aleatoare X , distribuită uniform pe $(-1, 1)$. Determinați densitățile de probabilitate, mediile și dispersiile pentru variabilele $Y = 2X + 1$ și $Z = 2X^2 + 1$.

3. Durata medie de funcționare a unei baterii este o variabilă aleatoare, pe care o notăm X și care este repartizată normal, $N(m, \sigma^2)$, unde $m = 120$ zile este timpul mediu de funcționare, iar $\sigma = 10$ zile este abaterea față de medie. Determinați:

- (a) probabilitatea ca bateria să funcționeze cel puțin 100 zile;
- (b) probabilitatea ca bateria să funcționeze între 100 și 150 zile;
- (c) intervalul de timp în care se poate spune că bateria funcționează cu o probabilitate de cel puțin 75% („aproape sigur“).

4. Fie $a, b > 0$ și $n \in \mathbb{N}$. Determinați a, b astfel încât funcția $f_n(x) = ax^n e^{-b^2 x^2}$ pentru $x > 0$ să fie o densitate de probabilitate pentru o variabilă aleatoare cu media m .

5. Fie densitatea de probabilitate a unei variabile aleatoare X de forma:

$$f(x) = \begin{cases} c \cdot \ln\left(\frac{a}{x}\right), & 0 < x < a \\ 0, & \text{în rest} \end{cases}$$

Să se determine constanta c astfel încât f să fie corect definită și să se calculeze valoarea medie și dispersia variabilei X .

6. Determinați funcția caracteristică a variabilei aleatoare X cu densitatea de probabilitate dată de:

$$f(x) = \begin{cases} \frac{1}{2} \left(1 - \frac{|x|}{2}\right), & |x| \leq 2 \\ 0, & |x| > 2 \end{cases}$$

Aflați funcția caracteristică a acestei variabile aleatoare.

7. Fie X, Y două variabile aleatoare independente, cu $X : N(1, 2)$ și $Y : U(0, 2)$. Determinați $M(X + Y), M(XY), M(X^2), M(X - Y^2), D^2(X + Y), D^2(X - Y)$.

8. Presupunem că emisia de particule dintr-un experiment este modelată de legea Poisson, cu $\lambda = 30$ particule pe oră. Care este probabilitatea ca în 10 minute să fie emise cel mult 20 particule?

9. Fie variabilele aleatoare X, Y , în relația $Y = 2 - 3X$. Calculați media și dispersia pentru Y , precum și corelația și coeficientul de corelație, știind că $m_X = -1, D_X^2 = 4$.

10. Presupunem că modulul vectorului viteză a unei particule este o variabilă aleatoare care este repartizată după legea Maxwell, adică are:

$$f(v) = \frac{4h^2}{\sqrt{\pi}} \cdot v^2 \cdot e^{-h^2 v^2}, \quad v > 0.$$

Aflați media și dispersia vitezei.

SEMINAR 12

VECTORI ALEATORI BIDIMENSIONALI

Putem gîndi vectorii aleatori bidimensionali ca pe niște *matrice aleatoare*. Însă noțiunea este chiar ceva mai generală. Astfel, dacă X și Y sunt două variabile aleatoare, atunci pur și simplu formăm perechea (X, Y) , care se numește *vector aleator bidimensional*. În majoritatea cazurilor, vom lucra cu X și Y definite pe același spațiu de evenimente, deci dacă $\text{card}(X) = \text{card}(Y) = n$, atunci perechea lor devine o matrice aleatoare $2 \times n$.

Repartiția unei astfel de matrice aleatoare se calculează intuitiv folosind repartițiile individuale. Avem, deci:

$$P(X = x_i, Y = y_j) = p_{ij},$$

unde se pot considera $1 \leq i \leq n$ și $1 \leq j \leq m$. Mai notăm probabilitățile individuale cu p_i , respectiv q_j , adică $p_i = P(X = x_i)$ și $q_j = P(Y = y_j)$. Aceste mărimi se mai numesc *probabilități marginale*.

Evident, dacă fixăm oricare dintre cele două variabile, obținem, de exemplu, pentru X fixat:

$$\cup_j (X = x_i, Y = y_j) = \sum_j P(X = x_i, Y = y_j) = \sum_j p_{ij} = p_i,$$

deoarece ambele variabile aleatoare X și Y sănt, individual, normate. Adică $\sum_i p_i = \sum_i P(X = x_i) = \sum_j q_j = \sum_j P(Y = y_j) = 1$.

Analog, desigur, $\sum_i p_{ij} = q_j$.

Luate împreună, obținem automat condiția de normare pentru perechea de variabile aleatoare, adică $\sum_{i,j} p_{ij} = 1$, în ipoteza că ambele componente ale perechii sănt normate.

Notăm cu $F_{(X,Y)}(x, y) = P(X < x, Y < y)$ funcția de repartitie a perechii de variabile aleatoare (vectorului aleator bidimensional) (X, Y) . Separat, $F_X(x)$ și $F_Y(y)$ se numesc *funcții de repartitie marginale* ale vectorului aleator (X, Y) .

Pentru *cazul continuu*, întîlnim noțiunea cunoscută din cazul vectorilor aleatori 1-dimensionali. Mai precis, avem:

$$F_{(X,Y)}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv,$$

unde f este *densitatea de probabilitate* și este o funcție cu valori pozitive, dublu-normată, adică:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(u, v) du dv = 1.$$

Totodată, putem recupera din această ecuație și densitatea de probabilitate știind funcția de repartitie, prin:

$$f(x, y) = \frac{\partial^2 F_{(X,Y)}(x, y)}{\partial x \partial y},$$

evident, pentru punctele (x, y) unde egalitatea are sens.

12.1 Repartiții condiționate

Pornim cu un vector aleator bidimensional (X, Y) , discret. Ne punem problema din cazul probabilităților condiționate, i.e. vom nota cu $P(x_i/y_j)$ probabilitatea să aibă loc evenimentul $X = x_i$, știind că a avut loc (i.e. condiționat de) evenimentul $Y = y_j$.

Aceasta se poate calcula simplu, ca în cazul probabilităților condiționate:

$$P(x_i/y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{q_j}.$$

Invers, obținem desigur $P(y_j/x_i) = \frac{p_{ij}}{p_i}$.

Dacă fixăm un eveniment $Y = y$, putem defini o *funcție de repartitie conditionată*, $F(x/y) = P(X < x/Y = y)$, asociată vectorului X (deoarece Y este fixat). Aceasta se calculează generalizând formulele de mai sus pe cazul continuu, anume:

$$F(x/y) = \frac{1}{f_Y(y)} \cdot \int_{-\infty}^x f(u, y) du.$$

Prin derivare în raport cu x , obținem densitatea de probabilitate a lui X , în ipoteza că $Y = y$:

$$f_X(x/y) = \frac{f(x, y)}{f_Y(y)}.$$

12.2 Variabile aleatoare independente

Stim deja că două variabile aleatoare X și Y sunt independente dacă evenimentele $X = x_i$ și $Y = y_j$ sunt independente, adică dacă are loc:

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j).$$

Egalitatea poate fi formulată și cu funcțiile de repartiție:

$$F_{(X,Y)}(x, y) = F_X(x) \cdot F_Y(y).$$

Mai mult decât atât, rezultatul de mai jos ne arată că egalitatea are loc și pentru densitățile de probabilitate:

Teoremă 12.1: *Fie X, Y variabile aleatoare cu densitățile de probabilitate f_X , respectiv f_Y . Atunci X și Y sunt independente dacă și numai dacă are loc:*

$$f(x, y) = f_X(x) \cdot f_Y(y),$$

unde $f(x, y)$ este densitatea de probabilitate a vectorului (X, Y) , format de cele două variabile aleatoare.

Atenție: Dacă lucrăm cu alte variabile aleatoare U, V , obținute din X și Y prin transformări funktionale de forma generală:

$$U = \varphi(X, Y), \quad V = \psi(X, Y),$$

atunci calculele care folosesc densitățile de probabilitate și funcțiile de repartiție se fac folosind schimbări de variabile de forma:

$$u = \varphi(x, y), v = \psi(x, y) \Leftrightarrow x = \varphi_1(u, v), y = \psi_1(u, v),$$

după care noua densitate de probabilitate se schimbă cu ajutorul jacobianului transformărilor de mai sus:

$$f_{(U,V)}(u, v) = \left| \frac{D(x, Y)}{D(u, v)} \right| \cdot f_{(X,Y)}(\varphi_1(u, v), \psi_1(u, v)),$$

unde:

$$\left| \frac{D(x, y)}{D(u, v)} \right| = \det \begin{pmatrix} x_u & x_v \\ y_u & y_v \end{pmatrix},$$

determinantul matricei jacobiene a transformării ($x_u = \frac{\partial x}{\partial u}$ etc.).

Dintre toate caracteristicile numerice asociate variabilelor aleatoare (medie, dispersie, coeficient de corelație, covarianță), pentru cazul bidimensional avem în plus *media condiționată*. Astfel, fie X, Y variabile aleatoare discrete. Atunci putem calcula mediile condiționate prin:

- $E(X/Y = y_j) = \sum_i x_i \cdot P(x_i/y_j);$
- $E(Y/X = x_i) = \sum_j y_j P(y_j/x_i).$

Pentru cazul continuu, sumele devin integrale, iar probabilitățile devin densități:

- $E(X/Y = y) = \int_{-\infty}^{\infty} x \cdot f_X(x/y) dx;$
- $E(Y/X = x) = \int_{-\infty}^{\infty} y \cdot f_Y(y/x) dy.$

12.3 Caracteristici numerice

Media și dispersia unei variabile aleatoare au fost discutate anterior. De asemenea, atunci cînd lucrăm cu două sau mai multe variabile aleatoare, devin relevante și alte mărimi, precum *covarianța* și *coeficientul de corelație*. Le redăm mai jos, împreună cu proprietăți importante ale lor și ale mediei și dispersiei.

Functia de medie are următoarele proprietăți esențiale:

- (a) **Liniaritatea:** $E(\alpha X + \beta Y) = \alpha E(X) + \beta E(Y)$, pentru orice $\alpha, \beta \in \mathbb{C}$;
- (b) **Monotonie:** Dacă $X \leq Y$, atunci $E(X) \leq E(Y)$;
- (c) Dacă X este o constantă c , atunci $E(X) = c$;
- (d) Dacă X și Y sunt variabile aleatoare independente, adică descriu evenimente independente, atunci $E(XY) = E(X) \cdot E(Y)$.

Functia de dispersie are proprietățile:

- (a) $D^2(X) = E(X^2) - (E(X))^2$;
- (b) $D^2(X) \geq 0$;
- (c) $D^2(X) = 0 \iff P(X = E(X)) = 1$, adică X este o constantă cu probabilitatea 1 (X descrie doar evenimentul sigur);
- (d) **Cebîșev:** Pentru orice $\varepsilon > 0$, are loc:

$$P(|X - E(X)| \geq \varepsilon) < \frac{D^2(X)}{\varepsilon^2}.$$

Echivalent, se mai poate scrie:

$$P(|X - E(X)| < \varepsilon) \geq 1 - \frac{D^2(X)}{\varepsilon^2}.$$

- (e) $D^2(\alpha X) = \alpha^2 D^2(X)$, pentru orice $\alpha \in \mathbb{C}$;
- (f) Dacă X și Y sunt independente, atunci:

$$D^2(X + Y) = D^2(X) + D^2(Y).$$

Mai definim două mărimi care se asociază variabilelor aleatorii.

Definiție 12.1: Fie X și Y două variabile aleatoare. Numim *covarianță* a variabilelor X și Y , notată $\text{cov}(X, Y)$ numărul:

$$\text{cov}(X, Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y).$$

Proprietățile esențiale ale covarianței sănt date de:

- (a) Dacă X și Y sănt variabile aleatoare independente, atunci $\text{cov}(X, Y) = 0$;
- (b) Dacă X_1, \dots, X_n sănt variabile aleatoare cu dispersiile D_i^2 și covariantele $\text{cov}(X_i, X_j)$, $i \neq j$, atunci are loc:

$$D^2\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D_i^2 + 2 \sum_{i < j} \text{cov}(X_i, X_j).$$

Definiție 12.2: Dacă X și Y sănt variabile aleatoare, se numește *coeficient de corelație* al lor, notat $\rho(X, Y)$, numărul calculat prin:

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{D^2(X) \cdot D^2(Y)}}$$

Se poate vedea din definiție că, atât covarianța, cât și corelația arată „gradul de independentă“ a variabilelor aleatoare X și Y . Într-adevăr, dacă X și Y sănt independente, atunci avem $\rho(X, Y) = 0$. Afirmația reciprocă este, însă, falsă!

Să luăm un exemplu: Fie $A = \{a_1, a_2, a_3, a_4\}$, cu $P(a_i) = \frac{1}{4}$.

Presupunem că variabila aleatoare X realizează corespondența:

$$X(a_1) = 1, X(a_2) = -1, X(a_3) = 2, X(a_4) = -2.$$

Atunci, ea are matricea de repartiție:

$$X \sim \begin{pmatrix} -2 & -1 & 1 & 2 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}.$$

Presupunem că o altă variabilă aleatoare Y realizează corespondența:

$$Y(a_1) = 1, Y(a_2) = 1, Y(a_3) = -1, Y(a_4) = -1.$$

Atunci matricea ei se poate reduce la:

$$Y \sim \begin{pmatrix} -1 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}.$$

Produsul celor două variabile aleatoare are matricea de repartiție:

$$XY : \begin{pmatrix} -2 & -1 & 1 & 2 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}.$$

Rezultă că $E(X) = E(Y) = E(XY)$, deci $\text{cov}(X, Y) = 0$. Însă putem observa că X și Y nu sănt independente. Într-adevăr, avem:

$$P(X = 1 \wedge Y = 1) = P(a_1) = \frac{1}{4} \neq P(X = 1) \cdot P(Y = 1) = \frac{1}{4} \cdot \frac{1}{2}.$$

În fine, o altă noțiune de care avem nevoie este *funcția generatoare*.

Definiție 12.3: Fie X o variabilă aleatoare discretă care ia valori naturale.

Funcția $G_X(t)$, definită prin:

$$G_X(t) = E(t^X) = \sum_{n \geq 0} p_n t^n,$$

cu $t \leq 1$ și $p_n = P(X = n)$ se numește *funcția generatoare* a variabilei aleatoare X .

Funcția generatoare codifică, de fapt, în coeficienții unei serii formale, repartitia unei variabile aleatoare. Ea are următoarele proprietăți:

- (a) Dacă avem variabilele aleatoare independente X_1, \dots, X_n , iar $X = X_1 + \dots + X_n$, atunci:

$$G_X(t) = G_{X_1}(t) \cdots G_{X_n}(t);$$

(b) $E(X) = G'_X(1)$;

(c) $D^2(X) = G''_X(1) + G'_X(1) - [G'_X(1)]^2$;

- (d) Două variabile aleatoare cu aceeași funcție generatoare au aceeași repartitie.

12.4 Exerciții

1. Fie variabilele aleatoare:

$$X = \begin{pmatrix} -1 & 2 \\ 0.5 & 0.5 \end{pmatrix}, \quad Y = \begin{pmatrix} -2 & 0 & 1 \\ 0.3 & 0.3 & 0.4 \end{pmatrix}.$$

- (a) Calculați $E(X/Y = 1)$;
 (b) Calculați $D^2(X)$ și $D^2(Y)$;
 (c) Calculați XY și apoi $E(XY)$;
 (d) Determinați coeficientul de corelație $\rho(X, Y)$.

2. Fie vectorul aleator (X, Y) , cu densitatea de repartitie:

$$f(x, y) = \begin{cases} e^{-y}, & 0 < x < y \\ 0, & \text{în rest} \end{cases}.$$

Determinați:

- (a) Densitățile marginale $f_X(x)$ și $f_Y(y)$;

- (b) Densitatea variabilei aleatoare Y condiționată de X ;
- (c) Probabilitatea ca $(x, y) \in (X, Y)$ să aparțină pătratului unitate $[0, 1] \times [0, 1]$.

3. Fie vectorul aleator (X, Y) , cu densitatea de repartiție:

$$f(x, y) = \begin{cases} k, & 0 < y \leq x < 1 \\ 0, & \text{în rest} \end{cases},$$

unde $k \in \mathbb{R}$ este o constantă fixată.

- (a) Determinați k , astfel încât funcția de mai sus să fie corect definită, ca densitate de repartiție;
- (b) Determinați densitățile de repartiție marginale $f_X(x), f_Y(y)$;
- (c) Calculați $P(0 < X < 0.5, 0 < Y < 0.5)$;
- (d) Determinați densitățile condiționate $f(y/x)$ și $f(x/y)$.

4. Fie funcția:

$$f(x, y) = \begin{cases} x^2 + \frac{xy}{c}, & x \in (0, 1), y \in (0, 2) \\ 0, & \text{în rest} \end{cases}.$$

- (a) Determinați $c \in \mathbb{R}$ astfel încât $f(x, y)$ să fie o densitate de repartiție;
- (b) Determinați funcția de repartiție $F_{(X,Y)}(x, y)$ a vectorului aleator bidimensional (X, Y) care are densitatea de repartiție calculată mai sus;
- (c) Determinați densitățile marginale $f_X(x), f_Y(y)$ și funcțiile de repartiție $F_X(x), F_Y(y)$;
- (d) Calculați $P(X > 0.5)$ și $P(Y < 0.5 | X < 0.5)$;
- (e) Calculați densitatea de repartiție condiționată $F(Y|X = x)$.

5. Vectorul aleator (X, Y) se dă prin tabloul de repartiție comună:

$X \mid Y$	$y_1 = -2$	$y_2 = -1$	$y_3 = 4$	$y_4 = 5$
$x_1 = 1$	$p_{11} = 0.1$	$p_{12} = 0.2$	$p_{13} = 0$	$p_{14} = 0.3$
$x_2 = 2$	$p_{21} = 0.2$	$p_{22} = 0.1$	$p_{23} = 0.1$	$p_{24} = 0$

- (a) Determinați repartițiile marginale p_X și p_Y ale celor două variabile aleatoare X și Y ;
- (b) Aflați dacă variabilele aleatoare sunt independente;

- (c) Calculați $E(X)$ și $E(Y)$;
- (d) Calculați $\text{cov}(X, Y)$ și determinați dacă variabilele aleatoare sunt corelate sau nu;
- (e) Calculați $\rho(X, Y)$.

6. Vectorul aleator (X, Y) se dă prin tabloul de repartitie comună:

$X \mid Y$	$y_1 = 0$	$y_2 = 1$
$x_1 = -1$	$p_{11} = \lambda$	$p_{12} = 3/20$
$x_2 = 0$	$p_{21} = 3/20$	$p_{22} = 1/4$
$x_3 = 1$	$p_{31} = 1/4$	$p_{32} = 3/20$

- (a) Determinați parametrul λ ;
- (b) Determinați $D^2(X)$ și $D^2(Y)$;
- (c) Verificați dacă cele două variabile aleatoare sunt independente.

7. Vectorul aleator (X, Y) se dă prin tabloul de repartitie comună:

$X \mid Y$	$y_1 = 0$	$y_2 = 1$	$y_3 = 2$
$x_1 = 2$	$p_{11} = 0.2$	$p_{12} = 0.3$	$p_{13} = 0.1$
$x_2 = 3$	$p_{21} = 0.1$	$p_{22} = 0.1$	$p_{23} = \lambda$

- (a) Determinați parametrul λ ;
- (b) Determinați repartițiile marginale ale vectorului aleator (X, Y) ;
- (c) Calculați $E(Y/X = 2)$ și $E(X/Y = 2)$.

INDEX

- convoluție, 40
- formula
 - Cauchy, 10
- funcție
 - L^1 , 49
 - analitică, 20
 - complexă
 - reziduu, 12
 - original, 30
- integrală
 - complexă, 9
 - trigonometrică, 18
- semnal
 - discret, 40
 - intîrziat, 40
 - unitar, 40
- serie
- de puteri complexă, 19
- Laurent, 20
- singularitate
 - aparentă, 21
 - esențială, 22
 - izolată, 21
 - pol, 22
 - reziduu, 23
- teorema
 - calculul reziduurilor, 12
 - Cauchy, 9
 - Mellin-Fourier, 38
 - reziduurilor, 13
- transformata
 - Fourier, 50
 - inversă, 50
 - Laplace, 30
 - Z, 41

MEDIA SI DISPERSIA UNEI VARIABILE ALEATOARE. PROBLEME

Lect. Dr. Costache Luminita

1. Variabila aleatoare X are repartiția $X \sim \begin{pmatrix} -1 & 0 & 1 \\ 0,2 & 0,3 & 0,5 \end{pmatrix}$. Să se calculeze valorile medii $E(X), E(2X), E(X + 1), E(2X + 1), E(X^2), E((X - 0,3)^2)$.
2. Doi jucători de tenis joacă în 4 meciuri 12 seturi. Considerând că probabilitățile celor 2 jucători de a câștiga un set sunt egale, să se calculeze valoarea medie, dispersia și abaterea medie pătratică a variabilei aleatoare ce reprezintă numărul de seturi câștigate de unul dintre jucători.
3. Doi parteneri cu forță egală boxează 10 runde (probabilitatea ca oricare din ei să câștige o rundă este $\frac{1}{2}$). Să se calculeze valoarea medie, dispersia și abaterea medie pătratică a v. a. care reprezintă numărul de runde câștigate de unul din parteneri.
4. O firmă se aprovisionează de la 3 furnizori. Din datele statistice privind furnizorii, firma estimează că probabilitatea cu care furnizorii nu pot onora contractul sunt $p_1 = 0,1, p_2 = 0,3, p_3 = 0,2$. Fie X variabila aleatoare ce indică numărul furnizorilor ce nu-și pot onora contractul. Să se afle:
 - a) repartiția v.a. X ;
 - b) $E(X), D^2(X)$.
5. Se fac experimente asupra alegerii filamentului unui girofar până când acesta este aprins. La fiecare experiment probabilitatea de succes este $\frac{1}{5}$. Se cer media și dispersia numărului de experimente.
6. Persoanele A și B joacă în următoarele condiții : se aruncă 2 zaruri și când suma punctelor obținute e mai mică decât 10, atunci B plătește lui A suma de 5 dolari. În caz contrar, A plătește lui B o sumă fixă a . Să se determine această sumă astfel încât jocul să fie echitabil.
7. Se dau densitățile de probabilitate

$$a) f_X(x) = \begin{cases} 2x, & 0 < x < 1 \\ 0, \text{în rest} \end{cases}$$

$$b) f_X(x) = \begin{cases} |x|, & |x| < 1 \\ 0, & \text{în rest} \end{cases}$$

Să se calculeze valoarea medie și dispersia variabilei X .

8. Se dau funcțiile de repartiție

$$a) F_X(x) = \begin{cases} 0, & x < 0 \\ x^2, & 0 \leq x \leq 1 \\ 1, & x > 1 \end{cases}$$

$$b) F_X(x) = \begin{cases} 0, & x < 0 \\ x^{\frac{1}{2}}, & 0 \leq x \leq 1 \\ 1, & x > 1 \end{cases}$$

Să se calculeze valorile medii și dispersiile corespunzătoare.

9. Fie X o variabilă aleatoare a cărei densitate de repartiție este

$$f_X(x) = \begin{cases} c \ln\left(\frac{a}{x}\right), & 0 \leq x < a \\ 0, & \text{în rest} \end{cases}$$

Să se determine constanta c și să se calculeze valoarea medie, momentul de ordinul doi și dispersia variabilei X .

10. Se dă densitatea de repartiție

$$f(x) = \begin{cases} 1 - |1 - x|, & 0 < x < 2 \\ 0, & \text{în rest} \end{cases}$$

Să se calculeze media și dispersia.

11. Variabila aleatoare X are densitatea de probabilitate

$$f(x) = \begin{cases} cx(1-x), & \text{dacă } 0 \leq x \leq 1 \\ 0, & \text{în rest} \end{cases}$$

Să se determine: a) constanta c astfel încât f să fie densitate de probabilitate; b) $P(X \leq \frac{1}{2})$; c) funcția de repartiție $F_X(x)$ a variabilei aleatoare X ; d) $D^2(X)$.

12. Cunoscând funcția de repartiție a depărtării stelelor de la steaua cea mai apropiată este $F_R(r) = 1 - e^{-\frac{4}{3}\pi\lambda r^3}$ și numărul mediu de stele în cubul parsec din vecinătatea soarelui $\lambda = 0,00163$, să se afle valoarea medie și dispersia variabilelor R .

13. Fiind dată densitatea de probabilitate a vectorului aleator (X, Y)

$$f(x, y) = \begin{cases} 2xye^{-(x^2+y^2)}, & x > 0, y > 0 \\ 0, & \text{în rest} \end{cases}$$

să se determine $E(X), E(Y), D^2(X), D^2(Y)$.

14. Fie (X, Y) un vector aleator cu densitatea

$$f(x, y) = \begin{cases} \frac{1}{8}(6 - x - y), & (x, y) \in (0, 2) \times (2, 4) \\ 0, & \text{în rest} \end{cases}$$

Să se afle:

- a) densitățile de repartiție condiționate $f(x/y), f(y/x)$;
- b) $E(X/Y = y), E(Y/X = x)$

SIRURI DE VARIABILE ALEATOARE. TEOREME LIMITĂ

Lect. Dr. Costache Luminita

1 Inegalitatea lui Cebășev

Teorema 1. (*Inegalitatea lui Cebășev*) Fie X o v.a. cu dispersia finită
Atunci $\forall \varepsilon > 0$ au loc

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{D^2(X)}{\varepsilon^2}$$

sau echivalent

$$P(|X - E(X)| < \varepsilon) \geq 1 - \frac{D^2(X)}{\varepsilon^2}$$

2 Tipuri de convergență

Definiția 1. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. reale sau complexe definite pe un spațiu de probabilitate (Ω, \mathcal{K}, P) , iar X o altă v.a. definită pe același spațiu de probabilitate.

1) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în probabilitate către X ($X_n \xrightarrow{P} X$, când $n \rightarrow \infty$), dacă $\forall \varepsilon > 0, P(|X_n - X| > \varepsilon) \rightarrow 0, n \rightarrow \infty$ sau $\forall \varepsilon > 0, P(|X_n - X| < \varepsilon) \rightarrow 1, n \rightarrow \infty$.

2) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur (tare) către X ($X_n \xrightarrow{a.s.} X$, când $n \rightarrow \infty$), dacă $P(\{\omega / \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\}) = 1$.

3) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în medie de ordinul r către X ($X_n \xrightarrow{r} X$, când $n \rightarrow \infty$), dacă există momentele absolute $E(|X_n|^r), n \in \mathbb{N}^*$ și $E(|X|)$ și dacă $E(|X_n - X|^r) \rightarrow 0$, când $n \rightarrow \infty$.

4) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în repartiție sau slab către X ($X_n \xrightarrow{w} X$, când $n \rightarrow \infty$), dacă $F_{X_n}(x) \rightarrow F_X(x), n \rightarrow \infty, \forall x$ punct de continuitate al funcției F_X , unde $F_{X_n}, n \in \mathbb{N}^*$ și F_X sunt funcții de repartiție ale v. a. $X_n, n \in \mathbb{N}^*$ și respectiv X .

Relații între tipurile de convergență

1) Dacă $X_n \xrightarrow{a.s.} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{P} X, n \rightarrow \infty$.

2) Dacă $X_n \xrightarrow{P} X, n \rightarrow \infty$, atunci există un subșir $(X_{n_k})_{k \in \mathbb{N}^*}$ astfel încât $X_{n_k} \xrightarrow{a.s.} X, k \rightarrow \infty$.

3) Dacă $X_n \xrightarrow{r} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{P} X, n \rightarrow \infty$. Implicația reciprocă nu are loc, deoarece $E(|X_n - X|^r)$ s-ar putea să nu existe.

4) Dacă $X_n \xrightarrow{r} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{r'} X, n \rightarrow \infty$, pentru $r' < r$.

5) Dacă $X_n \xrightarrow{P} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{w} X, n \rightarrow \infty$.

3 Legea numerelor mari

Am văzut că nu putem să înainte de efectuarea experienței ce valoare va lua variabila aleatoare pe care o studiem. S-ar părea că, întrucât despre fiecare variabilă aleatoare dispunem de informații reduse, cu greu am putea determina comportarea medie aritmetică a unui număr suficient de mare de variabile aleatoare. În realitate, în condiții puțin restrictive media aritmetică a unui număr suficient de mare de variabile aleatoare își pierde caracterul întâmplător. Pentru practică este foarte important să cunoaștem condițiile în care acțiunea combinată a mai mulți factori întâmplători conduce la un rezultat care să nu depindă de întâmplare, deci care să ne permită să prevedem mersul fenomenului studiat. Astfel de condiții se dau în teoremele cunoscute în calculul probabilităților sub denumirea comună de **legea numerelor mari**. Termenul de lege a numerelor mari a fost folosit pentru prima oară de Poisson, deși, cu aproximativ un secol înainte, Jacob Bernoulli a pus în evidență acțiunea legii numerelor mari cu referire la repartitia binomială. În 1867, Cebâșev precizează riguros din punct de vedere matematic legea numerelor mari în condiții generale.

Fie (Ω, \mathcal{K}, P) un spațiu de probabilitate și $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. reale definite pe acest spațiu.

Ne interesează cazul în care există un sir de numere reale $(a_n)_{n \in \mathbb{N}^*}$ astfel încât:

$$1) \frac{1}{n} \sum_{k=1}^n X_k - a_n \xrightarrow{P} 0, n \rightarrow \infty$$

sau

$$2) \frac{1}{n} \sum_{k=1}^n X_k - a_n \xrightarrow{a.s.} 0, n \rightarrow \infty$$

De obicei se consideră cazul în care $a_n = \frac{1}{n} \sum_{k=1}^n E(X_k)$.

In cazul 1) (resp. 2)) se spune că sirul $(X_n)_{n \in \mathbb{N}^*}$ satisfacă **legea slabă a numerelor mari** (resp. **legea tare a numerelor mari**) sau că $(X_n)_{n \in \mathbb{N}^*}$ este **slab stabil** (resp. **tare stabil**).

Teorema 2. (Cebâșev) Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. independente două câte două ale căror dispersii verifică $D^2(X_i) < c, \forall i \in \mathbb{N}^*, c \in \mathbb{R}$. Atunci

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right) = 1$$

sau echivalent

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| \geq \varepsilon\right) = 0$$

Deși v.a. independente pot lua valori depărtate de mediile lor, media aritmetică a unui număr suficient de mare de astfel de v.a. ia, cu o probabilitate mare, valori apropiate de un număr constant $\frac{1}{n} \sum_{i=1}^n E(X_i)$.

In acest fel, între comportarea fiecărei v.a. și a mediei lor aritmetice există o mare deosebire: nu este posibil să prevedem ce valoare va lua fiecare dintre v.a., însă cu o probabilitate mare putem prevedea ce valoare va lua media aritmetică a acestor v.a. De aici tragem concluzia că media aritmetică a unui număr suficient de mare de v.a. (cu dispersii mărginite) își pierde caracterul de v.a.

Exemplul 1. Fie şirurile de variabile aleatoare definite pe acelaşi câmp de probabilitate $(X_n)_{n \geq 1}$, $(Y_n)_{n \geq 1}$, $(Z_n)_{n \geq 1}$, unde $X_n \sim \begin{pmatrix} -5n & 0 & 5n \\ \frac{1}{3n^2} & 1 - \frac{2}{3n^2} & \frac{1}{3n^2} \end{pmatrix}$, $Y_n \sim \begin{pmatrix} -n^2 & 0 & n^2 \\ \alpha^{-n} & 1 - 2\alpha^{-n} & \alpha^{-n} \end{pmatrix}$ și Z_n are densitatea de probabilitate

$$f_n(x) = \begin{cases} \lambda^{-n} e^{-\frac{x}{\lambda^n}}, & x > 0 \\ 0, & \text{în rest} \end{cases}$$

$\forall n \geq 1, \lambda > 0$. Să se verifice aplicabilitatea teoremei lui Cebîșev celor trei şiruri.

Demonstratie. Teorema este aplicabilă dacă media este finită și dispersia este mărginită .

$$\begin{aligned} E(X_n) &= (-5n) \cdot \frac{1}{3n^2} + 0 \cdot \left(1 - \frac{2}{3n^2}\right) + 5n \cdot \frac{1}{3n^2} = 0, E(X_n^2) = (-5n)^2 \cdot \frac{1}{3n^2} + 0^2 \cdot \left(1 - \frac{2}{3n^2}\right) + (5n)^2 \cdot \frac{1}{3n^2} = \frac{50}{3}, D^2(X_n) = \frac{50}{3} \implies \text{teorema se aplică} \\ E(Y_n) &= (-n^2) \cdot \alpha^{-n} + 0 \cdot (1 - 2\alpha^{-n}) + n^2 \cdot \alpha^{-n} = 0, E(Y_n^2) = (-n^2)^2 \cdot \alpha^{-n} + 0^2 \cdot (1 - 2\alpha^{-n}) + (n^2)^2 \cdot \alpha^{-n} = \frac{2n^4}{\alpha^n}, D^2(Y_n) = \frac{2n^4}{\alpha^n} \implies \\ \implies \lim_{n \rightarrow \infty} D^2(Y_n) &= 0 \implies \exists c \in (0, \infty) \text{ astfel încât } \forall n \geq 1, D^2(Y_n) \leq c \implies \text{teorema se aplică} \end{aligned}$$

$$\begin{aligned} E(Z_n) &= \int_0^\infty x \lambda^{-n} e^{-\frac{x}{\lambda^n}} dx = \lambda^n, E(Z_n^2) = \int_0^\infty x^2 \lambda^{-n} e^{-\frac{x}{\lambda^n}} dx = 2\lambda^{2n} \implies \\ \implies D^2(Z_n) &= \lambda^{2n} \implies \end{aligned}$$

$$\lim_{n \rightarrow \infty} D^2(Z_n) = \begin{cases} 0, & \lambda \in (0, 1) \\ 1, & \lambda = 1 \\ \infty, & \lambda > 1 \end{cases}$$

deci teorema se aplică numai dacă $\lambda \in (0, 1]$

□

Teorema 3. (Teorema lui Bernoulli) Fie ν_n numărul de realizări ale unui eveniment A în n experimente independente și p probabilitatea de realizare a lui A în fiecare experiment. Atunci pentru

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P\left(\left|\frac{\nu_n}{n} - p\right| < \varepsilon\right) = 1$$

sau echivalent

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{\nu_n}{n} - p\right| \geq \varepsilon\right) = 0$$

Observația 1. Rezultatul poate fi formulat și astfel: sirul de v.a. $(\frac{\nu_n}{n})_n$ converge în probabilitate către p .

In condițiile teoremei lui Bernoulli, Borel a arătat în 1909 un rezultat mai profund : $\frac{\nu_n}{n} \xrightarrow{a.s.} p$.

Observația 2. In cazul unei populații de volum mare, dacă se efectuează o selecție de volum n și se obțin ν_n rezultate favorabile, atunci cu o probabilitate apropiată de unitate, putem afirma că probabilitatea evenimentului cercetat este dată de frecvență relativă . Prin urmare, în studiul populațiilor pentru care nu putem determina apriori probabilitatea de realizare a unui eveniment, probabilitatea teoretică p se poate exprima pe cale experimentală prin frecvență relativă $\frac{\nu_n}{n}$ a evenimentului considerat, fapt ce constituie justificarea teoretică a folosirii frecvenței în loc de probabilitate.

Corolarul 1. Pentru $\forall \varepsilon > 0$ avem $\lim_{n \rightarrow \infty} P(|f_n - p| < \varepsilon) \geq 1 - \frac{pq}{n\varepsilon^2}$, unde $f_n = \frac{\nu_n}{n}$, ν_n = de câte ori s-a realizat evenimentul A în n probe independente.

Exemplul 2. Pentru un studiu biologic sunt cercetate 1000 de probe independente, dacă au sau nu o anumită caracteristică biologică . Să se determine o margine inferioară a probabilității ca diferență, în valoare absolută , dintre frecvență relativă și probabilitatea p de a apărea caracteristica într-o probă , să fie mai mică decât 0,03.

Demonstrație. Cf. consecinței teoremei lui Bernoulli $\implies p = q = \frac{1}{2}, \varepsilon = 0,03 \implies P\left(\left|\frac{x}{n} - p\right| < 0,03\right) \geq 1 - \frac{pq}{n\varepsilon^2} = 1 - \frac{\frac{1}{2} \cdot \frac{1}{2}}{1000 \cdot 0,03^2} = 0,72$ \square

Teorema 4. (Teorema limită centrală) Fie $(X_n)_n$ un sir de v.a. independente, identic repartizate. Presupunem că $E(X_i) = m$, $D^2(X_i) = \sigma^2$, $i = \overline{1, n}$ există și notăm $Z_n = \frac{Y_n - E(Y_n)}{D^2(Y_n)}$, unde $Y_n = \sum_{i=1}^n X_i$. Atunci $\forall x \in \mathbb{R}$, $\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P(Z_n < x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{u^2}{2}} du$, adică sirul $(Z_n)_n$ converge în repartiție către o v.a. $Z \sim N(0, 1)$.

Când v.a. au repartiții diferite avem o altă variantă a celebrei teoreme limită centrală :

Teorema 5. (Teorema lui A. M. Leapunov). Fie $(X_n)_n$ un sir de v.a. independente. Presupunem că $E(X_k) = m_k$, $D^2(X_k) = \sigma_k^2$,

$$E(|X_k - m_k|^3) = \rho_k^3, 1 \leq k \leq n \text{ există și notăm } Y_n = \sum_{k=1}^n X_k, \sigma^2(n) = \sum_{k=1}^n \sigma_k^2, \rho^3(n) = \sum_{k=1}^n \rho_k^3, Z_n = \frac{Y_n - E(Y_n)}{\sigma(n)} \text{ și } F_n \text{ funcția de repartiție a v.a.}$$

Z_n . Dacă $\lim_{n \rightarrow \infty} \frac{\rho(n)}{\sigma(n)} = 0$, atunci $\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P(Z_n < x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{u^2}{2}} du$, adică $(Z_n)_n$ converge în repartitie către v. a. $Z \sim N(0, 1)$.

Exemplul 3. Fie $(X_n)_{n \geq 1}$ un sir de variabile aleatoare independente astfel încât $P(X_n = \frac{1}{n^\beta}) = P(X_n = -\frac{1}{n^\beta}) = p$, cu $\frac{1}{3} < \beta \leq \frac{1}{2}, n \in \mathbb{N}^*$ și $P(X_n = 0) = 1 - 2p$. Să se arate că sirului $(X_n)_{n \geq 1}$ i se poate aplica teorema lui Leapunov.

Demonstrație. Obținem $E(X_k) = \frac{1}{k^\beta} \cdot p + (-\frac{1}{k^\beta}) \cdot p = 0$

$$E(X_k^2) = (\frac{1}{k^\beta})^2 \cdot p + (-\frac{1}{k^\beta})^2 \cdot p = \frac{2p}{k^{2\beta}} = \mu_k^2$$

$$E(|X_k|^3) = \frac{2p}{k^{3\beta}} = \rho_k^3$$

$$\text{Atunci } \sigma^2(n) = \sum_{k=1}^n \sigma_k^2 = 2p \sum_{k=1}^n \frac{1}{k^{2\beta}}, \rho^3(n) = \sum_{k=1}^n \rho_k^3 = 2p \sum_{k=1}^n \frac{1}{k^{3\beta}}$$

Cum $\frac{1}{3} < \beta \leq \frac{1}{2} \implies 1 < 3\beta \leq \frac{3}{2} \implies \lim_{n \rightarrow \infty} \sum_{k=1}^n \frac{1}{k^{3\beta}} = \sum_{k=1}^{\infty} \frac{1}{k^{3\beta}}$ este o serie

convergentă (serie Riemann)

$$\sum_{k=1}^n \frac{1}{k^{2\beta}} > \sum_{k=1}^n \frac{1}{k} \text{ ce tinde la } \infty \text{ când } n \rightarrow \infty$$

Condiția lui Leapunov $\lim_{n \rightarrow \infty} \frac{\sqrt[3]{\rho(n)^3}}{\sqrt{\sigma(n)^2}} = 0$ este îndeplinită, deci sirului $(X_n)_{n \geq 1}$ i se poate aplica teorema lui Leapunov \square

Un caz particular al teoremei limită centrală este:

Teorema 6. (Teorema integrală a lui Moivre-Laplace) Fie un sir de experimente independente astfel încât în fiecare experiment probabilitatea de realizare a unui eveniment A este p. Dacă ν_n este numărul de apariții ale lui A în primele n experimente, atunci

$$\forall x \in \mathbb{R}, \lim_{n \rightarrow \infty} P\left(\frac{\nu_n - np}{\sqrt{npq}} < x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{u^2}{2}} du = \Phi(x)$$

sau

$$\forall x_1, x_2 \in \mathbb{R}, \lim_{n \rightarrow \infty} P\left(x_1 < \frac{\nu_n - np}{\sqrt{npq}} < x_2\right) = \frac{1}{\sqrt{2\pi}} \int_{-x_1}^{x_2} e^{-\frac{u^2}{2}} du$$

SEMINAR 10

ȘIRURI DE VARIABILE ALEATOARE

Pentru aspectele teoretice privitoare la aceste noțiuni, puteți consulta *Lecții de matematici speciale*, L. Costache.

În continuare, vom insista pe exerciții.

10.1 Exerciții rezolvate

1. Fie variabila aleatoare:

$$X = \begin{pmatrix} 0.2 & 0.3 & 0.4 & 0.5 \\ 0.1 & 0.2 & 0.3 & 0.4 \end{pmatrix}.$$

Estimați probabilitatea $P(|X - m| < 0.2)$, unde $m = M[X] = E[X]$ este media lui X .

Soluție: Se folosește inegalitatea lui Cebîșev, sub forma:

$$P(|X - m| < \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2},$$

unde σ este dispersia, iar $\varepsilon = 0.2$ în acest caz (alegem).

Avem succesiv: $M[X] = 0.4$, deci $(M[X])^2 = 0.16$, iar variabila la pătrat este:

$$X^2 = \begin{pmatrix} 0.04 & 0.09 & 0.16 & 0.25 \\ 0.1 & 0.2 & 0.3 & 0.4 \end{pmatrix}.$$

Rezultă $M[X^2] = 0.17$, de unde obținem $\sigma^2 = D^2[X] = M[X^2] - (M[X])^2 = 0.01$.

Din egalitatea lui Cebîșev, rezultă în fine:

$$P(|X - m| < 0.02) \geq 0.9975.$$

2. Se aruncă 2 monede, simultan, de 800 de ori. Determinați probabilitatea de apariție a stemei pe ambele monede de un număr de ori cuprins între 150 și 250.

Soluție: Fie evenimentul A , care arată că apare stema pe ambele monede. Pentru o singură aruncare, avem $p = P(A) = \frac{1}{4}$.

Fie acum o variabilă aleatoare cu repartitie binomială (potrivită pentru studiul aruncării monetelor), deci de forma:

$$X = \binom{k}{C_n^k p^k q^{n-k}},$$

unde $n = 800$, $1 \leq k \leq 800$ și $p = \frac{1}{4}$.

Media variabilei (folosim direct formulele cunoscute din seminariile anterioare) este $M[X] = np = 800 \cdot \frac{1}{4} = 200$, iar dispersia se calculează cu:

$$\sigma^2 = np(1 - p) = 150.$$

Acum, din egalitatea lui Cebîșev:

$$P(\{|X - m| < \varepsilon\}) \geq 1 - \frac{\sigma^2}{\varepsilon^2},$$

unde $m = M[X]$, trebuie să determinăm ε convenabil.

Evenimentul căutat $|X - m| < \varepsilon$ poate fi scris în mod echivalent:

$$m - \varepsilon < X < \varepsilon + m \Rightarrow 200 - \varepsilon < X < \varepsilon + 200.$$

Dar în ipoteză, avem cerința $150 < X < 250$, deci se ajunge la sistemul:

$$\begin{cases} 200 - \varepsilon = 150 \\ 200 + \varepsilon = 250 \end{cases},$$

sistem care are soluția $\varepsilon = 50$. Acum revenim în inegalitatea lui Cebîșev și obținem:

$$P(150 < X < 250) \geq 1 - \frac{150}{50^2} \Rightarrow P(150 < X < 250) \geq 0.94.$$

3. Un zar se aruncă de 1200 de ori. Să se determine probabilitatea minimă ca numărul de apariții ale feței cu i puncte, pentru un i fixat, să fie între 150 și 250.

Soluție: Fie evenimentul A care arată că apare față cu i puncte, pentru un i fixat, la o anume aruncare. Considerăm $n = 1200$ variabile aleatoare identic repartizate, cu forma Bernoulli (potrivită pentru aruncarea zarului), deci:

$$X_k = \begin{pmatrix} 1 & 0 \\ p & q \end{pmatrix},$$

unde $p + q = 1$ și $P(X_k = 1) = P(A) = p = \frac{1}{6}$.

Media unei asemenea variabile (din formula corespunzătoare cazului Bernoulli) este $M[X_k] = p$, pentru orice k .

Vom folosi legea slabă a numerelor mari, în forma generală, unde frecvența relativă de apariție a evenimentului A este $f_{1200} = \frac{k}{1200}$. Rezultă:

$$P\left(\left|\frac{k}{1200} - \frac{1}{6}\right| < \varepsilon\right) > 1 - \delta, \quad \text{Cor. 1, p. 102}$$

unde avem $n = \frac{1}{4\delta\varepsilon^2}$, care conduce la $\delta = \frac{1}{4 \cdot 1200 \cdot \varepsilon^2}$.

Pentru a determina valoarea lui ε , calculăm:

$$\left|\frac{k}{1200} - \frac{1}{6}\right| < \varepsilon \iff \frac{1}{6} - \varepsilon < \frac{k}{1200} < \frac{1}{6} + \varepsilon,$$

de unde, în fine: $200 - 1200\varepsilon < k < 200 + 1200\varepsilon$. Deoarece cerința problemei este $150 < k < 250$, se ajunge la sistemul:

$$\begin{cases} 200 - 1200\varepsilon = 150 \\ 200 + 1200\varepsilon = 250 \end{cases} \Rightarrow \varepsilon = \frac{1}{24}.$$

Pentru această valoare, avem $\delta = 0.12$, deci $1 - \delta = 0.88$. Concluzia este că probabilitatea cerută este de 80%.

4. Folosind teorema Moivre-Laplace, estimăți probabilitatea ca din 100 de aruncări ale unei monede, să apară banul de un număr de ori cuprins între 40 și 60.

Soluție: Fie $n = 100$ variabile aleatoare repartizate identic, binomial (model potrivit pentru aruncarea monedelor). Putem considera simplu:

$$X_k = \begin{pmatrix} 1 & 0 \\ p & q \end{pmatrix},$$

unde $P(X_k = 1) = p = 0.5$. Media fiecărei dintre aceste variabile este $M[X_k] = p$. Avem de calculat probabilitatea:

$$P\left(a < \sum_{k=1}^n X_k < b\right), \quad a = 40, b = 60.$$

Aplicăm teorema Moivre-Laplace:

$$\ell = \lim_{n \rightarrow \infty} P\left(a < \sum_{k=1}^n X_k < b\right) = \phi\left(\frac{b - np}{\sqrt{npq}}\right) - \phi\left(\frac{a - np}{\sqrt{npq}}\right). \quad (\text{vezi p. 78})$$

Rezultă $\ell = \phi(2) - \phi(-2) = \phi(2) - (1 - \phi(2))$. Acum, cu valorile din tabel pentru funcția lui Laplace, avem rezultatul cerut ca fiind 0.9544.

5. Fie sirul de variabile aleatoare, independente $(X_n)_{n \in \mathbb{N}}$, cu repartiția:

$$X_n = \begin{pmatrix} -n & 0 & n \\ \frac{1}{2n^2} & 1 - \frac{1}{n^2} & \frac{1}{2n^2} \end{pmatrix}.$$

Arătați că acest sir de variabile aleatoare îndeplinește condițiile legii numerelor mari în forma Cebîsev.

Soluție: Avem de arătat că dispersiile sirului de variabile aleatoare sunt finite și uniform mărginite, adică există $c \in \mathbb{R}$ constantă, astfel încât $\sigma^2(X_k) \leq c$, pentru toți k .

Dar calcule imediate arată:

$$\begin{aligned} M[X_n] &= -\frac{n}{2n^2} + \frac{n}{2n^2} = 0 \\ M[X_n^2] &= \frac{n^2}{2n^2} + \frac{n^2}{2n^2} = 1 \\ \sigma^2 &= M[X_n^2] - M^2[X_n] = 1 - 0 = 1, \end{aligned}$$

care adeveresc condiția.

10.2 Exerciții propuse

1. Timpul mediu de răspuns al unui calculator este de 15 secunde pentru o anumită operatie, cu abaterea standard de 3 secunde.

Estimați probabilitatea ca timpul de răspuns să se abată cu mai puțin de 5 secunde față de medie.

Indicație: Folosiți inegalitatea Cebîsev. ([seminarTP, ex. 22, p. 85](#))

2.* Arătați că sirul de variabile aleatoare $(X_n)_n$, independente, cu repartiția:

$$X_n = \begin{pmatrix} -\sqrt{\ln n} & \sqrt{\ln n} \\ 0.5 & 0.5 \end{pmatrix} \quad (\text{Curs & Seminar RP})$$

urmează legea slabă a numerelor mari.

Indicație: Verificați mai întâi dacă variabilele din sir au dispersii finite, iar în caz negativ, verificați formularea Markov.

3. Într-o școală se află 100 de unități electrice care funcționează independent. Probabilitatea deconectării uneia dintre ele într-un interval de timp dat este de 5%. Determinați probabilitatea ca în acest interval anume să fie deconectate:

- (a) nu mai puțin de 5 unități;
- (b) nu mai mult de 5 unități;
- (c) între 5 și 10 unități.

Indicație: Teorema Moivre-Laplace, pentru variabile repartizate Bernoulli.

4. Se știe că 5% dintre produsele unui anumit lot sănt defecte. Care este probabilitatea ca dintr-o selecție de 200 de produse, cel puțin 10% să fie defecte?

Indicație: Teorema Moivre-Laplace, pentru variabile repartizate Bernoulli.

5. O fabrică folosește 2 tipuri de aparate, A și B. După un timp, tipul A se strică și trebuie reparate cu probabilitatea de 20%, iar tipul B, cu probabilitatea de 40%.

Numărul total de aparate din tip A disponibile în fabrică este de 1000, iar cele de tip B sănt în număr de 1500.

- (a) Care este probabilitatea ca la un moment dat, numărul de aparate care trebuie reparate (de oricare dintre tipuri) să fie între 750 și 850?
- (b) Determinați, cu o probabilitate de 0.99, numărul maxim de aparate care ar trebui reparate la un moment dat.

Indicație: Teorema Moivre-Laplace, pentru variabile repartizate Bernoulli (considerați două siruri, corespunzătoare celor două tipuri de aparate).

INDEX

- convoluție, 36
- formula
 - Cauchy, 10
- funcție
 - L^1 , 43
 - analitică, 20
 - complexă
 - reziduu, 12
 - original, 27
- integrală
 - complexă, 9
 - trigonometrică, 18
- semnal
 - discret, 36
 - intîrziat, 36
 - unitar, 36
- serie
- de puteri complexă, 19
- Laurent, 20
- singularitate
 - aparentă, 21
 - esențială, 22
 - izolată, 21
 - pol, 22
 - reziduu, 23
- teorema
 - calculul reziduurilor, 12
 - Cauchy, 9
 - Mellin-Fourier, 35
 - reziduurilor, 12
- transformata
 - Fourier, 44
 - inversă, 44
 - Laplace, 27
 - Z, 36

MATEMATICI SPECIALE

Culegere de probleme

TANIA-LUMINIȚA COSTACHE

Capitolul 4

Şiruri de variabile aleatoare

4.1 Notiuni teoretice

Tipuri de convergență

Definiția 4.1. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. reale sau complexe definite pe un spațiu de probabilitate (Ω, \mathcal{K}, P) , iar X o altă v.a. definită pe același spațiu de probabilitate.

1) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în probabilitate către X ($X_n \xrightarrow{P} X$, când $n \rightarrow \infty$), dacă $\forall \varepsilon > 0, P(|X_n - X| > \varepsilon) \rightarrow 0, n \rightarrow \infty$ sau $\forall \varepsilon > 0, P(|X_n - X| < \varepsilon) \rightarrow 1, n \rightarrow \infty$.

2) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur către X ($X_n \xrightarrow{a.s.} X$, când $n \rightarrow \infty$), dacă $P(\{\omega / \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\}) = 1$.

3) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în medie de ordinul r către X ($X_n \xrightarrow{r} X$, când $n \rightarrow \infty$), dacă există momentele absolute $E(|X_n|^r), n \in \mathbb{N}^*$ și $E(|X|)$ și dacă $E(|X_n - X|^r) \rightarrow 0$, când $n \rightarrow \infty$.

4) Sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în repartiție sau slab către X ($X_n \xrightarrow{w} X$, când $n \rightarrow \infty$), dacă $F_{X_n}(x) \rightarrow F_X(x), n \rightarrow \infty, \forall x \in C(F_X)$, unde $F_{X_n}, n \in \mathbb{N}^*$ și F_X sunt funcții de repartiție ale v. a. $X_n, n \in \mathbb{N}^*$ și respectiv X , iar $C(F_X) = \{x / F_X(x)\text{ este continuă în }x\}$ reprezintă multimea de continuitate a lui F_X .

Relații între tipurile de convergență

1) Dacă $X_n \xrightarrow{a.s.} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{P} X, n \rightarrow \infty$.

2) Dacă $X_n \xrightarrow{P} X, n \rightarrow \infty$, atunci există un subșir $(X_{n_k})_{k \in \mathbb{N}^*}$ astfel încât $X_{n_k} \xrightarrow{a.s.} X, k \rightarrow \infty$.

3) Dacă $X_n \xrightarrow{r} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{P} X, n \rightarrow \infty$. Implicația reciprocă nu are loc, deoarece $E(|X_n - X|^r)$ s-ar putea să nu existe.

4) Dacă $X_n \xrightarrow{r} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{r'} X, n \rightarrow \infty$, pentru $r' < r$.

5) Dacă $X_n \xrightarrow{P} X, n \rightarrow \infty$, atunci $X_n \xrightarrow{w} X, n \rightarrow \infty$.

Teorema 4.1. Fie X, X_1, X_2, \dots v. a. discrete cu valori întregi nenegative.

Dacă $G_{X_n}(t) \rightarrow G_X(t)$, $n \rightarrow \infty$, atunci $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Teorema 4.2. (Helly) Dacă $X_n \xrightarrow{w} X$, $n \rightarrow \infty$, atunci șirul $(\varphi_{X_n})_{n \geq 0}$ converge uniform în orice interval mărginit către φ_X . Reciproc, dacă șirul $(\varphi_{X_n})_{n \geq 0}$ converge punctual pe \mathbb{R} către o funcție φ continuă în origine, atunci există o v. a. X cu funcția caracteristică $\varphi_X = \varphi$, astfel încât $X_n \xrightarrow{w} X$, $n \rightarrow \infty$.

Legea numerelor mari

Am văzut că nu putem să înainte de efectuarea experienței ce valoare va lua variabila aleatoare pe care o studiem. S-ar părea că, întrucât despre fiecare variabilă aleatoare dispunem de informații reduse, cu greu am putea determina comportarea mediei aritmetice a unui număr suficient de mare de variabile aleatoare. În realitate, în condiții puțin restrictive media aritmetică a unui număr suficient de mare de variabile aleatoare își pierde caracterul întâmplător. Pentru practică este foarte important să cunoaștem condițiile în care acțiunea combinată a mai mulți factori întâmplători conduce la un rezultat care să nu depindă de întâmplare, deci care să ne permită să prevedem mersul fenomenului studiat. Astfel de condiții se dau în teoremele cunoscute în calculul probabilităților sub denumirea comună de **legea numerelor mari**. Termenul de lege a numerelor mari a fost folosit pentru prima oară de Poisson, deși, cu aproximativ un secol înainte, Jacob Bernoulli a pus în evidență acțiunea legii numerelor mari cu referire la repartiția binomială. În 1867, Cebîșev precizează riguros din punct de vedere matematic legea numerelor mari în condiții generale.

Fie (Ω, \mathcal{K}, P) un spațiu de probabilitate și $(X_n)_{n \in \mathbb{N}^*}$ un șir de v. a. reale definite pe acest spațiu.

Ne interesează cazul în care există un șir de numere reale $(a_n)_{n \in \mathbb{N}^*}$ astfel încât:

$$1) \frac{1}{n} \sum_{k=1}^n X_k - a_n \xrightarrow{P} 0, n \rightarrow \infty$$

sau

$$2) \frac{1}{n} \sum_{k=1}^n X_k - a_n \xrightarrow{a.s.} 0, n \rightarrow \infty$$

De obicei se consideră cazul în care $a_n = \frac{1}{n} \sum_{k=1}^n E(X_k)$.

In cazul 1) (resp. 2)) se spune că șirul $(X_n)_{n \in \mathbb{N}^*}$ satisfacă **legea slabă a numerelor mari** (resp. **legea tare a numerelor mari**) sau că $(X_n)_{n \in \mathbb{N}^*}$ este **slab stabil** (resp. **tare stabil**).

Teorema 4.3. (Hincin) Fie $(X_n)_{n \in \mathbb{N}^*}$ un șir de v. a. independente, identic repartizate, având valoarea medie m ($m < \infty$). Atunci șirul $(X_n)_{n \in \mathbb{N}^*}$ verifică **legea slabă a numerelor mari**.

Teorema 4.4. (Teorema lui Bernoulli) Să presupunem că se fac n experiențe independente, în fiecare experiență probabilitatea evenimentului A fiind p , și fie ν numărul de realizări ale evenimentului A , în cele n experiențe. Dacă ε este un număr pozitiv arbitrar suficient de mic, atunci $\lim_{n \rightarrow \infty} P\left(\left|\frac{\nu}{n} - p\right| < \varepsilon\right) = 1$.

Observația 4.1. În cazul unei populații de volum mare, dacă se efectuează o selecție de volum n și se obțin ν rezultate favorabile, atunci cu o probabilitate apropiată de unitate, putem afirma că probabilitatea evenimentului cercetat este dată de frecvență relativă. Prin urmare, dacă în studiul populațiilor pentru care nu putem determina apriori probabilitatea de realizare a unui eveniment, probabilitatea teoretică p se poate exprima pe cale experimentală prin frecvență relativă $\frac{\nu}{n}$ a evenimentului considerat, fapt ce constituie justificarea teoretică a folosirii frecvenței în loc de probabilitate.

Corolarul 4.1. Pentru $\forall \varepsilon > 0$ avem $\lim_{n \rightarrow \infty} P(|f_n - p| < \varepsilon) \geq 1 - \frac{pq}{n\varepsilon^2}$, unde $f_n = \frac{\nu}{n}$, $\nu =$ de câte ori s-a realizat evenimentul A în n probe independente.

Teorema 4.5. (Teorema lui Poisson) Fie sirul de evenimente $A_1, A_2, \dots, A_n, \dots$ ale căror probabilități de verificare au valorile successive $p_1, p_2, \dots, p_n, \dots$. Dacă notăm cu f_n frecvența relativă a numărului care indică de câte ori s-au realizat evenimentele $A_1, A_2, \dots, A_n, \dots$ și cu p expresia $p = \lim_{n \rightarrow \infty} \frac{p_1 + p_2 + \dots + p_n}{n}$, atunci

$$\lim_{n \rightarrow \infty} P\left(\left|f_n - \frac{p_1 + p_2 + \dots + p_n}{n}\right| < \varepsilon\right) = 1$$

Teorema 4.6. (Cebîșev) Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. independente astfel încât $E(X_i) = m_i$, $D^2(X_i) = \sigma_i^2$, $\forall i \in \mathbb{N}^*$. Dacă există o constantă $M < \infty$ astfel încât $\sigma_i^2 \leq M$, $\forall i \in \mathbb{N}^*$, atunci sirul $(X_n)_{n \in \mathbb{N}^*}$ verifică legea slabă a numerelor mari.

Problema limită centrală

Teorema 4.7. (Teorema Moivre-Laplace) Se consideră v. a. bernouliliene $X_1, X_2, \dots, X_n, n \in \mathbb{N}^*$, adică

$$X_i = \begin{cases} 1, & \text{cu probabilitatea } p \\ 0, & \text{cu probabilitatea } q = 1 - p \end{cases}$$

$\forall 1 \leq i \leq n$ și v. a. $S_n = X_1 + X_2 + \dots + X_n, n \in \mathbb{N}^*$. Atunci sirul de v. a. $(Y_n)_{n \in \mathbb{N}^*}$, $Y_n = \frac{S_n - np}{\sqrt{npq}}$, $n \in \mathbb{N}^*$ converge în repartiție către o v. a. repartizată normal $N(0, 1)$.

Teorema 4.8. (Teorema lui A. M. Leapunov) Fie X_1, X_2, \dots, X_n v. a. independente. Să notăm $m_k = E(X_k)$, $\mu_k^2 = D^2(X_k)$,

$\rho_k^3 = E(|X_k - m_k|^3), 1 \leq k \leq n, \mu^2(n) = \sum_{k=1}^n \mu_k^2, \rho^3(n) = \sum_{k=1}^n \rho_k^3.$ Dacă $\lim_{n \rightarrow \infty} \frac{\rho(n)}{\mu(n)} = 0,$ atunci $(Y_n)_n$ converge în repartiție către v. a. $Y,$ unde $Y_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n m_k}{\mu(n)}$ și $Y \sim N(0, 1).$

4.2 Probleme rezolvate

1. Fie X o v. a. a cărei densitate de repartiție este

$$f(x) = \begin{cases} \frac{x^m}{m!} \cdot e^{-x}, & x > 0 \\ 0, & \text{în rest} \end{cases}$$

Să se arate că $P(0 < X < 2(m+1)) > \frac{m}{m+1}.$

Soluție. Folosim inegalitatea lui Cebîșev:

$$P(|X - E(X)| < \varepsilon) > 1 - \frac{D^2(X)}{\varepsilon^2}$$

$$\begin{aligned} \text{Avem } E(X) &= \int_0^\infty x \cdot f(x) dx = \frac{1}{m!} \int_0^\infty x^{m+1} \cdot e^{-x} dx = \frac{\Gamma(m+2)}{m!} = \\ &= \frac{(m+1)!}{m!} = m+1 \end{aligned}$$

$$\begin{aligned} E(X^2) &= \int_0^\infty x^2 \cdot f(x) dx = \frac{1}{m!} \int_0^\infty x^{m+2} \cdot e^{-x} dx = \frac{\Gamma(m+3)}{m!} = \\ &= \frac{(m+2)!}{m!} = (m+1)(m+2) \end{aligned}$$

$$D^2(X) = E(X^2) - [E(X)]^2 = m+1$$

$$\begin{aligned} \text{Luăm } \varepsilon = m+1 \implies P(|X - (m+1)| < m+1) &> 1 - \frac{m+1}{(m+1)^2} = \\ &= \frac{m}{m+1} \implies P(0 < X < 2(m+1)) > \frac{m}{m+1} \quad \square \end{aligned}$$

2. Se aruncă o monedă de n ori. Cât de mare trebuie să fie n pentru ca $P\left(\left|\frac{\alpha}{n} - \frac{1}{2}\right| < \frac{1}{100}\right) > 0,99,$ știind că α reprezintă numărul de apariții ale unei fețe alese de mai înainte.

Soluție. Se știe că $D^2(X) = E((X - E(X))^2) = E_2(|X - E(X)|)$

Folosim inegalitatea lui Cebîșev și obținem

$$\begin{aligned} P\left(\left|\frac{\alpha}{n} - \frac{1}{2}\right| < \frac{1}{100}\right) &> 1 - \frac{E_2\left(\left|\frac{\alpha}{n} - \frac{1}{2}\right|\right)}{10^{-4}} \\ E\left(\left|\frac{\alpha}{n} - \frac{1}{2}\right|\right) &= E\left(\left|\frac{\alpha}{n} - \frac{1}{2}\right|^2\right) = E\left(\frac{\alpha^2}{n^2} - \frac{\alpha}{n} + \frac{1}{4}\right) = \frac{E(\alpha^2)}{n^2} - \frac{E(\alpha)}{n} + \frac{1}{4} = \\ &= \frac{n^2 p^2}{n^2} + \frac{n p q}{n^2} - \frac{n p}{n} + \frac{1}{4} = \frac{1}{4n}, \text{ deoarece } p = q = \frac{1}{2} \end{aligned}$$

$$\text{Deci } P\left(\left|\frac{\alpha}{n} - \frac{1}{2}\right| < \frac{1}{100}\right) > 1 - \frac{10^4}{4n}$$

$$\text{Aflăm } n \text{ din inegalitatea } 1 - \frac{10^4}{4n} > 0,99 \implies n > 5^2 \cdot 10^4 \quad \square$$

3. O variabilă aleatoare X are $E(X) = 80$, $E_2(X) = 6416$. Să se determine o limită inferioară a probabilității $P(40 < X < 120)$.

Soluție. $40 < X < 120 \iff 80 - 40 < X < 80 + 40 \iff -40 < X - 80 < 40 \iff |X - 80| < 40 \implies P(40 < X < 120) = P(|X - 80| < 40)$

Folosim inegalitatea lui Cebîșev și luăm $\varepsilon = 40$

$$\text{Calculăm } D^2(X) = E_2(X) - (E(X))^2 = 16$$

$$\text{Avem } P(|X - 80| < 40) > 1 - \frac{16}{1600} = 0,99 \quad \square$$

4. Limita superioară a probabilității ca abaterile, în modul, ale valorilor v. a. X față de medie, să fie mai mare decât 3, este 0,96. Să se afle $D^2(X)$.

Soluție. Folosim inegalitatea lui Cebîșev :

$$P(|X - E(X)| \geq \varepsilon) < \frac{D^2(X)}{\varepsilon^2}$$

$$P(|X - E(X)| \geq 3) < \frac{D^2(X)}{9} = 0,96 \implies D^2(X) = 8,64 \quad \square$$

5. Cu ce probabilitate putem afirma că din 100 de aruncări ale unei monede, stema apare de un număr de ori cuprins între 40 și 60?

Soluție. Aplicăm formula lui Moivre-Laplace:

$$\begin{aligned} P\left(\alpha \leq \frac{X_n - np}{\sqrt{npq}} \leq \beta\right) &\simeq \Phi(\beta) - \Phi(\alpha) \iff P\left(\alpha \leq \sqrt{\frac{n}{pq}}(X_n - p) \leq \beta\right) \simeq \\ &\simeq \Phi(\beta) - \Phi(\alpha), \text{ unde } X_n \text{ e v. a. ce ne dă numărul de apariții ale stemei când aruncăm moneda de } n \text{ ori} \end{aligned}$$

$$\begin{aligned} \text{Avem } p = q = \frac{1}{2}, n = 100 \implies \alpha &= \sqrt{\frac{100}{\frac{1}{2} \cdot \frac{1}{2}}}(0,4 - 0,5) = -2, \beta = \\ &= \sqrt{\frac{100}{\frac{1}{2} \cdot \frac{1}{2}}}(0,6 - 0,5) = 2 \end{aligned}$$

$$\text{Atunci } P(0,4 \leq X_n \leq 0,6) \simeq \Phi(2) - \Phi(-2) = 2\Phi(2) - 1 \simeq 2 \cdot 0,9772 - 1 = 0,9544 \quad \square$$

6. De câte ori trebuie aruncată o monedă pentru ca să putem spune cu o probabilitate de 0,6 că abaterea frecvenței de apariție a stemei de la probabilitatea $p = \frac{1}{2}$ să fie mai mică decât 0,01?

Soluție. Cf. teoremei Moivre-Laplace avem $P\left(\sqrt{\frac{n}{pq}}|X_n - p| \leq \beta\right) \simeq 2\Phi(\beta) - 1$

$$\text{Stim } 2\Phi(\beta) - 1 = 0,6 \implies \Phi(\beta) = 0,8 \implies \beta = 0,84$$

$$\text{Dar } 0,84 = \sqrt{\frac{n}{\frac{1}{2} \cdot \frac{1}{2}}} \cdot 0,01 \implies n = 1764 \quad \square$$

7. Se aruncă de 360 de ori o pereche de zaruri. Cu ce probabilitate ne putem aștepta să apară 12 puncte (dubla 6) de un număr de ori cuprins între 8 și 12?

Soluție. Probabilitatea ca să apară 12 puncte într-o aruncare cu 2 zaruri este $p = \frac{1}{36}$, iar probabilitatea ca să nu apară 12 puncte este $q = 1 - p = \frac{35}{36}$

Cf. teoremei Moivre-Laplace $\Rightarrow P(\alpha \leq \sqrt{\frac{n}{pq}}(X_n - p) \leq \beta) \simeq \Phi(\beta) - \Phi(\alpha)$

$$n = 360, \alpha = \sqrt{\frac{360}{\frac{1}{36} \cdot \frac{35}{36}}} \cdot \left(\frac{8}{360} - \frac{1}{36}\right) = -\frac{6}{5\sqrt{3,5}} \simeq -0,641, \beta = \sqrt{\frac{360}{\frac{1}{36} \cdot \frac{35}{36}}} \cdot \left(\frac{12}{360} - \frac{1}{36}\right) = \frac{6}{5\sqrt{3,5}} \simeq 0,641$$

$$P\left(-\frac{6}{5\sqrt{3,5}} \leq X_n - \frac{1}{36} \leq \frac{6}{5\sqrt{3,5}}\right) \simeq 2\Phi(\beta) - 1 = 2 \cdot 0,7389 - 1 = 0,48 \quad \square$$

8. Probabilitatea ca o anumită operație chirurgicală să fie un succes este 0,8. Dacă operația este făcută la 120 de persoane, găsiți probabilitatea ca mai mult de 90 de operații să aibă succes?

Soluție. Dacă X este v. a. binomială ce reprezintă numărul de operații cu succes, atunci vrem să aflăm probabilitatea $P(X \geq 90)$.

Cum n e mare, vom folosi distribuția normală cu $m = 120 \cdot 0,8 = 96$ și $\sigma = \sqrt{120 \cdot 0,8 \cdot 0,2} = 4,38$ pentru a aproxima distribuția binomială a lui X .

$$\text{Obtinem } P(X \geq 90) = P\left(\frac{X-96}{4,38} \geq \frac{90-96}{4,38}\right) = P\left(\frac{X-96}{4,38} \geq -1,37\right) = 1 - P\left(\frac{X-96}{4,38} < -1,37\right) = 1 - \Phi(-1,37) = 0,9147. \quad \square$$

9. Probabilitatea obținerii unei piese rebut din producția unei mașini automate este $p = 0,005$. Să se determine probabilitatea ca din 10000 de piese fabricate la această mașină, numărul pieselor rebut să fie:
- între 60 și 70;
 - cel mult 70.

Soluție. Fie $X_k \sim \begin{pmatrix} 0 & 1 \\ 0,995 & 0,005 \end{pmatrix}, k \in \mathbb{N}^*$ și $S_n = \sum_{k=1}^n X_k$

S_n reprezintă numărul de piese rebut; este o v. a. cu o repartiție binomială de parametrii $n = 10000, p = 0,005$. Deci $E(S_n) = np = 50, D^2(S_n) = npq = 49,75, \sigma = \sqrt{D^2(S_n)} \approx 7$

Cf. teoremei Moivre-Laplace, repartiția limită a repartiției binomiale este repartiția normală de parametrii np și \sqrt{npq} și rezultă că

$$P(a \leq S_n \leq b) \simeq \Phi\left(\frac{b-np}{\sqrt{npq}}\right) - \Phi\left(\frac{a-np}{\sqrt{npq}}\right)$$

$$\begin{aligned} \text{a)} P(60 \leq S_n \leq 70) &\simeq \Phi\left(\frac{70-50}{7}\right) - \Phi\left(\frac{60-50}{7}\right) = \Phi\left(\frac{20}{7}\right) - \Phi\left(\frac{10}{7}\right) = \\ &= 0,49788 - 0,42364 \simeq 0,07 \\ \text{b)} P(0 \leq S_n \leq 70) &\simeq \Phi\left(\frac{70-50}{7}\right) - \Phi\left(-\frac{50}{7}\right) \simeq 0,997 \quad \square \end{aligned}$$

10. 500 de aparate de tipul I și 1000 de aparate de tipul II cu aceeași destinație sunt în serviciu. Ele trebuie reparate după exploatare cu probabilitatea de 0,3 pentru tipul I și de 0,4 pentru tipul II.
- 1) Să se determine probabilitatea ca numărul de aparate ce trebuie reparate să fie cuprins între 250 și 350;
 - 2) Să se determine numărul de reparații n ce trebuie efectuate în atelier pentru ca probabilitatea p a numărului de aparate în reparație să fie $p = 0,9$.

Soluție. 1) Fie evenimentul $A =$ aparatul trebuie reparat și $X =$ numărul de apariții ale evenimentului A ; X este o v. a. repartizată normal

$$\text{Atunci } E(X) = 500 \cdot 0,3 + 1000 \cdot 0,4 = 550, D^2(X) = 500 \cdot 0,3 \cdot 0,7 + 1000 \cdot 0,4 \cdot 0,6 = 345$$

$$\begin{aligned} P(250 \leq X \leq 350) &\simeq P(250 < X < 350) = P(|X - 300| < 50) = \\ &= 2\Phi\left(\frac{50}{\sqrt{345}}\right) - 1 \end{aligned}$$

$$2) P(X < n) = 0,9 = \Phi\left(\frac{n-300}{\sqrt{345}}\right)$$

$$\text{Din tabele } \Phi(1,27) \simeq 0,9 \implies \frac{n-300}{\sqrt{345}} = 1,27 \implies n \simeq 323 \quad \square$$

11. O întreprindere fabrică un anumit produs cu 5% rebuturi. Ce comandă trebuie să facă un beneficiar pentru ca, cu probabilitatea 0,8, să nu achiziționeze mai mult de 4 produse defecte?

Soluție. Fie $X =$ numărul de produse fără defecte achiziționate dintr-o comandă de n produse

$$\text{Cf. teoremei Moivre-Laplace} \implies 0,8 = P(X \geq 5) \simeq 1 - \Phi\left(\frac{5-0,05n}{\sqrt{0,05 \cdot 0,95 \cdot n}}\right)$$

$$\text{Din tabel } \Phi(0,84) \simeq 0,8$$

$$\text{Deci } \frac{5-0,05n}{\sqrt{0,05 \cdot 0,95 \cdot n}} = -0,84 \implies n \simeq 144 \text{ (deoarece } \Phi(0,84) = 1 - \Phi(-0,84)) \quad \square$$

12. Presupunem că 120 de persoane stau la coada unei casierii pentru a-și primi drepturile bănești. Sumele care trebuie primite de fiecare sunt v. a. X_1, \dots, X_{120} independente și identic repartizate cu media $m = 50$ și abaterea standard $\sigma = 30$. Casieria dispune de 6500 unități monetare. Calculați probabilitatea ca toate persoanele să-și primească drepturile.

Soluție. Notăm $S = X_1 + \dots + X_{120}$

$$\begin{aligned} S &\text{ poate fi aproximată cu o v. a. normală cu } E(S) = E\left(\sum_{k=1}^{120} X_k\right) = \\ &= \sum_{k=1}^{120} E(X_k) = 120 \cdot 50 = 6000 \text{ și } D^2(S) = D^2\left(\sum_{k=1}^{120} X_k\right) = \sum_{k=1}^{120} D^2(X_k) = \\ &= 120 \cdot 30^2 = 108000 \\ \text{Atunci } P(S \leq 6500) &\simeq \Phi\left(\frac{6500 - 6000}{\sqrt{108000}}\right) \simeq 0,936 \quad \square \end{aligned}$$

13. La un restaurant pot servi prânzul 75 de clienți. Din practică, proprietarul știe că 20% dintre clienții care au rezervat loc nu se mai prezintă.
- Proprietarul acceptă 90 de rezervări. Care este probabilitatea ca să se prezinte mai mult de 50 de clienți?
 - Câte rezervări trebuie să accepte proprietarul pentru ca, cu o probabilitate mai mare sau egală cu 0,9, să poată servi toți clienții care se prezintă? ($\Phi(1,281) = 0,9$)

Soluție. a) Fie X v. a. ce reprezintă numărul de clienți care se prezintă la restaurant; X este repartizată binomial cu $p = 0,8$.

$$\begin{aligned} \text{Avem } n &= 90, E(X) = np = 72, D^2(X) = npq = 14,4 \implies \sigma = \\ &= \sqrt{14,4} \simeq 3,795 \end{aligned}$$

$$\begin{aligned} \text{Cf. th. Moivre-Laplace obținem } P(X > 50) &= 1 - P(X \leq 50) = 1 - \\ &- P\left(\frac{X-np}{\sigma} \leq \frac{50-72}{3,795}\right) = 1 - \Phi(-5,797) = 1 - 1 + \Phi(5,975) = \Phi(5,975) \simeq \\ &\simeq 1 \end{aligned}$$

b) Vom determina n astfel încât $P(X \leq 75) \geq 0,9$

$$P(X \leq 75) = P\left(\frac{X-np}{\sqrt{npq}} \leq \frac{75-0,8n}{\sqrt{0,16n}}\right) \geq 0,9 = \Phi(1,281) \implies \frac{75-0,8n}{\sqrt{0,16n}} \geq 1,281 \implies n < 88 \quad \square$$

14. Probabilitatea de câștig la ruletă este de $\frac{1}{35}$. Presupunem că la fiecare joc, un jucător poate câștiga sau pierde 1 dolar.
- Câte jocuri trebuie jucate zilnic în cazino astfel încât cu probabilitatea 0,5, câștigul cazinoului să fie cel puțin 1000 dolari zilnic. ($\Phi(0) = 0,5$)
 - Să se determine apoi procentul zilelor în care cazinoul pierde.

Soluție. a) Fie X_i v. a. ce reprezintă profitul cazinoului într-o zi; $X_i \sim \begin{pmatrix} 0 & 1 \\ \frac{34}{35} & \frac{1}{35} \end{pmatrix}$

$$\begin{aligned}
P\left(\sum_{i=1}^n X_i > 1000\right) &= 1 - P\left(\sum_{i=1}^n X_i \leq 1000\right) = 1 - \\
&- P\left(\frac{\sum_{i=1}^n X_i - n \cdot \frac{1}{35}}{\sqrt{n \cdot \frac{1}{35} \cdot \frac{34}{35}}} \leq \frac{1000 - n \cdot \frac{1}{35}}{\sqrt{n \cdot \frac{1}{35} \cdot \frac{34}{35}}}\right) = 1 - \Phi\left(\frac{1000 - n \cdot \frac{1}{35}}{\sqrt{n \cdot \frac{1}{35} \cdot \frac{34}{35}}}\right) = 0,5 \Rightarrow \\
&\Rightarrow \Phi\left(\frac{1000 - n \cdot \frac{1}{35}}{\sqrt{n \cdot \frac{1}{35} \cdot \frac{34}{35}}}\right) = 0,5 \Rightarrow \frac{1000 - n \cdot \frac{1}{35}}{\sqrt{n \cdot \frac{1}{35} \cdot \frac{34}{35}}} = 0 \Rightarrow n = 35000 \\
\text{b)} \quad P\left(\sum_{i=1}^{35000} X_i < 0\right) &= \Phi\left(\frac{-1000}{\sqrt{35000 \cdot \frac{1}{35} \cdot \frac{34}{35}}}\right) \simeq 0 \quad \square
\end{aligned}$$

15. Calitatea unor piese este apreciată prin caracteristica X care este repartizată normal cu media 10 cm și abaterea medie pătratică 0,15 cm. Piezele sunt acceptate numai dacă valorile caracteristicii X sunt cuprinse în intervalul (9,8 cm, 10,2 cm). Firma producătoare are o comandă de 3000 de piese. Să se determine numărul de piese care trebuie să fie produse de firmă astfel încât să se poată onora contractul.

Soluție. Fie n numărul de piese care trebuie să fie produse de firmă astfel încât contractul să fie onorat, x numărul pieselor contractate și p probabilitatea realizării evenimentului ($9,8 \text{ cm} < X < 10,2 \text{ cm}$)

Cf. teoremei lui Bernoulli, pentru n suficient de mare se poate considera $n \approx x \cdot \frac{1}{p}$

$$P(9,8 < X < 10,2) = \Phi\left(\frac{10,2 - 10}{0,15}\right) - \Phi\left(\frac{9,8 - 10}{0,15}\right) = 0,81$$

$$\text{Deci } n = 3000 \cdot \frac{1}{0,81} = 3690 \quad \square$$

16. Pentru un studiu biologic sunt cercetate 1000 de probe independente, dacă au sau nu o anumită caracteristică biologică. Să se determine o margine inferioară a probabilității ca diferența, în valoare absolută, dintre frecvența relativă și probabilitatea p de a apărea caracteristica într-o probă, să fie mai mică decât 0,03.

Soluție. Cf. consecinței teoremei lui Bernoulli $\Rightarrow p = q = \frac{1}{2}, \varepsilon = 0,03 \Rightarrow P(|\frac{x}{n} - p| < 0,03) \geq 1 - \frac{pq}{n\varepsilon^2} = 1 - \frac{\frac{1}{2} \cdot \frac{1}{2}}{1000 \cdot 0,03^2} = 0,72 \quad \square$

17. Fie sirurile de variabile aleatoare definite pe același câmp de probabilitate $(X_n)_{n \geq 1}, (Y_n)_{n \geq 1}, (Z_n)_{n \geq 1}$, unde $X_n \sim \begin{pmatrix} -5n & 0 & 5n \\ \frac{1}{3n^2} & 1 - \frac{2}{3n^2} & \frac{1}{3n^2} \end{pmatrix}$,

$Y_n \sim \begin{pmatrix} -n^2 & 0 & n^2 \\ \alpha^{-n} & 1 - 2\alpha^{-n} & \alpha^{-n} \end{pmatrix}$ și Z_n are densitatea de repartiție

$$f_n(x) = \begin{cases} \lambda^{-n} e^{-\frac{x}{\lambda^n}}, & x > 0 \\ 0, & \text{în rest} \end{cases}$$

$\forall n \geq 1, \lambda > 0$. Să se verifice aplicabilitatea teoremei lui Cebîșev celor trei řiruri.

Soluție. Teorema este aplicabilă dacă media e finită și dispersia este egal mărginită .

$$\begin{aligned} E(X_n) &= (-5n) \cdot \frac{1}{3n^2} + 0 \cdot (1 - \frac{2}{3n^2}) + 5n \cdot \frac{1}{3n^2} = 0, E(X_n^2) = (-5n)^2 \cdot \frac{1}{3n^2} + 0^2 \cdot (1 - \frac{2}{3n^2}) + (5n)^2 \cdot \frac{1}{3n^2} = \frac{50}{3}, D^2(X_n) = \frac{50}{3} \implies \text{teorema se aplică} \end{aligned}$$

$$\begin{aligned} E(Y_n) &= (-n^2) \cdot \alpha^{-n} + 0 \cdot (1 - 2\alpha^{-n}) + n^2 \cdot \alpha^{-n} = 0, E(Y_n^2) = \\ &= (-n^2)^2 \cdot \alpha^{-n} + 0^2 \cdot (1 - 2\alpha^{-n}) + (n^2)^2 \cdot \alpha^{-n} = \frac{2n^4}{\alpha^n}, D^2(Y_n) = \frac{2n^4}{\alpha^n} \implies \\ &\implies \lim_{n \rightarrow \infty} D^2(Y_n) = 0 \implies \exists c \in (0, \infty) \text{ astfel încât } \forall n \geq 1, D^2(Y_n) \leq \\ &\leq c \implies \text{teorema se aplică} \end{aligned}$$

$$\begin{aligned} E(Z_n) &= \int_0^\infty x \lambda^{-n} e^{-\frac{x}{\lambda^n}} dx = \lambda^n, E(Z_n^2) = \int_0^\infty x^2 \lambda^{-n} e^{-\frac{x}{\lambda^n}} dx = 2\lambda^{2n} \implies \\ &\implies D^2(Z_n) = \lambda^{2n} \implies \end{aligned}$$

$$\lim_{n \rightarrow \infty} D^2(Z_n) = \begin{cases} 0, & \lambda \in (0, 1) \\ 1, & \lambda = 1 \\ \infty, & \lambda > 1 \end{cases}$$

deci teorema se aplică numai dacă $\lambda \in (0, 1]$

□

18. Fie $(X_n)_{n \geq 1}$ un řir de variabile aleatoare independente ce pot lua valoile $\pm \sqrt{\lg n}$ cu probabilitățile $P(X_k = \sqrt{\lg k}) = P(X_k = -\sqrt{\lg k}) = = \frac{1}{2}, k = 2, 3, \dots, P(X_1 = 0) = 1$. Să se arate că řirul dat se supune legii numerelor mari în formularea lui Cebîșev.

Soluție. Se constată că $E(X_k) = \sqrt{\lg k} \cdot \frac{1}{2} + (-\sqrt{\lg k}) \cdot \frac{1}{2} = 0, E(X_k^2) = (\sqrt{\lg k})^2 \cdot \frac{1}{2} + (-\sqrt{\lg k})^2 \cdot \frac{1}{2} = \lg k, D^2(X_k) = \lg k, k = 2, 3, \dots$

$$\text{Luăm } Y_n = \frac{1}{n} \sum_{k=1}^n X_k \implies E(Y_n) = \frac{1}{n} \sum_{k=1}^n E(X_k) = 0$$

$$D^2(Y_n) = \frac{1}{n^2} \sum_{k=1}^n D^2(X_k) = \frac{1}{n^2} \sum_{k=1}^n \lg k$$

$D^2(Y_n)$ poate fi majorată astfel:

$$\begin{aligned} \sum_{k=1}^n \lg k &< \int_1^{n+1} \lg x dx = x \lg x |_1^{n+1} - \int_1^{n+1} dx = (n+1) \lg(n+1) - \\ &- n \implies D^2(Y_n) < \frac{(n+1) \lg(n+1)}{n^2} \implies \lim_{n \rightarrow \infty} D^2(Y_n) = 0 \end{aligned}$$

Sunt îndeplinite condițiile teoremei Markov și rezultă

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \varepsilon \right) = 1 \implies \text{șirului dat i se poate aplica legea numerelor mari} \quad \square$$

19. Fie $(X_n)_{n \geq 1}$ un sir de variabile aleatoare independente astfel încât $P(X_n = \frac{1}{n^\beta}) = P(X_n = -\frac{1}{n^\beta}) = p$, cu $\frac{1}{3} < \beta \leq \frac{1}{2}$, $n \in \mathbb{N}^*$ și $P(X_n = 0) = 1 - 2p$. Să se arate că sirului $(X_n)_{n \geq 1}$ i se poate aplica teorema lui Leapunov.

Soluție. Obținem $E(X_k) = \frac{1}{k^\beta} \cdot p + (-\frac{1}{k^\beta}) \cdot p = 0$, $E(X_k^2) = (\frac{1}{k^\beta})^2 \cdot p + + (-\frac{1}{k^\beta})^2 \cdot p = \frac{2p}{k^{2\beta}} = \mu_k^2$, $E(|X_k|^3) = \frac{2p}{k^{3\beta}} = \rho_k^3 \implies \mu^2(n) = \sum_{k=1}^n \mu_k^2 =$

$$= 2p \sum_{k=1}^n \frac{1}{k^{2\beta}}, \rho^3(n) = \sum_{k=1}^n \rho_k^3 = 2p \sum_{k=1}^n \frac{1}{k^{3\beta}}$$

Cum $\frac{1}{3} < \beta \leq \frac{1}{2} \implies 1 < 3\beta \leq \frac{3}{2} \implies \lim_{n \rightarrow \infty} \sum_{k=1}^n \frac{1}{k^{3\beta}} = \sum_{k=1}^{\infty} \frac{1}{k^{3\beta}}$ e o serie convergentă

$$\sum_{k=1}^n \frac{1}{k^{2\beta}} > \sum_{k=1}^n \frac{1}{k} \text{ ce tinde la } \infty \text{ când } n \rightarrow \infty$$

Condiția lui Leapunov $\lim_{n \rightarrow \infty} \frac{\sqrt[3]{\rho(n)^3}}{\sqrt{\mu(n)^2}} = 0$ e îndeplinită \implies sirului $(X_n)_{n \geq 1}$ i se poate aplica teorema lui Leapunov \square

20. Fie $(X_n)_{n \geq 1}$ un sir de variabile aleatoare independente pentru care $P(X_n = 3^{n-1}) = P(X_n = -3^{n-1}) = \frac{1}{2}$, $n = 1, 2, 3, \dots$. Dacă notăm cu $Y_n = \frac{1}{S_n} \sum_{k=1}^n X_k$, unde $S_n = D^2(\sum_{k=1}^n X_k)$, să se arate că Y_n nu converge în probabilitate către 0.

Soluție. Avem $E(X_k) = 3^{k-1} \cdot \frac{1}{2} + (-3^{k-1}) \cdot \frac{1}{2} = 0$, $E(X_k^2) = (3^{k-1})^2 \cdot \frac{1}{2} + (-3^{k-1})^2 \cdot \frac{1}{2} = 3^{2(k-1)}$, $D^2(X_k) = 3^{2(k-1)}$

$$D^2(\sum_{k=1}^n X_k) = \sum_{k=1}^n D^2(X_k) = \sum_{k=1}^n 3^{2(k-1)} = \frac{3^{2n} - 1}{3^2 - 1} = \frac{9^n - 1}{8}$$

$$|X_n| = |X_n + X_{n-1} - X_{n-1}| \leq |X_n + X_{n-1}| + |X_{n-1}| \leq |X_n + X_{n-1} + \dots + X_1| + |X_{n-1}| + \dots + |X_1| \implies |Y_n| \geq \frac{|X_n| - |X_1| - |X_2| - \dots - |X_{n-1}|}{S_n} = \\ = \frac{3^{n-1} - (1+3+\dots+3^{n-2})}{\sqrt{\frac{9^n - 1}{8}}} > \frac{\sqrt{2}}{3} \implies P(|Y_n| > \frac{\sqrt{2}}{3}) = 1 \implies P(|Y_n| > \varepsilon) \text{ nu}$$

tinde la 0, dacă $\varepsilon \leq \frac{\sqrt{2}}{3} \implies (Y_n)_n$ nu converge în probabilitate către 0 \square

21. Dacă funcțiile de repartiție corespunzătoare șirului de variabile $(X_n)_n$ tind către o repartiție limită și dacă șirul $(Y_n)_n$ converge în probabilitate la 0, atunci șirul $(X_n Y_n)_n$ converge în probabilitate către 0.

Soluție. Fie $a \in \mathbb{R}, a > 0 \implies \{\omega / |X_n(\omega)Y_n(\omega)| > \varepsilon\} \subset \{\omega / |X_n(\omega)| > a\} \cup \{\omega / |Y_n(\omega)| > \frac{\varepsilon}{a}\} \implies P(\{\omega / |X_n(\omega)Y_n(\omega)| > \varepsilon\}) \leq P(\{\omega / |X_n(\omega)| > a\}) + P(\{\omega / |Y_n(\omega)| > \frac{\varepsilon}{a}\}) \leq P(X_n(\omega) < -a) + 1 - P(X_n(\omega) \leq a) + P(|Y_n(\omega)| > \frac{\varepsilon}{a}) \leq F_n(-a) + 1 - F_n(a) + P(|Y_n(\omega)| > \frac{\varepsilon}{a})$

Dacă a e luat astfel încât $-a$ și a să fie puncte de continuitate pentru funcția de repartiție limită F , atunci din ipoteză obținem

$$\limsup_{n \rightarrow \infty} P(\{\omega / |X_n(\omega)Y_n(\omega)| > \varepsilon\}) \leq F(-a) + 1 - F(a)$$

Alegem a astfel încât $-a$ și a să fie puncte de continuitate pentru F și, în plus, să avem $F(-a) < \frac{\delta}{2}, 1 - F(a) < \frac{\delta}{2}$ cu $\delta > 0 \implies \limsup_{n \rightarrow \infty} P(\{\omega / |X_n(\omega)Y_n(\omega)| > \varepsilon\}) \leq \delta$

Cum δ e arbitrar $\implies (X_n Y_n)_n$ converge în probabilitate către 0 \square

22. Fie $(X_n)_n$ un șir de variabile aleatoare Poisson, independente cu $E(X_k) = \lambda_k$ și $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$. Să se arate că dacă există $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n \lambda_k = \lambda$, atunci șirul de variabile aleatoare $(Y_n)_n$ converge în probabilitate către λ .

Soluție. Cum $(X_n)_n$ un șir de variabile aleatoare Poisson $\implies \lambda_k = E(X_k) = D^2(X_k)$

$$\begin{aligned} \text{Cum variabilele } X_n \text{ sunt independente} \implies D^2(Y_n) &= \frac{1}{n^2} \sum_{k=1}^n D^2(X_k) = \\ &= \frac{1}{n^2} \sum_{k=1}^n \lambda_k = \frac{1}{n} \cdot \frac{\sum_{k=1}^n \lambda_k}{n} \longrightarrow 0, \text{ când } n \longrightarrow \infty \end{aligned}$$

$$E(Y_n) = \frac{1}{n} \sum_{k=1}^n E(X_k) = \frac{1}{n} \sum_{k=1}^n \lambda_k \longrightarrow \lambda$$

Folosind inegalitatea lui Cebîșev $\implies 0 \leq P(|Y_n - \lambda| \geq \varepsilon) < \frac{D^2(Y_n)}{\varepsilon^2} \longrightarrow 0$, deci $P(|Y_n - \lambda| \geq \varepsilon) \longrightarrow 0 \implies (Y_n)_n$ converge în probabilitate către 0 \square

23. Fie $(X_n)_n$ un sir de v. a. independente astfel încât $P(X_n = 1) = 1 - \frac{1}{n}$, $P(X_n = n) = \frac{1}{n}$, $n > 1$. Să se arate că $(X_n)_n$ converge în probabilitate la 1, când $n \rightarrow \infty$, dar $(X_n)_n$ nu converge aproape sigur la 1, când $n \rightarrow \infty$.

Soluție. $\forall \varepsilon > 0, P(|X_n - 1| > \varepsilon) = P(X_n = n) = \frac{1}{n} \rightarrow 0 \implies X_n \xrightarrow{P} 1$

$X_n \xrightarrow{a.s.} X \iff \forall \varepsilon > 0, \forall \delta \in (0, 1) \exists n_0$ astfel încât $\forall n > n_0$ avem $P(\bigcap_{m>n} \{|X_m - X| < \varepsilon\}) > 1 - \delta$ (1)

Pentru $\forall \varepsilon > 0, \delta \in (0, 1), N > n$ obținem $P(\bigcap_{m>n} \{|X_m - 1| < \varepsilon\}) \leq$
 $\leq P(\bigcap_{m=n+1}^N \{|X_m - 1| < \varepsilon\}) = \prod_{m=n+1}^N P(|X_m - 1| < \varepsilon) =$
 $= \prod_{m=n+1}^N P(X_m = 1) = \prod_{m=n+1}^N \left(1 - \frac{1}{m}\right) = \frac{n}{N} < 1 - \delta$ cu condiția să
alegem N astfel încât $N > \frac{n}{1-\delta} \implies$ nu există n_0 astfel încât să aibă
loc (1) $\implies (X_n)_n$ nu converge aproape sigur la 1, când $n \rightarrow \infty$ \square

24. Fie $\alpha > 0$ și $(X_n)_n$ un sir de v. a. astfel încât $P(X_n = 1) = 1 - \frac{1}{n^\alpha}$, $P(X_n = n) = \frac{1}{n^\alpha}$, $n > 1$. Să se arate că $(X_n)_n$ converge în probabilitate la 1 și $(X_n)_n$ converge în medie de ordinul r la 1, când $r < \alpha$, dar $(X_n)_n$ nu converge în medie de ordinul r la 1, când $r \geq \alpha$.

Soluție. $P(|X_n - 1| > \varepsilon) = P(X_n = n) = \frac{1}{n^\alpha} \rightarrow 0 \implies X_n \xrightarrow{P} 1$

Cum $E(|X_n - 1|^r) = 0 \cdot \left(1 - \frac{1}{n^\alpha}\right) + |n - 1|^r \cdot \frac{1}{n^\alpha} = \frac{(n-1)^r}{n^\alpha} \implies$

$$E(|X_n - 1|^r) \rightarrow \begin{cases} 0, & r < \alpha \\ 1, & r = \alpha \\ \infty, & r > \alpha \end{cases}$$

\square

25. Fie $(X_n)_n$ un sir de v. a. având repartiția $X_n \sim \begin{pmatrix} -n^{\frac{2}{r}} & 0 & n^{\frac{2}{r}} \\ \frac{1}{2n^2} & 1 - \frac{1}{n^2} & \frac{1}{2n^2} \end{pmatrix}$.
Să se arate că $(X_n)_n$ converge aproape sigur către 0.

Soluție. $A_{j,\delta} = \{\omega / |X_j(\omega)| \leq \delta\}$

$$B_{n,\delta} = \bigcap_{j=n}^{\infty} A_{j,\delta}$$

$$B_{n,\delta}^c = \bigcup_{j=n}^{\infty} A_{j,\delta}^c$$

$$P(B_{n,\delta}^c) = P\left(\bigcup_{j=n}^{\infty} A_{j,\delta}^c\right) \leq \sum_{j=n}^{\infty} P(A_{j,\delta}^c) = \sum_{j=n}^{\infty} P(|X_j(\omega)| > \delta)$$

Din definiția șirului $(X_n)_n \implies$ pentru $n \geq 1, \delta < 1$ avem $P(|X_j(\omega)| > \delta) = P(X_j(\omega) = -j^{\frac{2}{r}}) + P(X_j(\omega) = j^{\frac{2}{r}}) = \frac{1}{j} \implies P(B_{n,\delta}) \leq \sum_{j=n}^{\infty} \frac{1}{j^2} \rightarrow \rightarrow 0$ (când $n \rightarrow \infty$)

$$\lim_{n \rightarrow \infty} P(B_{n,\delta}) = \lim_{n \rightarrow \infty} P\left(\bigcap_{j=n}^{\infty} \{\omega / |X_j(\omega)| \leq \delta\}\right) = 1$$

□

26. Fie $(X_n)_n$ un șir de v. a. pozitive cu densitățile de repartiție date de

$$f_n(x) = \begin{cases} \frac{x^{n-1} e^{-x}}{(n-1)!}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Să se arate că șirul $\left(\frac{X_n - E(X_n)}{\sqrt{D^2(X_n)}} \right)_n$ urmează la limită o lege normală $N(0, 1)$.

$$Soluție. E(X_n) = \frac{1}{(n-1)!} \int_0^\infty x^n e^{-x} dx = \frac{\Gamma(n+1)}{(n-1)!} = n$$

$$E(X_n^2) = \frac{1}{(n-1)!} \int_0^\infty x^{n+1} e^{-x} dx = \frac{\Gamma(n+2)}{(n-1)!} = n(n+1)$$

$$D^2(X_n) = n(n+1) - n^2 = n$$

$$\text{Șirul } Y_n = \frac{X_n - E(X_n)}{\sqrt{D^2(X_n)}} \text{ devine } Y_n = \frac{X_n - n}{\sqrt{n}} = \frac{1}{\sqrt{n}} X_n - \sqrt{n}$$

Dacă notăm $\varphi_n(t)$ funcția caracteristică a v. a. Y_n și reușim să arătăm că $\lim_{n \rightarrow \infty} \varphi_n(t) = e^{-\frac{t^2}{2}}$, demonstrația s-a încheiat, deoarece folosim teorema ce leagă între ele șirurile de funcții de repartiție și cele caracteristice corespunzătoare unui șir de v. a.

Folosind definiția funcției caracteristice avem

$$\begin{aligned} \varphi_n(t) &= \int_0^\infty e^{it\left(\frac{x}{\sqrt{n}} - \sqrt{n}\right)} f_n(x) dx = e^{-it\sqrt{n}} \cdot \frac{1}{(n-1)!} \int_0^\infty x^{n-1} e^{-\left(1 - \frac{it}{\sqrt{n}}\right)x} dx = \\ &= e^{-it\sqrt{n}} \left(1 - \frac{it}{\sqrt{n}}\right)^{-n} \text{ (cu ajutorul funcției } \Gamma) \end{aligned}$$

$$\begin{aligned} \ln \varphi_n(t) &= -it\sqrt{n} - n \ln \left(1 - \frac{it}{\sqrt{n}}\right) = -it\sqrt{n} + n \cdot \left(\frac{it}{\sqrt{n}} - \frac{t^2}{2n} + o(n)\right) = \\ &= -\frac{t^2}{2} + o'(n), \text{ dacă } \left|\frac{t}{\sqrt{n}}\right| < 1 \end{aligned}$$

$$\begin{aligned} \text{Cum } \lim_{n \rightarrow \infty} \ln \varphi_n(t) = -\frac{t^2}{2} \implies \lim_{n \rightarrow \infty} \varphi_n(t) = e^{-\frac{t^2}{2}} \implies \\ \implies \lim_{n \rightarrow \infty} P \left(\frac{X_n(\omega) - E(X_n)}{\sqrt{D^2(X_n)}} < x \right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt \end{aligned} \quad \square$$

27. Se știe că dacă $(X_n)_{n \in \mathbb{N}^*}$ este un sir de v. a. convergent în medie pătratică, atunci $\lim_{n \rightarrow \infty} E(X_n) = E(X)$ și $\lim_{n \rightarrow \infty} E(X_n^2) = E(X^2)$, unde $X = \lim_{n \rightarrow \infty} X_n$. Să se arate că dacă se înlocuiește condiția de convergență în medie pătratică cu convergența în probabilitate, afirmația nu mai este adevărată.

Soluție. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. care pot lua valorile $-(n+4), -1, n+4$ cu probabilitățile $P(X_n = -n-4) = \frac{1}{n+4}, P(X_n = -1) = 1 - \frac{4}{n+4}, P(X_n = n+4) = \frac{3}{n+4}$

Avem $\lim_{n \rightarrow \infty} P(|X_n + 1| > \varepsilon) = 0$, ceea ce arată că sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în probabilitate către -1.

Pe de altă parte $E(X_n) = 1 + \frac{4}{n+4}$, deci $\lim_{n \rightarrow \infty} E(X_n) = 1$, de unde rezultă concluzia că $\lim_{n \rightarrow \infty} E(X_n) = 1 \neq -1 = E(\lim_{n \rightarrow \infty} X_n)$. \square

28. Să se arate că există siruri de v. a. care converg atât în medie de ordinul r cât și aproape sigur.

Soluție. Fie sirul de v. a. $(X_n)_{n \in \mathbb{N}^*}$, unde $X_n \sim \begin{pmatrix} -\frac{1}{n} & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$. Deoarece $E(|X_n|^r) = \frac{1}{n^r}$ rezultă că $\lim_{n \rightarrow \infty} E(|X_n|^r) = 0$, ceea ce arată că sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în medie de ordinul r .

Fie $T_{j,\delta} = \{\omega / |X_j(\omega)| \leq \delta\}$

Din felul cum am definit sirul $(X_n)_{n \in \mathbb{N}^*}$ rezultă că pentru orice $j < k$ avem $|X_j| > |X_k|$.

Deci $\{\omega / |X_j(\omega)| \leq \delta\} \subset \{\omega / |X_k(\omega)| \leq \delta\} \implies T_{1,\delta} \subset T_{2,\delta} \subset \dots \subset T_{n,\delta} \subset T_{n+1,\delta} \subset \dots$

In acest caz $S_{n,\delta} = \bigcap_{j=n}^{\infty} T_{j,\delta} = T_{n,\delta}$

Fie $\delta > 0$ dat. Dacă $n > \frac{1}{\delta}$ din definiția sirului și din relațiile găsite avem $P(S_{n,\delta}) = P(T_{n,\delta}) = P(\{\omega / |X_n(\omega)| \leq \delta\}) = 1$, ceea ce înseamnă că $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur către 0. \square

29. Să se arate că poate există un sir de v. a. convergent în medie pătratică și care să nu fie convergent aproape sigur.

Soluție. Fie $(Y_n)_{n \in \mathbb{N}^*}$ un řir de v. a. independente care iau doar valorile -1, 0, 1 cu probabilită̄ile $P(Y_n = -1) = P(Y_n = 1) = \frac{1}{2\sqrt[4]{n}}$, $P(Y_n = 0) = 1 - \frac{1}{\sqrt[4]{n}}, n = 1, 2, \dots$

Pentru $n \geq 2$ definim evenimentul E_n ca fiind evenimentul ce constă în faptul că toți $Y_i = 0$ cu $n - \sqrt{n} \leq i < n$.

Probabilitatea acestui eveniment este, datorită independentei v. a. $(Y_n)_{n \in \mathbb{N}^*}$:

$$P(E_n) = \prod_{n - \sqrt{n} \leq i < n} P(Y_i = 0) = \prod_{n - \sqrt{n} \leq i < n} \left(1 - \frac{1}{\sqrt[4]{i}}\right)$$

Se știe că pentru orice număr real, $0 \leq b < 1$ este adevărată inegalitatea $1 - b \leq e^{-b}$.

$$- \sum_{n - \sqrt{n} \leq i < n} \frac{1}{\sqrt[4]{i}}$$

Utilizând acest fapt, putem scrie $P(E_n) \leq e^{-n + \sqrt{n}}$, de unde rezultă $\lim_{n \rightarrow \infty} P(E_n) = 0$.

Definim, cu ajutorul řirului $(Y_n)_{n \in \mathbb{N}^*}$ considerat mai înainte řirul de v. a. $(X_n)_{n \in \mathbb{N}^*}$ astfel :

$$X_1 = Y_1$$

$$X_n = \begin{cases} Y_n, & \text{dacă se realizează } E_n^c \\ \pm 1, & \text{cu probabilită̄i egale dacă se realizează evenimentul } E_n \end{cases}$$

pentru orice $n \geq 2$

Avem $E(X_n) = 0$ și $E(X_n^2) = P(E_n) + (1 - P(E_n)) \frac{1}{\sqrt[4]{n}}$ de unde $\lim_{n \rightarrow \infty} E(X_n^2) = 0$, adică $(X_n)_{n \in \mathbb{N}^*}$ converge în medie de ordinul 2 către 0. Să arătăm că řirul $(X_n)_{n \in \mathbb{N}^*}$ nu converge aproape sigur către 0.

Să presupunem că řirul $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur către 0.

Atunci, deoarece v. a. limită $X = 0$, rezultă că pentru orice $\delta < 1$ avem

$$T_{j,\delta} = \{\omega / |X_j(\omega)| \leq \delta\} = \{\omega / X_j(\omega) = 0\} = E_j^c \cap \{\omega / Y_j(\omega) = 0\}$$

Prin urmare $T_{j,\delta} \subset \{\omega / Y_j(\omega) = 0\}$ și $T_{j,\delta} \subset E_j^c$

Deoarece $S_{n,\delta} = \bigcap_{j=n}^{\infty} T_{j,\delta}$ va rezulta că putem scrie

$S_{[m-\sqrt{m}],\delta} = \bigcap_{j=[m-\sqrt{m}]}^{\infty} T_{j,\delta} \subset \bigcap_{j=[m-\sqrt{m}]}^{\infty} \{\omega / Y_j(\omega) = 0\} \subset E_m$, unde prin $[m - \sqrt{m}]$ înțelegem partea întreagă a numărului $m - \sqrt{m}$.

Mai departe putem scrie $S_{n,\delta} = \bigcap_{j=n}^{\infty} T_{j,\delta} \subset \bigcap_{j=n}^{\infty} E_j^c \subset E_n^c$.

Deoarece am presupus că sirul $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur, rezultă că pentru orice $\varepsilon > 0$ există un rang $N = N(\varepsilon)$ astfel încât $P(S_{n,\delta}) > 1 - \varepsilon$ pentru toți $n \geq N$.

Alegând pe m astfel încât $m - \sqrt{m} \geq N$ obținem
 $P(E_m) \geq P(S_{[m-\sqrt{m}],\delta}) > 1 - \varepsilon$, rezultat în contradicție cu
 $P(E_m^c) \geq P(S_{m,\delta}) > 1 - \varepsilon$ \square

30. Convergența aproape sigură nu implică convergența în medie de ordinul r .

Soluție. Fie $(X_n)_{n \in \mathbb{N}^*}$ un sir de v. a. cu repartițiile

$$X_n \sim \begin{pmatrix} -n^{\frac{2}{r}} & 0 & n^{\frac{2}{r}} \\ \frac{1}{2n^2} & 1 - \frac{1}{n^2} & \frac{1}{2n^2} \end{pmatrix}, r > 0, n \in \mathbb{N}^*$$

Fie $T_{j,\delta} = \{\omega / |X_j(\omega)| \leq \delta\}$, $S = \bigcap_{j=n}^{\infty} T_{j,\delta}$ și $S_{n,\delta}^c = \bigcup_{j=n}^{\infty} T_{j,\delta}^c$

$$\begin{aligned} \text{Atunci } P(S_{n,\delta}^c) &= P\left(\bigcup_{j=n}^{\infty} T_{j,\delta}^c\right) \leq \sum_{j=n}^{\infty} P(T_{j,\delta}^c) = \\ &= \sum_{j=n}^{\infty} P(\{\omega / |X_j(\omega)| > \delta\}) \end{aligned}$$

Din definiția sirului de v. a. $(X_n)_{n \in \mathbb{N}^*}$ urmează că pentru $n \geq 1$ și $\delta < 1$ avem $P(\{\omega / |X_j(\omega)| > \delta\}) = P(\{\omega / X_j(\omega) = -j^{\frac{2}{r}}\}) + P(\{\omega / X_j(\omega) = j^{\frac{2}{r}}\}) = \frac{1}{j^2}$, aşa că $P(S_{n,\delta}^c) \leq \sum_{j=n}^{\infty} \frac{1}{j^2}$

Deci $\lim_{n \rightarrow \infty} P(S_{n,\delta}^c) = \lim_{n \rightarrow \infty} P\left(\bigcap_{j=n}^{\infty} \{\omega / |X_j(\omega)| \leq \delta\}\right) = 1$, adică $(X_n)_{n \in \mathbb{N}^*}$ converge aproape sigur către 0.

Pe de altă parte, $E(|X_n|^r) = P(|X_n|^r \neq 0) + P(|X_n|^r = 0) = 1$, deci sirul $(X_n)_{n \in \mathbb{N}^*}$ nu converge în medie de ordinul r către 0. \square

31. Să se arate că dacă un sir de v. a. converge în probabilitate, nu rezultă că sirul dat converge aproape sigur.

Soluție. Considerăm câmpul de probabilitate (Ω, K, P) , unde $\Omega = [0, 1]$, $K = \mathcal{B}_{[0,1]}$, P măsura Lebesgue pe dreapta.

Pentru fiecare număr natural m vom considera sirul de v. a. $X_1^{(m)}, X_2^{(m)}, \dots, X_m^{(m)}$ definite astfel:

$$X_j^{(m)}(\omega) = \begin{cases} 1, & \text{dacă } \omega \in \left[\frac{j-1}{m}, \frac{j}{m}\right) \\ 0, & \text{în rest} \end{cases}$$

Punem $X_1^{(1)}(\omega) = 1, \omega \in [0, 1]$ și considerăm următorul sir de v. a. $X_1^{(1)}, X_1^{(2)}, X_2^{(2)}, X_1^{(3)}, X_2^{(3)}, X_3^{(3)}, \dots, X_1^{(n)}, X_2^{(n)}, \dots, X_n^{(n)}, \dots$

Oricare ar fi $\varepsilon > 0$ avem

$$P(\{\omega / |X_k^{(n)}(\omega)| \geq \varepsilon\}) = P(\{\omega / \omega \in [\frac{k-1}{n}, \frac{k}{n}]\}) = \frac{1}{n}.$$

Dacă $n > N(\varepsilon, \eta)$ atunci $P(\{\omega / |X_k^{(n)}(\omega)| \geq \varepsilon\}) < \eta$, deci sirul de v. a. considerat converge în probabilitate către 0.

Se observă că sirul nu converge aproape sigur către 0. Intr-adevăr, dacă $\omega_0 \in [0, 1]$, atunci pentru orice m există un j astfel încât

$\omega_0 \in [\frac{j-1}{m}, \frac{j}{m}]$, deci $X_j^{(m)}(\omega_0) = 1$ și de aici rezultă că în sirul

$X_1^{(1)}(\omega_0), X_1^{(2)}(\omega_0), X_2^{(2)}(\omega_0), X_1^{(3)}(\omega_0), X_2^{(3)}(\omega_0), X_3^{(3)}(\omega_0), \dots$ oricare ar fi rangul termenului din sir găsim după el termeni ai sirului egali cu 1, care demonstrează afirmația. \square

32. Convergența în probabilitate nu implică întotdeauna convergența în medie de ordinul r .

Soluție. Fie sirul de v. a. $(X_n)_{n \in \mathbb{N}^*}$, unde $P(X_n = 0) = 1 - \frac{1}{n^2}$, $P(X_n = -n) = P(X_n = n) = \frac{1}{2n^2}$.

Atunci $\forall \varepsilon > 0$ și $\forall \eta > 0 \exists n > N(\varepsilon, \eta)$ astfel încât $P(|X_n| > \varepsilon) = \frac{1}{2n^2} < \eta$ îndată ce $n > N(\varepsilon, \eta)$, ceea ce arată că sirul $(X_n)_{n \in \mathbb{N}^*}$, converge în probabilitate către 0.

Pe de altă parte, $E(|X_n - 0|^2) = E(X_n^2) = 1$, deci sirul nu converge în medie de ordinul 2. \square

33. Să se arate că dacă $(X_n)_{n \in \mathbb{N}^*}$ converge în repartiție, nu rezultă că el converge și în probabilitate.

Soluție. Considerăm câmpul de probabilitate (Ω, K, P) , unde $\Omega = [0, 1], K = \mathcal{B}_{[0,1]}$ și P măsura Lebesgue pe dreaptă.

Definim sirul de v. a. $(X_n)_{n \in \mathbb{N}^*}$ astfel:

$$X_n(\omega) = \begin{cases} 0, & \text{dacă } \omega \in [0, \frac{1}{2}] \\ 1, & \text{dacă } \omega \in [\frac{1}{2}, 1] \end{cases}$$

și v. a. X astfel

$$X(\omega) = \begin{cases} 1, & \text{dacă } \omega \in [0, \frac{1}{2}] \\ 0, & \text{dacă } \omega \in [\frac{1}{2}, 1] \end{cases}$$

Atunci $P(\{\omega / |X_n(\omega) - X(\omega)| = 1\}) = 1$, deci sirul $(X_n)_{n \in \mathbb{N}^*}$ nu converge în probabilitate către X .

Functiile de repartiție ale v. a X_n și X sunt:

$$F_n(x) = P(\{\omega/X_n(\omega) < x\}) = \begin{cases} 0, & \text{dacă } x \leq 0 \\ \frac{1}{2}, & \text{dacă } 0 < x \leq 1 \\ 1, & \text{dacă } x > 1 \end{cases}$$

$$F(x) = P(\{\omega/X(\omega) < x\}) = \begin{cases} 0, & \text{dacă } x \leq 0 \\ \frac{1}{2}, & \text{dacă } 0 < x \leq 1 \\ 1, & \text{dacă } x > 1 \end{cases}$$

deci $F_n(x) = F(x)$, $x \in \mathbb{R}$, $n = 1, 2, \dots \Rightarrow \lim_{n \rightarrow \infty} F_n(x) = F(x)$ ceea ce dovedește că sirul $(X_n)_{n \in \mathbb{N}^*}$ converge în repartiție către X . \square

34. Se știe că funcția caracteristică este continuă pentru orice $t \in \mathbb{R}$, precum și teorema lui Helly. Să se arate că este esențial ca limita $\varphi(t)$ să fie continuă în $t = 0$.

Soluție. Fie

$$F_n(x) = \begin{cases} 0, & \text{dacă } x \leq -n \\ \frac{x+n}{2n}, & \text{dacă } -n < x < n \\ 1, & \text{dacă } x \geq 1 \end{cases}$$

Densitatea de repartiție corespunzătoare este

$$f_n(x) = \begin{cases} \frac{1}{2n}, & \text{dacă } -n < x < n \\ 0, & \text{în rest} \end{cases}$$

Sirul funcțiilor caracteristice este dat de $\varphi_n(t) = \frac{1}{2n} \int_{-n}^n e^{itx} dx = \frac{\sin nt}{nt}$

$$\lim_{n \rightarrow \infty} \varphi_n(t) = \varphi(t) = \begin{cases} 1, & \text{dacă } t = 0 \\ 0, & \text{în rest} \end{cases}$$

Se vede că funcția limită nu este continuă în $t = 0$.

Corespunzător acestui fapt avem pentru orice x fixat $\lim_{n \rightarrow \infty} F_n(x) = \frac{1}{2}$, adică limita sirului $(F_n(x))_{n \in \mathbb{N}^*}$ nu este o funcție de repartiție. \square

35. Să se arate că sirul funcțiilor de repartiție $(F_n(x))_{n \in \mathbb{N}^*}$ corespunzător sirului de funcții caracteristice $(\varphi_n)_{n \in \mathbb{N}^*}$ date prin relațiile $\varphi_n(t) = e^{int}$, $n \in \mathbb{N}^*$ nu converge către o funcție de repartiție.

Soluție. Se observă că sirul $(\varphi_n)_{n \in \mathbb{N}^*}$ nu converge în afară de $t = 2k\pi$. Nefiind îndeplinite condițiile din teorema lui Helly, rezultă că $F_n(x)_{n \in \mathbb{N}^*}$ nu converge către o funcție de repartiție.

Acest lucru se observă și direct, și anume $\varphi_n(t) = e^{int}$ reprezintă funcția caracteristică a v. a. X_n cu masa concentrată în punctul n .

Deci

$$F_n(x) = P(\{\omega/X_n(\omega) \leq x\}) = \varepsilon(x-n) == \begin{cases} 0, & \text{dacă } x < n \\ 1, & \text{în rest} \end{cases}$$

Sub această formă se vede că $\lim_{n \rightarrow \infty} F_n(x) = 0$ pentru orice x fixat. \square

4.3 Probleme propuse

1. Aplicând inegalitatea lui Cebîșev, să se găsească limita inferioară a probabilității inegalității $|\frac{\alpha}{10^5} - \frac{1}{6}| < \frac{1}{100}$, unde α reprezintă numărul de apariții ale feței 5 în 100000 aruncări de zar.

R: $\frac{71}{72}$

2. Să se determine numărul n al probelor independente începând cu care are loc $P(|\frac{x}{n} - p| < 0,1) \geq 0,97$, dacă într-o singură probă evenimentul se realizează cu o probabilitate $p = 0,8$.

R: Cf. teoremei lui Bernoulli $\Rightarrow n \geq 534$

3. Fie $(X_n)_n$ un șir de v. a. independente ale căror valori și probabilități sunt

$$X_k \sim \begin{pmatrix} -k & -(k-1) & \dots & -1 & 0 & 1 & \dots & k-1 & k \\ \frac{1}{3k^3} & \frac{1}{3(k-1)^3} & \dots & \frac{1}{3} & 1 - \frac{2}{3}(1 + \dots + \frac{1}{k^3}) & \frac{1}{3} & \dots & \frac{1}{3(k-1)^3} & \frac{1}{3k^3} \end{pmatrix}$$

$k = 1, 2, \dots$. Să se arate că șirul dat se supune legii numerelor mari în formularea lui Cebîșev.

4. Fie $(X_n)_n$ un șir de v. a. independente care pot lua valorile $\pm\sqrt{n}$ și 0 cu probabilitățile $P(X_1 = 0) = 1$, $P(X_k = \sqrt{k}) = P(X_k = -\sqrt{k}) = \frac{1}{k}$, $P(X_k = 0) = 1 - \frac{2}{k}$, $k = 2, 3, \dots$. Să se arate că șirul dat se supune legii numerelor mari.

5. Fie $(X_n)_n$ un șir de v. a. independente de valori medii $E(X_n) = 0$, $\forall n \geq 1$ și dispersii $D^2(X_n) = n^\lambda$, $\forall n \geq 1$, unde $0 < \lambda < 1$. Să se arate că șirul dat se supune legii numerelor mari.

6. Fie $(X_n)_n$ un șir de v. a. independente astfel încât $P(X_k = -\sqrt{k}) = P(X_k = \sqrt{k}) = \frac{1}{2}$. Să se arate că șirului i se poate aplica teorema lui Leapunov.

7. Fie $(X_n)_n$ un șir de v. a. cu densitățile de repartiție

$$f_{X_k}(x) = \begin{cases} \frac{1}{ck^\alpha} \cdot e^{-\frac{x}{ck^\alpha}}, & x > 0, c > 0, 0 < \alpha < \frac{1}{2} \\ 0, & x \leq 0 \end{cases}$$

Notăm $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$, să se arate că sirul de v. a. $\left(Y_n - \frac{cn^\alpha}{\alpha+1}\right)_n$ converge în probabilitate la 0.

R: Calculăm dispersia variabilei $Y_n - \frac{cn^\alpha}{\alpha+1}$ și apoi folosim inegalitatea lui Cebîșev

Chebyshev's inequality

In probability theory, **Chebyshev's inequality** (also called the **Bienaymé–Chebyshev inequality**) guarantees that, for a wide class of probability distributions, no more than a certain fraction of values can be more than a certain distance from the mean. Specifically, no more than $1/k^2$ of the distribution's values can be k or more standard deviations away from the mean (or equivalently, over $1 - 1/k^2$ of the distribution's values are less than k standard deviations away from the mean). The rule is often called Chebyshev's theorem, about the range of standard deviations around the mean, in statistics. The inequality has great utility because it can be applied to any probability distribution in which the mean and variance are defined. For example, it can be used to prove the weak law of large numbers.

Its practical usage is similar to the 68–95–99.7 rule, which applies only to normal distributions. Chebyshev's inequality is more general, stating that a minimum of just 75% of values must lie within two standard deviations of the mean and 88.89% within three standard deviations for a broad range of different probability distributions.^{[1][2]}

The term *Chebyshev's inequality* may also refer to Markov's inequality, especially in the context of analysis. They are closely related, and some authors refer to Markov's inequality as "Chebyshev's First Inequality," and the similar one referred to on this page as "Chebyshev's Second Inequality."

Contents

History

Statement

Probabilistic statement

Measure-theoretic statement

Example

Sharpness of bounds

Proof (of the two-sided version)

Probabilistic proof

Measure-theoretic proof

Proof assuming random variable X is continuous

Extensions

Asymmetric two-sided

Bivariate generalization

Bivariate, known correlation

Multivariate

Finite-dimensional vector

Infinite dimensions

Higher moments

Exponential moment

Bounded variables

Finite samples

Univariate case

Dependence on sample size

Samuelson's inequality

Multivariate case

Remarks

Sharpened bounds

Standardised variables

Semivariances

Selberg's inequality

Cantelli's inequality

An application - distance between the mean and the median

Bhattacharyya's inequality

Mitzenmacher and Upfal's inequality

Related inequalities

Zelen's inequality

He, Zhang and Zhang's inequality

Hoeffding's lemma

Van Zuijlen's bound

Unimodal distributions[Unimodal symmetrical distributions](#)[Notes](#)[Effects of symmetry and unimodality](#)[Symmetrical unimodal distributions](#)[Normal distributions](#)**Bounds for specific distributions****Zero means**[Unit variance](#)**Integral Chebyshev inequality**[Other inequalities](#)**Haldane's transformation****Notes****See also****References****Further reading****External links**

History

The theorem is named after Russian mathematician Pafnuty Chebyshev, although it was first formulated by his friend and colleague Irénée-Jules Bienaymé.^{[3]:98} The theorem was first stated without proof by Bienaymé in 1853^[4] and later proved by Chebyshev in 1867.^[5] His student Andrey Markov provided another proof in his 1884 Ph.D. thesis.^[6]

Statement

Chebyshev's inequality is usually stated for [random variables](#), but can be generalized to a statement about [measure spaces](#).

Probabilistic statement

Let X (integrable) be a [random variable](#) with finite [expected value](#) μ and finite non-zero [variance](#) σ^2 . Then for any [real number](#) $k > 0$,

$$\Pr(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Only the case $k > 1$ is useful. When $k \leq 1$ the right-hand side $\frac{1}{k^2} \geq 1$ and the inequality is trivial as all probabilities are ≤ 1 .

As an example, using $k = \sqrt{2}$ shows that the probability that values lie outside the interval $(\mu - \sqrt{2}\sigma, \mu + \sqrt{2}\sigma)$ does not exceed $\frac{1}{2}$.

Because it can be applied to completely arbitrary distributions provided they have a known finite mean and variance, the inequality generally gives a poor bound compared to what might be deduced if more aspects are known about the distribution involved.

k	Min. % within k standard deviations of mean	Max. % beyond k standard deviations from mean
1	0%	100%
$\sqrt{2}$	50%	50%
1.5	55.56%	44.44%
2	75%	25%
$2\sqrt{2}$	87.5%	12.5%
3	88.8889%	11.1111%
4	93.75%	6.25%
5	96%	4%
6	97.2222%	2.7778%
7	97.9592%	2.0408%
8	98.4375%	1.5625%
9	98.7654%	1.2346%
10	99%	1%

Measure-theoretic statement

Let (X, Σ, μ) be a measure space, and let f be an extended real-valued measurable function defined on X . Then for any real number $t > 0$ and $0 < p < \infty$,^[7]

$$\mu(\{x \in X : |f(x)| \geq t\}) \leq \frac{1}{t^p} \int_{|f| \geq t} |f|^p d\mu.$$

More generally, if g is an extended real-valued measurable function, nonnegative and nondecreasing, with $g(t) \neq 0$ then:

$$\mu(\{x \in X : f(x) \geq t\}) \leq \frac{1}{g(t)} \int_X g \circ f d\mu.$$

The previous statement then follows by defining $g(x)$ as $|x|^p$ if $x \geq t$ and 0 otherwise.

Example

Suppose we randomly select a journal article from a source with an average of 1000 words per article, with a standard deviation of 200 words. We can then infer that the probability that it has between 600 and 1400 words (i.e. within $k = 2$ standard deviations of the mean) must be at least 75%, because there is no more than $\frac{1}{k^2} = \frac{1}{4}$ chance to be outside that range, by Chebyshev's inequality. But if we additionally know that the distribution is normal, we can say there is a 75% chance the word count is between 770 and 1230 (which is an even tighter bound).

Sharpness of bounds

As shown in the example above, the theorem typically provides rather loose bounds. However, these bounds cannot in general (remaining true for arbitrary distributions) be improved upon. The bounds are sharp for the following example: for any $k \geq 1$,

$$X = \begin{cases} -1, & \text{with probability } \frac{1}{2k^2} \\ 0, & \text{with probability } 1 - \frac{1}{k^2} \\ 1, & \text{with probability } \frac{1}{2k^2} \end{cases}$$

For this distribution, the mean $\mu = 0$ and the standard deviation $\sigma = \frac{1}{k}$, so

$$\Pr(|X - \mu| \geq k\sigma) = \Pr(|X| \geq 1) = \frac{1}{k^2}.$$

Chebyshev's inequality is an equality for precisely those distributions that are a linear transformation of this example.

Proof (of the two-sided version)

Probabilistic proof

Markov's inequality states that for any real-valued random variable Y and any positive number a , we have $\Pr(|Y| > a) \leq E(|Y|)/a$. One way to prove Chebyshev's inequality is to apply Markov's inequality to the random variable $Y = (X - \mu)^2$ with $a = (k\sigma)^2$.

It can also be proved directly using conditional expectation:

$$\begin{aligned} \sigma^2 &= E[(X - \mu)^2] \\ &= E[(X - \mu)^2 \mid k\sigma \leq |X - \mu|] \Pr[k\sigma \leq |X - \mu|] + E[(X - \mu)^2 \mid k\sigma > |X - \mu|] \Pr[k\sigma > |X - \mu|] \\ &\geq (k\sigma)^2 \Pr[k\sigma \leq |X - \mu|] + 0 \cdot \Pr[k\sigma > |X - \mu|] \\ &= k^2 \sigma^2 \Pr[k\sigma \leq |X - \mu|] \end{aligned}$$

Chebyshev's inequality then follows by dividing by $k^2 \sigma^2$.

This proof also shows why the bounds are quite loose in typical cases: the conditional expectation on the event where $|X - \mu| < k\sigma$ is thrown away, and the lower bound of $k^2 \sigma^2$ on the event $|X - \mu| \geq k\sigma$ can be quite poor.

Measure-theoretic proof

Fix t and let $A_t = \{x \in X \mid f(x) \geq t\}$, and let 1_{A_t} be the indicator function of the set A_t . Then, it is easy to check that, for any x ,

$$g(t)1_{A_t}(x) \leq g(f(x))1_{A_t}(x),$$

since g is nondecreasing, and therefore,

$$\begin{aligned} g(t)\mu(A_t) &= \int_X g(t)1_{A_t} d\mu \\ &\leq \int_{A_t} g \circ f d\mu \\ &\leq \int_X g \circ f d\mu, \end{aligned}$$

where the last inequality is justified by the non-negativity of g . The desired inequality follows from dividing the above inequality by $g(t)$.

Proof assuming random variable X is continuous

Using the definition of probability density function $f(x)$, and a standard characterization of variance $\text{Var}(X)$:

$$\Pr(a \leq X \leq b) = \int_a^b f_X(x) dx,$$

$$\text{Var}(X) = \sigma^2 = \int_{\mathbb{R}} (x - \mu)^2 f(x) dx,$$

we have:

$$\begin{aligned} \Pr(|X - \mu| \geq k\sigma) &= \int_{|x-\mu| \geq k\sigma} f(x) dx \\ &\leq \int_{|x-\mu| \geq k\sigma} \frac{|x - \mu|}{k\sigma} f(x) dx \\ &\leq \int_{|x-\mu| \geq k\sigma} \frac{(x - \mu)^2}{k^2 \sigma^2} f(x) dx \\ &= \int_{|x-\mu| \geq k\sigma} \frac{1}{k^2 \sigma^2} (x - \mu)^2 f(x) dx \\ &= \frac{1}{k^2 \sigma^2} \int_{|x-\mu| \geq k\sigma} (x - \mu)^2 f(x) dx \\ &\leq \frac{1}{k^2 \sigma^2} \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx \\ &= \frac{1}{k^2 \sigma^2} \sigma^2 \\ &= \frac{1}{k^2}. \end{aligned}$$

Replacing $k\sigma$ with ε , where $k = \varepsilon/\sigma$, we have another form of the Chebyshev's inequality:

$$\Pr(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2},$$

or, the equivalent

$$\Pr(|X - \mu| < \varepsilon) > 1 - \frac{\sigma^2}{\varepsilon^2},$$

where ε is defined the same way as k ; any positive real number.

Extensions

Several extensions of Chebyshev's inequality have been developed.

Asymmetric two-sided

If X has mean μ and variance σ^2 , then

$$\Pr(\ell < X < u) \geq \frac{4[(\mu - \ell)(u - \mu) - \sigma^2]}{(\ell - u)^2}, [8]$$

if $(\mu - \ell)(u - \mu) \geq \sigma^2$ and $(\mu - \ell)(u - \mu) - \sigma^2 \leq 2\sigma^2$, where $k = \min(\mu - \ell, u - \mu)$ and $\ell < \mu < u$. [9]

This reduces to Chebyshev's inequality in the symmetric case (ℓ and u equidistant from the mean).

Bivariate generalization

Let X_1, X_2 be two random variables with means μ_1, μ_2 and finite variances σ_1^2, σ_2^2 respectively. Then a union bound shows that

$$\Pr\left(\ell_1 \leq \frac{X_1 - \mu_1}{\sigma_1} \leq u_1, \ell_2 \leq \frac{X_2 - \mu_2}{\sigma_2} \leq u_2\right) \geq 1 - \frac{4 + (u_1 + \ell_1)^2}{(u_1 - \ell_1)^2} - \frac{4 + (u_2 + \ell_2)^2}{(u_2 - \ell_2)^2}$$

This bound does not require X_1 and X_2 independent. [9]

Bivariate, known correlation

Berge derived an inequality for two correlated variables X_1, X_2 . [10] Let ρ be the correlation coefficient between X_1 and X_2 and let σ_i^2 be the variance of X_i . Then

$$\Pr\left(\bigcap_{i=1}^2 \left[\frac{|X_i - \mu_i|}{\sigma_i} < k\right]\right) \geq 1 - \frac{1 + \sqrt{1 - \rho^2}}{k^2}.$$

Lal later obtained an alternative bound [11]

$$\Pr\left(\bigcap_{i=1}^2 \left[\frac{|X_i - \mu_i|}{\sigma_i} \leq k_i\right]\right) \geq 1 - \frac{k_1^2 + k_2^2 + \sqrt{(k_1^2 + k_2^2)^2 - 4k_1^2 k_2^2 \rho}}{2(k_1 k_2)^2}$$

Isii derived a further generalisation. [12] Let

$$Z = \Pr((-k_1 < X_1 < k_2) \cap (-k_1 < X_2 < k_2)), \quad 0 < k_1 \leq k_2.$$

and define:

$$\lambda = \frac{k_1(1 + \rho) + \sqrt{(1 - \rho^2)(k_1^2 + \rho)}}{2k_1 - 1 + \rho}$$

There are now three cases.

- **Case A:** If $2k_1^2 > 1 - \rho$ and $k_2 - k_1 \geq 2\lambda$ then

$$Z \leq \frac{2\lambda^2}{2\lambda^2 + 1 + \rho}.$$

- **Case B:** If the conditions in case A are not met but $k_1 k_2 \geq 1$ and

$$2(k_1 k_2 - 1)^2 \geq 2(1 - \rho^2) + (1 - \rho)(k_2 - k_1)^2$$

then

$$Z \leq \frac{(k_2 - k_1)^2 + 4 + \sqrt{16(1 - \rho^2) + 8(1 - \rho)(k_2 - k_1)}}{(k_1 + k_2)^2}.$$

- **Case C:** If none of the conditions in cases A or B are satisfied then there is no universal bound other than 1.

Multivariate

The general case is known as the Birnbaum–Raymond–Zuckerman inequality after the authors who proved it for two dimensions. [13]

$$\Pr \left(\sum_{i=1}^n \frac{(X_i - \mu_i)^2}{\sigma_i^2 t_i^2} \geq k^2 \right) \leq \frac{1}{k^2} \sum_{i=1}^n \frac{1}{t_i^2}$$

where X_i is the i -th random variable, μ_i is the i -th mean and σ_i^2 is the i -th variance.

If the variables are independent this inequality can be sharpened.^[14]

$$\Pr \left(\bigcap_{i=1}^n \frac{|X_i - \mu_i|}{\sigma_i} \leq k_i \right) \geq \prod_{i=1}^n \left(1 - \frac{1}{k_i^2} \right)$$

Olkin and Pratt derived an inequality for n correlated variables.^[15]

$$\Pr \left(\bigcap_{i=1}^n \frac{|X_i - \mu_i|}{\sigma_i} < k_i \right) \geq 1 - \frac{1}{n^2} \left(\sqrt{u} + \sqrt{n-1} \sqrt{n \sum_i \frac{1}{k_i^2} - u} \right)^2$$

where the sum is taken over the n variables and

$$u = \sum_{i=1}^n \frac{1}{k_i^2} + 2 \sum_{i=1}^n \sum_{j < i} \frac{\rho_{ij}}{k_i k_j}$$

where ρ_{ij} is the correlation between X_i and X_j .

Olkin and Pratt's inequality was subsequently generalised by Godwin.^[16]

Finite-dimensional vector

Ferentinos^[9] has shown that for a vector $X = (x_1, x_2, \dots)$ with mean $\mu = (\mu_1, \mu_2, \dots)$, standard deviation $\sigma = (\sigma_1, \sigma_2, \dots)$ and the Euclidean norm $\|\cdot\|$ that

$$\Pr(\|X - \mu\| \geq k\|\sigma\|) \leq \frac{1}{k^2}.$$

A second related inequality has also been derived by Chen.^[17] Let n be the dimension of the stochastic vector X and let $E(X)$ be the mean of X . Let S be the covariance matrix and $k > 0$. Then

$$\Pr((X - E(X))^T S^{-1} (X - E(X)) < k) \geq 1 - \frac{n}{k}$$

where Y^T is the transpose of Y . A simple proof was obtained in Navarro^[18] as follows:

$$Z = (X - E(X))^T S^{-1} (X - E(X)) = (X - E(X))^T S^{-1/2} S^{-1/2} (X - E(X)) = Y^T Y \geq 0$$

where

$$Y = (Y_1, \dots, Y_n)^T = S^{-1/2} (X - E(X))$$

and $S^{-1/2}$ is a symmetric invertible matrix such that: $S^{-1/2} S^{-1/2} = S^{-1}$. Hence $E(Y) = (0, \dots, 0)^T$ and $\text{Cov}(Y) = I_n$ where I_n represents the identity matrix of dimension n . Then $E(Y_i^2) = \text{Var}(Y_i) = 1$ and

$$E(Z) = E(Y^T Y) = \sum_{i=1}^n E(Y_i^2) = n$$

Finally, by applying Markov's inequality to Z we get

$$\Pr(Z \geq k) = \Pr((X - E(X))^T S^{-1} (X - E(X)) \geq k) \leq \frac{E(Z)}{k} = \frac{n}{k}$$

and so the desired inequality holds.

The inequality can be written in terms of the Mahalanobis distance as

$$\Pr(d_S^2(X, E(X)) < k) \geq 1 - \frac{n}{k}$$

where the Mahalanobis distance based on S is defined by

$$d_S(x, y) = \sqrt{(x - y)^T S^{-1} (x - y)}$$

Navarro^[19] proved that these bounds are sharp, that is, they are the best possible bounds for that regions when we just know the mean and the covariance matrix of X.

Stellato et al.^[20] showed that this multivariate version of the Chebyshev inequality can be easily derived analytically as a special case of Vandenberghe et al.^[21] where the bound is computed by solving a semidefinite program (SDP).

Infinite dimensions

There is a straightforward extension of the vector version of Chebyshev's inequality to infinite dimensional settings. Let X be a random variable which takes values in a Fréchet space \mathcal{X} (equipped with seminorms $\|\cdot\|_\alpha$). This includes most common settings of vector-valued random variables, e.g., when \mathcal{X} is a Banach space (equipped with a single norm), a Hilbert space, or the finite-dimensional setting as described above.

Suppose that X is of "strong order two", meaning that

$$\mathbf{E}(\|X\|_\alpha^2) < \infty$$

for every seminorm $\|\cdot\|_\alpha$. This is a generalization of the requirement that X have finite variance, and is necessary for this strong form of Chebyshev's inequality in infinite dimensions. The terminology "strong order two" is due to Vakhania.^[22]

Let $\mu \in \mathcal{X}$ be the Pettis integral of X (i.e., the vector generalization of the mean), and let

$$\sigma_\alpha := \sqrt{\mathbf{E} \|X - \mu\|_\alpha^2}$$

be the standard deviation with respect to the seminorm $\|\cdot\|_\alpha$. In this setting we can state the following:

$$\text{General version of Chebyshev's inequality. } \forall k > 0 : \quad \Pr(\|X - \mu\|_\alpha \geq k\sigma_\alpha) \leq \frac{1}{k^2}.$$

Proof. The proof is straightforward, and essentially the same as the finitary version. If $\sigma_\alpha = 0$, then X is constant (and equal to μ) almost surely, so the inequality is trivial.

If

$$\|X - \mu\|_\alpha \geq k\sigma_\alpha$$

then $\|X - \mu\|_\alpha > 0$, so we may safely divide by $\|X - \mu\|_\alpha$. The crucial trick in Chebyshev's inequality is to recognize that $\mathbf{1} = \frac{\|X - \mu\|_\alpha^2}{\|X - \mu\|_\alpha^2}$.

The following calculations complete the proof:

$$\begin{aligned} \Pr(\|X - \mu\|_\alpha \geq k\sigma_\alpha) &= \int_{\Omega} \mathbf{1}_{\|X - \mu\|_\alpha \geq k\sigma_\alpha} d\Pr \\ &= \int_{\Omega} \left(\frac{\|X - \mu\|_\alpha^2}{\|X - \mu\|_\alpha^2} \right) \cdot \mathbf{1}_{\|X - \mu\|_\alpha \geq k\sigma_\alpha} d\Pr \\ &\leq \int_{\Omega} \left(\frac{\|X - \mu\|_\alpha^2}{(k\sigma_\alpha)^2} \right) \cdot \mathbf{1}_{\|X - \mu\|_\alpha \geq k\sigma_\alpha} d\Pr \\ &\leq \frac{1}{k^2\sigma_\alpha^2} \int_{\Omega} \|X - \mu\|_\alpha^2 d\Pr \quad \mathbf{1}_{\|X - \mu\|_\alpha \geq k\sigma_\alpha} \leq 1 \\ &= \frac{1}{k^2\sigma_\alpha^2} (\mathbf{E} \|X - \mu\|_\alpha^2) \\ &= \frac{1}{k^2\sigma_\alpha^2} (\sigma_\alpha^2) \\ &= \frac{1}{k^2} \end{aligned}$$

Higher moments

An extension to higher moments is also possible:

$$\Pr\left(|X - \mathbb{E}(X)| \geq k \mathbb{E}(|X - \mathbb{E}(X)|^n)^{\frac{1}{n}}\right) \leq \frac{1}{k^n}, \quad k > 0, n \geq 2.$$

Exponential moment

A related inequality sometimes known as the exponential Chebyshev's inequality^[23] is the inequality

$$\Pr(X \geq \varepsilon) \leq e^{-t\varepsilon} \mathbb{E}(e^{tX}), \quad t > 0.$$

Let $K(t)$ be the cumulant generating function,

$$K(t) = \log(\mathbb{E}(e^{tX})).$$

Taking the Legendre–Fenchel transformation of $K(t)$ and using the exponential Chebyshev's inequality we have

$$-\log(\Pr(X \geq \varepsilon)) \geq \sup_t (t\varepsilon - K(t)).$$

This inequality may be used to obtain exponential inequalities for unbounded variables.^[24]

Bounded variables

If $P(x)$ has finite support based on the interval $[a, b]$, let $M = \max(|a|, |b|)$ where $|x|$ is the absolute value of x . If the mean of $P(x)$ is zero then for all $k > 0$ ^[25]

$$\frac{\mathbb{E}(|X|^r) - k^r}{M^r} \leq \Pr(|X| \geq k) \leq \frac{\mathbb{E}(|X|^r)}{k^r}.$$

The second of these inequalities with $r = 2$ is the Chebyshev bound. The first provides a lower bound for the value of $P(x)$.

Sharp bounds for a bounded variate have been proposed by Niemitalo, but without a proof though^[26]

Let $0 \leq X \leq M$ where $M > 0$. Then

- **Case 1:**

$$\Pr(X < k) = 0 \quad \text{if} \quad \mathbb{E}(X) > k \quad \text{and} \quad \mathbb{E}(X^2) < k \mathbb{E}(X) + M \mathbb{E}(X) - kM$$

- **Case 2:**

$$\Pr(X < k) \geq 1 - \frac{k \mathbb{E}(X) + M \mathbb{E}(X) - \mathbb{E}(X^2)}{kM} \quad \text{if} \quad \begin{cases} \mathbb{E}(X) > k & \text{and} & \mathbb{E}(X^2) \geq k \mathbb{E}(X) + M \mathbb{E}(X) - kM \\ & \text{or} & \\ \mathbb{E}(X) \leq k & \text{and} & \mathbb{E}(X^2) \geq k \mathbb{E}(X) \end{cases}$$

- **Case 3:**

$$\Pr(X < k) \geq \frac{\mathbb{E}(X)^2 - 2k \mathbb{E}(X) + k^2}{\mathbb{E}(X^2) - 2k \mathbb{E}(X) + k^2} \quad \text{if} \quad \mathbb{E}(X) \leq k \quad \text{and} \quad \mathbb{E}(X^2) < k \mathbb{E}(X)$$

Finite samples

Univariate case

Saw *et al* extended Chebyshev's inequality to cases where the population mean and variance are not known and may not exist, but the sample mean and sample standard deviation from N samples are to be employed to bound the expected value of a new drawing from the same distribution.^[27]

$$P(|X - m| \geq ks) \leq \frac{g_{N+1}\left(\frac{Nk^2}{N-1+k^2}\right)}{N+1} \left(\frac{N}{N+1}\right)^{1/2}$$

where X is a random variable which we have sampled N times, m is the sample mean, k is a constant and s is the sample standard deviation. $g(x)$ is defined as follows:

Let $x \geq 1$, $Q = N + 1$, and R be the greatest integer less than Q/x . Let

$$a^2 = \frac{Q(Q-R)}{1+R(Q-R)}.$$

Now

$$g_Q(x) = \begin{cases} R & \text{if } R \text{ is even,} \\ R & \text{if } R \text{ is odd and } x < a^2, \\ R - 1 & \text{if } R \text{ is odd and } x \geq a^2. \end{cases}$$

This inequality holds even when the population moments do not exist, and when the sample is only weakly exchangeably distributed; this criterion is met for randomised sampling. A table of values for the Saw–Yang–Mo inequality for finite sample sizes ($N < 100$) has been determined by Konijn.^[28] The table allows the calculation of various confidence intervals for the mean, based on multiples, C, of the standard error of the mean as calculated from the sample. For example, Konijn shows that for $N = 59$, the 95 percent confidence interval for the mean m is $(m - Cs, m + Cs)$ where $C = 4.447 \times 1.006 = 4.47$ (this is 2.28 times larger than the value found on the assumption of normality showing the loss on precision resulting from ignorance of the precise nature of the distribution).

Kabán gives a somewhat less complex version of this inequality.^[29]

$$P(|X - m| \geq ks) \leq \frac{1}{N+1} \left[\frac{N+1}{N} \left(\frac{N-1}{k^2} + 1 \right) \right]$$

If the standard deviation is a multiple of the mean then a further inequality can be derived,^[29]

$$P(|X - m| \geq ks) \leq \frac{N-1}{N} \frac{1}{k^2} \frac{s^2}{m^2} + \frac{1}{N}.$$

A table of values for the Saw–Yang–Mo inequality for finite sample sizes ($N < 100$) has been determined by Konijn.^[28]

For fixed N and large m the Saw–Yang–Mo inequality is approximately^[30]

$$P(|X - m| \geq ks) \leq \frac{1}{N+1}.$$

Beasley *et al* have suggested a modification of this inequality^[30]

$$P(|X - m| \geq ks) \leq \frac{1}{k^2(N+1)}.$$

In empirical testing this modification is conservative but appears to have low statistical power. Its theoretical basis currently remains unexplored.

Dependence on sample size

The bounds these inequalities give on a finite sample are less tight than those the Chebyshev inequality gives for a distribution. To illustrate this let the sample size $N = 100$ and let $k = 3$. Chebyshev's inequality states that at most approximately 11.11% of the distribution will lie at least three standard deviations away from the mean. Kabán's version of the inequality for a finite sample states that at most approximately 12.05% of the sample lies outside these limits. The dependence of the confidence intervals on sample size is further illustrated below.

For $N = 10$, the 95% confidence interval is approximately ± 13.5789 standard deviations.

For $N = 100$ the 95% confidence interval is approximately ± 4.9595 standard deviations; the 99% confidence interval is approximately ± 140.0 standard deviations.

For $N = 500$ the 95% confidence interval is approximately ± 4.5574 standard deviations; the 99% confidence interval is approximately ± 11.1620 standard deviations.

For $N = 1000$ the 95% and 99% confidence intervals are approximately ± 4.5141 and approximately ± 10.5330 standard deviations respectively.

The Chebyshev inequality for the distribution gives 95% and 99% confidence intervals of approximately ± 4.472 standard deviations and ± 10 standard deviations respectively.

Samuelson's inequality

Although Chebyshev's inequality is the best possible bound for an arbitrary distribution, this is not necessarily true for finite samples. Samuelson's inequality states that all values of a sample will lie within $\sqrt{N} - 1$ standard deviations of the mean. Chebyshev's bound improves as the sample size increases.

When $N = 10$, Samuelson's inequality states that all members of the sample lie within 3 standard deviations of the mean: in contrast Chebyshev's states that 99.5% of the sample lies within 13.5789 standard deviations of the mean.

When $N = 100$, Samuelson's inequality states that all members of the sample lie within approximately 9.9499 standard deviations of the mean: Chebyshev's states that 99% of the sample lies within 10 standard deviations of the mean.

When $N = 500$, Samuelson's inequality states that all members of the sample lie within approximately 22.3383 standard deviations of the mean: Chebyshev's states that 99% of the sample lies within 10 standard deviations of the mean.

Multivariate case

Stellato et al.^[20] simplified the notation and extended the empirical Chebyshev inequality from Saw et al.^[27] to the multivariate case. Let $\xi \in \mathbb{R}^{n_\xi}$ be a random variable and let $N \in \mathbb{Z}_{\geq n_\xi}$. We draw $N + 1$ iid samples of ξ denoted as $\xi^{(1)}, \dots, \xi^{(N)}, \xi^{(N+1)} \in \mathbb{R}^{n_\xi}$. Based on the first N samples, we define the empirical mean as $\mu_N = \frac{1}{N} \sum_{i=1}^N \xi^{(i)}$ and the unbiased empirical covariance as $\Sigma_N = \frac{1}{N} \sum_{i=1}^N (\xi^{(i)} - \mu_N)(\xi^{(i)} - \mu_N)^\top$. If Σ_N is nonsingular, then for all $\lambda \in \mathbb{R}_{\geq 0}$ then

$$\begin{aligned} & P^{N+1} \left((\xi^{(N+1)} - \mu_N)^\top \Sigma_N^{-1} (\xi^{(N+1)} - \mu_N) \geq \lambda^2 \right) \\ & \leq \min \left\{ 1, \frac{1}{N+1} \left\lfloor \frac{n_\xi(N+1)(N^2 - 1 + N\lambda^2)}{N^2 \lambda^2} \right\rfloor \right\}. \end{aligned}$$

Remarks

In the univariate case, i.e. $n_\xi = 1$, this inequality corresponds to the one from Saw et al.^[27] Moreover, the right-hand side can be simplified by upper bounding the floor function by its argument

$$P^{N+1} \left((\xi^{(N+1)} - \mu_N)^\top \Sigma_N^{-1} (\xi^{(N+1)} - \mu_N) \geq \lambda^2 \right) \leq \min \left\{ 1, \frac{n_\xi(N^2 - 1 + N\lambda^2)}{N^2 \lambda^2} \right\}.$$

As $N \rightarrow \infty$, the right-hand side tends to $\min \left\{ 1, \frac{n_\xi}{\lambda^2} \right\}$ which corresponds to the multivariate Chebyshev inequality over ellipsoids shaped according to Σ and centered in μ .

Sharpened bounds

Chebyshev's inequality is important because of its applicability to any distribution. As a result of its generality it may not (and usually does not) provide as sharp a bound as alternative methods that can be used if the distribution of the random variable is known. To improve the sharpness of the bounds provided by Chebyshev's inequality a number of methods have been developed; for a review see eg.^[31]

Standardised variables

Sharpened bounds can be derived by first standardising the random variable.^[32]

Let X be a random variable with finite variance $\text{Var}(X)$. Let Z be the standardised form defined as

$$Z = \frac{X - \mathbf{E}(X)}{\sqrt{\text{Var}(X)}}.$$

Cantelli's lemma is then

$$P(Z \geq k) \leq \frac{1}{1 + k^2}.$$

This inequality is sharp and is attained by k and $-1/k$ with probability $1/(1 + k^2)$ and $k^2/(1 + k^2)$ respectively.

If $k > 1$ and the distribution of X is symmetric then we have

$$P(Z \geq k) \leq \frac{1}{2k^2}.$$

Equality holds if and only if $Z = -k$, 0 or k with probabilities $1/2k^2$, $1 - 1/k^2$ and $1/2k^2$ respectively.^[32] An extension to a two-sided inequality is also possible.

Let $u, v > 0$. Then we have^[32]

$$P(Z \leq -u \text{ or } Z \geq v) \leq \frac{4 + (u - v)^2}{(u + v)^2}.$$

Semivariances

An alternative method of obtaining sharper bounds is through the use of semivariances (partial variances). The upper (σ_+^2) and lower (σ_-^2) semivariances are defined as

$$\sigma_+^2 = \frac{\sum_{x>m} (x - m)^2}{n - 1},$$

$$\sigma_-^2 = \frac{\sum_{x<m} (m - x)^2}{n - 1},$$

where m is the arithmetic mean of the sample and n is the number of elements in the sample.

The variance of the sample is the sum of the two semivariances:

$$\sigma^2 = \sigma_+^2 + \sigma_-^2.$$

In terms of the lower semivariance Chebyshev's inequality can be written^[33]

$$\Pr(x \leq m - a\sigma_-) \leq \frac{1}{a^2}.$$

Putting

$$a = \frac{k\sigma}{\sigma_-}.$$

Chebyshev's inequality can now be written

$$\Pr(x \leq m - k\sigma) \leq \frac{1}{k^2} \frac{\sigma_-^2}{\sigma^2}.$$

A similar result can also be derived for the upper semivariance.

If we put

$$\sigma_u^2 = \max(\sigma_-^2, \sigma_+^2),$$

Chebyshev's inequality can be written

$$\Pr(|x \leq m - k\sigma|) \leq \frac{1}{k^2} \frac{\sigma_u^2}{\sigma^2}.$$

Because $\sigma_u^2 \leq \sigma^2$, use of the semivariance sharpens the original inequality.

If the distribution is known to be symmetric, then

$$\sigma_+^2 = \sigma_-^2 = \frac{1}{2}\sigma^2$$

and

$$\Pr(x \leq m - k\sigma) \leq \frac{1}{2k^2}.$$

This result agrees with that derived using standardised variables.

Note

The inequality with the lower semivariance has been found to be of use in estimating downside risk in finance and agriculture.^{[33][34][35]}

Selberg's inequality

Selberg derived an inequality for $P(x)$ when $a \leq x \leq b$.^[36] To simplify the notation let

$$\mathbf{Y} = \boldsymbol{\alpha}\mathbf{X} + \beta$$

where

$$\boldsymbol{\alpha} = \frac{2k}{b - a}$$

and

$$\beta = \frac{-(b+a)k}{b-a}.$$

The result of this linear transformation is to make $P(a \leq X \leq b)$ equal to $P(|Y| \leq k)$.

The mean (μ_X) and variance (σ_X^2) of X are related to the mean (μ_Y) and variance (σ_Y^2) of Y :

$$\mu_Y = \alpha\mu_X + \beta$$

$$\sigma_Y^2 = \alpha^2\sigma_X^2.$$

With this notation Selberg's inequality states that

$$\Pr(|Y| < k) \geq \frac{(k - \mu_Y)^2}{(k - \mu_Y)^2 + \sigma_Y^2} \quad \text{if } \sigma_Y^2 \leq \mu_Y(k - \mu_Y)$$

$$\Pr(|Y| < k) \geq 1 - \frac{\sigma_Y^2 + \mu_Y^2}{k^2} \quad \text{if } \mu_Y(k - \mu_Y) \leq \sigma_Y^2 \leq k^2 - \mu_Y^2$$

$$P(|Y| < k) \geq 0 \quad \text{if } k^2 - \mu_Y^2 \leq \sigma_Y^2.$$

These are known to be the best possible bounds.^[37]

Cantelli's inequality

Cantelli's inequality^[38] due to Francesco Paolo Cantelli states that for a real random variable (X) with mean (μ) and variance (σ^2)

$$P(X - \mu \geq a) \leq \frac{\sigma^2}{\sigma^2 + a^2}$$

where $a \geq 0$.

This inequality can be used to prove a one tailed variant of Chebyshev's inequality with $k > 0$ ^[39]

$$\Pr(X - \mu \geq k\sigma) \leq \frac{1}{1 + k^2}.$$

The bound on the one tailed variant is known to be sharp. To see this consider the random variable X that takes the values

$$X = 1 \text{ with probability } \frac{\sigma^2}{1 + \sigma^2}$$

$$X = -\sigma^2 \text{ with probability } \frac{1}{1 + \sigma^2}.$$

Then $E(X) = 0$ and $E(X^2) = \sigma^2$ and $P(X < 1) = 1 / (1 + \sigma^2)$.

An application - distance between the mean and the median

The one-sided variant can be used to prove the proposition that for probability distributions having an expected value and a median, the mean and the median can never differ from each other by more than one standard deviation. To express this in symbols let μ , ν , and σ be respectively the mean, the median, and the standard deviation. Then

$$|\mu - \nu| \leq \sigma.$$

There is no need to assume that the variance is finite because this inequality is trivially true if the variance is infinite.

The proof is as follows. Setting $k = 1$ in the statement for the one-sided inequality gives:

$$\Pr(X - \mu \geq \sigma) \leq \frac{1}{2} \implies \Pr(X \geq \mu + \sigma) \leq \frac{1}{2}.$$

Changing the sign of X and of μ , we get

$$\Pr(X \leq \mu - \sigma) \leq \frac{1}{2}.$$

As the median is by definition any real number m that satisfies the inequalities

$$\Pr(X \leq m) \geq \frac{1}{2} \text{ and } \Pr(X \geq m) \geq \frac{1}{2}$$

this implies that the median lies within one standard deviation of the mean. A proof using Jensen's inequality also exists.

Bhattacharyya's inequality

Bhattacharyya^[40] extended Cantelli's inequality using the third and fourth moments of the distribution.

Let $\mu = 0$ and σ^2 be the variance. Let $\gamma = E(X^3)/\sigma^3$ and $\kappa = E(X^4)/\sigma^4$.

If $k^2 - k\gamma - 1 > 0$ then

$$\Pr(X > k\sigma) \leq \frac{\kappa - \gamma^2 - 1}{(\kappa - \gamma^2 - 1)(1 + k^2) + (k^2 - k\gamma - 1)}.$$

The necessity of $k^2 - k\gamma - 1 > 0$ requires that k be reasonably large.

Mitzenmacher and Upfal's inequality

Mitzenmacher and Upfal^[41] note that

$$(X - E[X])^{2k} > 0$$

for any integer $k > 0$ and that

$$E[(X - E[X])^{2k}]$$

is the $2k^{\text{th}}$ central moment. They then show that for $t > 0$

$$\Pr(|X - E[X]| > t E[(X - E[X])^{2k}]^{1/2k}) \leq \frac{1}{t^{2k}}.$$

For $k = 1$ we obtain Chebyshev's inequality. For $t \geq 1$, $k > 2$ and assuming that the k^{th} moment exists, this bound is tighter than Chebyshev's inequality.

Related inequalities

Several other related inequalities are also known.

Zelen's inequality

Zelen has shown that^[42]

$$\Pr(X - \mu \geq k\sigma) \leq \left[1 + k^2 + \frac{(k^2 - k\theta_3 - 1)^2}{\theta_4 - \theta_3^2 - 1} \right]^{-1}$$

with

$$k \geq \frac{\theta_3 + \sqrt{\theta_3^2 + 4}}{2}, \quad \theta_m = \frac{M_m}{\sigma}$$

where M_m is the m -th moment and σ is the standard deviation.

He, Zhang and Zhang's inequality

For any collection of n non-negative independent random variables X_i with expectation 1^[43]

$$\Pr\left(\frac{\sum_{i=1}^n X_i}{n} - 1 \geq \frac{1}{n}\right) \leq \frac{7}{8}.$$

Hoeffding's lemma

Let X be a random variable with $a \leq X \leq b$ and $E[X] = 0$, then for any $s > 0$, we have

$$E[e^{sX}] \leq e^{\frac{1}{8}s^2(b-a)^2}.$$

Van Zuijlen's bound

Let X_i be a set of independent Rademacher random variables: $\Pr(X_i = 1) = \Pr(X_i = -1) = 0.5$. Then^[44]

$$\Pr\left(\left|\frac{\sum_{i=1}^n X_i}{\sqrt{n}}\right| \leq 1\right) \geq 0.5.$$

The bound is sharp and better than that which can be derived from the normal distribution (approximately $\Pr > 0.31$).

Unimodal distributions

A distribution function F is unimodal at v if its cumulative distribution function is convex on $(-\infty, v)$ and concave on (v, ∞) ^[45]. An empirical distribution can be tested for unimodality with the dip test.^[46]

In 1823 Gauss showed that for a unimodal distribution with a mode of zero^[47]

$$P(|X| \geq k) \leq \frac{4E(X^2)}{9k^2} \quad \text{if } k^2 \geq \frac{4}{3} E(X^2),$$

$$P(|X| \geq k) \leq 1 - \frac{k}{\sqrt{3}E(X^2)} \quad \text{if } k^2 \leq \frac{4}{3} E(X^2).$$

If the mode is not zero and the mean (μ) and standard deviation (σ) are both finite, then denoting the median as v and the root mean square deviation from the mode by ω , we have

$$\sigma \leq \omega \leq 2\sigma$$

and

$$|v - \mu| \leq \sqrt{\frac{3}{4}}\omega.$$

Winkler in 1866 extended Gauss' inequality to r^{th} moments^[48] where $r > 0$ and the distribution is unimodal with a mode of zero:

$$P(|X| \geq k) \leq \left(\frac{r}{r+1}\right)^r \frac{E(|X|)^r}{k^r} \quad \text{if } k^r \geq \frac{r^r}{(r+1)^{r+1}} E(|X|^r),$$

$$P(|X| \geq k) \leq \left(1 - \left[\frac{k^r}{(r+1)E(|X|)^r}\right]^{1/r}\right) \quad \text{if } k^r \leq \frac{r^r}{(r+1)^{r+1}} E(|X|^r).$$

Gauss' bound has been subsequently sharpened and extended to apply to departures from the mean rather than the mode due to the Vysochanskii–Petunin inequality. The latter has been extended by Dharmadhikari and Joag-Dev^[49]

$$P(|X| > k) \leq \max\left(\left[\frac{r}{(r+1)k}\right]^r E|X^r|, \frac{s}{(s-1)k^r} E|X^r| - \frac{1}{s-1}\right)$$

where s is a constant satisfying both $s > r + 1$ and $s(s - r - 1) = r^r$ and $r > 0$.

It can be shown that these inequalities are the best possible and that further sharpening of the bounds requires that additional restrictions be placed on the distributions.

Unimodal symmetrical distributions

The bounds on this inequality can also be sharpened if the distribution is both unimodal and symmetrical.^[50] An empirical distribution can be tested for symmetry with a number of tests including McWilliam's R*.^[51] It is known that the variance of a unimodal symmetrical distribution with finite support $[a, b]$ is less than or equal to $(b - a)^2 / 12$.^[52]

Let the distribution be supported on the finite interval $[-N, N]$ and the variance be finite. Let the mode of the distribution be zero and rescale the variance to 1. Let $k > 0$ and assume $k < 2N/3$. Then^[50]

$$P(X \geq k) \leq \frac{1}{2} - \frac{k}{2\sqrt{3}} \quad \text{if } 0 \leq k \leq \frac{2}{\sqrt{3}},$$

$$P(X \geq k) \leq \frac{2}{9k^2} \quad \text{if } \frac{2}{\sqrt{3}} \leq k \leq \frac{2N}{3}.$$

If $0 < k \leq 2 / \sqrt{3}$ the bounds are reached with the density^[50]

$$f(x) = \frac{1}{2\sqrt{3}} \quad \text{if } |x| < \sqrt{3}$$

$$f(x) = 0 \quad \text{if } |x| \geq \sqrt{3}.$$

If $2 / \sqrt{3} < k \leq 2N / 3$ the bounds are attained by the distribution

$$(1 - \beta_k)\delta_0(x) + \beta_k f_k(x),$$

where $\beta_k = 4 / 3k^2$, δ_0 is the Dirac delta function and where

$$f_k(x) = \frac{1}{3k} \quad \text{if } |x| < \frac{3k}{2},$$

$$f_k(x) = 0 \quad \text{if } |x| \geq \frac{3k}{2}.$$

The existence of these densities shows that the bounds are optimal. Since N is arbitrary these bounds apply to any value of N .

The Camp–Meidell's inequality is a related inequality.^[53] For an absolutely continuous unimodal and symmetrical distribution

$$P(|X - \mu| \geq k\sigma) \leq 1 - \frac{k}{\sqrt{3}} \quad \text{if } k \leq \frac{2}{\sqrt{3}},$$

$$P(|X - \mu| \geq k\sigma) \leq \frac{4}{9k^2} \quad \text{if } k > \frac{2}{\sqrt{3}}.$$

DasGupta has shown that if the distribution is known to be normal^[54]

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{3k^2}.$$

Notes

Effects of symmetry and unimodality

Symmetry of the distribution decreases the inequality's bounds by a factor of 2 while unimodality sharpens the bounds by a factor of 4/9.

Because the mean and the mode in a unimodal distribution differ by at most $\sqrt{3}$ standard deviations^[55] at most 5% of a symmetrical unimodal distribution lies outside $(2\sqrt{10} + 3\sqrt{3})/3$ standard deviations of the mean (approximately 3.840 standard deviations). This is sharper than the bounds provided by the Chebyshev inequality (approximately 4.472 standard deviations).

These bounds on the mean are less sharp than those that can be derived from symmetry of the distribution alone which shows that at most 5% of the distribution lies outside approximately 3.162 standard deviations of the mean. The Vysochanskii–Petunin inequality further sharpens this bound by showing that for such a distribution that at most 5% of the distribution lies outside $4\sqrt{5}/3$ (approximately 2.981) standard deviations of the mean.

Symmetrical unimodal distributions

For any symmetrical unimodal distribution

- at most approximately 5.784% of the distribution lies outside 1.96 standard deviations of the mode
- at most 5% of the distribution lies outside $2\sqrt{10}/3$ (approximately 2.11) standard deviations of the mode

Normal distributions

DasGupta's inequality states that for a normal distribution at least 95% lies within approximately 2.582 standard deviations of the mean. This is less sharp than the true figure (approximately 1.96 standard deviations of the mean).

Bounds for specific distributions

- DasGupta has determined a set of best possible bounds for a normal distribution for this inequality.^[54]

- Steliga and Szynal have extended these bounds to the [Pareto distribution](#).^[8]
- Grechuk et al. developed a general method for deriving the best possible bounds in Chebyshev's inequality for any family of distributions, and any [deviation risk measure](#) in place of standard deviation. In particular, they derived Chebyshev inequality for distributions with [log-concave densities](#).^[56]

Zero means

When the mean (μ) is zero Chebyshev's inequality takes a simple form. Let σ^2 be the variance. Then

$$P(|X| \geq 1) \leq \sigma^2.$$

With the same conditions Cantelli's inequality takes the form

$$P(X \geq 1) \leq \frac{\sigma^2}{1 + \sigma^2}.$$

Unit variance

If in addition $E(X^2) = 1$ and $E(X^4) = \psi$ then for any $0 \leq \varepsilon \leq 1$ ^[57]

$$\Pr(|X| > \varepsilon) \geq \frac{(1 - \varepsilon^2)^2}{\psi - 1 + (1 - \varepsilon^2)^2} \geq \frac{(1 - \varepsilon^2)^2}{\psi}.$$

The first inequality is sharp. This is known as the [Paley–Zygmund inequality](#).

It is also known that for a random variable obeying the above conditions that^[58]

$$P(X \geq \varepsilon) \geq \frac{C_0}{\psi} - \frac{C_1}{\sqrt{\psi}} \varepsilon + \frac{C_2}{\psi \sqrt{\psi}} \varepsilon^2$$

where

$$C_0 = 2\sqrt{3} - 3 \quad (\approx 0.464),$$

$$C_1 = 1.397,$$

$$C_2 = 0.0231.$$

It is also known that^[58]

$$\Pr(X > 0) \geq \frac{C_0}{\psi}.$$

The value of C_0 is optimal and the bounds are sharp if

$$\psi \geq \frac{3}{\sqrt{3} + 1} \quad (\approx 1.098).$$

If

$$\psi \leq \frac{3}{\sqrt{3} + 1}$$

then the sharp bound is

$$P(X > 0) \geq \frac{2}{3 + \psi + \sqrt{(1 + \psi)^2 - 4}}.$$

Integral Chebyshev inequality

There is a second (less well known) inequality also named after Chebyshev^[59]

If $f, g : [a, b] \rightarrow \mathbf{R}$ are two monotonic functions of the same monotonicity, then

$$\frac{1}{b-a} \int_a^b f(x)g(x) dx \geq \left[\frac{1}{b-a} \int_a^b f(x) dx \right] \left[\frac{1}{b-a} \int_a^b g(x) dx \right].$$

If f and g are of opposite monotonicity, then the above inequality works in the reverse way.

This inequality is related to [Jensen's inequality](#),^[60] [Kantorovich's inequality](#),^[61] the [Hermite–Hadamard inequality](#)^[61] and [Walter's conjecture](#).^[62]

Other inequalities

There are also a number of other inequalities associated with Chebyshev:

- [Chebyshev's sum inequality](#)
- [Chebyshev–Markov–Stieltjes inequalities](#)

Haldane's transformation

One use of Chebyshev's inequality in applications is to create confidence intervals for variates with an unknown distribution. [Haldane](#) noted,^[63] using an equation derived by [Kendall](#),^[64] that if a variate (x) has a zero mean, unit variance and both finite [skewness](#) (γ) and [kurtosis](#) (κ) then the variate can be converted to a normally distributed standard score (z):

$$z = x - \frac{\gamma}{6}(x^2 - 1) + \frac{x}{72}[2\gamma^2(4x^2 - 7) - 3\kappa(x^2 - 3)] + \dots$$

This transformation may be useful as an alternative to Chebyshev's inequality or as an adjunct to it for deriving confidence intervals for variates with unknown distributions.

While this transformation may be useful for moderately skewed and/or kurtotic distributions, it performs poorly when the distribution is markedly skewed and/or kurtotic.

Notes

The Environmental Protection Agency has suggested best practices for the use of Chebyshev's inequality for estimating confidence intervals. [Calculating Upper Confidence Limits for Exposure Point Concentrations at hazardous Waste Sites \(http://nepis.epa.gov/Exe/ZyNET.exe/P100CYCE.TXT?ZyActionD=ZyDocument&Client=EPA&Index=2000+Thru+2005&Docs=&Query=&Time=&EndTime=&SearchMethod=1&TocRestrict=n&Toc=&TocEntry=&QField=&QFieldYear=&QFieldMonth=&QFieldDay=&IntQFieldOp=o&ExtQFieldOp=o&XmlQuery=&File=D%3A%5Czyfiles%5CIndex%20Data%5Coothruo5%5CTxt%5Coooooo29%5CP100CYCE.txt&User=ANONYMOUS&Password=anonymous&SortMethod=h%7C&MaximumDocuments=1&FuzzyDegree=0&ImageQuality=r75g8/r75g8/x15oy15og16/i425&Display=p%7Cf&DefSeekPage=x&SearchBack=ZyActionL&Back=ZyActionS&BackDesc=Results%20page&MaximumPages=1&ZyEntry=1&SeekPage=x&ZyPURL#\)](http://nepis.epa.gov/Exe/ZyNET.exe/P100CYCE.TXT?ZyActionD=ZyDocument&Client=EPA&Index=2000+Thru+2005&Docs=&Query=&Time=&EndTime=&SearchMethod=1&TocRestrict=n&Toc=&TocEntry=&QField=&QFieldYear=&QFieldMonth=&QFieldDay=&IntQFieldOp=o&ExtQFieldOp=o&XmlQuery=&File=D%3A%5Czyfiles%5CIndex%20Data%5Coothruo5%5CTxt%5Coooooo29%5CP100CYCE.txt&User=ANONYMOUS&Password=anonymous&SortMethod=h%7C&MaximumDocuments=1&FuzzyDegree=0&ImageQuality=r75g8/r75g8/x15oy15og16/i425&Display=p%7Cf&DefSeekPage=x&SearchBack=ZyActionL&Back=ZyActionS&BackDesc=Results%20page&MaximumPages=1&ZyEntry=1&SeekPage=x&ZyPURL#) (Report). Office of Emergency and Remedial Response of the U.S. Environmental Protection Agency. December 2002. Retrieved 5 August 2016.

See also

- [Multidimensional Chebyshev's inequality](#)
- [Concentration inequality](#) – a summary of tail-bounds on random variables.
- [Cornish–Fisher expansion](#)
- [Eaton's inequality](#)
- [Kolmogorov's inequality](#)
- [Proof of the weak law of large numbers using Chebyshev's inequality](#)
- [Le Cam's theorem](#)
- [Paley–Zygmund inequality](#)
- [Vysochanskii–Petunin inequality](#) — a stronger result applicable to [unimodal probability distributions](#)

References

1. Kvanli, Alan H.; Pavur, Robert J.; Keeling, Kellie B. (2006). *Concise Managerial Statistics* (<https://books.google.com/books?id=h6CQ1J0gwNgC&pg=PT95>). cEngage Learning. pp. 81–82. ISBN 9780324223880.
2. Chernick, Michael R. (2011). *The Essentials of Biostatistics for Physicians, Nurses, and Clinicians* (<https://books.google.com/books?id=JP4azqd8ONEC&pg=PA50>). John Wiley & Sons. pp. 49–50. ISBN 9780470641859.
3. Knuth, Donald (1997). *The Art of Computer Programming: Fundamental Algorithms, Volume 1* (<http://www-cs-faculty.stanford.edu/~uno/taocp.html>) (3rd ed.). Reading, Massachusetts: Addison–Wesley. ISBN 978-0-201-89683-1. Retrieved 1 October 2012.
4. Bienaymé, I.-J. (1853). "Considérations à l'appui de la découverte de Laplace". *Comptes Rendus de l'Académie des Sciences*. **37**: 309–324.
5. Tchebichef, P. (1867). "Des valeurs moyennes". *Journal de Mathématiques Pures et Appliquées*. 2. **12**: 177–184.
6. Markov A. (1884) On certain applications of algebraic continued fractions, Ph.D. thesis, St. Petersburg
7. Grafakos, Lukas (2004). *Classical and Modern Fourier Analysis*. Pearson Education Inc. p. 5.
8. Steliga, Katarzyna; Szynal, Dominik (2010). "On Markov-Type Inequalities" (<http://ijpam.eu/contents/2010-58-2/2/2.pdf>) (PDF). *International Journal of Pure and Applied Mathematics*. **58** (2): 137–152. ISSN 1311-8080 (<https://www.worldcat.org/issn/1311-8080>). Retrieved 10 October 2012.

9. Ferentinos, K (1982). "On Tchebycheff type inequalities". *Trabajos Estadist Investigacion Oper.* **33**: 125–132. doi:10.1007/BF02888707 (<https://doi.org/10.1007%2FBF02888707>). S2CID 123762564 (<https://api.semanticscholar.org/CorpusID:123762564>).
10. Berge, P. O. (1938). "A note on a form of Tchebycheff's theorem for two variables". *Biometrika*. **29** (3/4): 405–406. doi:10.2307/2332015 (<https://doi.org/10.2307%2F2332015>). JSTOR 2332015 (<https://www.jstor.org/stable/2332015>).
11. Lal D. N. (1955) A note on a form of Tchebycheff's inequality for two or more variables. *Sankhya* 15(3):317–320
12. Isii K. (1959) On a method for generalizations of Tchebycheff's inequality. *Ann Inst Stat Math* 10: 65–88
13. Birnbaum, Z. W.; Raymond, J.; Zuckerman, H. S. (1947). "A Generalization of Tshebyshev's Inequality to Two Dimensions" (<http://projecteuclid.org/DPubS?service=UI&version=1.0&verb=Display&handle=euclid.aoms/1177730493>). *The Annals of Mathematical Statistics*. **18** (1): 70–79. doi:10.1214/aoms/1177730493 (<https://doi.org/10.1214%2Faoms%2F1177730493>). ISSN 0003-4851 (<https://www.worldcat.org/issn/0003-4851>). MR 0019849 (<https://www.ams.org/mathscinet-getitem?mr=0019849>). Zbl 0032.03402 (<https://zbmath.org/?format=complete&q=an:0032.03402>). Retrieved 7 October 2012.
14. Kotz, Samuel; Balakrishnan, N.; Johnson, Norman L. (2000). *Continuous Multivariate Distributions, Volume 1, Models and Applications* (<http://www.wiley.com/WileyCDA/WileyTitle/productCd-0471183873.html>) (2nd ed.). Boston [u.a.]: Houghton Mifflin. ISBN 978-0-471-18387-7. Retrieved 7 October 2012.
15. Olkin, Ingram; Pratt, John W. (1958). "A Multivariate Tchebycheff Inequality" (<https://doi.org/10.1214%2Faoms%2F1177706720>). *The Annals of Mathematical Statistics*. **29** (1): 226–234. doi:10.1214/aoms/1177706720 (<https://doi.org/10.1214%2Faoms%2F1177706720>). MR 0093865 (<https://www.ams.org/mathscinet-getitem?mr=0093865>). Zbl 0085.35204 (<https://zbmath.org/?format=complete&q=an:0085.35204>).
16. Godwin H. J. (1964) Inequalities on distribution functions. New York, Hafner Pub. Co.
17. Xinjia Chen (2007). "A New Generalization of Chebyshev Inequality for Random Vectors". arXiv:0707.0805v2 (<https://arxiv.org/abs/0707.0805v2>) [math.ST (<https://arxiv.org/archive/math.ST>)].
18. Jorge Navarro (2016). "A very simple proof of the multivariate Chebyshev's inequality". *Communications in Statistics – Theory and Methods*. **45** (12): 3458–3463. doi:10.1080/03610926.2013.873135 (<https://doi.org/10.1080%2F03610926.2013.873135>). S2CID 121107480 (<https://api.semanticscholar.org/CorpusID:121107480>).
19. Jorge Navarro (2014). "Can the bounds in the multivariate Chebyshev inequality be attained?". *Statistics and Probability Letters*. **91**: 1–5. doi:10.1016/j.spl.2014.03.028 (<https://doi.org/10.1016%2Fj.spl.2014.03.028>).
20. Stellato, Bartolomeo; Parys, Bart P. G. Van; Goulart, Paul J. (2016-05-31). "Multivariate Chebyshev Inequality with Estimated Mean and Variance". *The American Statistician*. **71** (2): 123–127. arXiv:1509.08398 (<https://arxiv.org/abs/1509.08398>). doi:10.1080/00031305.2016.1186559 (<https://doi.org/10.1080%2F00031305.2016.1186559>). ISSN 0003-1305 (<https://www.worldcat.org/issn/0003-1305>). S2CID 53407286 (<https://api.semanticscholar.org/CorpusID:53407286>).
21. Vandenberghe, L.; Boyd, S.; Comanor, K. (2007-01-01). "Generalized Chebyshev Bounds via Semidefinite Programming". *SIAM Review*. **49** (1): 52–64. Bibcode:2007SIAMR..49...52V (<https://ui.adsabs.harvard.edu/abs/2007SIAMR..49...52V>). CiteSeerX 10.1.1.126.9105 (<https://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.126.9105>). doi:10.1137/S003614450440543 (<https://doi.org/10.1137%2FS003614450440543>). ISSN 0036-1445 (<https://www.worldcat.org/issn/0036-1445>).
22. Vakhania, Nikolai Nikolaevich. Probability distributions on linear spaces. New York: North Holland, 1981.
23. Section 2.1 (<http://www.math.utah.edu/~firas/Papers/rassoul-seppalainen-ldp.pdf>) Archived (<https://web.archive.org/web/20150430075226/http://www.math.utah.edu/~firas/Papers/rassoul-seppalainen-ldp.pdf>) April 30, 2015, at the Wayback Machine
24. Baranowski, Gladimir V. G.; Rokne, Jon G.; Xu, Guangwu (15 May 2001). "Applying the exponential Chebyshev inequality to the nondeterministic computation of form factors". *Journal of Quantitative Spectroscopy and Radiative Transfer*. **69** (4): 199–200. Bibcode:2001JQSRT..69..447B (<https://ui.adsabs.harvard.edu/abs/2001JQSRT..69..447B>). doi:10.1016/S0022-4073(00)00095-9 (<https://doi.org/10.1016%2FS0022-4073%2800%2900095-9>). (the references for this article are corrected by Baranowski, Gladimir V. G.; Rokne, Jon G.; Guangwu Xu (15 January 2002). "Corrigendum to: 'Applying the exponential Chebyshev inequality to the nondeterministic computation of form factors'". *Journal of Quantitative Spectroscopy and Radiative Transfer*. **72** (2): 199–200. Bibcode:2002JQSRT..72..199B (<https://ui.adsabs.harvard.edu/abs/2002JQSRT..72..199B>). doi:10.1016/S0022-4073(01)00171-6 (<https://doi.org/10.1016%2FS0022-4073%2801%2900171-6>.)
25. Dufour (2003) Properties of moments of random variables (http://www2.cirano.qc.ca/~dufourj/Web_Site/ResE/Dufour_1999_C_TS_Moments.pdf)
26. Niemitalo O. (2012) One-sided Chebyshev-type inequalities for bounded probability distributions. (<http://yehar.com/blog/?p=1225>)
27. Saw, John G.; Yang, Mark C. K.; Mo, Tse Chin (1984). "Chebyshev Inequality with Estimated Mean and Variance". *The American Statistician*. **38** (2): 130–2. doi:10.2307/2683249 (<https://doi.org/10.2307%2F2683249>). ISSN 0003-1305 (<https://www.worldcat.org/issn/0003-1305>). JSTOR 2683249 (<https://www.jstor.org/stable/2683249>).
28. Konijn, Hendrik S. (February 1987). "Distribution-Free and Other Prediction Intervals". *The American Statistician*. **41** (1): 11–15. doi:10.2307/2684311 (<https://doi.org/10.2307%2F2684311>). JSTOR 2684311 (<https://www.jstor.org/stable/2684311>).
29. Kabán, Ata (2012). "Non-parametric detection of meaningless distances in high dimensional data". *Statistics and Computing*. **22** (2): 375–85. doi:10.1007/s11222-011-9229-0 (<https://doi.org/10.1007%2Fs11222-011-9229-0>). S2CID 6018114 (<https://api.semanticscholar.org/CorpusID:6018114>).
30. Beasley, T. Mark; Page, Grier P.; Brand, Jaap P. L.; Gadbury, Gary L.; Mountz, John D.; Allison, David B. (January 2004). "Chebyshev's inequality for nonparametric testing with small N and σ in microarray research". *Journal of the Royal Statistical Society. C (Applied Statistics)*. **53** (1): 95–108. doi:10.1111/j.1467-9876.2004.00428.x (<https://doi.org/10.1111%2Fj.1467-9876.2004.00428.x>). ISSN 1467-9876 (<https://www.worldcat.org/issn/1467-9876>).
31. Savage, I. Richard. "Probability inequalities of the Tchebycheff type." *Journal of Research of the National Bureau of Standards-B. Mathematics and Mathematical Physics B* 65 (1961): 211-222 (http://nvlpubs.nist.gov/nistpubs/jres/65B/jres65Bn3p211_A1b.pdf)
32. Ion, Roxana Alice (2001). "Chapter 4: Sharp Chebyshev-type inequalities" (<http://dare.uva.nl/document/60326>). *Nonparametric Statistical Process Control*. Universiteit van Amsterdam. ISBN 978-9057760761. Retrieved 1 October 2012.
33. Berck, Peter; Hihn, Jairus M. (May 1982). "Using the Semivariance to Estimate Safety-First Rules". *American Journal of Agricultural Economics*. **64** (2): 298–300. doi:10.2307/1241139 (<https://doi.org/10.2307%2F1241139>). ISSN 0002-9092 (<https://www.worldcat.org/issn/0002-9092>). JSTOR 1241139 (<https://www.jstor.org/stable/1241139>).

34. Nantell, Timothy J.; Price, Barbara (June 1979). "An Analytical Comparison of Variance and Semivariance Capital Market Theories". *The Journal of Financial and Quantitative Analysis*. 14 (2): 221–42. doi:10.2307/2330500 (<https://doi.org/10.2307%2F2330500>). JSTOR 2330500 (<https://www.jstor.org/stable/2330500>).
35. Neave, Edwin H.; Ross, Michael N.; Yang, Jun (2009). "Distinguishing upside potential from downside risk". *Management Research News*. 32 (1): 26–36. doi:10.1108/01409170910922005 (<https://doi.org/10.1108%2F01409170910922005>). ISSN 0140-9174 (<https://www.worldcat.org/issn/0140-9174>).
36. Selberg, Henrik L. (1940). "Zwei Ungleichungen zur Ergänzung des Tchebycheffschen Lemmas" [Two Inequalities Supplementing the Tchebycheff Lemma]. *Skandinavisk Aktuarierstidskrift (Scandinavian Actuarial Journal)* (in German). 1940 (3–4): 121–125. doi:10.1080/03461238.1940.10404804 (<https://doi.org/10.1080%2F03461238.1940.10404804>). ISSN 0346-1238 (<https://www.worldcat.org/issn/0346-1238>). OCLC 610399869 (<https://www.worldcat.org/oclc/610399869>).
37. Conlon, J.; Dulá, J. H. "A geometric derivation and interpretation of Tchebyscheff's Inequality" (<http://www.people.vcu.edu/~jdula/WORKINGPAPERS/tcheby.pdf>) (PDF). Retrieved 2 October 2012.
38. Cantelli F. (1910) Intorno ad un teorema fondamentale della teoria del rischio. *Bulletino dell'Associazione degli Attuari Italiani*
39. Grimmett and Stirzaker, problem 7.11.9. Several proofs of this result can be found in [Chebyshev's Inequalities](http://www.mcdowell.a.demon.co.uk/Chebyshev.html) (<http://www.mcdowell.a.demon.co.uk/Chebyshev.html>) by A. G. McDowell.
40. Bhattacharyya, B. B. (1987). "One-sided chebyshev inequality when the first four moments are known". *Communications in Statistics – Theory and Methods*. 16 (9): 2789–91. doi:10.1080/03610928708829540 (<https://doi.org/10.1080%2F03610928708829540>). ISSN 0361-0926 (<https://www.worldcat.org/issn/0361-0926>).
41. Mitzenmacher, Michael; Upfal, Eli (January 2005). *Probability and Computing: Randomized Algorithms and Probabilistic Analysis* (http://www.cambridge.org/us/knowledge/item1171566/?site_locale=en_US) (Repr. ed.). Cambridge [u.a.]: Cambridge Univ. Press. ISBN 9780521835404. Retrieved 6 October 2012.
42. Zelen M. (1954) Bounds on a distribution function that are functions of moments to order four. *J Res Nat Bur Stand* 53:377–381
43. He, S.; Zhang, J.; Zhang, S. (2010). "Bounding probability of small deviation: A fourth moment approach". *Mathematics of Operations Research*. 35 (1): 208–232. doi:10.1287/moor.1090.0438 (<https://doi.org/10.1287%2Fmoor.1090.0438>). S2CID 11298475 (<https://api.semanticscholar.org/CorpusID:11298475>).
44. Martien C. A. van Zuijlen (2011) On a conjecture concerning the sum of independent Rademacher random variables (<https://arxiv.org/abs/1112.4988>)
45. Feller, William (1966). *An Introduction to Probability Theory and Its Applications, Volume 2* (<https://books.google.com/books?id=LhrvAAAAMAAJ&q=%22An+introduction+to+probability+theory+and+its+applications%22+%22volume+2%22+feller>) (2 ed.). Wiley. p. 155. ISBN 9789994311071. Retrieved 6 October 2012.
46. Hartigan, J. A.; Hartigan, P. M. (1985). "The Dip Test of Unimodality" (<https://doi.org/10.1214%2Faos%2F1176346577>). *The Annals of Statistics*. 13: 70–84. doi:10.1214/aos/1176346577 (<https://doi.org/10.1214%2Faos%2F1176346577>). MR 0773153 (<https://www.ams.org/mathscinet-getitem?mr=0773153>).
47. Gauss C. F. *Theoria Combinationis Observationum Erroribus Minimis Obnoxiae. Pars Prior. Pars Posterior. Supplementum. Theory of the Combination of Observations Least Subject to Errors. Part One. Part Two. Supplement.* 1995. Translated by G. W. Stewart. Classics in Applied Mathematics Series, Society for Industrial and Applied Mathematics, Philadelphia
48. Winkler A. (1886) Math-Natur theorie Kl. Akad. Wiss Wien Zweite Abt 53, 6–41
49. Dharmadhikari, S. W.; Joag-Dev, K. (1985). "The Gauss–Tchebyshev inequality for unimodal distributions" (<http://www.mathnet.ru/links/1043b08ee307d37ab64be90bd9332b88/tvp1919.pdf>) (PDF). *Teoriya Veroyatnostei i ee Primeneniya*. 30 (4): 817–820.
50. Clarkson, Eric; Denny, J. L.; Shepp, Larry (2009). "ROC and the bounds on tail probabilities via theorems of Dubins and F. Riesz" (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2828638>). *The Annals of Applied Probability*. 19 (1): 467–76. arXiv:0903.0518 (<https://arxiv.org/abs/0903.0518>). Bibcode:2009arXiv0903.0518C (<https://ui.adsabs.harvard.edu/abs/2009arXiv0903.0518C>). doi:10.1214/08-AAP536 (<https://doi.org/10.1214%2F08-AAP536>). PMC 2828638 (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2828638>). PMID 20191100 (<https://pubmed.ncbi.nlm.nih.gov/20191100>).
51. McWilliams, Thomas P. (1990). "A Distribution-Free Test for Symmetry Based on a Runs Statistic". *Journal of the American Statistical Association*. 85 (412): 1130–3. doi:10.2307/2289611 (<https://doi.org/10.2307%2F2289611>). ISSN 0162-1459 (<https://www.worldcat.org/issn/0162-1459>). JSTOR 2289611 (<https://www.jstor.org/stable/2289611>).
52. Seaman, John W., Jr.; Young, Dean M.; Odell, Patrick L. (1987). "Improving small sample variance estimators for bounded random variables". *Industrial Mathematics*. 37: 65–75. ISSN 0019-8528 (<https://www.worldcat.org/issn/0019-8528>). Zbl 0637.62024 (<https://zbmath.org/?format=complete&q=an:0637.62024>).
53. Bickel, Peter J.; Krieger, Abba M. (1992). "Extensions of Chebyshev's Inequality with Applications" (<http://www.math.uni.wroc.pl/~pms/files/13.2/Article/13.2.11.pdf>) (PDF). *Probability and Mathematical Statistics*. 13 (2): 293–310. ISSN 0208-4147 (<https://www.worldcat.org/issn/0208-4147>). Retrieved 6 October 2012.
54. DasGupta, A (2000). "Best constants in Chebychev inequalities with various applications". *Metrika*. 5 (1): 185–200. doi:10.1007/s184-000-8316-9 (<https://doi.org/10.1007%2Fs184-000-8316-9>). S2CID 121436601 (<https://api.semanticscholar.org/CorpusID:121436601>).
55. "More thoughts on a one tailed version of Chebyshev's inequality – by Henry Bottomley" (<http://www.se16.info/~se16/hgb/cheb2.htm#3unimodalinequalities>). se16.info. Retrieved 2012-06-12.
56. Grechuk, B., Molyboha, A., Zabarankin, M. (2010). *Chebyshev Inequalities with Law Invariant Deviation Measures* (https://www.researchgate.net/publication/231939730_Chebyshev_inequalities_with_law-invariant_deviation_measures), Probability in the Engineering and Informational Sciences, 24(1), 145-170.
57. Godwin H. J. (1964) Inequalities on distribution functions. (Chapter 3) New York, Hafner Pub. Co.
58. Lesley F. D., Rotar V. I. (2003) Some remarks on lower bounds of Chebyshev's type for half-lines. *J Inequalities Pure Appl Math* 4(5) Art 96
59. Fink, A. M.; Jodeit, Max, Jr. (1984). "On Chebyshev's other inequality" (<http://projecteuclid.org/euclid.lnms/1215465617>). In Tong, Y. L.; Gupta, Shanti S. (eds.). *Inequalities in Statistics and Probability*. Institute of Mathematical Statistics Lecture Notes - Monograph Series. 5. pp. 115–120. doi:10.1214/lnms/1215465637 (<https://doi.org/10.1214%2Flnms%2F1215465637>). ISBN 978-0-940600-04-1. MR 0789242 (<https://www.ams.org/mathscinet-getitem?mr=0789242>). Retrieved 7 October 2012.

60. Niculescu, Constantin P. (2001). "An extension of Chebyshev's inequality and its connection with Jensen's inequality" (http://emis.matem.unam.mx/journals/HOA/JIA/Volume6_4/462.html). *Journal of Inequalities and Applications*. **6** (4): 451–462. CiteSeerX 10.1.1.612.7056 (<https://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.612.7056>). doi:10.1155/S1025583401000273 (<https://doi.org/10.1155%2FS1025583401000273>). ISSN 1025-5834 (<https://www.worldcat.org/issn/1025-5834>). Retrieved 6 October 2012.
61. Niculescu, Constantin P.; Pečarić, Josip (2010). "The Equivalence of Chebyshev's Inequality to the Hermite–Hadamard Inequality" (http://www.csm.ro/reviste/Mathematical_Reports/Pdfs/2010/2/Niculescu.pdf) (PDF). *Mathematical Reports*. **12** (62): 145–156. ISSN 1582-3067 (<https://www.worldcat.org/issn/1582-3067>). Retrieved 6 October 2012.
62. Malamud, S. M. (15 February 2001). "Some complements to the Jensen and Chebyshev inequalities and a problem of W. Walter" (<https://www.ams.org/journals/proc/2001-129-09/S0002-9939-01-05849-X/>). *Proceedings of the American Mathematical Society*. **129** (9): 2671–2678. doi:10.1090/S0002-9939-01-05849-X (<https://doi.org/10.1090%2FS0002-9939-01-05849-X>). ISSN 0002-9939 (<https://www.worldcat.org/issn/0002-9939>). MR 1838791 (<https://www.ams.org/mathscinet-getitem?mr=1838791>). Retrieved 7 October 2012.
63. Haldane, J. B. (1952). "Simple tests for bimodality and bitangentiality". *Annals of Eugenics*. **16** (4): 359–364. doi:10.1111/j.1469-1809.1951.tb02488.x (<https://doi.org/10.1111%2Fj.1469-1809.1951.tb02488.x>). PMID 14953132 (<https://pubmed.ncbi.nlm.nih.gov/14953132>).
64. Kendall M. G. (1943) The Advanced Theory of Statistics, 1. London

Further reading

- A. Papoulis (1991), *Probability, Random Variables, and Stochastic Processes*, 3rd ed. McGraw–Hill. ISBN 0-07-100870-5. pp. 113–114.
- G. Grimmett and D. Stirzaker (2001), *Probability and Random Processes*, 3rd ed. Oxford. ISBN 0-19-857222-0. Section 7.3.

External links

- "Chebyshev inequality in probability theory" (https://www.encyclopediaofmath.org/index.php?title=Chebyshev_inequality_in_probability_theory), *Encyclopedia of Mathematics*, EMS Press, 2001 [1994]
- Formal proof (https://web.archive.org/web/20131204193123/http://mws.cs.ru.nl/mwiki/random_2.html#T7) in the Mizar system.

Retrieved from "https://en.wikipedia.org/w/index.php?title=Chebyshev%27s_inequality&oldid=1021975106"

This page was last edited on 7 May 2021, at 18:23 (UTC).

Text is available under the Creative Commons Attribution-ShareAlike License; additional terms may apply. By using this site, you agree to the Terms of Use and Privacy Policy. Wikipedia® is a registered trademark of the Wikimedia Foundation, Inc., a non-profit organization.

Convergence of random variables

In probability theory, there exist several different notions of **convergence of random variables**. The convergence of sequences of random variables to some limit random variable is an important concept in probability theory, and its applications to statistics and stochastic processes. The same concepts are known in more general mathematics as **stochastic convergence** and they formalize the idea that a sequence of essentially random or unpredictable events can sometimes be expected to settle down into a behavior that is essentially unchanging when items far enough into the sequence are studied. The different possible notions of convergence relate to how such a behavior can be characterized: two readily understood behaviors are that the sequence eventually takes a constant value, and that values in the sequence continue to change but can be described by an unchanging probability distribution.

Contents

Background

Convergence in distribution

- [Definition](#)
- [Properties](#)

Convergence in probability

- [Definition](#)
- [Properties](#)

Almost sure convergence

- [Definition](#)
- [Properties](#)

Sure convergence or pointwise convergence

Convergence in mean

Properties

See also

Notes

References

Background

"Stochastic convergence" formalizes the idea that a sequence of essentially random or unpredictable events can sometimes be expected to settle into a pattern. The pattern may for instance be

- Convergence in the classical sense to a fixed value, perhaps itself coming from a random event
- An increasing similarity of outcomes to what a purely deterministic function would produce
- An increasing preference towards a certain outcome
- An increasing "aversion" against straying far away from a certain outcome
- That the probability distribution describing the next outcome may grow increasingly similar to a certain distribution

Some less obvious, more theoretical patterns could be

- That the series formed by calculating the expected value of the outcome's distance from a particular value may converge to 0
- That the variance of the random variable describing the next event grows smaller and smaller.

These other types of patterns that may arise are reflected in the different types of stochastic convergence that have been studied.

While the above discussion has related to the convergence of a single series to a limiting value, the notion of the convergence of two series towards each other is also important, but this is easily handled by studying the sequence defined as either the difference or the ratio of the two series.

For example, if the average of n independent random variables Y_i , $i = 1, \dots, n$, all having the same finite mean and variance, is given by

$$X_n = \frac{1}{n} \sum_{i=1}^n Y_i,$$

then as n tends to infinity, X_n converges *in probability* (see below) to the common mean, μ , of the random variables Y_i . This result is known as the weak law of large numbers. Other forms of convergence are important in other useful theorems, including the central limit theorem.

Throughout the following, we assume that (X_n) is a sequence of random variables, and X is a random variable, and all of them are defined on the same probability space $(\Omega, \mathcal{F}, \Pr)$.

Convergence in distribution

With this mode of convergence, we increasingly expect to see the next outcome in a sequence of random experiments becoming better and better modeled by a given probability distribution.

Examples of convergence in distribution

Dice factory

Convergence in distribution is the weakest form of convergence typically discussed, since it is implied by all other types of convergence mentioned in this article. However, convergence in distribution is very frequently used in practice; most often it arises from application of the [central limit theorem](#).

Definition

A sequence X_1, X_2, \dots of real-valued [random variables](#) is said to **converge in distribution**, or **converge weakly**, or **converge in law** to a random variable X if

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

for every number $x \in \mathbb{R}$ at which F is [continuous](#). Here F_n and F are the [cumulative distribution functions](#) of random variables X_n and X , respectively.

The requirement that only the continuity points of F should be considered is essential. For example, if X_n are distributed [uniformly](#) on intervals $(0, \frac{1}{n})$, then this sequence converges in distribution to a [degenerate](#) random variable $X = 0$. Indeed, $F_n(x) = 0$ for all n when $x \leq 0$, and $F_n(x) = 1$ for all $x \geq \frac{1}{n}$ when $n > 0$. However, for this limiting random variable $F(0) = 1$, even though $F_n(0) = 0$ for all n . Thus the convergence of cdfs fails at the point $x = 0$ where F is discontinuous.

Convergence in distribution may be denoted as

Suppose a new dice factory has just been built. The first few dice come out quite biased, due to imperfections in the production process. The outcome from tossing any of them will follow a distribution markedly different from the desired uniform distribution.

As the factory is improved, the dice become less and less loaded, and the outcomes from tossing a newly produced die will follow the uniform distribution more and more closely.

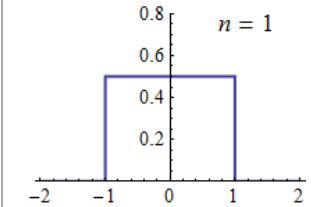
Tossing coins

Let X_n be the fraction of heads after tossing up an unbiased coin n times. Then X_1 has the [Bernoulli distribution](#) with expected value $\mu = 0.5$ and variance $\sigma^2 = 0.25$. The subsequent random variables X_2, X_3, \dots will all be distributed [binomially](#).

As n grows larger, this distribution will gradually start to take shape more and more similar to the [bell curve](#) of the normal distribution. If we shift and rescale X_n appropriately, then $Z_n = \frac{\sqrt{n}}{\sigma} (X_n - \mu)$ will be [converging in distribution](#) to the standard normal, the result that follows from the celebrated [central limit theorem](#).

Graphic example

Suppose $\{X_i\}$ is an [iid](#) sequence of [uniform](#) $U(-1, 1)$ random variables. Let $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i$ be their [\(normalized\)](#) sums. Then according to the [central limit theorem](#), the distribution of Z_n approaches the [normal](#) $N(0, \frac{1}{3})$ distribution. This convergence is shown in the picture: as n grows larger, the shape of the probability density function gets closer and closer to the Gaussian curve.



$$X_n \xrightarrow{d} X, \quad X_n \xrightarrow{D} X, \quad X_n \xrightarrow{L} X, \quad X_n \xrightarrow{d} \mathcal{L}_X, \\ X_n \rightsquigarrow X, \quad X_n \Rightarrow X, \quad \mathcal{L}(X_n) \rightarrow \mathcal{L}(X), \quad (1)$$

where \mathcal{L}_X is the law (probability distribution) of X . For example, if X is standard normal we can write $X_n \xrightarrow{d} \mathcal{N}(0, 1)$.

For [random vectors](#) $\{X_1, X_2, \dots\} \subset \mathbf{R}^k$ the convergence in distribution is defined similarly. We say that this sequence **converges in distribution** to a random k -vector X if

$$\lim_{n \rightarrow \infty} \Pr(X_n \in A) = \Pr(X \in A)$$

for every $A \subset \mathbf{R}^k$ which is a [continuity set](#) of X .

The definition of convergence in distribution may be extended from random vectors to more general random elements in arbitrary metric spaces, and even to the “random variables” which are not measurable — a situation which occurs for example in the study of empirical processes. This is the “weak convergence of laws without laws being defined” — except asymptotically.^[1]

In this case the term **weak convergence** is preferable (see weak convergence of measures), and we say that a sequence of random elements $\{X_n\}$ converges weakly to X (denoted as $X_n \Rightarrow X$) if

$$\mathbf{E}^* h(X_n) \rightarrow \mathbf{E} h(X)$$

for all continuous bounded functions h .^[2] Here \mathbf{E}^* denotes the *outer expectation*, that is the expectation of a “smallest measurable function g that dominates $h(X_n)$ ”.

Properties

- Since $F(a) = \Pr(X \leq a)$, the convergence in distribution means that the probability for X_n to be in a given range is approximately equal to the probability that the value of X is in that range, provided n is sufficiently large.
- In general, convergence in distribution does not imply that the sequence of corresponding probability density functions will also converge. As an example one may consider random variables with densities $f_n(x) = (1 - \cos(2\pi nx))\mathbf{1}_{(0,1)}$. These random variables converge in distribution to a uniform $U(0, 1)$, whereas their densities do not converge at all.^[3]
 - However, according to Scheffé's theorem, convergence of the probability density functions implies convergence in distribution.^[4]
- The **portmanteau lemma** provides several equivalent definitions of convergence in distribution. Although these definitions are less intuitive, they are used to prove a number of statistical theorems. The lemma states that $\{X_n\}$ converges in distribution to X if and only if any of the following statements are true:^[5]
 - $\Pr(X_n \leq x) \rightarrow \Pr(X \leq x)$ for all continuity points of $x \mapsto \Pr(X \leq x)$;
 - $\mathbf{E} f(X_n) \rightarrow \mathbf{E} f(X)$ for all bounded, continuous functions f (where \mathbf{E} denotes the expected value operator);
 - $\mathbf{E} f(X_n) \rightarrow \mathbf{E} f(X)$ for all bounded, Lipschitz functions f ;
 - $\liminf \mathbf{E} f(X_n) \geq \mathbf{E} f(X)$ for all nonnegative, continuous functions f ;
 - $\liminf \Pr(X_n \in G) \geq \Pr(X \in G)$ for every open set G ;
 - $\limsup \Pr(X_n \in F) \leq \Pr(X \in F)$ for every closed set F ;
 - $\Pr(X_n \in B) \rightarrow \Pr(X \in B)$ for all continuity sets B of random variable X ;
 - $\limsup \mathbf{E} f(X_n) \leq \mathbf{E} f(X)$ for every upper semi-continuous function f bounded above;
 - $\liminf \mathbf{E} f(X_n) \geq \mathbf{E} f(X)$ for every lower semi-continuous function f bounded below.
- The **continuous mapping theorem** states that for a continuous function g , if the sequence $\{X_n\}$ converges in distribution to X , then $\{g(X_n)\}$ converges in distribution to $g(X)$.
 - Note however that convergence in distribution of $\{X_n\}$ to X and $\{Y_n\}$ to Y does in general not imply convergence in distribution of $\{X_n + Y_n\}$ to $X + Y$ or of $\{X_n Y_n\}$ to XY .
- **Lévy's continuity theorem:** the sequence $\{X_n\}$ converges in distribution to X if and only if the sequence of corresponding characteristic functions $\{\varphi_n\}$ converges pointwise to the characteristic function φ of X .
- Convergence in distribution is metrizable by the Lévy–Prokhorov metric.
- A natural link to convergence in distribution is the Skorokhod's representation theorem.

Convergence in probability

The basic idea behind this type of convergence is that the probability of an “unusual” outcome becomes smaller and smaller as the sequence progresses.

The concept of convergence in probability is used very often in statistics. For example, an estimator is called consistent if it converges in probability to the quantity being estimated. Convergence in probability is also the type of convergence established by the weak law of large numbers.

Definition

A sequence $\{X_n\}$ of random variables **converges in probability** towards the random variable X if for all $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} \Pr(|X_n - X| > \varepsilon) = 0.$$

More explicitly, let $P_n(\varepsilon)$ be the probability that X_n is outside the ball of radius ε centered at X . Then X_n is said to converge in probability to X if for any $\varepsilon > 0$ and any $\delta > 0$ there exists a number N (which may depend on ε and δ) such that for all $n \geq N$, $P_n(\varepsilon) < \delta$ (the definition of limit).

Notice that for the condition to be satisfied, it is not possible that for each n the random variables X and X_n are independent (and thus convergence in probability is a condition on the joint cdf's, as opposed to convergence in distribution, which is a condition on the individual cdf's), unless X is deterministic like for the weak law of large numbers. At the same time, the case of a deterministic X cannot, whenever the deterministic value is a discontinuity point (not isolated), be handled by convergence in distribution, where discontinuity points have to be explicitly excluded.

Examples of convergence in probability

Height of a person

Consider the following experiment. First, pick a random person in the street. Let X be his/her height, which is *ex ante* a random variable. Then ask other people to estimate this height by eye. Let X_n be the average of the first n responses. Then (provided there is no systematic error) by the law of large numbers, the sequence X_n will converge in probability to the random variable X .

Predicting random number generation

Suppose that a random number generator generates a pseudorandom floating point number between 0 and 1. Let random variable X represent the distribution of possible outputs by

Convergence in probability is denoted by adding the letter p over an arrow indicating convergence, or using the "plim" probability limit operator:

the algorithm. Because the pseudorandom number is generated deterministically, its next value is not truly random. Suppose that as you observe a sequence of randomly generated numbers, you can deduce a pattern and make increasingly accurate predictions as to what the next randomly generated number will be. Let X_n be your guess of the value of the next random number after observing the first n random numbers. As you learn the pattern and your guesses become more accurate, not only will the distribution of X_n converge to the distribution of X , but the outcomes of X_n will converge to the outcomes of X .

$$X_n \xrightarrow{p} X, \quad X_n \xrightarrow{P} X, \quad \text{plim}_{n \rightarrow \infty} X_n = X. \quad (2)$$

For random elements $\{X_n\}$ on a separable metric space (S, d) , convergence in probability is defined similarly by^[6]

$$\forall \varepsilon > 0, \Pr(d(X_n, X) \geq \varepsilon) \rightarrow 0.$$

Properties

- Convergence in probability implies convergence in distribution.[\[proof\]](#)
- In the opposite direction, convergence in distribution implies convergence in probability when the limiting random variable X is a constant.[\[proof\]](#)
- Convergence in probability does not imply almost sure convergence.[\[proof\]](#)
- The continuous mapping theorem states that for every continuous function $g(\cdot)$, if $X_n \xrightarrow{P} X$, then also $g(X_n) \xrightarrow{P} g(X)$.
- Convergence in probability defines a topology on the space of random variables over a fixed probability space. This topology is metrizable by the Ky Fan metric.^[7]

$$d(X, Y) = \inf\{\varepsilon > 0 : \Pr(|X - Y| > \varepsilon) \leq \varepsilon\}$$

or alternately by this metric

$$d(X, Y) = \mathbb{E}[\min(|X - Y|, 1)].$$

Almost sure convergence

This is the type of stochastic convergence that is most similar to pointwise convergence known from elementary real analysis.

Definition

To say that the sequence X_n converges **almost surely** or **almost everywhere** or **with probability 1** or **strongly** towards X means that

$$\Pr\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

This means that the values of X_n approach the value of X , in the sense (see almost surely) that events for which X_n does not converge to X have probability 0. Using the probability space $(\Omega, \mathcal{F}, \Pr)$ and the concept of the random variable as a function from Ω to \mathbf{R} , this is equivalent to the statement

$$\Pr\left(\omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right) = 1.$$

Using the notion of the limit superior of a sequence of sets, almost sure convergence can also be defined as follows:

$$\Pr\left(\limsup_{n \rightarrow \infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) = 0 \quad \text{for all } \varepsilon > 0.$$

Almost sure convergence is often denoted by adding the letters *a.s.* over an arrow indicating convergence:

$$X_n \xrightarrow{\text{a.s.}} X. \quad (3)$$

For generic random elements $\{X_n\}$ on a metric space (S, d) , convergence almost surely is defined similarly:

Examples of almost sure convergence

Example 1

Consider an animal of some short-lived species. We record the amount of food that this animal consumes per day. This sequence of numbers will be unpredictable, but we may be *quite certain* that one day the number will become zero, and will stay zero forever after.

Example 2

Consider a man who tosses seven coins every morning. Each afternoon, he donates one pound to a charity for each head that appeared. The first time the result is all tails, however, he will stop permanently.

Let X_1, X_2, \dots be the daily amounts the charity received from him.

We may be *almost sure* that one day this amount will be zero, and stay zero forever after that.

$$\Pr \left(\omega \in \Omega : d(X_n(\omega), X(\omega)) \xrightarrow{n \rightarrow \infty} 0 \right) = 1$$

However, when we consider *any finite number* of days, there is a nonzero probability the terminating condition will not occur.

Properties

- Almost sure convergence implies convergence in probability (by Fatou's lemma), and hence implies convergence in distribution. It is the notion of convergence used in the strong law of large numbers.
- The concept of almost sure convergence does not come from a topology on the space of random variables. This means there is no topology on the space of random variables such that the almost surely convergent sequences are exactly the converging sequences with respect to that topology. In particular, there is no metric of almost sure convergence.

Sure convergence or pointwise convergence

To say that the sequence of random variables (X_n) defined over the same probability space (i.e., a random process) converges **surely** or **everywhere** or **pointwise** towards X means

$$\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega), \quad \forall \omega \in \Omega.$$

where Ω is the sample space of the underlying probability space over which the random variables are defined.

This is the notion of pointwise convergence of a sequence of functions extended to a sequence of random variables. (Note that random variables themselves are functions).

$$\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\} = \Omega.$$

Sure convergence of a random variable implies all the other kinds of convergence stated above, but there is no payoff in probability theory by using sure convergence compared to using almost sure convergence. The difference between the two only exists on sets with probability zero. This is why the concept of sure convergence of random variables is very rarely used.

Convergence in mean

Given a real number $r \geq 1$, we say that the sequence X_n converges **in the r -th mean** (or **in the L^r -norm**) towards the random variable X , if the r -th absolute moments $E(|X_n|^r)$ and $E(|X|^r)$ of X_n and X exist, and

$$\lim_{n \rightarrow \infty} E(|X_n - X|^r) = 0,$$

where the operator E denotes the expected value. Convergence in r -th mean tells us that the expectation of the r -th power of the difference between X_n and X converges to zero.

This type of convergence is often denoted by adding the letter L^r over an arrow indicating convergence:

$$X_n \xrightarrow{L^r} X. \tag{4}$$

The most important cases of convergence in r -th mean are:

- When X_n converges in r -th mean to X for $r = 1$, we say that X_n converges **in mean** to X .
- When X_n converges in r -th mean to X for $r = 2$, we say that X_n converges **in mean square** (or **in quadratic mean**) to X .

Convergence in the r -th mean, for $r \geq 1$, implies convergence in probability (by Markov's inequality). Furthermore, if $r > s \geq 1$, convergence in r -th mean implies convergence in s -th mean. Hence, convergence in mean square implies convergence in mean.

It is also worth noticing that if

$$X_n \xrightarrow{L^r} X, \tag{4}$$

then

$$\lim_{n \rightarrow \infty} E[|X_n|^r] = E[|X|^r]$$

Properties

Provided the probability space is complete:

- If $X_n \xrightarrow{p} X$ and $X_n \xrightarrow{p} Y$, then $X = Y$ almost surely.
- If $X_n \xrightarrow{\text{a.s.}} X$ and $X_n \xrightarrow{\text{a.s.}} Y$, then $X = Y$ almost surely.
- If $X_n \xrightarrow{L^r} X$ and $X_n \xrightarrow{L^r} Y$, then $X = Y$ almost surely.
- If $X_n \xrightarrow{p} X$ and $Y_n \xrightarrow{p} Y$, then $aX_n + bY_n \xrightarrow{p} aX + bY$ (for any real numbers a and b) and $X_n Y_n \xrightarrow{p} XY$.
- If $X_n \xrightarrow{\text{a.s.}} X$ and $Y_n \xrightarrow{\text{a.s.}} Y$, then $aX_n + bY_n \xrightarrow{\text{a.s.}} aX + bY$ (for any real numbers a and b) and $X_n Y_n \xrightarrow{\text{a.s.}} XY$.

- If $X_n \xrightarrow{L^r} X$ and $Y_n \xrightarrow{L^r} Y$, then $aX_n + bY_n \xrightarrow{L^r} aX + bY$ (for any real numbers a and b).
- None of the above statements are true for convergence in distribution.

The chain of implications between the various notions of convergence are noted in their respective sections. They are, using the arrow notation:

$$\begin{array}{ccccc} \xrightarrow{L^s} & & \xrightarrow{L^r} & & \\ s > r \geq 1 & \Rightarrow & & & \\ & \downarrow & & & \\ \xrightarrow{\text{a.s.}} & \Rightarrow & \xrightarrow{p} & \Rightarrow & \xrightarrow{d} \end{array}$$

These properties, together with a number of other special cases, are summarized in the following list:

- Almost sure convergence implies convergence in probability.^[8][\[proof\]](#)

$$X_n \xrightarrow{\text{a.s.}} X \Rightarrow X_n \xrightarrow{p} X$$

- Convergence in probability implies there exists a sub-sequence (k_n) which almost surely converges:^[9]

$$X_n \xrightarrow{p} X \Rightarrow X_{k_n} \xrightarrow{\text{a.s.}} X$$

- Convergence in probability implies convergence in distribution:^[8][\[proof\]](#)

$$X_n \xrightarrow{p} X \Rightarrow X_n \xrightarrow{d} X$$

- Convergence in r -th order mean implies convergence in probability:

$$X_n \xrightarrow{L^r} X \Rightarrow X_n \xrightarrow{p} X$$

- Convergence in r -th order mean implies convergence in lower order mean, assuming that both orders are greater than or equal to one:

$$X_n \xrightarrow{L^r} X \Rightarrow X_n \xrightarrow{L^s} X, \quad \text{provided } r \geq s \geq 1.$$

- If X_n converges in distribution to a constant c , then X_n converges in probability to c .^[8][\[proof\]](#)

$$X_n \xrightarrow{d} c \Rightarrow X_n \xrightarrow{p} c, \quad \text{provided } c \text{ is a constant.}$$

- If X_n converges in distribution to X and the difference between X_n and Y_n converges in probability to zero, then Y_n also converges in distribution to X .^[8][\[proof\]](#)

$$X_n \xrightarrow{d} X, |X_n - Y_n| \xrightarrow{p} 0 \Rightarrow Y_n \xrightarrow{d} X$$

- If X_n converges in distribution to X and Y_n converges in distribution to a constant c , then the joint vector (X_n, Y_n) converges in distribution to (X, c) .^[8][\[proof\]](#)

$$X_n \xrightarrow{d} X, Y_n \xrightarrow{d} c \Rightarrow (X_n, Y_n) \xrightarrow{d} (X, c) \quad \text{provided } c \text{ is a constant.}$$

Note that the condition that Y_n converges to a constant is important, if it were to converge to a random variable Y then we wouldn't be able to conclude that (X_n, Y_n) converges to (X, Y) .

- If X_n converges in probability to X and Y_n converges in probability to Y , then the joint vector (X_n, Y_n) converges in probability to (X, Y) .^[8][\[proof\]](#)

$$X_n \xrightarrow{p} X, Y_n \xrightarrow{p} Y \Rightarrow (X_n, Y_n) \xrightarrow{p} (X, Y)$$

- If X_n converges in probability to X , and if $\mathbf{P}(|X_n| \leq b) = 1$ for all n and some b , then X_n converges in r th mean to X for all $r \geq 1$. In other words, if X_n converges in probability to X and all random variables X_n are almost surely bounded above and below, then X_n converges to X also in any r th mean.

- **Almost sure representation.** Usually, convergence in distribution does not imply convergence almost surely. However, for a given sequence $\{X_n\}$ which converges in distribution to X_0 it is always possible to find a new probability space (Ω, \mathcal{F}, P) and random variables $\{Y_n, n = 0, 1, \dots\}$ defined on it such that Y_n is equal in distribution to X_n for each $n \geq 0$, and Y_n converges to Y_0 almost surely.^[10][\[11\]](#)

- If for all $\varepsilon > 0$,

$$\sum_n \mathbf{P}(|X_n - X| > \varepsilon) < \infty,$$

then we say that X_n converges almost completely, or almost in probability towards X . When X_n converges almost completely towards X then it also converges almost surely to X . In other words, if X_n converges in probability to X sufficiently quickly (i.e. the above sequence of tail probabilities is summable for all $\varepsilon > 0$), then X_n also converges almost surely to X . This is a direct implication from the Borel-Cantelli lemma.

- If S_n is a sum of n real independent random variables:

$$S_n = X_1 + \cdots + X_n$$

then S_n converges almost surely if and only if S_n converges in probability.

- The dominated convergence theorem gives sufficient conditions for almost sure convergence to imply L^1 -convergence:

$$\left. \begin{array}{l} X_n \xrightarrow{\text{a.s.}} X \\ |X_n| < Y \\ \mathbb{E}(Y) < \infty \end{array} \right\} \Rightarrow X_n \xrightarrow{L^1} X \quad (5)$$

- A necessary and sufficient condition for L^1 convergence is $X_n \xrightarrow{P} X$ and the sequence (X_n) is uniformly integrable.

See also

- [Proofs of convergence of random variables](#)
- [Convergence of measures](#)
- [Convergence in measure](#)
- Continuous stochastic process: the question of continuity of a stochastic process is essentially a question of convergence, and many of the same concepts and relationships used above apply to the continuity question.
- [Asymptotic distribution](#)
- [Big O in probability notation](#)
- [Skorokhod's representation theorem](#)
- [The Tweedie convergence theorem](#)
- [Slutsky's theorem](#)
- [Continuous mapping theorem](#)

Notes

- Bickel et al. 1998, A.8, page 475
- van der Vaart & Wellner 1996, p. 4
- Romano & Siegel 1985, Example 5.26
- Durrett, Rick (2010). *Probability: Theory and Examples*. p. 84.
- van der Vaart 1998, Lemma 2.2
- Dudley 2002, Chapter 9.2, page 287
- Dudley 2002, p. 289
- van der Vaart 1998, Theorem 2.7
- Gut, Allan (2005). *Probability: A graduate course*. Theorem 3.4: Springer. ISBN 978-0-387-22833-4.
- van der Vaart 1998, Th.2.19
- Fristedt & Gray 1997, Theorem 14.5

References

- Bickel, Peter J.; Klaassen, Chris A.J.; Ritov, Ya'acov; Wellner, Jon A. (1998). *Efficient and adaptive estimation for semiparametric models*. New York: Springer-Verlag. ISBN 978-0-387-98473-5.
- Billingsley, Patrick (1986). *Probability and Measure*. Wiley Series in Probability and Mathematical Statistics (2nd ed.). Wiley.
- Billingsley, Patrick (1999). [Convergence of probability measures](https://archive.org/details/convergenceofprob0000bill) (<https://archive.org/details/convergenceofprob0000bill>) (2nd ed.). John Wiley & Sons. pp. 1–28 (<https://archive.org/details/convergenceofprob0000bill/page/1>). ISBN 978-0-471-19745-4.
- Dudley, R.M. (2002). *Real analysis and probability*. Cambridge, UK: Cambridge University Press. ISBN 978-0-521-80972-6.
- Fristedt, Bert; Gray, Lawrence (1997). *A Modern Approach to Probability Theory*. New York: Springer Science+Business Media. doi:10.1007/978-1-4899-2837-5 (<https://doi.org/10.1007%2F978-1-4899-2837-5>). ISBN 978-1-4899-2837-5.
- Grimmett, G.R.; Stirzaker, D.R. (1992). *Probability and random processes* (2nd ed.). Clarendon Press, Oxford. pp. 271–285. ISBN 978-0-19-853665-9.
- <https://www.ma.utexas.edu/users/gordanz/notes/weak.pdf>
- Jacobsen, M. (1992). *Videregående Sandsynlighedsregning (Advanced Probability Theory)* (3rd ed.). HCØ-tryk, Copenhagen. pp. 18–20. ISBN 978-87-91180-71-2.
- Ledoux, Michel; Talagrand, Michel (1991). *Probability in Banach spaces*. Berlin: Springer-Verlag. pp. xii+480. ISBN 978-3-540-52013-9. MR 1102015 (<https://www.ams.org/mathscinet-getitem?mr=1102015>).
- Romano, Joseph P.; Siegel, Andrew F. (1985). *Counterexamples in probability and statistics*. Great Britain: Chapman & Hall. ISBN 978-0-412-98901-8.
- van der Vaart, Aad W.; Wellner, Jon A. (1996). *Weak convergence and empirical processes*. New York: Springer-Verlag. ISBN 978-0-387-94640-5.
- van der Vaart, Aad W. (1998). *Asymptotic statistics*. New York: Cambridge University Press. ISBN 978-0-521-49603-2.
- Williams, D. (1991). *Probability with Martingales*. Cambridge University Press. ISBN 978-0-521-40605-5.
- Wong, E.; Hájek, B. (1985). *Stochastic Processes in Engineering Systems*. New York: Springer-Verlag.

This article incorporates material from the [Citizendium](#) article "Stochastic convergence", which is licensed under the [Creative Commons Attribution-ShareAlike 3.0 Unported License](#) but not under the [GFDL](#).

Retrieved from "https://en.wikipedia.org/w/index.php?title=Convergence_of_random_variables&oldid=1006923930"

This page was last edited on 15 February 2021, at 15:33 (UTC).

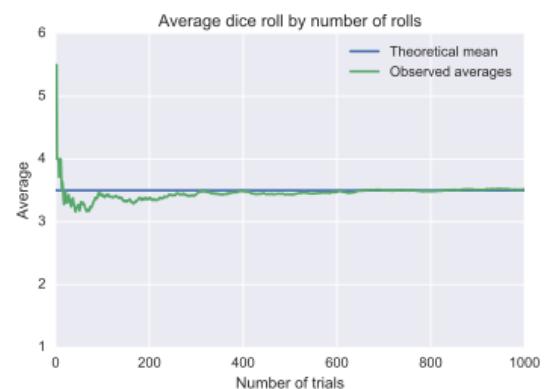
Text is available under the Creative Commons Attribution-ShareAlike License; additional terms may apply. By using this site, you agree to the Terms of Use and Privacy Policy. Wikipedia® is a registered trademark of the Wikimedia Foundation, Inc., a non-profit organization.

WIKIPEDIA

Law of large numbers

In probability theory, the **law of large numbers (LLN)** is a theorem that describes the result of performing the same experiment a large number of times. According to the law, the average of the results obtained from a large number of trials should be close to the expected value and will tend to become closer to the expected value as more trials are performed.^[1]

The LLN is important because it guarantees stable long-term results for the averages of some random events.^{[1][2]} For example, while a casino may lose money in a single spin of the roulette wheel, its earnings will tend towards a predictable percentage over a large number of spins. Any winning streak by a player will eventually be overcome by the parameters of the game. It is important to remember that the law only applies (as the name indicates) when a *large number* of observations is considered. There is no principle that a small number of observations will coincide with the expected value or that a streak of one value will immediately be "balanced" by the others (see the gambler's fallacy).



An illustration of the law of large numbers using a particular run of rolls of a single die. As the number of rolls in this run increases, the average of the values of all the results approaches 3.5. Although each run would show a distinctive shape over a small number of throws (at the left), over a large number of rolls (to the right) the shapes would be extremely similar.

Contents

[Examples](#)

[Limitation](#)

[History](#)

[Forms](#)

[Weak law](#)

[Strong law](#)

[Differences between the weak law and the strong law](#)

[Uniform law of large numbers](#)

[Borel's law of large numbers](#)

[Proof of the weak law](#)

[Proof using Chebyshev's inequality assuming finite variance](#)

[Proof using convergence of characteristic functions](#)

[Consequences](#)

[See also](#)

[Notes](#)

[References](#)

[External links](#)

Examples

For example, a single roll of a fair, six-sided die produces one of the numbers 1, 2, 3, 4, 5, or 6, each with equal probability. Therefore, the expected value of the average of the rolls is:

$$\frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3.5$$

According to the law of large numbers, if a large number of six-sided dice are rolled, the average of their values (sometimes called the sample mean) is likely to be close to 3.5, with the precision increasing as more dice are rolled.

It follows from the law of large numbers that the empirical probability of success in a series of Bernoulli trials will converge to the theoretical probability. For a Bernoulli random variable, the expected value is the theoretical probability of success, and the average of n such variables (assuming they are independent and identically distributed (i.i.d.)) is precisely the relative frequency.

For example, a fair coin toss is a Bernoulli trial. When a fair coin is flipped once, the theoretical probability that the outcome will be heads is equal to $\frac{1}{2}$. Therefore, according to the law of large numbers, the proportion of heads in a "large" number of coin flips "should be" roughly $\frac{1}{2}$. In particular, the proportion of heads after n flips will almost surely converge to $\frac{1}{2}$ as n approaches infinity.

Although the proportion of heads (and tails) approaches $\frac{1}{2}$, almost surely the absolute difference in the number of heads and tails will become large as the number of flips becomes large. That is, the probability that the absolute difference is a small number approaches zero as the number of flips becomes large. Also, almost surely the ratio of the absolute difference to the number of flips will approach zero. Intuitively, the expected difference grows, but at a slower rate than the number of flips.

Another good example of the LLN is the [Monte Carlo method](#). These methods are a broad class of [computational algorithms](#) that rely on repeated [random sampling](#) to obtain numerical results. The larger the number of repetitions, the better the approximation tends to be. The reason that this method is important is mainly that, sometimes, it is difficult or impossible to use other approaches.^[3]

Limitation

The average of the results obtained from a large number of trials may fail to converge in some cases. For instance, the average of n results taken from the [Cauchy distribution](#) or some [Pareto distributions](#) ($\alpha < 1$) will not converge as n becomes larger; the reason is [heavy tails](#). The Cauchy distribution and the Pareto distribution represent two cases: the Cauchy distribution does not have an expectation,^[4] whereas the expectation of the Pareto distribution ($\alpha < 1$) is infinite.^[5] Another example is where the random numbers equal the [tangent](#) of an angle uniformly distributed between -90° and $+90^\circ$. The [median](#) is zero, but the expected value does not exist, and indeed the average of n such variables have the same distribution as one such variable. It does not converge in probability toward zero (or any other value) as n goes to infinity.

History

The Italian mathematician [Gerolamo Cardano](#) (1501–1576) stated without proof that the accuracies of empirical statistics tend to improve with the number of trials.^[6] This was then formalized as a law of large numbers. A special form of the LLN (for a binary random variable) was first proved by [Jacob Bernoulli](#).^[7] It took him over 20 years to develop a sufficiently rigorous mathematical proof which was published in his *Ars Conjectandi* (The Art of Conjecturing) in 1713. He named this his "Golden Theorem" but it became generally known as "**Bernoulli's Theorem**". This should not be confused with [Bernoulli's principle](#), named after Jacob Bernoulli's nephew [Daniel Bernoulli](#). In 1837, [S.D. Poisson](#) further described it under the name "*la loi des grands nombres*" ("the law of large numbers").^{[8][9]} Thereafter, it was known under both names, but the "law of large numbers" is most frequently used.

After Bernoulli and Poisson published their efforts, other mathematicians also contributed to refinement of the law, including [Chebyshev](#),^[10] [Markov](#), [Borel](#), [Cantelli](#) and [Kolmogorov](#) and [Khinchin](#). Markov showed that the law can apply to a random variable that does not have a finite variance under some other weaker assumption, and Khinchin showed in 1929 that if the series consists of independent identically distributed random variables, it suffices that the expected value exists for the weak law of large numbers to be true.^{[11][12]} These further studies have given rise to two prominent forms of the LLN. One is called the "weak" law and the other the "strong" law, in reference to two different modes of convergence of the cumulative sample means to the expected value; in particular, as explained below, the strong form implies the weak.^[11]

Forms

There are two different versions of the **law of large numbers** that are described below. They are called the **strong law of large numbers** and the **weak law of large numbers**.^{[13][1]} Stated for the case where X_1, X_2, \dots is an infinite sequence of [independent and identically distributed](#) (i.i.d.) Lebesgue integrable random variables with expected value $E(X_1) = E(X_2) = \dots = \mu$, both versions of the law state that – with virtual certainty – the sample average

$$\bar{X}_n = \frac{1}{n}(X_1 + \dots + X_n)$$

converges to the expected value:

$$\bar{X}_n \rightarrow \mu \quad \text{as } n \rightarrow \infty. \tag{law. 1}$$

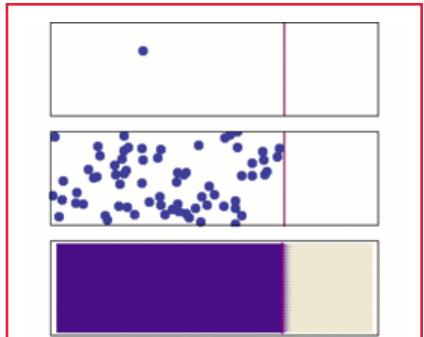
(Lebesgue integrability of X_j means that the expected value $E(X_j)$ exists according to [Lebesgue integration](#) and is finite. It does *not* mean that the associated probability measure is [absolutely continuous](#) with respect to [Lebesgue measure](#).)

Based on the assumption of finite [variance](#) $\text{Var}(X_i) = \sigma^2$ (for all i) and no correlation between random variables, the variance of the average of n random variables

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n}(X_1 + \dots + X_n)\right) = \frac{1}{n^2} \text{Var}(X_1 + \dots + X_n) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Sometimes an assumption of finite [variance](#) $\text{Var}(X_1) = \text{Var}(X_2) = \dots = \sigma^2 < \infty$ is **not necessary**. Large or infinite variance will make the convergence slower, but the LLN holds anyway. This assumption is often used because it makes the proofs easier and shorter.

[Mutual independence](#) of the random variables can be replaced by [pairwise independence](#) in both versions of the law.^[14]



Diffusion is an example of the law of large numbers. Initially, there are [solute](#) molecules on the left side of a barrier (magenta line) and none on the right. The barrier is removed, and the solute diffuses to fill the whole container.

Top: With a single molecule, the motion appears to be quite random.

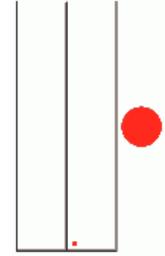
Middle: With more molecules, there is clearly a trend where the solute fills the container more and more uniformly, but there are also random fluctuations.

Bottom: With an enormous number of solute molecules (too many to see), the randomness is essentially gone: The solute appears to move smoothly and systematically from high-concentration areas to low-concentration areas. In realistic situations, chemists can describe diffusion as a deterministic macroscopic phenomenon (see [Fick's laws](#)), despite its underlying random nature.

The difference between the strong and the weak version is concerned with the mode of convergence being asserted. For interpretation of these modes, see [Convergence of random variables](#).

Weak law

The **weak law of large numbers** (also called [Khinchin's law](#)) states that the sample average converges in probability towards the expected value^[15]



Simulation illustrating the law of large numbers. Each frame, a coin that is red on one side and blue on the other is flipped, and a dot is added in the corresponding column. A pie chart shows the proportion of red and blue so far. Notice that while the proportion varies significantly at first, it approaches 50% as the number of trials increases.

$$\overline{X}_n \xrightarrow{P} \mu \quad \text{when } n \rightarrow \infty. \quad (\text{law. 2})$$

That is, for any positive number ε ,

$$\lim_{n \rightarrow \infty} \Pr(|\overline{X}_n - \mu| > \varepsilon) = 0.$$

Interpreting this result, the weak law states that for any nonzero margin specified, no matter how small, with a sufficiently large sample there will be a very high probability that the average of the observations will be close to the expected value; that is, within the margin.

As mentioned earlier, the weak law applies in the case of i.i.d. random variables, but it also applies in some other cases. For example, the variance may be different for each random variable in the series, keeping the expected value constant. If the variances are bounded, then the law applies, as shown by Chebyshev as early as 1867. (If the expected values change during the series, then we can simply apply the law to the average deviation from the respective expected values. The law then states that this converges in probability to zero.) In fact, Chebyshev's proof works so long as the variance of the average of the first n values goes to zero as n goes to infinity.^[12] As an example, assume that each random variable in the series follows a Gaussian distribution with mean zero, but with variance equal to $2n/\log(n+1)$, which is not bounded. At each stage, the average will be normally distributed (as the average of a set of normally distributed variables). The variance of the sum is equal to the sum of the variances, which is asymptotic to $n^2/\log n$. The variance of the average is therefore asymptotic to $1/\log n$ and goes to zero.

There are also examples of the weak law applying even though the expected value does not exist.

Strong law

The **strong law of large numbers** (also called [Kolmogorov's law](#)) states that the sample average converges almost surely to the expected value^[16]

$$\overline{X}_n \xrightarrow{\text{a.s.}} \mu \quad \text{when } n \rightarrow \infty.$$

That is,

$$\Pr\left(\lim_{n \rightarrow \infty} \overline{X}_n = \mu\right) = 1.$$

What this means is that the probability that, as the number of trials n goes to infinity, the average of the observations converges to the expected value, is equal to one.

The proof is more complex than that of the weak law.^[17] This law justifies the intuitive interpretation of the expected value (for Lebesgue integration only) of a random variable when sampled repeatedly as the "long-term average".

Almost sure convergence is also called strong convergence of random variables. This version is called the strong law because random variables which converge strongly (almost surely) are guaranteed to converge weakly (in probability). However the weak law is known to hold in certain conditions where the strong law does not hold and then the convergence is only weak (in probability). See [#Differences between the weak law and the strong law](#).

The strong law of large numbers can itself be seen as a special case of the [pointwise ergodic theorem](#).

The strong law applies to independent identically distributed random variables having an expected value (like the weak law). This was proved by Kolmogorov in 1930. It can also apply in other cases. Kolmogorov also showed, in 1933, that if the variables are independent and identically distributed, then for the average to converge almost surely on *something* (this can be considered another statement of the strong law), it is necessary that they have an expected value (and then of course the average will converge almost surely on that).^[18]

If the summands are independent but not identically distributed, then

$$\overline{X}_n - \mathbb{E}[\overline{X}_n] \xrightarrow{\text{a.s.}} 0,$$

provided that each X_k has a finite second moment and

$$\sum_{k=1}^{\infty} \frac{1}{k^2} \text{Var}[X_k] < \infty.$$

This statement is known as *Kolmogorov's strong law*, see e.g. [Sen & Singer \(1993, Theorem 2.3.10\)](#).

An example of a series where the weak law applies but not the strong law is when X_k is plus or minus $\sqrt{k / \log \log \log k}$ (starting at sufficiently large k so that the denominator is positive) with probability $1/2$ for each.^[18] The variance of X_k is then $k / \log \log \log k$. Kolmogorov's strong law does not apply because the partial sum in his criterion up to $k=n$ is asymptotic to $\log n / \log \log \log n$ and this is unbounded.

If we replace the random variables with Gaussian variables having the same variances, namely $\sqrt{k / \log \log \log k}$, then the average at any point will also be normally distributed. The width of the distribution of the average will tend toward zero (standard deviation asymptotic to $1 / \sqrt{2 \log \log \log n}$), but for a given ε , there is probability which does not go to zero with n , while the average sometime after the n th trial will come back up to ε . Since the width of the distribution of the average is not zero, it must have a positive lower bound $p(\varepsilon)$, which means there is a probability of at least $p(\varepsilon)$ that the average will attain ε after n trials. It will happen with probability $p(\varepsilon)/2$ before some m which depends on n . But even after m , there is still a probability of at least $p(\varepsilon)$ that it will happen. (This seems to indicate that $p(\varepsilon)=1$ and the average will attain ε an infinite number of times.)

Differences between the weak law and the strong law

The *weak law* states that for a specified large n , the average \overline{X}_n is likely to be near μ . Thus, it leaves open the possibility that $|\overline{X}_n - \mu| > \varepsilon$ happens an infinite number of times, although at infrequent intervals. (Not necessarily $|\overline{X}_n - \mu| \neq 0$ for all n).

The *strong law* shows that this almost surely will not occur. In particular, it implies that with probability 1, we have that for any $\varepsilon > 0$ the inequality $|\overline{X}_n - \mu| < \varepsilon$ holds for all large enough n .^[19]

The strong law does not hold in the following cases, but the weak law does.^{[20][21][22]}

- Let X be an exponentially distributed random variable with parameter 1. The random variable $\sin(X)e^X X^{-1}$ has no expected value according to Lebesgue integration, but using conditional convergence and interpreting the integral as a Dirichlet integral, which is an improper Riemann integral, we can say:

$$E\left(\frac{\sin(X)e^X}{X}\right) = \int_0^\infty \frac{\sin(x)e^x}{x} e^{-x} dx = \frac{\pi}{2}$$

2. Let x be geometric distribution with probability 0.5. The random variable $2^X(-1)^X X^{-1}$ does not have an expected value in the conventional sense because the infinite series is not absolutely convergent, but using conditional convergence, we can say:

$$E\left(\frac{2^X(-1)^X}{X}\right) = \sum_1^\infty \frac{2^x(-1)^x}{x} 2^{-x} = -\ln(2)$$

3. If the cumulative distribution function of a random variable is

$$1 - F(x) = \frac{e}{2x \ln(x)}, x \geq e$$

$$F(x) = \frac{e}{-2x \ln(-x)}, x \leq -e$$

then it has no expected value, but the weak law is true.^{[23][24]}

Uniform law of large numbers

Suppose $f(x, \theta)$ is some function defined for $\theta \in \Theta$, and continuous in θ . Then for any fixed θ , the sequence $\{f(X_1, \theta), f(X_2, \theta), \dots\}$ will be a sequence of independent and identically distributed random variables, such that the sample mean of this sequence converges in probability to $E[f(X, \theta)]$. This is the *pointwise* (in θ) convergence.

The **uniform law of large numbers** states the conditions under which the convergence happens *uniformly* in θ . If^{[25][26]}

1. Θ is compact,
2. $f(x, \theta)$ is continuous at each $\theta \in \Theta$ for almost all xs, and measurable function of x at each θ .
3. there exists a dominating function $d(x)$ such that $E[d(X)] < \infty$, and

$$\|f(x, \theta)\| \leq d(x) \quad \text{for all } \theta \in \Theta.$$

Then $E[f(X, \theta)]$ is continuous in θ , and

$$\sup_{\theta \in \Theta} \left\| \frac{1}{n} \sum_{i=1}^n f(X_i, \theta) - E[f(X, \theta)] \right\| \xrightarrow{\text{a.s.}} 0.$$

This result is useful to derive consistency of a large class of estimators (see Extremum estimator).

Borel's law of large numbers

Borel's law of large numbers, named after Émile Borel, states that if an experiment is repeated a large number of times, independently under identical conditions, then the proportion of times that any specified event occurs approximately equals the probability of the event's occurrence on any particular trial; the larger the number of repetitions, the better the approximation tends to be. More precisely, if E denotes the event in question, p its probability of occurrence, and $N_n(E)$ the number of times E occurs in the first n trials, then with probability one,^[27]

$$\frac{N_n(E)}{n} \rightarrow p \text{ as } n \rightarrow \infty.$$

This theorem makes rigorous the intuitive notion of probability as the long-run relative frequency of an event's occurrence. It is a special case of any of several more general laws of large numbers in probability theory.

Chebyshev's inequality. Let X be a random variable with finite expected value μ and finite non-zero variance σ^2 . Then for any real number $k > 0$,

$$\Pr(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Proof of the weak law

Given X_1, X_2, \dots an infinite sequence of i.i.d. random variables with finite expected value $E(X_1) = E(X_2) = \dots = \mu < \infty$, we are interested in the convergence of the sample average

$$\bar{X}_n = \frac{1}{n}(X_1 + \dots + X_n).$$

The weak law of large numbers states:

Theorem: $\overline{X}_n \xrightarrow{P} \mu$ when $n \rightarrow \infty$. (law. 2)

Proof using Chebyshev's inequality assuming finite variance

This proof uses the assumption of finite variance $\text{Var}(X_i) = \sigma^2$ (for all i). The independence of the random variables implies no correlation between them, and we have that

$$\text{Var}(\overline{X}_n) = \text{Var}\left(\frac{1}{n}(X_1 + \dots + X_n)\right) = \frac{1}{n^2} \text{Var}(X_1 + \dots + X_n) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

The common mean μ of the sequence is the mean of the sample average:

$$E(\overline{X}_n) = \mu.$$

Using Chebyshev's inequality on \overline{X}_n results in

$$P(|\overline{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}.$$

This may be used to obtain the following:

$$P(|\overline{X}_n - \mu| < \varepsilon) = 1 - P(|\overline{X}_n - \mu| \geq \varepsilon) \geq 1 - \frac{\sigma^2}{n\varepsilon^2}.$$

As n approaches infinity, the expression approaches 1. And by definition of convergence in probability, we have obtained

$\overline{X}_n \xrightarrow{P} \mu$ when $n \rightarrow \infty$. (law. 2)

Proof using convergence of characteristic functions

By Taylor's theorem for complex functions, the characteristic function of any random variable, X , with finite mean μ , can be written as

$$\varphi_X(t) = 1 + it\mu + o(t), \quad t \rightarrow 0.$$

All X_1, X_2, \dots have the same characteristic function, so we will simply denote this φ_X .

Among the basic properties of characteristic functions there are

$$\varphi_{\frac{1}{n}X}(t) = \varphi_X\left(\frac{t}{n}\right) \quad \text{and} \quad \varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t) \quad \text{if } X \text{ and } Y \text{ are independent.}$$

These rules can be used to calculate the characteristic function of \overline{X}_n in terms of φ_X :

$$\varphi_{\overline{X}_n}(t) = \left[\varphi_X\left(\frac{t}{n}\right) \right]^n = \left[1 + i\mu\frac{t}{n} + o\left(\frac{t}{n}\right) \right]^n \rightarrow e^{it\mu}, \quad \text{as } n \rightarrow \infty.$$

The limit $e^{it\mu}$ is the characteristic function of the constant random variable μ , and hence by the Lévy continuity theorem, \overline{X}_n converges in distribution to μ :

$$\overline{X}_n \xrightarrow{D} \mu \quad \text{for } n \rightarrow \infty.$$

μ is a constant, which implies that convergence in distribution to μ and convergence in probability to μ are equivalent (see Convergence of random variables.) Therefore,

$\overline{X}_n \xrightarrow{P} \mu$ when $n \rightarrow \infty$. (law. 2)

This shows that the sample mean converges in probability to the derivative of the characteristic function at the origin, as long as the latter exists.

Consequences

The law of large numbers provides an expectation of an unknown distribution from a realization of the sequence, but also any feature of the probability distribution.^[1] By applying Borel's law of large numbers, one could easily obtain the probability mass function. For each event in the objective probability mass function, one could approximate the probability of the event's occurrence with the proportion of times that any specified event occurs. The larger the number of repetitions, the better the approximation. As for the continuous case: $C = (a - h, a + h]$, for small positive h. Thus, for large n:

$$\frac{N_n(C)}{n} \approx p = P(X \in C) = \int_{a-h}^{a+h} f(x) dx \approx 2hf(a)$$

With this method, one can cover the whole x-axis with a grid (with grid size 2h) and obtain a bar graph which is called a histogram.

See also

- [Asymptotic equipartition property](#)
- [Central limit theorem](#)
- [Infinite monkey theorem](#)
- [Law of averages](#)
- [Law of the iterated logarithm](#)
- [Law of truly large numbers](#)
- [Lindy effect](#)
- [Regression toward the mean](#)
- [Sortition](#)

Notes

1. Dekking, Michel (2005). *A Modern Introduction to Probability and Statistics* (<https://archive.org/details/modernintroducti00fmde>). Springer. pp. 181 (<https://archive.org/details/modernintroducti00fmde/page/n191>)–190. ISBN 9781852338961.
2. Yao, Kai; Gao, Jinwu (2016). "Law of Large Numbers for Uncertain Random Variables". *IEEE Transactions on Fuzzy Systems*. 24 (3): 615–621. doi:10.1109/TFUZZ.2015.2466080 (<https://doi.org/10.1109%2FTFUZZ.2015.2466080>). ISSN 1063-6706 (<https://www.worldcat.org/issn/1063-6706>). S2CID 2238905 (<https://api.semanticscholar.org/CorpusID:2238905>).
3. Kroese, Dirk P.; Brereton, Tim; Taimre, Thomas; Botev, Zdravko I. (2014). "Why the Monte Carlo method is so important today". *Wiley Interdisciplinary Reviews: Computational Statistics*. 6 (6): 386–392. doi:10.1002/wics.1314 (<https://doi.org/10.1002%2Fwics.1314>).
4. Dekking, Michel (2005). *A Modern Introduction to Probability and Statistics* (<https://archive.org/details/modernintroducti00fmde>). Springer. pp. 92 (<https://archive.org/details/modernintroducti00fmde/page/n102>). ISBN 9781852338961.
5. Dekking, Michel (2005). *A Modern Introduction to Probability and Statistics* (<https://archive.org/details/modernintroducti00fmde>). Springer. pp. 63 (<https://archive.org/details/modernintroducti00fmde/page/n74>). ISBN 9781852338961.
6. Mlodinow, L. *The Drunkard's Walk*. New York: Random House, 2008. p. 50.
7. Jakob Bernoulli, *Ars Conjectandi: Usum & Applicationem Praecedentis Doctrinae in Civilibus, Moralibus & Oeconomicis*, 1713, Chapter 4, (Translated into English by Oscar Sheynin)
8. Poisson names the "law of large numbers" (*la loi des grands nombres*) in: S.D. Poisson, *Probabilité des jugements en matière criminelle et en matière civile, précédées des règles générales du calcul des probabilités* (Paris, France: Bachelier, 1837), p. 7 (<https://archive.org/details/recherchessurla02poisgoog/page/n30>). He attempts a two-part proof of the law on pp. 139–143 and pp. 277 ff.
9. Hacking, Ian. (1983) "19th-century Cracks in the Concept of Determinism", *Journal of the History of Ideas*, 44 (3), 455-475 JSTOR 2709176 (<https://www.jstor.org/stable/2709176>)
10. Tchebichef, P. (1846). "Démonstration élémentaire d'une proposition générale de la théorie des probabilités" (<https://zenodo.org/record/1448850>). *Journal für die reine und angewandte Mathematik*. 1846 (33): 259–267. doi:10.1515/crll.1846.33.259 (<https://doi.org/10.1515%2Fcrll.1846.33.259>). S2CID 120850863 (<https://api.semanticscholar.org/CorpusID:120850863>).
11. Seneta 2013.
12. Yuri Prohorov. "Law of large numbers" (https://www.encyclopediaofmath.org/index.php/Law_of_large_numbers). *Encyclopedia of Mathematics*.
13. Bhattacharya, Rabi; Lin, Lizhen; Patrangenaru, Victor (2016). *A Course in Mathematical Statistics and Large Sample Theory*. Springer Texts in Statistics. New York, NY: Springer New York. doi:10.1007/978-1-4939-4032-5 (<https://doi.org/10.1007%2F978-1-4939-4032-5>). ISBN 978-1-4939-4030-1.
14. Etemadi, N.Z. (1981). "An elementary proof of the strong law of large numbers". *Wahrscheinlichkeitstheorie Verw Gebiete*. 55 (1): 119–122. doi:10.1007/BF01013465 (<https://doi.org/10.1007%2FBF01013465>). S2CID 122166046 (<https://api.semanticscholar.org/CorpusID:122166046>).
15. Loèvre 1977, Chapter 1.4, p. 14
16. Loèvre 1977, Chapter 17.3, p. 251
17. "The strong law of large numbers – What's new" (<http://terrytao.wordpress.com/2008/06/18/the-strong-law-of-large-numbers/>). Terrytao.wordpress.com. Retrieved 2012-06-09.
18. Yuri Prokhorov. "Strong law of large numbers" (https://www.encyclopediaofmath.org/index.php/Strong_law_of_large_numbers). *Encyclopedia of Mathematics*.
19. Ross (2009)

20. Lehmann, Erich L; Romano, Joseph P (2006-03-30). *Weak law converges to constant* (<https://books.google.com/books?id=K6t5qn-SEp8C&q=%22even%20if%20the%20mean%20does%20not%20exist%22&pg=PA432>). ISBN 9780387276052.
21. "A NOTE ON THE WEAK LAW OF LARGE NUMBERS FOR EXCHANGEABLE RANDOM VARIABLES" (https://web.archive.org/web/20160701234328/http://www.mathnet.or.kr/mathnet/kms_tex/31810.pdf) (PDF). Dguvl Hun Hong and Sung Ho Lee. Archived from the original (http://www.mathnet.or.kr/mathnet/kms_tex/31810.pdf) (PDF) on 2016-07-01. Retrieved 2014-06-28.
22. "weak law of large numbers: proof using characteristic functions vs proof using truncation VARIABLES" (<https://math.stackexchange.com/q/266870>).
23. Mukherjee, Sayan. "Law of large numbers" (<https://web.archive.org/web/20130309032810/http://www.isds.duke.edu/courses/Fall09/sta205/lec/l1n.pdf>) (PDF). Archived from the original (<http://www.isds.duke.edu/courses/Fall09/sta205/lec/l1n.pdf>) (PDF) on 2013-03-09. Retrieved 2014-06-28.
24. J. Geyer, Charles. "Law of large numbers" (<http://www.stat.umn.edu/geyer/8112/notes/weaklaw.pdf>) (PDF).
25. Newey & McFadden 1994, Lemma 2.4
26. Jennrich, Robert I. (1969). "Asymptotic Properties of Non-Linear Least Squares Estimators" (<https://doi.org/10.1214%2Faoms%2F1177697731>). *The Annals of Mathematical Statistics*. **40** (2): 633–643. doi:[10.1214/aoms/1177697731](https://doi.org/10.1214/aoms/1177697731) (<https://doi.org/10.1214%2Faoms%2F1177697731>).
27. An Analytic Technique to Prove Borel's Strong Law of Large Numbers Wen, L. Am Math Month 1991 (<https://www.jstor.org/discover/10.2307/2323947?uid=3738032&uid=2&uid=4&sid=21103621939777>)

References

- Grimmett, G. R.; Stirzaker, D. R. (1992). *Probability and Random Processes, 2nd Edition*. Clarendon Press, Oxford. ISBN 0-19-853665-8.
- Richard Durrett (1995). *Probability: Theory and Examples, 2nd Edition*. Duxbury Press.
- Martin Jacobsen (1992). *Videregående Sandsynlighedsregning (Advanced Probability Theory) 3rd Edition*. HCØ-tryk, Copenhagen. ISBN 87-91180-71-6.
- Loève, Michel (1977). *Probability theory 1* (4th ed.). Springer Verlag.
- Newey, Whitney K.; McFadden, Daniel (1994). *Large sample estimation and hypothesis testing*. Handbook of econometrics, vol. IV, Ch. 36. Elsevier Science. pp. 2111–2245.
- Ross, Sheldon (2009). *A first course in probability* (8th ed.). Prentice Hall press. ISBN 978-0-13-603313-4.
- Sen, P. K; Singer, J. M. (1993). *Large sample methods in statistics*. Chapman & Hall, Inc.
- Seneta, Eugene (2013), "A Tricentenary history of the Law of Large Numbers", *Bernoulli*, **19** (4): 1088–1121, arXiv:1309.6488 (<https://arxiv.org/abs/1309.6488>), doi:[10.3150/12-BEJSP12](https://doi.org/10.3150/12-BEJSP12) (<https://doi.org/10.3150%2F12-BEJSP12>), S2CID 88520834 (<https://api.semanticscholar.org/CorpusID:88520834>)

External links

- "Law of large numbers" (https://www.encyclopediaofmath.org/index.php?title=Law_of_large_numbers), *Encyclopedia of Mathematics*, EMS Press, 2001 [1994]
- Weisstein, Eric W. "Weak Law of Large Numbers" (<https://mathworld.wolfram.com/WeakLawofLargeNumbers.html>). *MathWorld*.
- Weisstein, Eric W. "Strong Law of Large Numbers" (<https://mathworld.wolfram.com/StrongLawofLargeNumbers.html>). *MathWorld*.
- Animations for the Law of Large Numbers (https://web.archive.org/web/20081110071309/http://animation.yihui.name/prob:law_of_large_numbers) by Yihui Xie using the R package animation (<https://cran.r-project.org/package=animation>)
- Apple CEO Tim Cook said something that would make statisticians cringe (<http://www.businessinsider.com/law-of-large-numbers-tim-cook-2015-2>). "We don't believe in such laws as laws of large numbers. This is sort of, uh, old dogma, I think, that was cooked up by somebody [...]" said Tim Cook and while: "However, the law of large numbers has nothing to do with large companies, large revenues, or large growth rates. The law of large numbers is a fundamental concept in probability theory and statistics, tying together theoretical probabilities that we can calculate to the actual outcomes of experiments that we empirically perform. explained *Business Insider*

Retrieved from "https://en.wikipedia.org/w/index.php?title=Law_of_large_numbers&oldid=1014300162"

This page was last edited on 26 March 2021, at 09:16 (UTC).

Text is available under the Creative Commons Attribution-ShareAlike License; additional terms may apply. By using this site, you agree to the Terms of Use and Privacy Policy. Wikipedia® is a registered trademark of the Wikimedia Foundation, Inc., a non-profit organization.

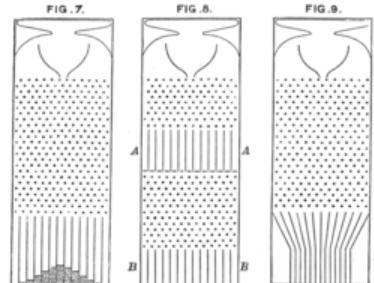
WIKIPEDIA

De Moivre–Laplace theorem

In probability theory, the **de Moivre–Laplace theorem**, which is a special case of the central limit theorem, states that the normal distribution may be used as an approximation to the binomial distribution under certain conditions. In particular, the theorem shows that the probability mass function of the random number of "successes" observed in a series of n independent Bernoulli trials, each having probability p of success (a binomial distribution with n trials), converges to the probability density function of the normal distribution with mean np and standard deviation $\sqrt{np(1-p)}$, as n grows large, assuming p is not 0 or 1.

The theorem appeared in the second edition of *The Doctrine of Chances* by Abraham de Moivre, published in 1738. Although de Moivre did not use the term "Bernoulli trials", he wrote about the probability distribution of the number of times "heads" appears when a coin is tossed 3600 times.^[1]

This is one derivation of the particular Gaussian function used in the normal distribution.



Within a system whose bins are filled according to the binomial distribution (such as Galton's "bean machine", shown here), given a sufficient number of trials (here the rows of pins, each of which causes a dropped "bean" to fall toward the left or right), a shape representing the probability distribution of k successes in n trials (see bottom of Fig. 7) matches approximately the Gaussian distribution with mean np and variance $np(1-p)$, assuming the trials are independent and successes occur with probability p .

Contents

Theorem

[Proof](#)

[Alternate Proof](#)

Trivia

See also

Notes

Theorem

As n grows large, for k in the neighborhood of np we can approximate^{[2][3]}

$$\binom{n}{k} p^k q^{n-k} \simeq \frac{1}{\sqrt{2\pi npq}} e^{-\frac{(k-np)^2}{2npq}}, \quad p+q=1, p,q>0$$

in the sense that the ratio of the left-hand side to the right-hand side converges to 1 as $n \rightarrow \infty$.

Proof

The theorem can be more rigorously stated as follows: $(X - np)/\sqrt{npq}$, with X a binomially distributed random variable, approaches the standard normal as $n \rightarrow \infty$, with the ratio of the probability mass of X to the limiting normal density being 1. This can be shown for an arbitrary nonzero and finite point c . On the unscaled curve for X , this would be a point k given by

$$k = np + c\sqrt{npq}$$

For example, with c at 3, k stays 3 standard deviations from the mean in the unscaled curve.

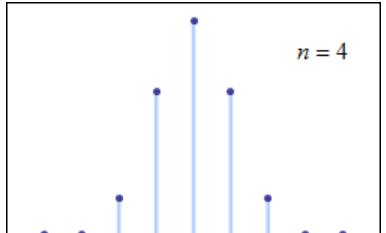
The normal distribution with mean μ and standard deviation σ is defined by the differential equation (DE)

$$f'(x) = -\frac{x-\mu}{\sigma^2} f(x) \text{ with initial condition set by the probability axiom } \int_{-\infty}^{\infty} f(x) dx = 1.$$

The binomial distribution limit approaches the normal if the binomial satisfies this DE. As the binomial is discrete the equation starts as a difference equation whose limit morphs to a DE. Difference equations use the discrete derivative (<https://calculus.subwiki.org/wiki/discrete%20derivative>), $p(k+1)-p(k)$, the change for step size 1. As $n \rightarrow \infty$, the discrete derivative becomes the continuous derivative. Hence the proof need show only that, for the unscaled binomial distribution,

$$\frac{f'(x)}{f(x)} \cdot \left(-\frac{\sigma^2}{x-\mu}\right) \rightarrow 1 \text{ as } n \rightarrow \infty.$$

The required result can be shown directly:



Consider tossing a set of n coins a very large number of times and counting the number of "heads" that result each time. The possible number of heads on each toss, k , runs from 0 to n along the horizontal axis, while the vertical axis represents the relative frequency of occurrence of the outcome k heads. The height of each dot is thus the probability of observing k heads when tossing n coins (a binomial distribution based on n trials). According to the de Moivre–Laplace theorem, as n grows large, the shape of the discrete distribution converges to the continuous Gaussian curve of the normal distribution.

$$\begin{aligned}
 \frac{f'(x)}{f(x)} \frac{npq}{np - k} &= \frac{p(n, k+1) - p(n, k)}{p(n, k)} \frac{\sqrt{npq}}{-c} \\
 &= \frac{np - k - q}{kq + q} \frac{\sqrt{npq}}{-c} \\
 &= \frac{-c\sqrt{npq} - q}{npq + cq\sqrt{npq} + q} \frac{\sqrt{npq}}{-c} \\
 &\rightarrow 1
 \end{aligned}$$

The last holds because the term $-cnpq$ dominates both the denominator and the numerator as $n \rightarrow \infty$.

As k takes just integral values, the constant c is subject to a rounding error. However, the maximum of this error, $0.5/\sqrt{npq}$, is a vanishing value.^[4]

Alternate Proof

The proof consists of transforming the left-hand side (in the statement of the theorem) to the right-hand side by three approximations.

First, according to Stirling's formula, the factorial of a large number n can be replaced with the approximation

$$n! \simeq n^n e^{-n} \sqrt{2\pi n} \quad \text{as } n \rightarrow \infty.$$

Thus

$$\begin{aligned}
 \binom{n}{k} p^k q^{n-k} &= \frac{n!}{k!(n-k)!} p^k q^{n-k} \\
 &\simeq \frac{n^n e^{-n} \sqrt{2\pi n}}{k^k e^{-k} \sqrt{2\pi k} (n-k)^{n-k} e^{-(n-k)} \sqrt{2\pi(n-k)}} p^k q^{n-k} \\
 &= \sqrt{\frac{n}{2\pi k(n-k)}} \frac{n^n}{k^k (n-k)^{n-k}} p^k q^{n-k} \\
 &= \sqrt{\frac{n}{2\pi k(n-k)}} \left(\frac{np}{k}\right)^k \left(\frac{nq}{n-k}\right)^{n-k}
 \end{aligned}$$

Next, the approximation $\frac{k}{n} \rightarrow p$ is used to match the root above to the desired root on the right-hand side.

$$\begin{aligned}
 \binom{n}{k} p^k q^{n-k} &\simeq \sqrt{\frac{1}{2\pi n \frac{k}{n} \left(1 - \frac{k}{n}\right)}} \left(\frac{np}{k}\right)^k \left(\frac{nq}{n-k}\right)^{n-k} \\
 &\simeq \frac{1}{\sqrt{2\pi npq}} \left(\frac{np}{k}\right)^k \left(\frac{nq}{n-k}\right)^{n-k} \quad p + q = 1
 \end{aligned}$$

Finally, the expression is rewritten as an exponential and the Taylor Series approximation for $\ln(1+x)$ is used:

$$\ln(1+x) \simeq x - \frac{x^2}{2} + \frac{x^3}{3} - \dots$$

Then

$$\begin{aligned}
\binom{n}{k} p^k q^{n-k} &\simeq \frac{1}{\sqrt{2\pi npq}} \exp \left\{ \ln \left(\left(\frac{np}{k} \right)^k \right) + \ln \left(\left(\frac{nq}{n-k} \right)^{n-k} \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -k \ln \left(\frac{k}{np} \right) + (k-n) \ln \left(\frac{n-k}{nq} \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -k \ln \left(\frac{np+x\sqrt{npq}}{np} \right) + (k-n) \ln \left(\frac{n-np-x\sqrt{npq}}{nq} \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -k \ln \left(1+x\sqrt{\frac{q}{np}} \right) + (k-n) \ln \left(1-x\sqrt{\frac{p}{nq}} \right) \right\} \quad p+q=1 \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -k \left(x\sqrt{\frac{q}{np}} - \frac{x^2q}{2np} + \dots \right) + (k-n) \left(-x\sqrt{\frac{p}{nq}} - \frac{x^2p}{2nq} - \dots \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ (-np-x\sqrt{npq}) \left(x\sqrt{\frac{q}{np}} - \frac{x^2q}{2np} + \dots \right) + (np+x\sqrt{npq}-n) \left(-x\sqrt{\frac{p}{nq}} - \frac{x^2p}{2nq} - \dots \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ (-np-x\sqrt{npq}) \left(x\sqrt{\frac{q}{np}} - \frac{x^2q}{2np} + \dots \right) - (nq-x\sqrt{npq}) \left(-x\sqrt{\frac{p}{nq}} - \frac{x^2p}{2nq} - \dots \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ \left(-x\sqrt{npq} + \frac{1}{2}x^2q - x^2q + \dots \right) + \left(x\sqrt{npq} + \frac{1}{2}x^2p - x^2p - \dots \right) \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -\frac{1}{2}x^2q - \frac{1}{2}x^2p - \dots \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -\frac{1}{2}x^2(p+q) - \dots \right\} \\
&\simeq \frac{1}{\sqrt{2\pi npq}} \exp \left\{ -\frac{1}{2}x^2 \right\} \\
&= \frac{1}{\sqrt{2\pi npq}} e^{-\frac{(k-np)^2}{2npq}}
\end{aligned}$$

Each " \simeq " in the above argument is a statement that two quantities are asymptotically equivalent as n increases, in the same sense as in the original statement of the theorem—i.e., that the ratio of each pair of quantities approaches 1 as $n \rightarrow \infty$.

Trivia

- The Wall is an example of a television game show that uses the De Moivre–Laplace theorem.^[5]

See also

- Poisson distribution is an alternative approximation of the binomial distribution for large values of n .

Notes

1. Walker, Helen M (1985). "De Moivre on the law of normal probability" (<http://www.york.ac.uk/depts/math/histstat/demovire.pdf>) (PDF). In Smith, David Eugene (ed.). *A source book in mathematics* (<https://archive.org/details/sourcebookinmath0000smi/page/78>). Dover. p. 78 (<https://archive.org/details/sourcebookinmath0000smi/page/78>). ISBN 0-486-64690-4. "But altho' the taking an infinite number of Experiments be not practicable, yet the preceding Conclusions may very well be applied to finite numbers, provided they be great, for Instance, if 3600 Experiments be taken, make $n = 3600$, hence $\frac{1}{2}n$ will be = 1800, and $\frac{1}{2}\sqrt{n}$ 30, then the Probability of the Event's neither appearing oftner than 1830 times, nor more rarely than 1770, will be 0.682688."
2. Papoulis, Athanasios; Pillai, S. Unnikrishna (2002). *Probability, Random Variables, and Stochastic Processes* (4th ed.). Boston: McGraw-Hill. ISBN 0-07-122661-3.
3. Feller, W. (1968). *An Introduction to Probability Theory and Its Applications*. Volume 1. Wiley. Section VII.3. ISBN 0-471-25708-7.
4. Thamattoor, Ajoy (2018). "Normal limit of the binomial via the discrete derivative". *The College Mathematics Journal*. 49 (3): 216–217. doi:10.1080/07468342.2018.1440872 (<https://doi.org/10.1080%2F07468342.2018.1440872>). S2CID 125977913 (<https://api.semanticscholar.org/CorpusID:125977913>).
5. Roeder, Oliver (November 17, 2017). "What if God Were a Giant Game of Plinko?" (<https://fivethirtyeight.com/features/what-if-god-were-a-giant-game-of-plinko/>). *FiveThirtyEight*. Retrieved November 24, 2017.

Retrieved from "https://en.wikipedia.org/w/index.php?title=De_Moivre–Laplace_theorem&oldid=1012814589"

This page was last edited on 18 March 2021, at 13:31 (UTC).

Text is available under the Creative Commons Attribution-ShareAlike License; additional terms may apply. By using this site, you agree to the Terms of Use and Privacy Policy. Wikipedia® is a registered trademark of the Wikimedia Foundation, Inc., a non-profit organization.

LANTURI MARKOV
Lect. Dr. Costache Luminita

1 Lanț Markov omogen. Criteriu de ergodicitate. Repartiție staționară

Definiția 1. Fie $(X_n)_{n \geq 0}$ un sir de v. a. discrete, luând valori într-o mulțime finită sau numărabilă S , numită **spațiul stărilor**.

a) Sirul $(X_n)_{n \geq 0}$ formează **un lanț Markov** dacă pentru orice $n \in \mathbb{N}^*$ și $i_0, \dots, i_n \in S$, avem

$$P(X_n = i_n / X_0 = i_0, \dots, X_{n-1} = i_{n-1}) = P(X_n = i_n / X_{n-1} = i_{n-1})$$

b) Un lanț Markov se numește **omogen** dacă probabilitățile

$$P(X_n = j / X_{n-1} = i) = p_{ij}$$

sunt independente de n .

In cazul când lanțul Markov are un număr finit de stări $1, 2, \dots, N$, el se numește **finit**.

Matricea $P = \begin{pmatrix} p_{11} & \dots & p_{1N} \\ \vdots & & \\ p_{N1} & \dots & p_{NN} \end{pmatrix}$ se numește **matricea probabilităților**

de trecere (tranzitie) a lanțului Markov considerat.

Proprietăți

1. Linia i a matricei P , formată din elementele $p_{i1} p_{i2} \dots p_{iN}$ conține probabilitățile de trecere din starea i în stările $1, 2, \dots, N$.

2. P este o **matrice stochastică**, adică este formată din elemente pozitive, iar suma elementelor fiecărei linii este 1.

3. Notând $p_{ij}(n) = P(X_n = j / X_0 = i)$, probabilitatea de a trece după n pași din starea i în starea j , se obține **matricea de trecere după n pași** $P(n) = (p_{ij}(n))_{i,j}$ care verifică relația $P(n) = P^n$.

In particular, $P(n) = P(n-1)P$ și $P(n) = PP(n-1)$, de unde rezultă ecuațiile directe ale lui Kolmogorov $p_{ij}(n) = \sum_k p_{ik}(n-1)p_{kj}$, $i, j \in S$, pre-

cum și ecuațiile inverse $p_{ij}(n) = \sum_k p_{ik}p_{kj}(n-1)$, $i, j \in S$.

4. Repartiția v. a. $X_n \sim \begin{pmatrix} 1 & 2 & \dots & N \\ p_1(n) & p_2(n) & \dots & p_N(n) \end{pmatrix}$ este definită de **vectorul de probabilitate** $p(n) = (p_1(n), p_2(n), \dots, p_N(n))$, unde $p(n) = p(0)P^n$

Definiția 2. Un lanț Markov cu matricea de trecere P este **ergodic** dacă $\lim_{n \rightarrow \infty} P^n = \Pi$, unde Π este o matrice stochastică, având toate liniile egale

cu un anumit vector de probabilitate $\sigma = (\sigma_1 \sigma_2 \dots \sigma_n)$ numit **repartiția staționară** a procesului.

Criteriu de ergodicitate Dacă $\exists n > 0$ astfel încât matricea P^n să aibă toate elementele strict pozitive, atunci lanțul este ergodic.

Găsirea repartiției staționare Fie P matricea de trecere a unui lanț Markov ergodic. Atunci distribuția limită este unicul vector de probabilitate σ satisfăcând ecuația vectorială $\sigma P = \sigma$.

Observația 1. Dacă σ este repartiția staționară a unui lanț Markov ergodic, atunci sirul distribuțiilor $p(n)$ la momentul n satisface relația

$$\lim_{n \rightarrow \infty} p(n) = \sigma$$

Lanturi Markov

Lucruri de bază de stat (prim exercițiu)

① În sesiune, dacă un student învăță azi, atunci el va învăța și mâine cu probabilitatea 0,7, iar dacă el nu învăță azi, atunci nu va învăța nici mâine cu probabilitatea 0,4.

a) Determinați probabilitatea ca dacă el învăță azi, poimâine să înceapă să învețe.

b) Determinați repartitia stationară.

Soluție: a) Lantul Markov are 2 stări: I (învăță) și N (nu învăță).

Atunci matricea probabilităților de trecere, notată cu P este:

$$P = \begin{pmatrix} I & N \\ I & N \end{pmatrix} = \begin{pmatrix} 0,7 & 0,3 \\ 0,6 & 0,4 \end{pmatrix}$$

I $\xrightarrow{0,7}$ I (adică elem. de pe poz. (1,1) este 0,7)
N $\xrightarrow{0,4}$ N (elem. de pe poz. (2,2) este 0,4)

completate astfel încât pe fiecare linie sumă să fie 1

(P final matrice stochastica)

De azi până poimâine sunt 2 zile, deci trec 2 pași -
(la fel dore am zice de joi până sâmbătă sau de luni până miercuri etc.)

Pentru că trebuie să determinăm probabilitatea ca de azi să învăță, atunci să nu învețe poimâine, acesta înseamnă că avem de aflat elementul $p_{12}(2)$, adică elementul din matricea P^2 aflat pe poziția (1,2) (trecerea din starea I în starea N după 2 pași)

$$P^2 = \begin{pmatrix} 0,7 & 0,3 \\ 0,6 & 0,4 \end{pmatrix} \begin{pmatrix} 0,7 & 0,3 \\ 0,6 & 0,4 \end{pmatrix} = \begin{pmatrix} 0,733 & \end{pmatrix} = p_{12}(2)$$

(Elementul căutat se obține înmulțind linia 1 cu coloana 2)
Nici nu trebuie calculată totă matricea P^2 .

b) Pentru a determina repartitia stationara trebuie verificat ca lantul este ergodic, adica $\exists n > 0$ astfel incat P^n sa aiba toate elementele strict positive. In cazul nostru, $n=1$, $P = \begin{pmatrix} 0,7 & 0,3 \\ 0,6 & 0,4 \end{pmatrix}$ are toate elem. strict positive, deci lantul este ergodic.

Astfel repartitia stationara se determina din ecuatia $\pi P = \pi$, unde π este vectorul $\pi = (\pi_1 \ \pi_2)$ cu $\pi_1 + \pi_2 = 1$ (cf. Def. 10.2).

$$\text{Aziadar, } (\pi_1 \ \pi_2) \begin{pmatrix} 0,7 & 0,3 \\ 0,6 & 0,4 \end{pmatrix} = (\pi_1 \ \pi_2) \Rightarrow$$

$$\Rightarrow \begin{pmatrix} 0,7\pi_1 + 0,6\pi_2 \\ 0,3\pi_1 + 0,4\pi_2 \end{pmatrix}^t = (\pi_1 \ \pi_2) \Rightarrow \begin{cases} 0,7\pi_1 + 0,6\pi_2 = \pi_1 \\ 0,3\pi_1 + 0,4\pi_2 = \pi_2 \\ \pi_1 + \pi_2 = 1 \end{cases} \Rightarrow$$

$$\Rightarrow \begin{cases} 0,6\pi_2 = 0,3\pi_1 \\ \pi_1 + \pi_2 = 1 \end{cases} \Rightarrow \begin{cases} \pi_1 = 2\pi_2 \\ \pi_1 + \pi_2 = 1 \\ \pi_1 = \frac{2}{3} \end{cases} \Rightarrow 3\pi_2 = 1 \Rightarrow \pi_2 = \frac{1}{3}$$

$$\Rightarrow \pi = \left(\frac{2}{3}, \frac{1}{3} \right) \text{ repartitia stationara}$$

9. Un lanț Markov cu 2 stări poate fi folosit să modeleze o varietate largă de sisteme ce alternează între stările ON și OFF. După fiecare unitate de timp în starea OFF, sistemul trece pe ON cu probabilitatea p . După fiecare unitate de timp în starea ON, sistemul trece în OFF cu probabilitatea q . Folosind 0 și 1 să notăm stările OFF și ON, care este matricea probabilităților de trecere? Stiind că sistemul este în starea OFF la momentul 0, care este probabilitatea ca sistemul să fie în starea OFF la momentul $n = 33$?

$$\mathbf{R: } P = \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix}, p_{00}(33) = \frac{q+[1-(p+q)]^{33}p}{p+q}$$

(L. Costache - Lecții de matematici speciale, p. 147)

②. Rezolvarea ex. 9 / pg. 146

Lantul Markov cu 2 stări OFF(0) și ON(1) are matricea probabilităților de trevere

$$P = \begin{pmatrix} 0 & 1 \\ 1-p & p \\ q & 1-q \end{pmatrix}$$

$$\begin{array}{l} \text{OFF} \xrightarrow{P} \text{ON} \quad (0 \xrightarrow{p} 1) \\ \text{ON} \xrightarrow{q} \text{OFF} \quad (1 \xrightarrow{q} 0) \end{array}$$

Pentru ca n este mare ($n=33$), nu vom ridica matricea P la puterea 33, ci vom calcula (cu mijloaci de la Algebra, semestrul I) matricea P^n .

Calculem mai întâi valoările proprii din $\det(P - \lambda I_2) = 0 \Rightarrow$

$$\Rightarrow \begin{vmatrix} 1-p-\lambda & p \\ q & 1-q-\lambda \end{vmatrix} = 0 \Rightarrow \lambda_1 = 1, \lambda_2 = 1-p-q$$

Determinăm vectorii proprii corespunzători acestui

$$P\mathbf{x} = \lambda_1 \mathbf{x} \Rightarrow \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \Rightarrow$$

$$\begin{cases} (1-p)x_1 + px_2 = x_1 \\ qx_1 + (1-q)x_2 = x_2 \end{cases} \Rightarrow \begin{cases} x_1 = x_2 \\ x_1 = x_2 \end{cases} \Rightarrow \begin{cases} x_1 = x_2 \\ x_1 = \text{spof} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \end{cases}$$

$$P\mathbf{y} = \lambda_2 \mathbf{y} \Rightarrow \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = (1-p-q) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \Rightarrow$$

$$\begin{cases} (1-p)y_1 + py_2 = (1-p-q)y_1 \\ qy_1 + (1-q)y_2 = (1-p-q)y_2 \end{cases} \Rightarrow \begin{cases} y_1 = y_2 \\ y_1 = \frac{-p}{p+q} \end{cases}$$

Scriem matricea vectorilor proprii: $T = \begin{pmatrix} 1 & \frac{-p}{p+q} \\ 1 & \frac{q}{p+q} \end{pmatrix}$

Se calculează T^{-1} și obținem $T^{-1} = \begin{pmatrix} \frac{q}{p+q} & \frac{p}{p+q} \\ -1 & 1 \end{pmatrix}$

Așadar $P = TDT^{-1}$, unde $D = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$

$$P^n = TDT^{-1} = \begin{pmatrix} 1 & \frac{-p}{p+q} \\ 1 & \frac{q}{p+q} \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & (1-p-q)^n \end{pmatrix} \begin{pmatrix} \frac{q}{p+q} & \frac{p}{p+q} \\ -1 & 1 \end{pmatrix} =$$

stările

$$= \begin{pmatrix} 0 & \frac{q}{p+q} + \frac{p}{p+q} (1-p-q)^n \\ 1 & \frac{q}{p+q} [1 - (1-p-q)^n] \end{pmatrix} \begin{pmatrix} \frac{p}{p+q} & \frac{p}{p+q} (1-p-q)^n \\ -1 & 1 \end{pmatrix}$$

Probabilitatea cercuită este $p_{00}(33)$, adică elementul de pe poziția $(1,1)$ din matricea P^{33} , deci $p_{00}(33) = \frac{q}{p+q} + \frac{p}{p+q} (1-p-q)^{33}$
 prima linie, prima coloană

Observație: 1) Dacă s-ar cere și în acest caz repartiția stacionară, ar trebui să se arate în prealabil că lantul este ergodic (eventual după ce s-a specificat în enunț anumite condiții asupra lui P și q), atunci, deoarece deja s-a aflat P^n , e mai ușor să determinăm π din Def. 10.2, adică liniu $P^n = T\pi$, unde T e o matrice stochastică cu toate liniile egale cu π .

$$\lim_{n \rightarrow \infty} P^n = \begin{pmatrix} \frac{q}{p+q} & \frac{p}{p+q} \\ \frac{q}{p+q} & \frac{p}{p+q} \end{pmatrix} \left(\text{pt că } \lim_{n \rightarrow \infty} (1-p-q)^n = 0 \right)$$

$$\text{Deci } \sigma = \begin{pmatrix} \frac{\varrho}{\varrho + \varrho} & \frac{\varrho}{\varrho + \varrho} \\ \frac{\varrho}{\varrho + \varrho} & \frac{\varrho}{\varrho + \varrho} \end{pmatrix}.$$

Evident σ prezinta fișaflat și ca la ex. precedent, din ecuația $\sigma P = \sigma$ (cu $\sigma = (\sigma_1 \ \sigma_2)$, $\sigma_1 + \sigma_2 = 1$)

2) Dacă știm că $p(0) = (p_1, p_2)$ și să arătăm $p(5^6)$, ar trebui să avem $X_0 \sim \begin{pmatrix} 0 & 1 \\ p_1 & p_2 \end{pmatrix} p(0)$

$$\begin{aligned} \text{Din proprietatea 4, } p(5^6) &= p(0)P^{5^6} = (p_1, p_2) \cdot P^{5^6} = \\ &= \left(p_1 \left(\frac{\varrho}{\varrho + \varrho} + \frac{\varrho}{\varrho + \varrho} (1 - p_1 - p_2)^{5^6} \right) + p_2 \left(\frac{\varrho}{\varrho + \varrho} (1 - (1 - p_1 - p_2)^{5^6}) \right), p_1 \cdot \frac{\varrho}{\varrho + \varrho} [1 - (1 - p_1 - p_2)^{5^6}] \right. \\ &\quad \left. + p_2 \left(\frac{\varrho}{\varrho + \varrho} + \frac{\varrho}{\varrho + \varrho} (1 - p_1 - p_2)^{5^6} \right) \right) \end{aligned}$$

Definiție Fie $N \in \mathbb{N}^*$, fixat și $(X_n)_{n \in N}$ un sir de variabile aleatoare care iau valori în mulțimea $\{1, 2, \dots, N\} = S$, pe care o vom numi spațiu stăriilor. Spunem că sirul $(X_n)_{n \in N}$ este un lant Markov omogen finit, placu.

$$\textcircled{*} \quad P(X_{n+1} = i_{n+1} | X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \\ = P(X_{n+1} = i_{n+1} | X_n = i_n) \stackrel{\text{not}}{=} p_{i_n i_{n+1}}$$

pentru orice n pentru care probabilitatea condiționată are sens și pentru $\{i_0, i_1, \dots, i_n\} \subseteq S$.

p_{ij} se numește probabilitatea de trecere, într-un singur pas, din starea i în starea j , iar matricea $P = (p_{ij})$ se numește matricea probabilităților de trecere într-un singur pas.

Fie $\pi_i = \stackrel{\text{not}}{P}(X_0 = i)$, $i \in S$. Atunci, vectorul $\pi_0 = (\pi_i)_{i \in S}$ se numește repartiția initială (π_0 conține probabilitățile ca lantul să pornească dintr-o anumită stare).

X_n reprezintă starea lantului Markov la momentul n , iar relația $\textcircled{*}$ arată că „viitorul” (starea lantului la momentul $n+1$) depinde doar de „prezent” (starea lantului la momentul n).

Unui lant Markov finit și omogen îl se poate asocia un graf orientat $G = (S, \Gamma)$, unde S este spațiul stăriilor lantului, iar $\Gamma \subseteq S \times S$ este o relație definită prin: $(i, j) \in \Gamma \Leftrightarrow p_{ij} > 0$. Arcurile orientate vor desemna trecerea lantului din starea i în starea j cu probabilitatea $p_{ij} (> 0)$ pentru $i, j \in S$.

Exemplu Să se deseneze graful asociat lantului Markov a cărui matrice de trecere este

$$P = \begin{pmatrix} 0 & 1 & 0 \\ \frac{1}{6} & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{3} & \frac{2}{3} & 0 \end{pmatrix} \Rightarrow \begin{array}{c} \text{Graph: } \begin{array}{ccc} \textcircled{1} & \xrightarrow{1} & \textcircled{2} \\ \downarrow & & \uparrow \\ \textcircled{2} & \xrightarrow{1/6} & \textcircled{1} \\ \uparrow & & \downarrow \\ \textcircled{2} & \xrightarrow{2/3} & \textcircled{3} \\ \downarrow & & \uparrow \\ \textcircled{3} & \xrightarrow{1/3} & \textcircled{2} \end{array} \end{array}$$

Propozitie 1 Un lant Markov este complet determinat de repartitia initiala si de probabilitatile de trecere.

(Propozitia afirmă că, dacă sunt cunoscute repartitia initială și probabilitatile de trecere într-un pas, atunci se poate calcula $P(X_0=i_0, X_1=i_1, \dots, X_n=i_n)$)

Propozitie 2 Dacă $\pi_0 = (p_1, p_2, \dots, p_N)$ este repartitia initială a unui lant Markov și $P = (p_{ij})_{i,j \in S}$ ($S = \{1, \dots, N\}$) matricea probabilităților de trecere într-un pas, atunci:

$$1) p_i \geq 0, \forall i = \overline{1, N} \text{ și } \sum_{i=1}^N p_i = 1$$

$$2) p_{ij} \geq 0, \forall i, j \in \{1, \dots, N\} \text{ și } \sum_{j=1}^N p_{ij} = 1, \forall i = \overline{1, N}$$

Justificările sunt simple exerciții de calcul:

$$1) \sum_{i=1}^N p_i = \sum_{i=1}^N P(X_0=i) = P\left(\bigcup_{i=1}^N (X_0=i)\right) = P(\text{ev. sigur}) = 1$$

$$2) \text{Fie } i \in \{1, \dots, N\}. \text{ Atunci: } \sum_{j=1}^N p_{ij} = \sum_{j=1}^N P(X_n=j | X_{n-1}=i)$$

$$= \sum_{j=1}^N \frac{P(X_n=j, X_{n-1}=i)}{P(X_{n-1}=i)} = \frac{P(\{(j)_{j=1}^N | X_n=j\} \cap (X_{n-1}=i))}{P(X_{n-1}=i)}$$

$$= \frac{P(X_{n-1}=i)}{P(X_{n-1}=i)} = 1.$$

$$\{\bigcup_{j=1}^N (X_n=j)\} = \text{ev. sigur}$$

Definitie O matrice $P = (p_{ij})_{1 \leq i, j \leq N}$ cu elemente

numere reale astfel încât $p_{ij} \geq 0 \forall i, j \in \{1, \dots, N\}$ și

$\sum_{j=1}^N p_{ij} = 1, \forall i = \overline{1, N}$ se numeste matrice stochastica

Așadar, din Prop 2 \Rightarrow matricea probabilităților de trecere într-un pas asociată unui lant Markov este o matrice stochastica.

Observatie Produsul a două matrice stochastice

-3-

este o matrice stoхастică: Fie $A = (a_{ij})_{1 \leq i, j \leq N}$
 $B = (b_{kj})_{1 \leq k, j \leq N}$ două matrice stoхастice și $AB \stackrel{\text{not}}{=} C = (c_{ij})_{1 \leq i, j \leq N}$. Atunci, pentru $i, j \in \{1, 2, \dots, N\}$:

$$c_{ij} = \sum_{k=1}^N a_{ik} b_{kj} \Rightarrow c_{ij} \geq 0 \quad \sum_{j=1}^N c_{ij} = \sum_{j=1}^N \left(\sum_{k=1}^N a_{ik} b_{kj} \right) =$$

$$\sum_{k=1}^N a_{ik} \underbrace{\left(\sum_{j=1}^N b_{kj} \right)}_{=1} = 1$$

\uparrow
B matr. stoхастică

Propoziția 3 Fie S o mulțime cel mult numărabilă de indici, un sir $(p_i)_{i \in S}$ și o matrice $P = (p_{ij})_{i, j \in S}$ a. i., $p_i \geq 0$, $\forall i \in S$, $\sum_{i \in S} p_i = 1$ și $p_{ij} \geq 0$, $\forall i, j \in S$, $\sum_{j \in S} p_{ij} = 1$, $\forall i \in S$. Atunci, există un câmp de probabilitate (Ω, \mathcal{F}, P) și un lant Markov $(X_n)_{n \in \mathbb{N}}$ pe acest câmp pentru care S este spațiu stăriilor, $\pi_0 = (p_i)_{i \in S}$ este repartiția inițială a lantului, iar P matricea probabilităților de trecere între pasuri.

Probabilități de trecere după n pasi

Fie $(X_n)_{n \in \mathbb{N}}$ un lant Markov sunogen finit cu spațiu stăriilor $S = \{1, 2, \dots, N\}$ și $P = (p_{ij})_{1 \leq i, j \leq N}$ matricea probabilităților de trecere între pasuri.

Definiție Pentru $n \in \mathbb{N}^*$: $p_{ij}^{(n)} \stackrel{\text{not}}{=} P(X_{n+k} = j | X_k = i)$

se numește probabilitate de trecere din starea i în starea j în n pasuri.

Propoziția 4 Probabilitățile de trecere în n pasi verifică relația

$$p_{ij}^{(n+1)} = \sum_{k=1}^N p_{ik}^{(n)} p_{kj}^{(n)}, \quad i, j \in S$$

numita ecuație CHAPMAN - KOLMOGOROV

-4-

Din Prop 4 \Rightarrow matricea probabilităților de trecere
 în n pași $P^{(n)} = (P_{ij}^{(n)})_{i,j \in S}$ verifică relația $P^{(n)} = P^n$
 și $P^{(n+1)} = P^{(n)} \cdot P$ -

Propoziția 5 Dacă $(X_n)_{n \in \mathbb{N}}$ este un lanț Markov pentru care $\exists k > 0$ a.î. p_k să aibă toate elementele strict pozitive, atunci există limită $P^n \xrightarrow{n \rightarrow \infty} Q$, unde Q este o matrice stochastică, cu toate liniile identice. Fie π vectorul reprezentând una din aceste linii. Atunci π se numește repartiția stacionară a lanțului Markov.

Proprietate Atunci sănătă, repartitia stacionară este unică repartiție π pentru care $\pi P = \pi$.

Exerc 1) Se consideră două urne A și B. Urna A are două bile albe, iar urna B are 3 bile negre. Din fiecare urnă se extrage côte o bilă, schimbându-se bilele între ele: cea extrasă din urna A se pună în urma B și invoca.

Se spune că sistemul de urne se află în starea „ i ” dacă în urma A sunt „ i ” bile negre. Să se justifice că procesul descris este un lanț Markov și să se scrie matricea probabilităților de trecere.

Stările sistemului:

	urna A	urna B
starea 0	1 0 0	0 0 0
starea 1	0 0 1	0 0 0
starea 2	0 0 0	1 0 0

Probabilitățile de trecere:

$p_{00} = 0$ (e imposibil ca schimbând două bile între ele sistemul să rămână în starea 0)
 $p_{01} = 1$ (din starea 0, schimbând două bile între ele, sistemul nu poate trece decât în starea 1)
 $p_{02} = 0$ (e imposibil ca printre două schimbări de bile să se treacă din starea 0 în starea 2)

Să notăm:

" $a \in A_i$ ": se extrage o bilă albă din urna A aflată în starea i

" $n \in A_i$ ": se extrage o bilă neagră din urna A aflată în starea i "

Asemănător, vom folosi notările " $a \in B_i$ " și " $n \in B_i$ "

Atenție: $p_{10} = P(a \in B_1, n \in A_1) = P(n \in A_1) \cdot P(a \in B_1) =$

$(a \in B_1), (n \in A_1)$ evenim. indep.

$$= \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{6}$$

$$p_{11} = P((a \in A_1, a \in B_1) \cup (n \in A_1, n \in B_1)) = P(a \in A_1, a \in B_1) + \\ + P(n \in A_1, n \in B_1) = P(a \in A_1) \cdot P(a \in B_1) + P(n \in A_1) \cdot P(n \in B_1) =$$

$$= \frac{1}{2} \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{2}{3} = \frac{1}{2}$$

$$p_{12} = P(a \in A_1, n \in B_1) = \frac{1}{2} \cdot \frac{2}{3} = \frac{1}{3}$$

$p_{20} = 0$ (sistemu de urme nu poate trece din starea 2 în starea 0)

$$p_{21} = P(n \in A_2, a \in B_2) = \frac{2}{2} \cdot \frac{2}{3} = \frac{2}{3}$$

$$p_{22} = P(n \in A_2, n \in B_2) = \frac{2}{2} \cdot \frac{1}{3} = \frac{1}{3}.$$

Matricea probabilităților de trecere între-un pas este

$$P = \begin{pmatrix} p_{00} & p_{01} & p_{02} \\ p_{10} & p_{11} & p_{12} \\ p_{20} & p_{21} & p_{22} \end{pmatrix} = \begin{pmatrix} 0 & 1 & 0 \\ \frac{1}{6} & \frac{1}{2} & \frac{1}{3} \\ 0 & \frac{2}{3} & \frac{1}{3} \end{pmatrix}$$

Faptul că starea viitoare a sistemului de urme este influențată doar de starea actuală, nu și de cele anterioare nu permite să afirmăm că sirul de r.a. $(X_n)_{n \in \mathbb{N}}$, unde X_n reprezintă starea sistemului de urme la momentul n , este un lanț Markov.

O altă justificare a acestui afirmații este faptul că matricea P este o matrice stoхastică (v. Prop 3)

-6-

Ex2 O stație de serviciu poate primi clienți la momentele $0, 1, 2, \dots$. Să notăm cu X_n variabila aleatoare ale cărei valori reprezintă numărul clientilor săsiți în stație în intervalul de timp $(n, n+1)$. Presupunem că $X_n, n \in \mathbb{N}$ sunt variabile aleatoare, identice reportate cu $P(X_n = k) = p_k$, $\forall n, k \in \mathbb{N}$. și că în stație există loc de așteptare pentru m clienti, inclusiv clientul servit. Persoanele care ajung în stație și găsesc m clienti, pleacă. Așadar, X_n are matricea de reportaj:

$$X_n : \begin{pmatrix} 0 & 1 & 2 & \dots & k & \dots \end{pmatrix} \text{ cu } \sum_{k=0}^{\infty} p_k = 1$$

Fie Y_n numărul clientilor prezenti în stație la momentul n (inclusiv clientul servit). Deoarece Y_{n+1} depinde doar de Y_n și X_n , Y_n sunt r.a. independente $\Rightarrow (Y_n)_{n \in \mathbb{N}}$ este un lant Markov. Să se determine matricea probabilităților de trecere între-un pas corespondător acestui lant Markov.

Să observăm că Y_{n+1} reprezintă suma între numărul clientilor prezenti în stație la momentul n , mai puțin cel servit, și numărul clientilor care sosesc în intervalul $(n, n+1)$, dacă această sumă este $\leq m$ și $Y_{n+1} = m$, în caz contrar. Mai exact:

$$Y_{n+1} = \begin{cases} Y_n - 1 + X_n, & \text{dacă } 0 \leq X_n + Y_n - 1 \leq m \text{ și } 1 \leq Y_n \leq m \\ X_n, & \text{dacă } Y_n = 0 \text{ și } 0 \leq X_n \leq m \\ m, & \text{altfel} \end{cases}$$

(Y_n) ia valori în multimea $\{0, 1, \dots, m\}$

Fie $P = (p_{ij})_{0 \leq i, j \leq m}$ matricea probabilităților de trecere între-un pas asociată lantului Markov

$(Y_n)_{n \in \mathbb{N}}$

$$\begin{aligned} \text{Pentru } j \in \{0, 1, \dots, m\}: p_{0j} &= P(Y_{n+1} = j | Y_n = 0) = \\ &= \begin{cases} P(X_n = j) = p_j & \text{pentru } 0 \leq j \leq m-1 \\ P(X_n \geq m) = \sum p_i & \text{pentru } j = m \end{cases} \end{aligned}$$

Întru $i \in \{1, \dots, m\}$ și $j \in \{0, 1, \dots, m\}$

$$p_{ij} = P(Y_{m+i} = j | Y_m = i) =$$

$$\begin{cases} P(X_m = j - (i-1)) = p_{j-i+1}, & \text{pentru } i-1 \leq j \leq m-1 \\ P(X_m \geq m+1-i) = \sum_{j=m}^{\infty} p_{j-i+1}, & \text{pentru } j = m \\ 0, & \text{altfel} \end{cases}$$

Dacă notăm $g_m = \sum_{k=m}^{\infty} p_k$, obținem:

$$P = \begin{pmatrix} p_0 & p_1 & p_2 & \dots & p_{m-1} & g_m \\ p_0 & p_1 & p_2 & \dots & p_{m-1} & g_m \\ 0 & p_0 & p_1 & \dots & p_{m-2} & g_{m-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & p_1 & g_2 \\ 0 & 0 & 0 & \dots & p_0 & g_1 \end{pmatrix}$$

E*3 Un lant Morkov are două stări: 1 și 2.
Matricea probabilităților de trecere într-un pas
corespunzătoare este

$$P = \begin{pmatrix} p & q \\ q & p \end{pmatrix} \quad \begin{matrix} \text{not} \\ = \end{matrix} \begin{pmatrix} p_{11} & p_{12} \\ p_{21} & p_{22} \end{pmatrix}$$

cu $p+q=1$, $0 < p, q < 1$. Să se determine matricea
probabilităților de trecere în trei pași și să se
calculeze $P(X(0)=1 | X(2)=1)$, știind că $P(X(0)=1)=\alpha$
și $P(X(0)=2)=\beta$.

Matricea probabilităților de trecere în trei pași
este P^3 . Vom calcula doar P^2 și ale cărei elemente
vom avea nevoie pentru a obține $P(X(0)=1 | X(2)=1)$.

$$P^2 = \begin{pmatrix} p^2 + q^2 & 2pq \\ 2pq & p^2 + q^2 \end{pmatrix} \quad \begin{matrix} \text{not} \\ = \end{matrix} \begin{pmatrix} p_{11}^{(2)} & p_{12}^{(2)} \\ p_{21}^{(2)} & p_{22}^{(2)} \end{pmatrix}$$

Folosind definiția probabilității condiționate \Rightarrow

-8-

$$\Rightarrow P(X(0)=1 | X(2)=1) = \frac{P(X(0)=1, X(2)=1)}{P(X(2)=1)} = \frac{\overbrace{P(X(2)=1 | X(0)=1)}^{P_{11}^{(2)}}}{\overbrace{P(X(2)=1)}^{P_{11}^{(2)}}}$$

$$\cdot \underbrace{P(X(0)=1)}_{\alpha} = \frac{(p^2+q^2)\alpha}{P(X(2)=1)}$$

Pentru a calcula $P(X(2)=1)$ vom folosi formula probabilității totale și matricea probabilităților de trecere în doi pași p^2 .

$$P(X(2)=1) = P(X(2)=1 | X(0)=1) \cdot P(X(0)=1) + P(X(2)=1 | X(0)=2) \cdot P(X(0)=2) = p_{11}^{(2)} \cdot \alpha + p_{21}^{(2)} \cdot \beta = (p^2+q^2) \cdot \alpha + 2pq \cdot \beta.$$

Așadar,

$$P(X(0)=1 | X(2)=1) = \frac{(p^2+q^2)\alpha}{(p^2+q^2)\alpha + 2pq\beta}$$

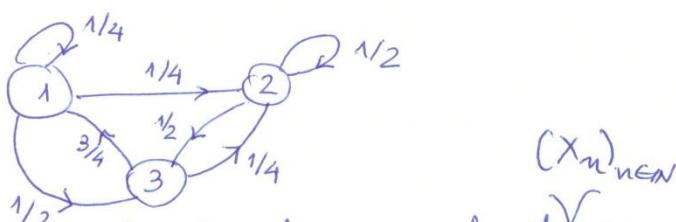
Observație Cum $X(0)$ se poate afla în starea 1 sau în starea 2 $\Rightarrow \alpha + \beta = 1$

Ez 4 Un lanț Markov are matricea de trecere

$$P = \begin{pmatrix} 1/4 & 1/4 & 1/2 \\ 0 & 1/2 & 1/2 \\ 3/4 & 1/4 & 0 \end{pmatrix} \text{ și reprezentă inițială } \pi_0: \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$$

- Se cere: a) să se reprezinte graful asociat lantului;
 b) să se determine distribuția sistemului după un pas; c) să se calculeze $P(X_1=2, X_2=3, X_3=1 | X_0=1)$ și d) să se calculeze $P(X_0=3, X_1=2, X_2=1)$

a) Graful asociat:



b) Să presupunem că lanțul Markov considerat are stările 1, 2 și 3. Din distribuția inițială $\Rightarrow P(X_0=1) = P(X_0=2) = P(X_0=3) = 1/3$. Să notăm $P = (p_{ij})_{1 \leq i, j \leq 3}$.

-9-

Așa că: $p_1 \stackrel{\text{not}}{=} P(X_1=1) = \sum_{i=1}^3 P(X_1=1 | X_0=i) \cdot P(X_0=i) =$
 form. probab. totale

$$= \sum_{i=1}^3 p_{i1} \cdot P(X_0=i) = \text{"primul element al liniei } \pi_0 \text{; } P"$$

La fel se arată că, pentru $j \in \{2, 3\}$: $p_j \stackrel{\text{not}}{=} P(X_1=j) =$
 = "elementul j al liniei π_0 ; $P"$

Așadar, distribuția sistemului după un pas este:

$$\pi_0 P = \begin{pmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{pmatrix}$$

c) $P(X_1=2, X_2=3, X_3=1 | X_0=1) = \frac{P(X_0=1, X_1=2, X_2=3, X_3=1)}{P(X_0=1)} =$
 $(X_n)_n$ lant, M. $\xrightarrow{\text{II}} P(X_3=1 | X_2=3) = p_{31}$

$$= \frac{P(X_3=1 | X_2=3, X_1=2, X_0=1)}{P(X_0=1)} \cdot P(X_2=3, X_1=2, X_0=1) =$$

$$= \frac{p_{31} \cdot P(X_2=3 | X_1=2, X_0=1)}{P(X_0=1)} = \frac{p_{31} \cdot \frac{P_{23}}{P(X_0=1)}}{p_{23}} \cdot P(X_1=2 | X_0=1)$$

$$X_0=1, P(X_0=1) = p_{31} \cdot p_{23} \cdot p_{12} = \frac{3}{4} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{3}{32}.$$

d) $P(X_0=3, X_1=2, X_2=1) = P(X_2=1 | X_1=2, X_0=3) = P(X_1=2, X_0=3)$
 $= \underbrace{P(X_2=1 | X_1=2)}_{\text{II}} \cdot P(X_1=2, X_0=3) = 0$
 $p_{21} = 0$

Ex5 Un student merge la facultate cu tramvaiul sau cu autobuzul. Dacă întăzi merge cu tramvaiul, a două zile merge cu autobuzul. Dacă întăzi merge cu două zile merge cu tramvaiul sau cu autobuzul, a două zile merge cu tramvaiul sau cu autobuzul (pentru a alerga, aruncă o monedă și obține stima, a două zile va merge cu autobuzul, dacă obține banul, va merge cu tramvaiul). Se cere: a) dacă în primele zile a mers cu autobuzul, care este probabilitatea ca în cea de-a 100-a zi să meargă cu tramvaiul? b) pe termen lung, să se stabilească se mijloc de transport

este mai probabil să alăgă studentul? -10-

a) Fie X_n variabila aleatoare care ia valoarea 0 sau 1 după cum în ziua n , studentul circulă cu tramvaiul sau cu autobuzul. Conform enunțului, valorile lui X_{nn} depend doar de cele ale lui X_n , asadar $(X_n)_{n \in \mathbb{N}}$ * este un lant Markov. cu două stări:

starea 1: circulă cu tramvaiul

starea 2: circulă cu autobuzul

Conform enunțului, matricea probabilităților de trecere este

$$P = \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

Dacă în prima zi, studentul circulă cu autobuzul, repartitia inițială va fi $(0, 1)$, iar repartitia din cea de-a 100-a zi va fi $(0, 1)$. P^{99} .

Să calculăm P^n ($n \geq 1$). Vom arăta că matricea P diagonalizează și apoi, vom calcula P^n folosind acest fapt.

$$\det(P - \lambda I_2) = \frac{1}{2}(2\lambda^2 - \lambda - 1) = (\lambda - 1)(\lambda + \frac{1}{2}) \Rightarrow P$$
 are

două valori proprii simple $\Rightarrow P$ diagonalizează \Rightarrow
 $\Rightarrow \exists T \in M_2(\mathbb{R})$ nesingulară și $T^{-1}PT = \begin{pmatrix} 1 & 0 \\ 0 & -\frac{1}{2} \end{pmatrix} = D$

(Reamintim că putem alege T să sită pe coloane vectorii proprii ai lui P corespondători valoilor proprii 1, respectiv $-\frac{1}{2}$).

$$P - \lambda_1 I_2 = P - I_2 = \begin{pmatrix} -1 & 1 \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix} \Rightarrow (P - I_2) \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Leftrightarrow x = y$$

$$\Rightarrow \begin{pmatrix} x \\ y \end{pmatrix} = x \begin{pmatrix} 1 \\ 1 \end{pmatrix} \Rightarrow \{x_1 = (1)\} \text{ o bază pentru } \text{Ker}(P - I_2)$$

$$P - \lambda_2 I_2 = P + \frac{1}{2} I_2 = \begin{pmatrix} 1/2 & 1 \\ 1/2 & 1 \end{pmatrix} \Rightarrow (P + \frac{1}{2}I_2) \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Leftrightarrow$$

$$\Leftrightarrow x + 2y = 0 \Rightarrow \begin{pmatrix} x \\ y \end{pmatrix} = y \begin{pmatrix} -2 \\ 1 \end{pmatrix} \Rightarrow \{x_2 = (-2)\} \text{ o bază pentru } \text{Ker}(P + \frac{1}{2}I_2).$$

Așadar, pentru $T = (v_1 | v_2) = \begin{pmatrix} 1 & -2 \\ 1 & 1 \end{pmatrix}$ avem

$$P = TDT^{-1} \Rightarrow P^n = TD^nT^{-1} = \begin{pmatrix} 1 & -2 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & (-\frac{1}{2})^n \end{pmatrix}.$$

inductie

$$\cdot \frac{1}{3} \begin{pmatrix} 1 & 2 \\ -1 & 1 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} 1 + 2 \cdot (-\frac{1}{2})^n & 2 - 2 \cdot (-\frac{1}{2})^n \\ 1 - (-\frac{1}{2})^n & 2 + (-\frac{1}{2})^n \end{pmatrix}$$

$$\begin{matrix} T^{-1} = \frac{1}{3} \begin{pmatrix} 1 & 2 \\ -1 & 1 \end{pmatrix} \\ \cdot \frac{1}{3} \begin{pmatrix} 1 & 2 \\ -1 & 1 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} 1 + 2 \cdot (-\frac{1}{2})^n & 2 - 2 \cdot (-\frac{1}{2})^n \\ 1 - (-\frac{1}{2})^n & 2 + (-\frac{1}{2})^n \end{pmatrix} \end{matrix}$$

\Rightarrow Repartitia din cea de-a 100-a zi este:

$$(0,1) P^{99} = \frac{1}{3} \left(1 - \left(-\frac{1}{2}\right)^{99}, 2 + \left(-\frac{1}{2}\right)^{99} \right) =$$

$$= \left(\frac{1}{3} + \frac{1}{3 \cdot 2^{99}}, \frac{2}{3} - \frac{1}{3 \cdot 2^{99}} \right) \Rightarrow \text{probabilitatea ca în}$$

ziua 100 să circule cu tramvaiul este $\frac{1}{3} + \frac{1}{3 \cdot 2^{99}}$

b) Dacă (a, b) este o repartitie initială, repartitie este o perioadă lungă de timp va fi $\lim_{n \rightarrow \infty} (a, b) P^n =$

$$= (a, b) \cdot \frac{1}{3} \begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix} = (a+b) \left(\frac{1}{3}, \frac{2}{3} \right) \Rightarrow \text{pe o perioadă}$$

mai lungă de timp, este mai probabil ca stădintul să circule cu autobuzul.

Obs Repartitie $\left(\frac{1}{3}, \frac{2}{3} \right)$ este oricare dintre liniile

$$\text{matricei } \lim_{n \rightarrow \infty} P^n = \begin{pmatrix} \frac{1}{3} & \frac{2}{3} \\ \frac{1}{3} & \frac{2}{3} \end{pmatrix}. \text{ Așa cum am}$$

mai menționat, această repartitie se numește repartitie stationară a lanțului Markov. Ea există pentru orice lanț Markov (o condiție suficientă este precizată la pag 4 a acestui seminor).

Când nu avem nevoie de matricea P^n , putem determina repartitie stationară (dacă există) din relația $\sigma P = \sigma$, aşa cum vom proceda în

problema următoare.

Ex 6 Departamentul de servicii al unei universități poate cumpăra calculatoare de la două firme: A și B. Notăm cu 1 starea de funcționare a unui calculator și cu 2 starea de nefuncționare. Matricele stochastice de funcționare probabilă a unui calculator în cele două firme sunt:

$$P = \begin{pmatrix} 0,95 & 0,05 \\ 0,9 & 0,1 \end{pmatrix} \text{ pentru firmă A și}$$

$$Q = \begin{pmatrix} 0,98 & 0,02 \\ 0,85 & 0,15 \end{pmatrix} \text{ pentru firmă B.}$$

De la care firmă este mai avantajos să se cumpere calculatoarele având în vedere că prețul este același?

Având în vedere că elementele matricelor P și Q sunt strict pozitive, conform prop. 5, ambele lanturi Morkov există distribuții statimare. Fie π , respectiv σ aceste distribuții.

$$\text{Dacă } \pi = (a, b), \text{ din } \pi P = \pi \Rightarrow \begin{cases} 0,95a + 0,9b = a \\ a + b = 1 \end{cases} \Rightarrow$$

$$\Rightarrow a = \frac{18}{19}, b = \frac{1}{19} \Rightarrow \pi = \left(\frac{18}{19}, \frac{1}{19} \right)$$

$$\text{Dacă } \sigma = (c, d), \text{ din } \sigma Q = \sigma \Rightarrow \begin{cases} c \cdot 0,98 + d \cdot 0,85 = c \\ c + d = 1 \end{cases} \Rightarrow$$

$$\Rightarrow c = \frac{85}{87}, d = \frac{2}{87} \Rightarrow \sigma = \left(\frac{85}{87}, \frac{2}{87} \right)$$

Cum $\frac{85}{87} > \frac{18}{19} \Rightarrow$ un calculator de la firma B are, pe termen lung, să funcționeze mai mult decât un calculator de la firma A.

LANTURI MARKOV. PROBLEME

Lect. Dr. Costache Luminita

1. Să se calculeze matricea probabilităților de trecere după 2 pași, respectiv 3 pași pentru lanțul Markov a cărui matrice de trecere este

$$P = \begin{pmatrix} 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 0 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}$$

2. Fie un lanț Markov dat de matricea de trecere $P = \begin{pmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ 0 & 0 & 1 \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}$. Să se calculeze probabilitățile staționare stabilind mai întâi că lanțul este ergodic.

3. Vremea în țara vrăjitorului din Oz este un lanț Markov omogen cu 3 stări : s_1 : "ploaie", s_2 : "vreme bună", s_3 : "zăpadă" și matricea probabilităților de trecere $P = \begin{pmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{2} & 0 & \frac{1}{2} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \end{pmatrix}$. Să se calculeze :

- a) probabilitatea ca după 3 zile de la o zi cu vreme bună să avem o zi cu zăpadă ;
b) repartiția staționară .

4. Calculați repartiția staționară a unui lanț Markov cu matricea de trecere $P = \begin{pmatrix} 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{3} & 0 & \frac{2}{3} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \end{pmatrix}$.

5. Un cumpărător preferă două tipuri de mezeluri: salam de Sibiu și șuncă de Praga. Dacă azi cumpără salam de Sibiu există o șansă de 0,75 să cumpere și mâine, iar dacă azi cumpără șuncă de Praga există o șansă de 0,6 să cumpere și mâine. Determinați probabilitatea ca dacă vineri cumpără salam, duminică să cumpere șuncă .

6. Presupunem că o persoană face cumpărături de la Carrefour și Kauffland. Dacă azi cumpără de la Carrefour, mâine va cumpăra de la Kauffland cu probabilitatea 0,45, iar dacă azi cumpără de la Kauffland, mâine va cumpăra de la Carrefour cu probabilitatea 0,6. Dacă marți cumpără de la Carrefour, care e probabilitatea ca joi să cumpere tot de acolo?

7. Un șofer își alimentează mașina de la OMV sau Lukoil. Dacă azi pune benzină de la Lukoil, mâine va pune de la OMV cu probabilitatea 0,6, iar dacă azi pune benzină de la OMV, mâine va pune de la Lukoil cu probabilitatea 0,3. Dacă azi e miercuri și a alimentat de la Lukoil, care

este probabilitatea ca pentru excursia de sămbătă să alimenteze de la OMV?

8. În Evul Mediu, universitățile Harvard, Dartmouth și Yale admiteau numai studenți bărbați. Presupunem că în acea perioadă 80% dintre fiii celor de la Harvard mergeau tot la Harvard și restul la Yale, 40% dintre fiii celor de la Yale mergeau la Yale și restul se împărteau în mod egal între Harvard și Dartmouth și 70% dintre fiii celor de la Dartmouth mergeau tot la Dartmouth, 20% la Harvard și 10% la Yale. Scrieți matricea probabilităților de trecere și calculați probabilitatea ca dacă bunicul a fost la Yale, nepotul să urmeze cursurile Universității Harvard.
9. Într-un anumit oraș există 3 profesii P_1, P_2, P_3 . Copiii unui tată cu profesia P_1, P_2, P_3 păstrează aceeași profesie cu probabilitatea $\frac{3}{5}, \frac{2}{3}$, respectiv $\frac{1}{4}$. Iar dacă nu o păstrează, atunci aleg una dintre celelalte două profesii cu probabilități egale. Să se calculeze: a) repartitia celor 3 profesii în generația următoare, dacă în generația actuală 20% din adulți au profesia P_1 , 30% din adulți au profesia P_2 și 50% din adulți au profesia P_3 ; b) repartitia staționară.
10. Un meteorolog a dezvoltat următorul model pentru prezicerea vremii. Dacă plouă azi, probabilitatea este 0,6 că va ploua și mâine și 0,4 că nu va mai ploua mâine. Dacă nu plouă azi, probabilitatea este 0,2 că va ploua și mâine și 0,8 că nu va ploua mâine.
 - a) Găsiți matricea de trecere P pentru acest lanț Markov și matricea de trecere după 2 pași.
 - b) Dacă plouă azi, care este probabilitatea că va ploua și poimâine?
 - c) Dacă nu plouă azi, care este probabilitatea ca să plouă și poimâine?
11. Fie un lanț Markov a cărui matrice de trecere este $P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{3} & 0 & \frac{2}{3} \end{pmatrix}$.
 - a) Să se calculeze matricea probabilităților de trecere după 2, respectiv 3 pași.
 - b) Lanțul este ergodic?
 - c) Dacă este ergodic, atunci să se determine probabilitățile limită.
12. Presupunem că înainte de a fi făcută o evidență a legăturii dintre fumat și bolile respiratorii, 40% din adulții de sex masculin erau fumători și 60% erau nefumători. La un an după această evidență a fost făcută public, 30% dintre fumători s-au oprit din fumat, în timp ce 10% din nefumători au început să fumeze.

- a) Scrieți matricea de trecere a lanțului Markov cu 2 stări;
- b) Reprezentați distribuția inițială a fumătorilor și nefumătorilor ca un vector probabilitate;
- c) Găsiți vectorul probabilitate ce descrie distribuția fumătorilor și nefumătorilor după un an;
- d) Găsiți vectorul probabilitate ce descrie distribuția fumătorilor și nefumătorilor după 2 ani.
13. În modelul stochastic de învățare bazat pe teoria selectării stimulilor propus de W.K. Estes în 1950, se consideră un lanț Markov cu 2 stări. Astfel starea 1 semnifică faptul că subiectul a învățat, de exemplu, să primească o alună sau să evite un soc electric. Starea 2 semnifică faptul că subiectul nu a învățat încă. Se presupune că de îndată ce subiectul a învățat el nu mai uită, iar dacă nu a învățat încă, el va reuși cu probabilitatea α să învețe după fiecare încercare. Să se determine matricea de trecere și să se calculeze $p_{21}(n)$.
14. Matricea probabilităților de trecere ale unui lanț Markov omogen este $P = \begin{pmatrix} 0,1 & 0,5 & 0,4 \\ 0,6 & 0,2 & 0,2 \\ 0,3 & 0,4 & 0,3 \end{pmatrix}$, iar $X_0 \sim \begin{pmatrix} 1 \\ 0,7 \\ 0,2 \end{pmatrix}$. Calculați repartitia variabilei X_1 și probabilitatea ca la momentele $n = 0, 1, 2$ lanțul să se găsească în stările 1,2,2 respectiv.
15. Un sistem de telecomunicații transmite cifrele 0 și 1. Fiecare cifră trece prin mai multe stadii de prelucrare, în fiecare stadiu existând probabilitatea p ca să fie transmisă corect și probabilitatea $q = 1 - p$ ca ea să fie transmisă greșit. Fie X_k cifra care intră în stadiul k de prelucrare.
- a) Scrieți matricea P a lanțului Markov omogen cu stările $\{0, 1\}$ astfel obținut și calculați $P^n, n \in \mathbb{N}^*$, precum și $P(X_2 = 1/X_0 = 1), P(X_7 = 0/X_3 = 1)$
- b) Determinați repartitia staționară
- c) Dacă $X_0 \sim \begin{pmatrix} 0 \\ \frac{1}{3} \\ \frac{2}{3} \end{pmatrix}$, calculați repartitia v. a. X_n și $P(X_0 = 0/X_n = 1)$
16. Un lanț Markov cu 2 stări poate fi folosit să modeleze o varietate largă de sisteme ce alternează între stările ON și OFF. După fiecare unitate de timp în starea OFF, sistemul trece pe ON cu probabilitatea p . După fiecare unitate de timp în starea ON, sistemul trece în OFF cu probabilitatea q . Folosind 0 și 1 să notăm stările OFF și ON, care este matricea probabilităților de trecere? Stiind că sistemul este în

starea OFF la momentul 0, care este probabilitatea ca sistemul să fie în starea OFF la momentul $n = 33$?

17. Fie lanțul Markov cu 2 stări E_1 și E_2 cu probabilitățile de trecere $p_{11} = p_{22} = p, p_{12} = p_{21} = q (0 < p < 1, p + q = 1)$ și repartiția inițială $P(X_0 = 1) = \alpha, P(X_0 = 2) = \beta (\alpha + \beta = 1)$. Se cer:
- să se determine probabilitățile de trecere după n pași ($p_{jk}(n)$);
 - să se determine probabilitățile limită ;
 - să se determine probabilitatea $P(X_0 = 1 | X_n = 1)$.

SELECTII. ESTIMATORI

Lect. Dr. Costache Luminita

Statistica matematică se ocupă cu gruparea, analiza și interpretarea datelor referitoare la anumite fenomene și unele previziuni privind producerea lor în viitor. Spre deosebire de teoria probabilităților al cărei demers este deductiv, în care se obțin concluzii dintr-o repartitie, statistica matematică urmează calea inductivă care face trecerea în sens invers, de la un rezultat la o repartitie. Statistică matematică este solicitată de fizică, biologie, medicină, arheologie. Începuturile statisticii matematice sunt prefigurate în special în lucrările lui Laplace. Construirea ei, spre sfârșitul secolului XIX, a fost pregătită de teoria probabilităților, statistica demografică, teoria erorilor, unele contribuții ale psihologiei și sociologiei. Crearea ei este legată de școala anlo-saxonă de statistică matematică, de numele lui Galton (1829-1911) și Pearson (1857-1936).

1 Teoria selecției

Orice mulțime de obiecte care au cel puțin o proprietate comună și este supusă unei prelucrări statistice se numește **populație statistică**. Numărul elementelor mulțimii, care se numește **volumul populației**, poate fi finit sau infinit. Proprietățile (trăsăturile) comune ale elementelor unei populații statistice se numesc **caracteristici**. Dacă o anumită caracteristică a elementelor se schimbă cantitativ se numește **variabilă**. Caracteristicile variabile pot fi discrete sau continue.

Fie X o v. a. reprezentând o anumită caracteristică numerică (durata de viață, venitul, număr de defecțiuni etc.) a unei populații statistice. Rezultatele numerice x_1, x_2, \dots, x_n obținute prin n măsurători (interrogări, observări etc.) formează o **selecție empirică de volum n** a v. a. X . Elementele mulțimii $\{x_1, x_2, \dots, x_n\}$ numite **variabile de selecție** au o dublă interpretare:

- 1) considerate după efectuarea selecției, variabilele x_1, x_2, \dots, x_n reprezintă valori concrete pe care le folosim ca informații asupra v. a. X și le notăm $X_1 = x_1, \dots, X_n = x_n$;
- 2) considerate înainte de efectuarea selecției, variabilele X_1, \dots, X_n pot fi privite ca v. a. independente și identic repartizate din punct de vedere probabilistic cu v. a. X .

Se consideră că fiecare v. a. $X_j, j = \overline{1, n}$ se realizează cu aceeași probabilitate egală cu $\frac{1}{n}$. Pe baza acestui fapt se construiește v. a. de selecție (variabila empirică).

Variabila aleatoare de selecție are următoarea repartitie

$$X^* \sim \begin{pmatrix} x_1 & \dots & x_n \\ \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}, \text{ în care } P(X^* = x_k) = \frac{1}{n}, \forall k = \overline{1, n}$$

Presupunând că după efectuarea a n observații am obținut : de n_1 ori

a apărut X_1, \dots , de n_k ori a apărut X_k , unde $n_1 + \dots + n_k = n$, atunci

$$X^* \sim \begin{pmatrix} x_1 & \dots & x_k \\ \frac{n_1}{n} & \dots & \frac{n_k}{n} \end{pmatrix}$$

Funcția empirică de repartiție se va nota cu F^* sau F_n^* .

Media de selecție este $\bar{x} = \frac{x_1 + \dots + x_n}{n}$

Dispersia de selecție este $S^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2$

Teorema 1. Dacă $E(X) = m$ și $D^2(X) = \sigma^2$, atunci $E(\bar{X}) = m$ și $D^2(\bar{X}) = \frac{\sigma^2}{n}$.

2 Selectii dintr-o populație normală

2.1 Repartiția mediei de selecție dintr-o populație normală

Teorema 2. Dacă $\{X_1, X_2, \dots, X_n\}$ este o selecție de volum n dintr-o populație normală $N(m, \sigma)$, atunci media de selecție $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$ urmează o repartiție normală $N(m, \frac{\sigma}{\sqrt{n}})$.

Corolarul 1. În condițiile anterioare $\frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}}$ are o repartiție normală standard $N(0, 1)$.

Teorema 3. Dacă $\{X_1, X_2, \dots, X_n\}$ reprezintă o selecție de volum n dintr-o populație normală $N(0, 1)$, atunci v. a. $Y = \sum_{k=1}^n X_k^2$ urmează o repartiție χ^2 cu n grade de libertate.

2.2 Repartiția dispersiei de selecție pentru selectii dintr-o populație normală

Fiind dată o populație statistică și X_1, X_2, \dots, X_n o selecție de volum n se pot defini:

a) media de selecție $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$

b) dispersia de selecție cu ajutorul căreia putem evalua dispersia populației:

1) dacă media m a populației generale este cunoscută atunci dispersia

de selecție este dată de $s_0^2 = \frac{1}{n} \sum_{k=1}^n (x_k - m)^2$

2) dacă media m a populației generale nu este cunoscută, dispersia de

selecție este $S^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2$

3) în cazul selectiilor de volum mic ($n < 30$) este indicat să fie folosită

dispersia modificată de selecție $s^2 = \frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})^2$, $s^2 = \frac{n}{n-1} S^2$

Teorema 4. Dacă $\{X_1, X_2, \dots, X_n\}$ este o selecție dintr-o populație normală $N(m, \sigma)$, atunci v. a. $\frac{n \cdot s^2}{\sigma^2}$ are o repartiție χ^2 cu n grade de libertate.

Teorema 5. Dacă $\{X_1, X_2, \dots, X_n\}$ este o selecție dintr-o populație normală $N(m, \sigma)$, atunci

(1) statisticile $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ și $S^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \bar{X})^2$ sunt independente;

(2) statistica $V = \frac{n \cdot S^2}{\sigma^2}$ are o repartiție χ^2 cu $n - 1$ grade de libertate.

Teorema 6. Dacă $\{X_1, X_2, \dots, X_n\}$ este o selecție dintr-o populație normală $N(m, \sigma)$, atunci v. a. $t = \frac{\bar{X} - m}{\frac{s}{\sqrt{n}}}$ are o repartiție Student cu $n - 1$ grade de libertate

3 Elemente de teoria estimării

3.1 Estimator nedeplasat, consistent, eficient

Operația prin care determinăm valorile parametrilor repartițiilor se numește **estimare**.

Considerăm o v. a. X dintr-o populație Γ având repartiția $f(x, \theta)$. Fie $\{X_1, X_2, \dots, X_n\}$ o selecție de volum n din Γ .

Definiția 1. Un **estimator** $\theta^*(X_1, X_2, \dots, X_n)$ pentru θ este o statistică (adică o variabilă aleatoare de variabile aleatoare) care ia valori numerice (adică valoarea lui $\theta^*(X_1, X_2, \dots, X_n)$ îl aproximează pe θ).

Definiția 2. $\theta^*(X_1, X_2, \dots, X_n)$ se numește **estimator consistent** pentru θ dacă $\lim_{n \rightarrow \infty} P(|\theta^*(X_1, X_2, \dots, X_n) - \theta| < \varepsilon) = 1$, $\forall \varepsilon > 0$, adică $\theta^*(X_1, X_2, \dots, X_n)$ converge în probabilitate către θ .

Definiția 3. $\theta^*(X_1, X_2, \dots, X_n)$ se numește **estimator nedeplasat** pentru θ dacă $E(\theta^*(X_1, X_2, \dots, X_n)) = \theta$.

Definiția 4. Dacă

$$\lim_{n \rightarrow \infty} E(\theta^*(X_1, X_2, \dots, X_n)) = \theta$$

$$\lim_{n \rightarrow \infty} D^2(\theta^*(X_1, X_2, \dots, X_n)) = 0$$

spunem că $\theta^*(X_1, X_2, \dots, X_n)$ este un **estimator corect** al parametrului θ .

Definiția 5. Dacă

$$E(\theta^*(X_1, X_2, \dots, X_n)) = \theta$$

$$\lim_{n \rightarrow \infty} D^2(\theta^*(X_1, X_2, \dots, X_n)) = 0$$

spunem că $\theta^*(X_1, X_2, \dots, X_n)$ este un **estimator absolut corect** al parametrului θ .

Teorema 7. Dacă $\theta^*(X_1, X_2, \dots, X_n)$ este un estimator pentru θ astfel încât $E(\theta^*(X_1, X_2, \dots, X_n)) = \theta$ și $\lim_{n \rightarrow \infty} D^2(\theta^*(X_1, X_2, \dots, X_n)) = 0$, atunci $\theta^*(X_1, X_2, \dots, X_n)$ este un estimator consistent pentru θ .

Teorema 8. (Rao-Cramer) Dacă $\theta^*(X_1, X_2, \dots, X_n)$ este un estimator nedeplasat pentru θ , atunci $D^2(\theta^*) \geq \frac{1}{nI(\theta)}$, unde $I(\theta) = -E\left(\frac{\partial^2 \ln f(x, \theta)}{\partial \theta^2}\right) = E\left[\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2\right]$

Definiția 6. Dacă $\theta^*(X_1, X_2, \dots, X_n)$ este un estimator nedeplasat astfel încât $D^2(\theta^*) = \frac{1}{nI(\theta)}$, atunci el se numește **eficient**.

Corolarul 2. Orice estimator eficient este consistent.

3.2 Metoda verosimilității maxime

Metoda verosimilității maxime este una dintre cele mai vechi metode de estimare. Ea a fost folosită de Gauss când a dezvoltat metoda celor mai mici pătrate și reintrodusă în 1912 de Fischer.

Se consideră o selecție $\{x_1, \dots, x_n\}$ de volum n dintr-o populație în care caracteristica sub cercetare X este o v.a. având densitatea de probabilitate $f(x, \theta)$ presupusă cunoscută, iar parametrul θ este necunoscut și poate lua valori într-o mulțime $\Theta \subset \mathbb{R}^k$.

Definiția 7. Vom numi **funcție de verosimilitate** corespunzătoare valorilor x_1, \dots, x_n , o funcție $L(x_1, \dots, x_n; \theta)$, considerată ca funcție de θ , definită prin $L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$, unde $f(x_i; \theta)$ este fie densitatea de probabilitate a v. a. X , fie repartiția sa, adică $f(x; \theta) = P(X = x)$, dacă X este discretă.

Definiția 8. Estimatorul de verosimilitate maximă pentru θ este acea valoare $\theta^* = \theta^*(x_1, \dots, x_n)$ cu proprietatea că $L(x_1, \dots, x_n; \theta^*) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$.

Intrucât funcțiile L și $\ln L$ au aceleași puncte de maxim rezultă că, dacă $\theta = (\theta_1, \dots, \theta_k)$, atunci $\theta^*(x_1, \dots, x_n) = (\theta_1(x_1, \dots, x_n), \dots, \theta_k(x_1, \dots, x_n))$ trebuie să verifice sistemul de ecuații

$$\frac{\partial}{\partial \theta_j} \ln L(x_1, \dots, x_n; \theta_1, \dots, \theta_k) = 0, j = \overline{1, k}$$

Observația 1. Orice estimator eficient al parametrului θ este un estimator de verosimilitate maximă.

INTERVALE DE INCREDERE. IPOTEZE PARAMETRICE

Lect. Dr. Costache Luminita

1 Intervale de încredere

Fie dată densitatea de probabilitate $f(x, \theta)$. În urma efectuării unei selecții de volum n , $\{x_1, \dots, x_n\}$, putem determina două statistici $\underline{\theta}(x_1, \dots, x_n)$ și $\bar{\theta}(x_1, \dots, x_n)$ astfel încât $(\underline{\theta}, \bar{\theta})$ să conțină valoarea adevărată a parametru-lui θ cu probabilitatea dată $p = 1 - \alpha$, adică $P(\underline{\theta} < \theta < \bar{\theta}) = p$, unde p nu depinde de θ .

Intervalul $(\underline{\theta}, \bar{\theta})$ care acoperă pe θ cu probabilitatea dată $1 - \alpha$ se numește **interval de încredere**. Cu cât intervalul de încredere este mai mic și probabilitatea $1 - \alpha$ este mai apropiată de 1, cu atât avem o indicație mai precisă despre θ . Intervalul încredere $(\underline{\theta}, \bar{\theta})$ este **bilateral**. Intervalul de încredere poate fi și **unilateral superior** sau **inferior**: $P(\theta < \bar{\theta}) = 1 - \alpha$ sau $P(\underline{\theta} < \theta) = 1 - \alpha$.

Fie $F(x)$ o funcție de repartiție și $\alpha \in (0, 1)$. Se numește **α -cuantilă** a repartiției F un număr $c \in \mathbb{R}$ pentru care $F(c) = \alpha$.

In cele ce urmează α -cuantilele repartițiilor $N(0, 1)$, $\chi^2(n)$, $T(n)$ vor fi notate respectiv z_α , $\chi^2_\alpha(n)$, $t_\alpha(n)$.

1.1 Intervale de încredere pentru media și dispersia repartiției normale

1. σ cunoscut, m necunoscut

$$m \in \left(\bar{x} - \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}, \bar{x} + \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}} \right)$$

2. m cunoscut, σ necunoscut

$$\sigma^2 \in \left(\frac{n}{\chi^2_{1-\frac{\alpha}{2}}(n)} \cdot s_0^2, \frac{n}{\chi^2_{\frac{\alpha}{2}}(n)} \cdot s_0^2 \right)$$

3. m și σ necunoscuți

$$\sigma^2 \in \left(\frac{n-1}{\chi^2_{1-\frac{\alpha}{2}}(n-1)} \cdot s^2, \frac{n-1}{\chi^2_{\frac{\alpha}{2}}(n-1)} \cdot s^2 \right)$$

$$m \in \left(\bar{x} - \sqrt{\frac{s^2}{n}} t_{1-\frac{\alpha}{2}}(n-1), \bar{x} + \sqrt{\frac{s^2}{n}} t_{1-\frac{\alpha}{2}}(n-1) \right)$$

2 Verificarea ipotezelor statistice parametrice

In statistica matematică prin ipoteză înțelegem o presupunere ce se poate face asupra unuia sau mai multor parametri ce caracterizează anumite repartiții sau asupra tipului legilor de repartiție ce caracterizează anumite populații.

Ipoteza statistică poate fi parametrică atunci când se referă la parametrul unei funcții de repartiție cunoscute și neparametrică atunci când se referă la forma funcției de repartiție necunoscută .

Considerăm o v.a. a cărei densitate de probabilitate $f(x, \theta)$ depinde de un singur parametru θ . Ne propunem să verificăm ipoteza că parametrul θ are valoarea θ_0 . Notăm această ipoteză $H_0 : \theta = \theta_0$ și o vom numi **ipoteza nulă** față de ipoteza $H_1 : \theta = \theta_1$ cu care este confruntată și este numită **ipoteză alternativă**.

Verificarea ipotezei nule H_0 se face pe baza unei selecții $\{x_1, \dots, x_n\}$ cu ajutorul valorii observate a unei statistici. Metoda aleasă pentru verificarea unei ipoteze statistice se numește **test sau criteriu statistic**.

Fie θ un parametru asociat v. a. X și ipoteza nulă $H_0 : \theta = \theta_0$ care trebuie testată (verificată) astfel încât probabilitatea **unei erori de prima speță** (respingerea lui H_0 atunci când ea este adevărată) să fie egală cu α . Numărul $\alpha \in (0, 1)$ se numește **nivelul de semnificație** al testului. Etapele aplicării testului sunt următoarele:

- Alegerea **ipotezei alternative** H_1 care poate fi **unilaterală** $H_1 : \theta < \theta_0, \theta > \theta_0$ sau **bilaterală** $H_1 : \theta \neq \theta_0$;
- Alegerea unei statistici $T = T(x_1, \dots, x_n)$ astfel încât, în ipoteza H_0 , repartiția lui T să fie cunoscută ;
- În funcție de ipoteza alternativă H_1 și de nivelul de semnificație α , fixarea unei regiuni critice de forma

$$R_{cr} = \{T/T < c_\alpha\}, R_{cr} = \{T/T > c_{1-\alpha}\}$$

în cazul unui test unilateral, sau

$$R_{cr} = \{T/T < c_{\frac{\alpha}{2}}\} \cup R_{cr} = \{T/T > c_{1-\frac{\alpha}{2}}\}$$

în cazul unui test bilateral. Cu $c_\alpha, c_{1-\alpha}, c_{\frac{\alpha}{2}}, c_{1-\frac{\alpha}{2}}$ s-au notat cuantilele repartiției lui T în ipoteza H_0 ; deci, în această ipoteză , probabilitatea unei erori de prima speță este $P(T \in R_{cr}) = \alpha$.

- Se calculează valoarea $T(x_1, \dots, x_n)$ luată de statistica T pe elementele unei anumite selecții empirice x_1, \dots, x_n
- Se respinge ipoteza H_0 dacă și numai dacă $T(x_1, \dots, x_n) \in R_{cr}$

2.1 Verificarea ipotezei asupra mediei m a unei populații normale cu σ^2 cunoscut

1.1. Testul bilateral

$$H_0 : m = m_0$$

$$H_1 : m = m_1 \neq m_0$$

Regiunea critică este $R_{cr} : \left| \frac{\bar{x}-m_0}{\frac{\sigma}{\sqrt{n}}} \right| > z_{1-\frac{\alpha}{2}}$

1.2. Testul unilateral stânga

$$H_0 : m = m_0$$

$$H_1 : m = m_1 < m_0$$

Regiunea critică este $R_{cr} : \frac{\bar{x}-m_0}{\frac{\sigma}{\sqrt{n}}} < z_\alpha$

1.3. Testul unilateral dreapta

$$H_0 : m = m_0$$

$$H_1 : m = m_1 > m_0$$

Regiunea critică este $R_{cr} : \frac{\bar{x}-m_0}{\frac{\sigma}{\sqrt{n}}} > z_{1-\alpha}$

2.2 Verificarea ipotezei asupra mediei m a unei populații normale cu σ^2 necunoscut

2.1. Testul bilateral

$$H_0 : m = m_0$$

$$H_1 : m = m_1 \neq m_0$$

Regiunea critică este $R_{cr} : \left| \frac{\bar{x}-m_0}{\frac{s}{\sqrt{n}}} \right| > t_{1-\frac{\alpha}{2}}(n-1)$

2.2. Testul unilateral stânga

$$H_0 : m = m_0$$

$$H_1 : m = m_1 < m_0$$

Regiunea critică este $R_{cr} : \frac{\bar{x}-m_0}{\frac{s}{\sqrt{n}}} < t_\alpha(n-1)$

2.3. Testul unilateral dreapta

$$H_0 : m = m_0$$

$$H_1 : m = m_1 > m_0$$

Regiunea critică este $R_{cr} : \frac{\bar{x}-m_0}{\frac{s}{\sqrt{n}}} > t_{1-\alpha}(n-1)$

2.3 Verificarea ipotezei asupra dispersiei unei populații normale

Fie ipoteza $H_0 : \sigma^2 = \sigma_0^2$ și alternativa ei $H_1 : \sigma^2 = \sigma_1^2$

3.1. Testul unilateral stânga

$$H_0 : \sigma^2 = \sigma_0^2$$

$$H_1 : \sigma^2 = \sigma_1^2 < \sigma_0^2$$

Regiunea critică este $R_{cr} : \frac{(n-1)s^2}{\sigma_0^2} < \chi_{\alpha}^2(n-1)$

3.2. Testul unilateral dreapta

$$H_0 : \sigma^2 = \sigma_0^2$$

$$H_1 : \sigma^2 = \sigma_1^2 > \sigma_0^2$$

Regiunea critică este $R_{cr} : \frac{(n-1)s^2}{\sigma_0^2} > \chi^2_{1-\alpha}(n-1)$

3.3. Testul bilateral

$$H_0 : \sigma^2 = \sigma_0^2$$

$$H_1 : \sigma^2 = \sigma_1^2 \neq \sigma_0^2$$

Regiunea critică este $R_{cr} : \frac{(n-1)s^2}{\sigma_0^2} < \chi^2_{\frac{\alpha}{2}}(n-1) \cup \frac{(n-1)s^2}{\sigma_0^2} > \chi^2_{1-\frac{\alpha}{2}}(n-1)$

PROBLEME ESTIMATORI

Lect. Dr. Costache Luminita

1. Repartiția valorilor defectiunilor unor aparate de măsură și control a fost analizată pe baza a 100 de observații care au furnizat următoarele valori cu privire la numărul de porniri (puneri în funcțiune) după care

x_i	1	3	6	8	10
n_i	15	20	30	10	25

acestea se defectează :

x_i	1	3	6	8	10
n_i	15	20	30	10	25

Stabilități:

- a) media și dispersia de selecție;
- b) funcția de repartiție a selecției și valorile ei în punctele $x = 2$ și $x = 7$.

2. Pentru a cerceta prezența studenților la un anumit curs s-a ales un eșantion de n studenți și s-a înregistrat numărul absențelor acestora la patru cursuri consecutive.

Nr. studenți n_i	50	20	15	8	7
Nr. absențe x_i	0	1	2	3	4

- a) Să se scrie repartiția empirică și funcția de repartiție empirică $F_n^*(x)$;
- b) Să se calculeze media și dispersia de selecție;
- c) Să se calculeze $F_{100}^*(3)$

3. Se controlează greutatea unor pachete și, pentru aceasta, se extrage o selecție de volum n , care dă următoarele valori:

Pachetul	1	2	3	4	5	6	7	8	9	10
Greutatea	21,5	21,6	21,75	22	22,45	22,6	23,2	23,4	23,5	23,65

Să se calculeze $F_{10}^*(20), F_{10}^*(22), F_{10}^*(23)$. Să se scrie repartiția empirică și să se calculeze media de selecție.

4. Repartiția valorilor rezistenței la rupere a unor fire de bumbac (în kg) a fost analizată pe baza a 100 de observații. Valorile observate împreună cu frecvențele lor absolute sunt date în tabelul următor:

x_i (valorile rezistenței la rupere în kg)	0,5	0,65	0,75	0,8	0,9	1	1,12	1,35
n_i (frecvențe absolute)	2	4	5	26	30	25	6	2

Se cer:

- a) Valoarea medie și dispersia de selecție a rezistenței la rupere;
- b) $F^*(0,78), F^*(0,9)$, unde $F^*(x)$ este funcția empirică de repartiție

5. Dintr-o populație normală cu media $m = 12$, probabilitatea ca media de selecție corespunzătoare unei selecții de volum $n = 16$ să nu depășească 14 (în modul) este de 0,24. Care este probabilitatea ca

o singură observație din această selecție să aibă o valoare mai mare decât 14?

6. Dintr-o populație normală se extrag toate selecțiile posibile de volum $n = 25$. Dacă $5^0/0$ dintre ele au medii care diferă de media populației cu cel puțin 5 unități în valoare absolută, aflați abaterea medie pătratică a populației.
7. Arătați că media de selecție este un estimator eficient pentru parametrul λ al repartiției Poisson.
8. Arătați că media de selecție este un estimator eficient pentru media m a repartiției normale.
9. Să se estimeze prin metoda verosimilității maxime parametrul θ al repartițiilor:
 - a) $f(x, \theta) = (2 - \theta)x^{(\ln 2)^{-1} \ln \frac{\theta-1}{2-\theta}}, 1 < \theta < 2$
 - b) $f(x, \theta) = \frac{\theta}{1-\theta}x^{\frac{2\theta-1}{1-\theta}}, \frac{1}{2} < \theta < 1$
 - c) $f(x, \theta) = \frac{1}{\sqrt{2\pi\theta}}e^{-\frac{1}{2\theta}(x-\theta)^2}, 0 < x < 1, \theta > 0$
 - d) $f(x, \theta) = \theta(1 - \theta)^x, x = 0, 1, 2 \dots, 0 < \theta < 1$
 - e) $f(x, \theta) = (1 + \theta)x^\theta, 0 < x < 1, \theta > 0$
 - f) $f(x, \theta) = \frac{\theta x_0^\theta}{x^{\theta+1}}, x > x_0 (x_0 \text{ constantă dată}), \theta > 0$
 - g) $f(x, \theta) = \frac{x^{\alpha-1}e^{-\frac{x}{\theta}}}{\Gamma(\alpha)\theta^\alpha}, x > 0, \theta > 0, \alpha \text{ dat}$
 - h) $f(x, \theta) = \theta e^{-\theta x}, x \geq 0, \theta > 0$
 - i) $f(x, \theta) = \frac{x}{\theta} \cdot e^{-\frac{x^2}{2\theta}}, x > 0, \theta > 0.$
10. Fie X o v. a. cu densitatea $f(x, \theta) = \frac{A}{\theta+1}x^{\frac{x}{\theta}}, x \geq 1, \theta > 0$ și să considerăm o selecție aleatoare X_1, \dots, X_n din populația de caracteristică X .
 - a) Să se determine A în funcție de θ ;
 - b) Să se afle estimatorul de verosimilitate al parametrului θ și să se studieze proprietățile acestuia.

INTERVALE DE INCREDERE. IPOTEZE PARAMETRICE. PROBLEME

Lect. Dr. Costache Luminita

1. Rectorul Universității Politehnice București vrea să știe care este media vârstei studenților. Din anii trecuți se cunoaște că abaterea standard este de 2 ani. Un sondaj asupra a 50 de studenți arată că media este de 23,2 ani. Cu un nivel de semnificație de 0,05, să se determine un interval de încredere pentru medie. Se presupune că populația are caracteristica normală .
2. Intr-o fabrică de țesut s-a constatat că rezistența la rupere a unui anumit fir de bumbac are o repartiție normală cu media necunoscută m și abaterea medie pătratică $\sigma = 36\text{g}$ (calitatea standard). Pentru a cerceta calitatea unui lot de fire de bumbac în ceea ce privește rezistența la rupere s-a făcut o selecție de volum $n = 9$ fire, obținându-se media de selecție $\bar{X} = 195\text{ g}$. Să estimeze rezistența la rupere m a lotului de fire controlat, printr-un interval de încredere $1 - \alpha = 0,95$.
3. Fie X v. a. normală care reprezintă greutatea unor ouă . O selecție de volum $n = 200$ a dat rezultatele următoare :

Greutatea (g)	37,5	42,5	47,5	52,5	57,5	62,5	67,5	72,5
Nr. observațiilor	8	14	26	44	68	20	14	6

Stiind că dispersia lui X este $\sigma^2 = 64$, aflați un interval de încredere 95% și 90% pentru media m .

4. Fie X o v. a. care reprezintă numărul de zile după care un anumit produs alimentar este absorbit pe piață . În urma unei selecții de volum $n = 8$ în rândul centrelor de desfacere, s-au obținut următoarele rezultate cu privire la numărul de zile după care se epuizează produsul respectiv :

Centru de desfacere i	1	2	3	4	5	6	7	8
Nr. de zile x_i	40	54	40	50	38	40	50	60

Presupunând că X are o repartiție normală să se afle:

- a) un interval de încredere 95% pentru viteza media cu care este absorbit produsul pe piață ;
 - b) un interval de încredere 95% pentru abaterea medie pătratică a numărului de zile după care se epuizează produsul respectiv.
5. Durabilitatea unor motoare de automobile poate fi considerată o v. a. normală cu media $m = 200000\text{ km}$ și dispersia 50000^2 km . Se face o schimbare în procesul de producție prin introducerea unei metode noi de fabricație. O selecție de volum $n = 100$ de motoare a dat

$\bar{X} = 220000$ km. Considerând $\alpha = 0,05$ se poate afirma că noua metodă duce la creșterea durabilității motoarelor?

6. Douăzeci de determinări a procentului de NaCl într-o anumită soluție au condus $\bar{X} = 0,7\%$ și $s = 0,03\%$. Stiind că procentul de NaCl într-o anumită soluție este o v. a. normală , să se verifice la pragul de semnificație $\alpha = 0,05$ ipoteza $H_0 : m = 0,8\%$ față de alternativa $H_1 : m < 0,8\%$.
7. Precizia unui cântar electronic se verifică cu ajutorul dispersiei măsurătorilor efectuate asupra unui etalon. Dispersia măsurătorilor nu trebuie să depășească valoarea nominală $\sigma_0^2 = 0,04$. S-au efectuat $n = 11$ cântăriri ale unui etalon și s-au obținut rezultatele :

i	1	2	3	4	5	6	7	8	9	10	11
x_i	100,6	99,6	100	100,1	100,3	100	99,9	100,2	100,4	100,6	100,5

Să se verifice, la un prag de semnificație $\alpha = 0,05$, dacă cântarul asigură precizia standard stabilită , presupunând că datele de selecție sunt observații asupra unei v. a. normale.

Pentru analiza preciziei unor măsurători s-au făcut $n = 16$ măsuratori și s-a stabilit $s^2 = 0,56$. Verificați ipoteza $H_0 : \sigma^2 = 0,41$ față de alternativa $H_1 : \sigma^2 \neq 0,41$ la pragul de semnificație $\alpha = 0,1$, stiind că populația în studiu este normală .

8. Pentru a estima precizia unui termometru se realizează 15 măsurători independente asupra temperaturii unui lichid menținut constant la $20^\circ C$. Presupunem că rezultatele măsurătorilor sunt realizări ale variabilelor aleatoare normale $X_k, k = \overline{1, 15}$ de medie $m = 20$ și σ necunoscută . Construiți un interval de încredere $1 - \alpha = 0,99$ pentru σ^2 , stiind că $\frac{1}{15} \sum_{k=1}^{15} (x_k - 20)^2 = 18$.
9. O fabrică de acumulatori afirmă că durata de funcționare a acumulatorilor este 300 de zile. Un laborator cercetează 4 acumulatori și obține rezultatele 298,290,306,302. Aceste rezultate indică faptul că acest tip de acumulatori are o durată de funcționare mai mică decât afirmă fabrica ($\alpha = 0,02, t_{0,02}(3) = -4,541$)?
10. S-a stabilit experimental că nivelul colesterolului în organismul unui adult este o v. a. normală . O selecție aleatoare de volum $n = 41$ adulți a dat un nivel mediu observat al colesterolului $\bar{X} = 213$ cu $s^2 = 48,4$. Să se testeze ipoteza $H_0 : m = m_0 = 200$ cu alternativa $H_1 : m = m_1 > 200$ la un prag de semnificație $\alpha = 0,05$.
11. Pentru stabilirea rezistenței la rupere a unor cabluri s-au efectuat $n = 36$ măsurători și s-a stabilit media de selecție $\bar{X} = 500$ kg. Stiind că

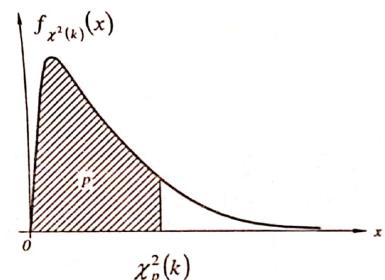
- rezistența la rupere este o v. a. normală cu $\sigma^2 = 100$ kg, să se verifice ipoteza $H_0 : m = 496$ kg față de alternativele : a) $H_1 : m \neq 496$ kg; b) $H_1 : m < 496$ kg la pragul de semnificație $\alpha = 0,01$.
12. S-a stabilit că greutatea unor ouă pentru a fi importate trebuie să fie de $m_0 = 50$ g. O cercetare selectivă asupra unui volum $n = 150$ ouă dintr-un lot importat a determinat o greutate medie observată de $\bar{X} = 43$ g. Se cere să se verifice la un prag de semnificație $\alpha = 0,01$, ipoteza $H_0 : m = m_0 = 50$ g față de ipoteza alternativă $H_1 : m < 50$ g, dacă greutatea ouălor este o v. a. normală $N(m, 16)$.
 13. Durata de funcționare a unui tip oarecare de bec electric de 100 wați poate fi considerată ca o v. a. X repartizată normal cu media $m = 1500$ și $\sigma^2 = 200^2$. O selecție de volum $n = 25$ de astfel de becuri dă o durată medie de funcționare de 1380 ore. La pragul $\alpha = 0,01$, să se verifice ipoteza $H_0 : m = m_0 = 1500$ față de $H_1 : m = m_1 < 1500$.
 14. O firmă producătoare de becuri afirmă că durata medie de viață a becurilor produse este de 170 ore. Un reprezentant al Oficiului pentru Protecția Consumatorilor cercetează un eșantion aleator de $n = 100$ de becuri, obținând o durată medie observată de viață de 158 ore și o abatere standard $s = 30$ ore. Determinați un interval de încredere $1 - \alpha = 0,99$ pentru durata medie de viață m , în ipoteza că durata de viață a becurilor este o v. a. normală. Poate fi acuzată firma producătoare de publicitate mincinoasă ?
 15. Consumul nominal de benzină al unui anumit motor de mașină este de $10 l$ la $100 km$. Se aleg la întâmplare 25 de motoare fabricate după o tehnologie modernizată, obținându-se media $\bar{x} = 9,3 l$ și varianța $s^2 = 4l^2$. Presupunând că selecția provine dintr-o populație normală, folosiți un test unilateral cu nivelul de semnificație $\alpha = 0,05$, pentru a testa ipoteza că noua tehnologie nu a influențat consumul de benzină
 16. Dintr-o populație normală o selecție de volum $n = 30$ a dat rezultatele:

x_i	0	1	2	3	4	5	6
n_i	2	3	6	7	7	3	2

Să se verifice ipoteza $H_0 : \sigma^2 = \sigma_0^2 = 1$ față de alternativa $H_1 : \sigma^2 = \sigma_1^2 > 1$ la pragul de semnificație $\alpha = 0,05$.

Tabelul A5. Cuantilele repartiției χ^2 hi-pătrat

$$f_{\chi^2(k)}(x) = \frac{1}{2^{k/2} \Gamma(k/2)} \cdot x^{\frac{k-2}{2}} \cdot e^{-\frac{x}{2}}, \quad x > 0; \quad k > 0.$$



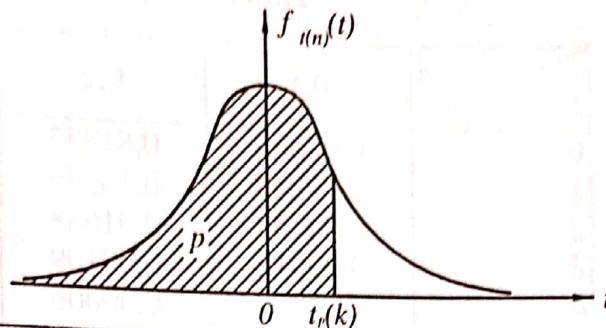
$k \setminus P$	0,005	0,010	0,025	0,05	0,10	0,20	0,30	0,70	0,80	0,90	0,95	0,975	0,990	0,995	0,999
1	0,04393	0,03157	0,03982	0,02393	0,0158	0,0642	0,1480	1,0700	1,6400	2,7100	3,8400	5,0200	6,6300	7,8800	10,800
2	0,0100	0,0201	0,0506	0,1030	0,2110	0,4460	0,7130	2,4100	3,2200	4,6100	5,9900	7,3800	9,2100	10,600	13,8000
3	0,0717	0,1150	0,2160	0,3520	0,5840	1,0050	1,4240	3,6600	4,6400	6,2500	7,8100	9,3500	11,3000	12,8000	16,3000
4	0,2070	0,2970	0,4840	0,7110	1,0600	1,6500	2,1900	4,8800	5,9900	7,7800	9,4900	11,1000	13,3000	14,9000	18,5000
5	0,4120	0,5540	0,8310	1,1500	1,6100	2,3400	3,0000	6,0600	7,2900	9,2400	11,1000	12,8000	15,1000	16,7000	20,5000
6	0,6760	0,8720	1,2400	1,6400	2,2000	3,0700	3,8300	7,2300	8,5600	10,6000	12,6000	14,4000	16,8000	18,5000	22,5000
7	0,9890	1,2400	1,6900	2,1700	2,8300	3,8200	4,6700	8,3800	9,8000	12,0000	14,1000	16,0000	18,5000	20,3000	24,3000
8	1,3400	1,6500	2,1800	2,7300	3,4900	4,5900	5,5300	9,5200	11,0000	13,4000	15,5000	17,5000	20,1000	22,0000	26,1000
9	1,7300	2,0900	2,7000	3,3300	4,1700	5,3800	6,3900	10,7000	12,2000	14,7000	16,9000	19,0000	21,7000	23,6000	27,9000
10	2,1600	2,5600	3,2500	3,9400	4,8700	6,1800	7,2700	11,8000	13,4000	16,0000	18,3000	20,5000	23,2000	25,2000	29,6000
11	2,6000	3,0500	3,8200	4,5700	5,5800	6,9900	8,1500	12,9000	14,6000	17,3000	19,7000	21,9000	24,7000	26,8000	31,3000
12	3,0700	3,5700	4,4000	5,2300	6,3000	7,8100	9,0300	14,0000	15,8000	18,5000	21,0000	23,3000	26,2000	28,3000	32,9000
13	3,5700	4,1100	5,0100	5,8900	7,0400	8,6300	9,9300	15,1000	17,0000	19,8000	22,4000	24,7000	27,7000	29,8000	34,5000
14	4,0700	4,6600	5,6300	6,5700	7,7900	9,4700	10,8000	16,2000	18,2000	21,1000	23,7000	26,1000	29,1000	31,3000	36,1000
15	4,6000	5,2300	6,2600	7,2600	8,5500	10,3000	11,7000	17,3000	19,3000	22,3000	25,0000	27,5000	30,6000	32,8000	37,7000
16	5,1400	5,8100	6,9100	7,9600	9,3100	11,2000	12,6000	18,4000	20,5000	23,5000	26,3000	28,8000	32,0000	34,3000	39,3000

Tabelul A5 (continuare)

$k \setminus p$	0,005	0,010	0,025	0,05	0,10	0,20	0,30	0,70	0,80	0,90	0,95	0,975	0,990	0,995	0,999
17	5,70	6,41	7,56	8,67	10,1	12,0	13,5	19,5	21,6	24,8	27,6	30,2	33,4	35,7	40,8
18	6,26	7,01	8,23	9,39	10,9	12,9	14,4	20,6	22,8	26,0	28,9	31,5	34,8	37,2	42,3
19	6,84	7,63	8,91	10,10	11,7	13,7	15,4	21,7	23,9	27,2	30,1	32,9	36,2	38,6	43,8
20	7,43	8,26	9,59	10,90	12,4	14,6	16,3	22,8	25,0	28,4	31,4	34,2	37,6	40,0	45,3
21	8,03	8,90	10,30	11,60	13,2	15,4	17,2	23,9	26,9	29,6	32,7	35,5	38,9	41,4	46,8
22	8,64	9,54	11,00	12,30	14,0	16,3	18,1	24,9	27,3	30,8	33,9	36,8	40,3	42,8	48,3
23	9,26	10,20	11,70	13,10	14,8	17,2	19,0	26,0	28,4	32,0	35,2	38,1	41,6	44,2	49,7
24	9,89	10,90	12,40	13,80	15,7	18,1	19,9	27,1	29,6	33,2	36,4	39,4	43,0	45,6	51,2
25	10,50	11,50	13,10	14,60	16,5	18,9	20,9	28,2	30,7	34,4	37,7	40,6	44,3	46,9	52,6
26	11,20	12,20	13,80	15,40	17,3	19,8	21,8	29,2	31,8	35,6	38,9	41,9	45,6	48,3	54,1
27	11,80	12,90	14,60	16,20	18,1	20,7	22,7	30,3	32,9	36,7	40,1	43,2	47,0	49,6	55,5
28	12,50	13,60	15,30	16,90	18,9	21,6	23,6	31,4	34,0	37,9	41,3	44,5	48,3	51,0	56,9
29	13,10	14,30	16,00	17,70	19,8	22,5	24,6	32,5	35,1	39,1	42,6	45,7	49,6	52,3	58,3
30	13,80	15,00	16,80	18,50	20,6	23,4	25,5	33,5	36,3	40,3	43,8	47,0	50,9	53,7	59,7
35	17,20	18,50	20,60	22,50	24,8	27,3	30,2	38,9	41,8	46,1	49,8	53,2	57,3	60,3	66,6
40	20,70	22,20	24,40	26,50	29,1	32,3	34,9	44,2	47,3	51,8	55,8	59,3	63,7	66,8	73,1
45	24,30	25,90	28,40	30,60	33,4	36,9	39,9	49,5	52,7	57,5	61,7	65,4	70,0	73,2	80,1
50	28,00	29,70	32,40	34,80	37,7	41,4	44,3	54,7	58,2	63,2	67,5	71,4	76,2	79,5	86,7
75	47,20	49,50	52,90	56,10	59,8	64,5	68,1	80,9	85,1	91,1	96,2	100,3	106,4	110,3	118,6
100	67,30	70,10	74,20	77,90	82,4	87,9	92,1	106,9	111,7	118,5	124,3	129,6	135,6	140,2	143,4

Tabelul A3. Cuantilele repartiției t – Student

$$F(t_p) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}} \int_{-\infty}^{t_p} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} dx$$



n	$t_{0,60}$	$t_{0,70}$	$t_{0,80}$	$t_{0,90}$	$t_{0,95}$	$t_{0,975}$	$t_{0,99}$	$t_{0,995}$
1	0,325	0,727	1,376	3,078	6,314	12,706	31,821	63,657
2	0,289	0,617	1,061	1,886	2,920	4,303	6,965	9,925
3	0,277	0,584	0978	1,638	2,353	3,182	4,541	5,841
4	0,271	0,569	0,911	1,533	2,132	2,776	3,747	4,604
5	0,267	0,559	0,920	1,476	2,015	2,571	3,365	4,032
6	0,265	0,553	0,906	1,440	1,943	2,447	3,143	3,707
7	0,263	0,549	0,896	1,415	1,895	2,365	2,998	3,499
8	0,262	0,546	0,889	1,397	1,860	2,306	2,896	3,355
9	0,261	0,543	0,883	1,383	1,833	2,262	2,821	3,250
10	0,260	0,542	0,879	1,372	1,812	2,228	2,764	3,169
11	0,260	0,540	0,876	1,363	1,796	2,201	2,718	3,106
12	0,259	0,539	0,873	1,356	1,782	2,179	2,681	3,055
13	0,259	0,538	0,870	1,350	1,771	2,160	2,650	3,012
14	0,258	0,537	0,868	1,345	1,761	2,145	2,624	2,977
15	0,258	0,536	0,866	1,341	1,753	2,131	2,602	2,947
16	0,258	0,535	0,865	1,337	1,746	2,120	2,583	2,921
17	0,257	0,534	0,863	1,333	1,740	2,110	2,567	2,898
18	0,257	0,534	0,862	1,330	1,734	2,101	2,552	2,878
19	0,257	0,533	0,861	1,328	1,729	2,093	2,539	2,861
20	0,257	0,533	0,860	1,325	1,725	2,086	2,528	2,845
21	0,257	0,532	0,859	1,323	1,721	2,080	2,518	2,831
22	0,256	0,532	0,858	1,321	1,717	2,074	2,508	2,819
23	0,256	0,532	0,858	1,319	1,714	2,069	2,500	2,807
24	0,256	0,531	0,857	1,318	1,711	2,064	2,492	2,797
25	0,256	0,531	0,856	1,316	1,708	2,060	2,485	2,787
26	0,256	0,531	0,856	1,315	1,706	2,056	2,479	2,779
27	0,256	0,531	0,855	1,314	1,703	2,052	2,473	2,771
28	0,256	0,530	0,855	1,313	1,701	2,048	2,467	2,763
29	0,256	0,530	0,854	1,311	1,699	2,045	2,462	2,756
30	0,256	0,530	0,854	1,310	1,697	2,042	2,457	2,750
40	0,255	0,529	0,851	1,303	1,681	2,021	2,423	2,704
60	0,254	0,527	0,848	1,296	1,671	2,000	2,390	2,660
120	0,254	0,526	0,845	1,289	1,658	1,980	2,358	2,617
∞	0,253	0,524	0,842	1,282	1,645	1,960	2,326	2,576
	$-t_{0,40}$	$-t_{0,30}$	$-t_{0,20}$	$-t_{0,10}$	$-t_{0,05}$	$-t_{0,025}$	$-t_{0,01}$	$-t_{0,005}$